

Especificação da Arquitetura LEBRE v0.51

Previsão online mínima, barata, competitiva e explicável

LEBRE: Lifecycle-governed Evidence-Based Resource Evolution

Arquitetura: especialista estrutural + especialista de memória + média dinâmica de modelos

CUSTO

~121 operações/passos; 0,4–3 KB conforme entradas e período

DESEMPENHO (HELD-OUT)

0,84× NLinear · 1,37× Chronos-2

SENSIBILIDADE À PARTIDA

variação máx. 1,08× entre 10 partidas

STATUS

versão de pesquisa promovida por avaliação pré-registrada

1. Sumário executivo

A **LEBRE** é um previsor **online** de séries temporais: a cada passo ela recebe uma observação, prevê o próximo valor, aprende com o erro e segue adiante, sem reprocessar o passado. A versão **v0.51** tem quatro peças: um **especialista estrutural** (dinâmica guiada por entradas, com descoberta de estrutura por testes estatísticos), um **especialista de memória** (nível e ciclo do próprio alvo), um **combinador** por média dinâmica de modelos e um **intervalo de predição** adaptativo com alvo de cobertura de 90%.

Premissa: a LEBRE **não** pretende ser o modelo mais preciso. O objetivo é oferecer **desempenho bom e competitivo** com **custo computacional mínimo** (dimensionado para dispositivos embarcados), **sem ajuste por série** e com **explicabilidade e observabilidade** de cada previsão. Modelos de fundação e modelos clássicos ajustados série a série podem ser mais precisos; este documento mostra onde e por quanto.

Resultado principal (avaliação pré-registrada em 10 séries reais nunca usadas no desenvolvimento, 5 delas brasileiras): melhor entre os comparadores online pré-registrados, com erro $0,84\times$ o do NLinear online calibrado; $1,37\times$ o do Chronos-2 (modelo de fundação), com custo $\sim 10^6\text{--}10^7$ vezes menor; 121 operações por passo em média (pico 196); $\sim 1,3$ KB de estado (mediana; 0,4–2,1 KB conforme o número de entradas e o período, §7); variação máxima de $1,076\times$ conforme o ponto de partida.

O que as análises pós-hoc mostraram (§10–§12): nas séries reais, **quase todo o resultado vem do especialista de memória**. A memória sozinha fica a $1,034\times$ da LEBRE completa e dá resultado idêntico em 8 de 10 séries. Um modelo airline clássico **ajustado série a série por máxima verossimilhança** é $\sim 5\text{--}10\%$ mais preciso que a LEBRE. O que a LEBRE acrescenta à memória é universalidade (sistemas guiados por entradas), descoberta estrutural nomeada, ausência de ajuste por série e intervalos adaptativos; a parte estrutural ainda não tem evidência em séries reais genuinamente guiadas por entradas. Em processos sintéticos, a descoberta estrutural é confiável para **um atraso**, parcial para **vários atrasos e falha** quando há um estado latente acionado por uma entrada, e a primeira promoção costuma levar 1,5–3 mil passos (§11.2).

Guia do documento

1. Sumário executivo	§1
2. O que é a LEBRE, para que serve e qual é a premissa	§2
3. Princípios de projeto	§3
4. Visão geral da arquitetura	§4
5. Formulação matemática	§5
6. Fluxo de um passo e causalidade	§6
7. Custo computacional	§7
8. Observabilidade e explicabilidade	§8
9. Validação empírica e rigor metodológico	§9
10. LEBRE contra a memória sozinha e contra clássicos fortes	§10
11. Garantias estatísticas e alcance da descoberta estrutural	§11
12. O que este documento demonstra e o que não demonstra	§12
13. Evolução da arquitetura e lições	§13
14. Limites e afirmações que não fazemos	§14
15. Parâmetros	§15
16. Referências	§16

2. O que é a LEBRE, para que serve e qual é a premissa

O problema

Muitos sistemas reais produzem medições em fluxo contínuo — consumo de energia, geração eólica e solar, vazão, qualidade do ar, sensores industriais, câmbio — e precisam de uma previsão do próximo valor *no próprio dispositivo*, com memória e energia escassas, sem GPU e sem a possibilidade de treinar offline com grandes históricos. Há três obstáculos: (i) os modelos modernos mais precisos (transformers e modelos de fundação) exigem centenas de megabytes e bilhões de operações por previsão; (ii) modelos estatísticos clássicos são baratos, mas precisam ser ajustados série a série; (iii) em aplicações críticas, uma previsão sem explicação e sem incerteza quantificada tem pouco valor operacional.

A premissa

A LEBRE **não compete para ser o modelo mais preciso**. Ela é projetada para ocupar um ponto específico do compromisso entre precisão, custo e transparência: **desempenho competitivo** (no nível de modelos modernos leves), **custo mínimo** (centenas de operações por passo e poucos KB), **nenhum ajuste por série** (as mesmas constantes em qualquer fluxo) e **explicabilidade e observabilidade** de cada previsão. Perder alguns pontos percentuais de precisão para um modelo de fundação ou para um modelo clássico ajustado série a série é aceitável dentro dessa premissa; perder a competitividade, o custo baixo ou a transparência, não.

O que a LEBRE faz

- **Aprende online, a cada passo**, sem fase de treino separada e sem calibração por série.
- **Funciona em dois tipos de problema**: séries guiadas pela própria memória (sazonalidade, nível) e sistemas guiados por entradas (atrasos, estados ocultos), decidindo sozinha qual hipótese vale a cada momento.
- **Decompõe cada previsão** em parcelas nomeadas e **registra** quando e por que cada estrutura entrou ou saiu do modelo.
- **Informa a própria incerteza** com um intervalo adaptativo com alvo de cobertura de 90% (§5.5).
- **Custa ~100–150 operações de ponto flutuante por passo** e de 0,4 a ~3 KB de estado, conforme o número de entradas e o período sazonal (§7). Esse orçamento é compatível com microcontroladores, mas a execução em hardware embarcado **não foi verificada**, e FP não mede energia.

Para que serve (casos de uso típicos)

Previsão de curto prazo embarcada em medidores e controladores de energia; monitoramento de geração renovável; sensores industriais; fluxos de IoT; qualquer contexto em que a previsão precise ser barata, auditável, acompanhada de incerteza e em que não seja viável ajustar um modelo para cada série.

O que a LEBRE não é

Não é um modelo de fundação nem um previsor de longo horizonte; não modela relações fortemente não lineares entre entradas e alvo (a classe é linear nos parâmetros); não afirma causalidade física (as explicações descrevem o modelo, isto é, relevância preditiva). O nome vem da família original de arquiteturas do projeto (*Lifecycle-governed Evidence-Based Resource Evolution*): estruturas entram e saem do modelo por evidência estatística, sob orçamento explícito de recursos.

3. Princípios de projeto

A LEBRE v0.51 foi projetada a partir de quatro exigências e de quatro princípios operacionais herdados das versões anteriores:

Princípio	Significado na v0.51
Custo	≤ 150 operações de ponto flutuante por passo em média e pico ≤ 500 (até ~6 entradas); memória de poucos KB.
Arquitetura mínima	Cada componente corresponde a um termo do modelo gerador e foi mantido só se a sua remoção piorasse o resultado (§9.6).
Competitividade	Desempenho no nível de modelos modernos leves (NLinear, DLinear) e próximo de modelos de fundação.
Observabilidade e explicabilidade	Decomposição exata de cada previsão, pesos interpretáveis, intervalo adaptativo, alarmes de mudança e custo contabilizado.
P2	Evidência em tempo de fluxo: a taxa de acumulação de evidência é fixa por passo, não por evento.
P4	Silêncio não é evidência: sem excitação das entradas nenhuma estatística de decisão é atualizada.
P6	Contrato de entrada: entradas padronizadas pelo ambiente, de forma causal (§9.1); um valor fora do contrato ($ x > 8$) é usado recortado na previsão, mas não gera evidência nem aprendizado.
Sem calibração	Nenhum hiperparâmetro é ajustado por série; o único dado do ambiente é o período de amostragem s (por exemplo, 24 para dados horários).

4. Visão geral da arquitetura



Por que dois especialistas. Séries reais sazonais e sistemas guiados por entradas pedem representações opostas. Nas primeiras, a informação decisiva está no próprio passado do alvo, e a previsão deve ser feita relativa ao último valor. Nos segundos, ancorar no último valor injeta ruído, e o que importa são as entradas e os seus atrasos. Durante o desenvolvimento, as tentativas de unir as duas representações num único modelo (em cascata, por aprendizado conjunto ou por regressão de combinação) falharam em pelo menos um dos dois mundos (§9.6). Por isso a arquitetura mínima tem dois especialistas e um combinador que acompanha qual hipótese está valendo.

5. Formulação matemática

5.1 Modelo gerador

Partimos da decomposição estrutural de séries temporais (Harvey, 1989):


$$y_t = \ell_t + c_{t \bmod s} + f(\mathbf{x}_{t-1}, \mathbf{x}_{t-2}, \dots) + \eta_t$$

em que ℓ_t é um nível que varia lentamente, c é um ciclo de período s , f é a dinâmica induzida pelas entradas (atrasos e estados ocultos) e η_t é ruído, possivelmente com autocorrelação curta. A suavização exponencial em espaço de estados (Hyndman et al., 2008), o modelo airline de Box e Jenkins (1970) e o Holt-Winters (Holt, 1957; Winters, 1960) são casos particulares. Métodos leves recentes usam a mesma ideia de separar o ciclo e prever o resto: CycleNet (Lin et al., 2024), SparseTSF (Lin et al., 2024), FITS (Xu et al., 2024) e o vencedor da competição M4 (Smyl, 2020).

5.2 Especialista de memória M (nível e ciclo)

D3: Especialista de memória — o que ele lê do passado

Todas as features são diferenças relativas ao último valor: não há nível a aprender



$\hat{y}_t^M = y(t-1) + w_1[m - y(t-1)] + w_2[y(t-1) - y(t-2)] + w_3[y(t-s) - y(t-1)] + w_4[y(t-s+1) - y(t-s)] + w_5 G[\text{fase}]$
 m : média exponencial do alvo (reversão à média $\Leftrightarrow$ suavização exponencial simples com α aprendido)
 $G[\text{fase}]$: média exponencial (fator 0,9) dos incrementos observados nesta mesma fase em ciclos anteriores
 $\Leftrightarrow$ incremento sazonal previsto pelo modelo airline SARIMA(0,1,1)(0,1,1) $_s \Leftrightarrow$ estado sazonal do Holt-Winters
 $w_1, \dots, w_5$: aprendidos online por NLMS (invariante à escala); sem período declarado usa-se só $[m - y(t-1), y(t-1) - y(t-2)]$

As cinco features da memória, todas relativas ao último valor.

$$\hat{y}_t^M = y_{t-1} + \mathbf{w}^\top \phi_t, \quad \phi_t = [m_{t-1} - y_{t-1}, y_{t-1} - y_{t-2}, y_{t-s} - y_{t-1}, y_{t-s+1} - y_{t-s}, G_{t \bmod s}]$$

$$G_p \leftarrow G_p + a [(y_t - y_{t-1}) - G_p], \quad a = 0,1; \quad m_t \leftarrow m_{t-1} + 0,01 (y_t - m_{t-1})$$

$$\mathbf{w} \leftarrow \mathbf{w} + \frac{\mu (y_t - \hat{y}_t^M)}{\|\phi_t\|^2} \phi_t, \quad \mu = 0,05$$

Por que estas features. (i) A previsão do modelo airline SARIMA(0,1,1)(0,1,1) $_s$ para o incremento sazonal é uma média exponencialmente ponderada dos incrementos da mesma fase em ciclos anteriores, com fator Θ ; o perfil G com $a = 0,1$ é exatamente isso com $\Theta = 0,9$, e coincide com o estado sazonal do Holt-Winters e com o "ciclo recorrente aprendível" do CycleNet. (ii) Com peso w_1 , a feature de reversão à média produz $y_{t-1} + w_1(m - y_{t-1})$, que é a suavização exponencial simples com constante aprendida — ótima para um nível local ruidoso (Muth, 1960). (iii) O incremento recente captura a autocorrelação curta, e as duas features de defasagem sazonal levam a informação bruta do último ciclo. (iv) Prever relativo ao último valor elimina a necessidade de aprender o nível, que era a causa da instabilidade de versões anteriores (§13); essa é também a normalização do NLinear (Zeng et al., 2023).

Por que NLMS. O NLMS (Nagumo e Noda, 1967) é o passo de norma mínima que zera o erro a posteriori na direção da feature; o LMS é ótimo no sentido H_∞ (Hassibi, Sayed e Kailath, 1996), isto é, minimiza a pior razão entre energia do erro e energia das

perturbações sem supor distribuição — a propriedade adequada a fluxos não estacionários. Além disso, o NLMS é *invariante à escala* das features, o que dispensa qualquer padronização do alvo. O RLS convergiria mais rápido, mas custa $O(k^2)$.

Contrato numérico. A atualização de M *não* tem termo de regularização no denominador: ela só é pulada quando $\|\phi_t\|^2 = 0$ exatamente. Isso mantém a invariância à escala exata, mas deixa um caso sem proteção: depois de um trecho longo exatamente constante, os incrementos recentes são nulos ou quase nulos, e um salto grande produz um passo enorme. Num teste sintético "constante seguido de degrau", os pesos de M divergiram. Esse caso não ocorreu em nenhuma das séries reais avaliadas, mas séries com platôs longos e saltos (por exemplo, sinais quantizados de sensores) estão fora do contrato numérico desta versão. O especialista S usa um termo fixo $\varepsilon = 10^{-6}$ no denominador; como as suas entradas são padronizadas, o efeito sobre a invariância é desprezível.

5.3 Especialista estrutural S (dinâmica guiada por entradas)

$$\hat{y}_t^S = \theta_0 + \theta_b^\top \mathbf{x}_t + \sum_{a \in \mathcal{A}_t} \theta_a \varphi_a(t), \quad |\mathcal{A}_t| \leq 4$$

A base densa lê as entradas atuais; o conjunto ativo $\mathcal{A}_t$ contém átomos estruturais com significado físico: *atrasos* $x_{i,t-k}$ com $k \leq 32$, um *estado latente* e um *acionamento* do estado latente. O estado latente implementa o preditor de Kalman estacionário em forma de inovações: para um estado oculto de primeira ordem, o preditor ótimo é linear em filtros de primeira ordem da inovação e da entrada com polo p ; a LEBRE usa um banco de polos $\{0; 0,5; 0,8; 0,95\}$:

$$s_t = p s_{t-1} + (1 - p) u_t / \hat{\sigma}, \quad q_{i,t} = p q_{i,t-1} + (1 - p) x_{i,t}$$


Todos os parâmetros são aprendidos por NLMS com o erro do próprio S . **Promoção:** cada candidato é testado em sombra (sem entrar na previsão) por um martingale de mistura auto-normalizado; ele é promovido quando

$$\log M_t = \frac{\tau S_t^2}{2(1 + \tau Q_t)} - \frac{1}{2} \log(1 + \tau Q_t) \geq \log(p_{\text{dict}}/\alpha), \quad S_t = \sum e_k \varphi_k, \quad Q_t = \sum (e_k \varphi_k)^2$$

Com incrementos condicionalmente simétricos, M_t é supermartingale (de la Peña, 1999; Howard et al., 2021), e pela desigualdade de Ville (1939) a probabilidade de uma promoção falsa em qualquer instante é $\leq \alpha/p$ por candidato e *por episódio de teste*. O controle vale por teste, não para o fluxo inteiro: como candidatos podem ser retestados com estatística nova, promoções falsas podem se acumular em fluxos muito longos (a taxa empírica está na §11). **Remoção:** um CUSUM (Page, 1954) da razão de log-verossimilhança "sem contra com" o átomo, acrescido de um aluguel de parcimônia $r = h/T_{\text{idle}}$ no espírito do MDL (Rissanen, 1978), remove o átomo quando cruza $h = \log(\text{ARL}) = \log 6000$; *sem* aluguel, o tempo médio até um alarme falso seria $\geq e^h$ (Lorden, 1971; Moustakides, 1986). **O aluguel quebra essa garantia:** ele empurra o CUSUM na direção da remoção, de modo que uma remoção significa "o átomo deixou de pagar o seu custo", seja por mudança real, seja por contribuição pequena. Por isso as remoções são tratadas como **sinais de perda de utilidade**, não como alarmes com taxa de erro controlada (taxa empírica na §11).

D4: Ciclo de vida estrutural do especialista S

Promoção: teste com erro tipo I controlado por episódio. Remoção: CUSUM com aluguel (sem garantia formal de ARL)



Nenhuma evidência é acumulada quando:

- silêncio: a potência das entradas lidas é < 10% da potência de longo prazo (P4: silêncio não é evidência);
- quarentena: há valor recortado ($|x| > 8$) legível por alguma defasagem (P6: entrada fora do contrato não é evidência);
- dormência: o peso de S no combinador é < 0,01 (a estrutura de S não afeta a previsão). Previsão e pesos continuam.

Ciclo de vida estrutural e as três condições em que a evidência não é acumulada.

Detalhes operacionais da busca e dos testes

- **Dicionário.** Atrasos $x_{i,t-k}$ com $1 \leq k \leq L = 32$ para cada entrada, 4 estados latentes (um por polo) e d acionamentos: $p_{\text{dict}} = dL + 4 + d$ (169 com $d = 5$, limiar $\approx 8,1$ nats).
- **Triagem.** A cada passo, 2 atrasos do dicionário são sondados em rodízio; o escore de cada um é uma média exponencial (peso 0,2) de $e_t x_{i,t-k}$. A cada 10 passos, as vagas livres de teste (no máximo 4 atrasos em teste ao mesmo tempo) recebem os atrasos de maior escore.
- **Teste.** Cada candidato em teste recebe uma amostra de evidência a cada 2 passos; as decisões são tomadas a cada 10 passos; após $T_{\text{max}} = 200$ amostras sem cruzar o limiar, o teste é encerrado por futilidade e o candidato volta ao dicionário.
- **Prior da mistura.** $\tau = \rho / (\hat{\sigma}^2 m_\varphi)$, com $\rho = 1$ (prior de informação unitária) e m_φ a potência de projeto do regressor (1 para entradas padronizadas e seus atrasos).
- **Estado latente.** No máximo **um** estado latente fica ativo. Enquanto não há latente ativo, um candidato por polo é testado em paralelo; o primeiro a cruzar o limiar é promovido, e os demais polos deixam de ser testados. Só então os d acionamentos são testados, sempre com o polo do latente promovido.
- **Orçamento.** No máximo $M_{\text{max}} = 4$ átomos estruturais ativos (latente e acionamento contam; a base densa não). Se um candidato cruza o limiar com o orçamento cheio, ele substitui o átomo ativo de maior CUSUM, desde que esse CUSUM seja $\geq h/2$; caso contrário, a promoção é adiada.

Três portões de evidência, uma só justificativa. Silêncio, quarentena e dormência são regras que dependem apenas do passado (são *previsíveis*). Pular observações por uma regra previsível preserva a propriedade de supermartingale das estatísticas de evidência (Ramdas et al., 2023), então o controle de erro de cada teste continua válido. A **quarentena** é uma rejeição forte de pontos de alavancagem, no espírito dos estimadores GM de Mallows (Hampel et al., 1986). A **dormência** segue a ideia dos *sleeping experts* (Freund et al., 1997): enquanto S tem peso desprezível, a sua estrutura não afeta a previsão, e só a descoberta estrutural é pausada. A previsão, o aprendizado dos pesos e a escala $\hat{\sigma}^2$ continuam, de modo que S pode recuperar peso. **Partida a frio:** ao promover um estado latente, os estados de acionamento começam em zero. O teste continua válido para qualquer regressor previsível, e o custo de pico cai de ~ 500 para $O(d)$.

5.4 Combinador: média dinâmica de modelos

$$D_t = \lambda D_{t-1} + \frac{(y_t - \hat{y}_t^S)^2 - (y_t - \hat{y}_t^M)^2}{\hat{\sigma}_t^2}, \quad w_t^S = \frac{1}{1 + e^{\eta D_t}}, \quad \hat{y}_t = \hat{y}_t^M + w_{t-1}^S (\hat{y}_t^S - \hat{y}_t^M)$$

Com dois especialistas, os pesos da média dinâmica de modelos com esquecimento (Raftery, Kárný e Ettler, 2010) dependem apenas da diferença acumulada das perdas. Com verossimilhança preditiva gaussiana e perdas normalizadas pela variância $\hat{\sigma}^2$ do erro combinado, o expoente é $\eta = 1/2$ — um valor derivado, não ajustado. O fator $\lambda = 0,99$ (memória de ~ 100 passos) permite acompanhar mudanças de regime, como no *fixed-share* (Herbster e Warmuth, 1998); o algoritmo pertence à família dos

agregadores de pesos exponenciais com garantias de arrependimento (Vovk, 1990; Cesa-Bianchi e Lugosi, 2006). Combinar por regressão (Granger e Ramanathan, 1984) foi testado e descartado: exige manter um peso próximo de 1 sobre uma feature de alta variância, e o desajuste do NLMS vira ruído (§9.6).

5.5 Intervalo de predição

$$\hat{q}_t = \max(0, \hat{q}_{t-1} + \gamma \hat{\sigma}_t (1\{|e_t| > \hat{q}_{t-1}\} - \alpha)), \quad \alpha = 0,1, \gamma = 0,1, \quad \text{intervalo} = \hat{y}_t \pm \hat{q}_t$$

Com uma atualização a cada passo, o rastreamento de quantil (Gibbs e Candès, 2021; Angelopoulos, Candès e Tibshirani, 2023) garante cobertura de longo prazo próxima de 90% sem supor distribuição. **A v0.51 não usa exatamente essa forma:** para reduzir o custo, a raiz, a inversa e o quantil são atualizados só a cada 8 passos, e a atualização usa apenas o indicador de erro *do passo em que ela ocorre*, com passo multiplicado por 8. A taxa média se preserva, mas a garantia acima não se transfere integralmente: quando o período sazonal é múltiplo de 8 (24, 48, 144), as atualizações só observam algumas fases do ciclo (3 de 24, por exemplo), e a cobertura passa a depender de quais fases são amostradas. Nas séries reais avaliadas, a cobertura por série variou entre 0,85 e 0,97. Numa análise posterior, acumular os 8 indicadores de cada bloco (mesma cadência, custo praticamente igual) levou todas as séries a 0,900–0,906; essa variante *não* faz parte da v0.51.

5.6 Explicação aditiva exata

$$\hat{y}_t = w^S \left[\theta_0 + \sum_i \theta_{b,i} x_{i,t} + \sum_{a \in \mathcal{A}_t} \theta_a \varphi_a(t) \right] + (1 - w^S) \left[y_{t-1} + \sum_{k=1}^5 w_k \phi_{k,t} \right]$$

Cada parcela tem nome e valor, e a soma é igual à previsão até o arredondamento de máquina. É uma explicação *intrínseca* (o modelo é a explicação; Rudin, 2019), não uma aproximação pós-hoc.

6. Fluxo de um passo e causalidade



Os dois especialistas nunca veem a previsão combinada nem o erro combinado; cada um aprende só com o próprio erro. Assim, o combinador não cria um laço de realimentação entre eles — uma cascata ou um aprendizado conjunto, testados durante o desenvolvimento, mostraram-se instáveis justamente por esse laço.

7. Custo computacional

Contamos cada adição, multiplicação, divisão e comparação em ponto flutuante executada pelo algoritmo (FP). Operações feitas a cada k passos entram divididas por k . FP não é energia, mas é um indicador reprodutível e independente de linguagem.

Componente	FP/passos	Composição
S — especialista estrutural ($d = 5$)	~85–100	base densa ~6d; átomos, latente, busca e evidência
S em dormência (séries sazonais)	~60–75	sem testes, CUSUM nem atualização de evidência
M — memória (5 features)	~40–47	diferenças, produto interno, NLMS, perfil, média
M sem período (2 features)	~22	—
Combinador	~17	erros, diferença de perdas, 1 exp a cada 8 passos
Intervalo	~2	comparação e atualização a cada 8 passos

Orçamento verificado. Nas 14 tarefas internas ($d = 5$) a média máxima por tarefa foi 147 FP e o pico 249; nas 10 séries do held-out ($d \leq 6$), 138 e 196. O custo cresce ~8 FP por entrada adicional (base densa de S); com 25 entradas mediu-se ~260 de média e ~520 de pico — é a fronteira do orçamento.


O que a contagem não inclui. A padronização causal das entradas (§9.1) é feita pelo ambiente de avaliação, igual para todos os modelos, e não entra na contagem acima. Num dispositivo, ela custaria cerca de 12 FP por entrada e por passo (~60–70 FP com 5–6 entradas).

Memória. O estado cresce com o número de entradas d (histórico de defasagens de S) e com o período s (buffer e perfil sazonal de M). Em precisão simples, o estado é de aproximadamente $196d + 12s + 190$ bytes (sem período: $196d + 180$); em Python, que usa precisão dupla, o dobro. O valor “~1,3 KB” é a mediana das séries do held-out, não um limite:

Entradas d	Sem período	$s = 24$	$s = 144$	$s = 1440$	Maior s com $\leq 1,3$ KB (1 331 B)
1	0,4 KB	0,7 KB	2,1 KB	17 KB	78
3	0,8 KB	1,0 KB	2,4 KB	18 KB	46
5	1,1 KB	1,4 KB	2,8 KB	18 KB	13
6	1,3 KB	1,6 KB	3,0 KB	18 KB	nenhum

D6: Custo computacional por previsão (escala logarítmica)

Operações de ponto flutuante por passo, média no conjunto held-out



Custo por previsão comparado com os modelos avaliados.

Modelo	FP/ passo (média)	FP pico	Memória do modelo	ms/ passo (CPU)
LEBRE v0.51	121	196	1,32 KB	0,072
Especialista estrutural sozinho	98	781	0,44 KB	0,054
Variante com janela densa	1.022	2.459	2,29 KB	0,155
NLinear online	812	2.022	0,75 KB	0,026
DLinear online	1.849	4.614	1,12 KB	0,051
Holt-Winters online	20	20	0,11 KB	0,014
Chronos-Bolt tiny	$\sim 6 \cdot 10^8$ (est.)	—	~ 36 MB	0,778
Chronos-Bolt small	$\sim 3 \cdot 10^9$ (est.)	—	~ 190 MB	3,171
Chronos-2	$\sim 8 \cdot 10^9$ (est.)	—	~ 480 MB	15,593
Chronos-2 c/ covariáveis	$\sim 10^{10}$ (est.)	—	~ 480 MB	50,887

Tempos de parede em Python num único núcleo de CPU (LEBRE e lineares) e em PyTorch com 16 threads (Chronos); em linguagem compilada a LEBRE ficaria na faixa de microssegundos. Memória dos modelos Chronos: ~ 36 MB (Bolt tiny, 9 M parâmetros), ~ 190 MB (Bolt small) e ~ 480 MB (Chronos-2, 120 M parâmetros) em float32.

8. Observabilidade e explicabilidade

A cada passo a LEBRE v0.51 entrega, além da previsão:

- **Decomposição exata** da previsão em parcelas nomeadas (§5.6).
- **Peso w_S** : indica se o sistema está se comportando como "guiado por entradas" ($w_S \approx 1$) ou "guiado pela própria memória" ($w_S \approx 0$).
- **Intervalo adaptativo** com alvo de cobertura de 90% (§5.5).
- **Registro do ciclo de vida**: quando e por que cada estrutura entrou ou saiu, com a evidência em nats. Promoções têm erro tipo I controlado por episódio de teste; remoções são sinais de perda de utilidade, *sem* taxa de alarme falso garantida (§5.3, §11).
- **Custo contabilizado** por componente.

O que é e o que não é diferencial. A decomposição exata é uma propriedade trivial de qualquer modelo linear aditivo: é verdadeira e útil, mas não distingue a LEBRE. O que a LEBRE acrescenta é (i) a *seleção* das parcelas por evidência estatística, com nomes físicos (quais atrasos e qual estado latente importam), (ii) o registro auditável dessas decisões e (iii) o peso w_S , que diz qual hipótese está valendo. Nas séries sazonais, em que a memória domina, a explicação real é simples: *último valor, corrigido pelo incremento sazonal típico desta fase* — como mostra o exemplo 1.

Exemplo real 1 — série sazonal (carga do SIN, último passo do held-out)

Previsão 59.707,0 MWmed (valor observado 60.217,7), intervalo $\pm 1.747,5$, peso estrutural $w_S = 0,000$: a memória domina. Parcelas (as maiores em módulo; a soma de todas é exatamente a previsão):

Parcela	Valor
Memória (peso 1,00): último valor $y(t-1)$	63.349,5
Memória (peso 1,00): perfil sazonal de incrementos	-2.496,2
Memória (peso 1,00): incremento recente	-754,9
Memória (peso 1,00): incremento de um ciclo atrás	-217,8
Memória (peso 1,00): sazonal: $y(t-24)$	-186,7
Memória (peso 1,00): reversão à média	13,176

Exemplo 2 — tarefa sintética guiada por entradas (atraso + estado latente)

Previsão $-0,520 \pm 0,916$ (observado 0,025), $w_S = 1,000$: o especialista estrutural domina e a explicação nomeia a estrutura recuperada. Primeiros eventos do ciclo de vida: $t=1400$: promovido — x3 atrasado 12 passos; $t=1650$: promovido — estado latente ($\tau \sim 2$ passos, polo 0,50); $t=1990$: promovido — x0 alimenta o estado latente (polo 0,50); $t=2330$: removido — estado latente ($\tau \sim 2$ passos, polo 0,50); $t=2330$: removido (acoplado) — x0 alimenta o estado latente (polo 0,50); $t=2650$: promovido — estado latente ($\tau \sim 5$ passos, polo 0,80).

Parcela	Valor
Estrutural (peso 1,00): x3 atrasado 12 passos	-0,855
Estrutural (peso 1,00): x0 alimenta o estado latente (polo 0,80)	0,251
Estrutural (peso 1,00): entradas atuais (base)	0,108
Estrutural (peso 1,00): viés	-0,061
Estrutural (peso 1,00): estado latente ($\tau \sim 5$ passos, polo 0,80)	0,038

9. Validação empírica e rigor metodológico

9.1 Protocolo e salvaguardas contra viés

- **Pré-registro.** Hipóteses, critérios, limiares, conjuntos de dados, comparadores e sementes foram escritos antes de qualquer execução, e o documento recebeu um hash SHA-256 registrado. O código do modelo foi congelado por hash, e a execução verifica os dois hashes antes de começar.
- **Separação desenvolvimento/avaliação.** Todas as escolhas de projeto foram feitas em dados de desenvolvimento já usados antes; o conjunto de avaliação principal (held-out) é formado por 10 séries que nenhuma versão da LEBRE tinha visto. Sementes aleatórias verificadas como nunca usadas.
- **Avaliação frequencial causal.** A cada passo o modelo prevê e só então vê o valor; as entradas são padronizadas de forma causal por médias e variâncias exponenciais (fator 10^{-4} , memória de $\sim 10\,000$ passos, iniciadas em média 0 e variância 1), atualizadas só depois de cada previsão; o erro é medido a partir de 30% da série. **NMSE** = erro quadrático médio / variância do trecho de teste. Como todas as comparações usam razões *dentro da mesma série*, o denominador se cancela: a média geométrica das razões de NMSE é idêntica à das razões de MSE. Reportamos também *skill* e MAE relativos à persistência (§9.5).
- **Vantagem dada aos comparadores.** NLinear, DLinear, Holt-Winters e IPNLMS tiveram hiperparâmetros escolhidos por série nos primeiros min(15%, 5000) passos. A LEBRE *não* foi calibrada. O Holt-Winters online com constantes de uma grade mostrou-se um comparador fraco (pior que a persistência em uma série); por isso a §10 acrescenta um modelo airline ajustado por máxima verossimilhança.
- **Modelos de fundação.** Chronos-Bolt tiny foi avaliado em todo o teste; por custo de CPU, Chronos-Bolt small e Chronos-2 em 1000 pontos igualmente espaçados, e Chronos-2 com covariáveis em 500 (erro médio estimado nesses pontos igualmente espaçados do trecho de teste). Mesmo conjunto de informação (valores até $t-1$; contexto 512, ou 256 com covariáveis). Séries públicas podem estar no pré-treino desses modelos, o que os favoreceria.
- **Sensibilidade ao ponto de partida.** Cada série foi reprocessada a partir de 10 pontos de partida diferentes (0, 50, ..., 450 passos descartados), com a mesma janela de teste. Isso mede quanto o resultado depende da inicialização e do aquecimento; *não* mede estabilidade entre trechos diferentes da série (estações, anos, regimes), que não foi avaliada.
- **Versões anteriores da LEBRE.** Elas não entram no ranking. Aparecem apenas como *ablações com nome descritivo*, quando respondem a uma pergunta de projeto: o *especialista estrutural sozinho* (versão anterior sem memória) mostra por que a memória é necessária; a *variante com janela densa* (versão anterior com 96–288 defasagens, ~ 1000 FP/passos) mostra que a simplificação não perdeu desempenho — era um critério pré-registrado.
- **Regra de decisão fixada antes.** A promoção exigia passar em *todos* os critérios vinculantes. As análises das §10–§11 foram feitas *depois* da avaliação e estão rotuladas como pós-hoc; elas não alteram a decisão pré-registrada. O pré-registro e os hashes são registros internos do projeto e não acompanham este documento.

9.2 Conjunto held-out (10 séries reais nunca usadas)

	Série	Frequência	d	s
Q1	ONS — carga do Sistema Interligado Nacional (2019–20)	horária	6	24
Q2	ONS — geração hidráulica, Sudeste/Centro-Oeste (2019–20)	horária	6	24
Q3	ONS — geração hidráulica, Sul (2019–20)	horária	6	24
Q4	ONS — geração eólica do SIN (2019–20)	horária	6	24
Q5	Banco Central do Brasil — libra/real (2005–24)	diária	1	—
Q6	Demanda elétrica australiana, série 4	30 min	1	48
Q7	Contagem de pedestres (Melbourne), série 4	horária	1	24
Q8	Geração solar (EUA), série 4	10 min	1	144
Q9	Qualidade do ar (KDD Cup 2018), série 4	horária	1	24
Q10	Demanda elétrica australiana, série 5	30 min	1	48

d = número de variáveis de entrada (todas as variáveis em $t-1$, incluindo o próprio alvo); s = período declarado. Seis das dez séries têm d = 1, isto é, **nenhuma entrada exógena**: nelas a hipótese estrutural só tem o próprio passado do alvo. Fontes: Operador Nacional do Sistema Elétrico (dados

abertos), Banco Central do Brasil (SGS) e Monash Time Series Forecasting Archive (Godahewa et al., 2021).

9.3 Critérios pré-registrados e resultado


Critério	Limiar	Resultado
Custo médio por tarefa (interno $d = 5$; held-out $d \leq 6$)	≤ 150 FP	147 / 138 ✓
Pico por passo	≤ 500 FP	249 / 196 ✓
Interno: não piora contra o especialista estrutural sozinho (limite sup. 95%)	$< +0,010$	+0,0018 ✓
Cobertura interna do intervalo de 90%	[0,88; 0,92]	0,902 ✓
Fidelidade da explicação (erro relativo)	$\leq 1e-9$	$1e-14$ ✓
Held-out: razão contra NLinear	$\leq 1,10$	0,839 ✓
Held-out: razão contra o melhor de NLinear, DLinear, Holt-Winters	$\leq 1,15$	0,839 ✓
Held-out: razão contra a variante anterior com janela densa (~1000 FP)	$\leq 1,10$	0,773 ✓
Sensibilidade ao ponto de partida, 10 partidas (mediana / máx.)	$\leq 1,10$ / $\leq 1,50$	1,000 / 1,076 ✓
Tarefas com cobertura em [0,85; 0,95]	$\geq 80\%$	90% ✓
Divergências numéricas	0	0 ✓
Meta (não vinculante): razão contra o melhor Chronos	$\leq 1,50$	1,367 ✓

DECISÃO PRÉ-REGISTRADA: PROMOVIDA — todos os critérios vinculantes atendidos. (Os critérios comparavam com modelos online leves; §10 mostra comparações mais exigentes feitas depois.)

9.4 Resultados por série (NMSE, menor é melhor)

	Série	LEBRE v0.51	Só M	NLinear	DLinear	Holt-W.	Melhor Chronos	Persist.	Partida	Cobert.
Q1	ONS — carga do Sistema Interligado Nacional (2019–20)	0,0114	0,0114	0,0162	0,0167	0,0259	0,0030	0,0707	1,000	0,965
Q2	ONS — geração hidráulica, Sudeste/Centro-Oeste (2019–20)	0,0161	0,0161	0,0214	0,0231	0,0331	0,0085	0,0671	1,000	0,937
Q3	ONS — geração hidráulica, Sul (2019–20)	0,0150	0,0150	0,0188	0,0200	0,0377	0,0101	0,0447	1,000	0,928
Q4	ONS — geração eólica do SIN (2019–20)	0,0119	0,0119	0,0146	0,0159	0,0280	0,0114	0,0240	1,000	0,922
Q5	Banco Central do Brasil — libra/real (2005–24)	0,0013	0,0013	0,0012	0,0023	0,0014	0,0011	0,0012	1,031	0,881
Q6	Demanda elétrica australiana, série 4	0,0052	0,0052	0,0073	0,0072	0,0452	0,0046	0,0321	1,000	0,851
Q7	Contagem de pedestres (Melbourne), série 4	0,0269	0,0269	0,0319	0,0321	0,0365	0,0169	0,1163	1,000	0,920
Q8	Geração solar (EUA), série 4	0,0078	0,0078	0,0087	0,0113	0,0145	0,0085	0,0115	1,003	0,906
Q9	Qualidade do ar (KDD Cup 2018), série 4	0,1008	0,1380	0,0921	0,1021	0,2133	0,0862	0,0934	1,076	0,893
Q10	Demanda elétrica australiana, série 5	0,0066	0,0066	0,0083	0,0085	0,0371	0,0068	0,0385	1,000	0,890

Negrito: menor NMSE entre as seis primeiras colunas de modelos. Só M: especialista de memória sozinho (análise pós-hoc). Partida: máx./mín. do NMSE entre 10 pontos de partida. Cobert.: cobertura empírica do intervalo de 90%.



Posição	Modelo	Classe	Posto médio
1º	Chronos-2	fundação	1,50
2º	Chronos-2 c/ covariáveis	fundação	1,75
3º	Chronos-Bolt small	fundação	3,50
4º	LEBRE v0.51	online leve	3,60
5º	NLinear online	online leve	4,20
6º	Chronos-Bolt tiny	fundação	5,80
7º	DLinear online	online leve	6,50
8º	Persistência	online leve	7,20
9º	Holt-Winters online	online leve	8,40
10º	ARX-NLMS	online leve	8,50
11º	IPNLMS	online leve	9,60
12º	Sazonal ingênuo	online leve	11,33

Leitura correta do ranking: a LEBRE v0.51 fica em 4º lugar geral, atrás apenas de três modelos de fundação, e é o **melhor modelo online leve** entre os comparadores pré-registrados. Em média geométrica, fica ~1,37× atrás do Chronos-2, com custo ~10⁶–10⁷ vezes menor, e empata com o Chronos-Bolt small (D5). As versões anteriores da LEBRE não entram no ranking. O modelo airline ajustado por série (pós-hoc, §10) não entra no ranking porque não foi avaliado nas mesmas condições (falhou em uma série).

9.5 Métricas relativas à persistência

$Skill = 1 - MSE/MSE_{persistência}$ (positivo = melhor que repetir o último valor); $MAE\text{ relativo} = MAE/MAE_{persistência}$. Valores por série resumidos pela mediana.

Modelo	Skill mediano	Séries com skill > 0	MAE relativo mediano
LEBRE v0.51	0,712	8/10	0,542
Só M (memória sozinha)	0,712	8/10	0,542
Airline (MLE, pós-hoc)	0,720	8/9	0,515
NLinear online	0,630	9/10	0,619
DLinear online	0,604	8/10	0,638
Holt-Winters online	-0,066	5/10	1,086
Chronos-Bolt small	0,713	9/10	0,562
Chronos-2	0,798	10/10	0,436

Nas duas séries de câmbio, nenhum modelo supera a persistência com folga: o câmbio diário se comporta como passeio aleatório.

9.6 Suíte interna (sistemas guiados por entradas)

14 processos sintéticos com estrutura conhecida — atrasos exatos e múltiplos, estados latentes, quiescência, mudanças de regime, estrutura redundante e um controle não linear; 30 sementes novas por tarefa:

Variante	NMSE	FP/passo (média)	FP pico	Cobertura	Estrutura exata
LEBRE v0.51	0,2151	133,6	249	0,902	90,9%
Especialista estrutural sozinho	0,2151	99,8	712	0,901	90,8%
Variante com janela densa	0,1954	940,1	2.065	0,902	90,8%

Aqui a LEBRE iguala o especialista estrutural sozinho. Nesta suíte interna, usada no desenvolvimento, a métrica agregada de estrutura exata foi de ~91%. Análises posteriores com processos diagnósticos adicionais (§11.2) mostraram que essa média não se generaliza a todos os tipos de estrutura: a recuperação é robusta para atrasos únicos, parcial para vários atrasos e falha no caso testado de estado latente acionado por entrada. A memória sozinha **não serve** nesses sistemas ($NMSE \approx 1,0$ nos dados de desenvolvimento).

Verificações secundárias (conjuntos já vistos em etapas anteriores, portanto *não* held-out): num segundo conjunto de 10 séries (5 brasileiras), já usado para avaliar uma versão anterior e com duas séries que são outros trechos de séries do benchmark abaixo, 0,80× o NLinear e 1,12× o melhor Chronos; num benchmark de 10 tarefas reais com 36 modelos (filtros adaptativos, redes e reservatórios online, árvores online, lineares modernos e modelos de fundação), 0,85× o NLinear, 1,33× o melhor Chronos e sensibilidade máxima ao ponto de partida de 1,16.

9.7 Evidência de projeto (ablações em dados de desenvolvimento)

13 séries reais já usadas e a suíte interna com sementes de desenvolvimento. "Séries reais" = razão geométrica do NMSE contra um NLinear online com janela densa.

Variante	Séries reais	Interno	Conclusão
só S (especialista estrutural sozinho)	2,07	0,221	sem M, não é competitivo em séries reais
só M (memória sozinha)	0,96	1,008	sem S, inútil em sistemas guiados por entradas
M sem perfil sazonal G	1,12	—	G é o ingrediente decisivo de M
cascata M → S (sem combinador)	0,97	0,304	combinador necessário
S → M sobre o resíduo de S	1,47	0,255	idem
combinação por regressão	0,94	0,240	média dinâmica preferível
sem dormência de S	0,98	0,220	dormência: – 25 FP sem perda
LEBRE v0.51	0,98	0,220	—

Observe que "só M" (0,96) é ligeiramente melhor que a v0.51 (0,98) nas séries reais de desenvolvimento: o especialista estrutural não ajuda nelas. Ele só é mantido porque, sem ele, o modelo falha nos sistemas guiados por entradas.

10. LEBRE contra a memória sozinha e contra clássicos fortes

Todas as análises desta seção são **pós-hoc** (feitas depois da avaliação pré-registrada) e cobrem o held-out principal e o segundo conjunto (já visto; §9.6), 20 séries ao todo.

10.1 Quanto do resultado vem da memória

	LEBRE v0.51	Só M	Airline (MLE)	ETS (MLE)	RLS	w_S médio	w_S máx.	tempo com $w_S > 0,5$
Q1	0,0114	0,0114	0,0080	0,0228	0,0110	0,000	0,000	0%
Q2	0,0161	0,0161	0,0139	0,0295	0,0157	0,000	0,000	0%
Q3	0,0150	0,0150	0,0139	0,0271	0,0145	0,000	0,000	0%
Q4	0,0119	0,0119	0,0111	0,0177	0,0113	0,000	0,053	0%
Q5	0,0013	0,0013	0,0012	0,0012	0,0012	0,443	1,000	43%
Q6	0,0052	0,0052	0,0039	—	—	0,000	0,000	0%
Q7	0,0269	0,0269	0,0326	0,0449	—	0,000	0,000	0%
Q8	0,0078	0,0078	—	0,0090	—	0,000	0,000	0%
Q9	0,1008	0,1380	0,1384	0,1846	0,0862	0,556	1,000	54%
Q10	0,0066	0,0066	0,0067	0,0188	—	0,000	0,000	0%

NMSE no held-out principal. w_S : peso do especialista estrutural ao longo do trecho de teste. "—": o método falhou (memória insuficiente para o airline com $s = 144$; divergência do RLS ou do ETS).

- **A LEBRE e a memória sozinha dão resultado idêntico em 8 de 10 séries** ($w_S \approx 0$ durante todo o teste). A razão geométrica só M / LEBRE é 1,034 no held-out principal e 1,006 no segundo conjunto.
- Nas 20 séries, 15 não tiveram nenhuma promoção estrutural, e em 16 o peso médio de S ficou abaixo de 0,01.
- O especialista estrutural só ganha peso no **câmbio** e na **qualidade do ar**, onde melhora o resultado da memória (ex.: 0,101 contra 0,138 na qualidade do ar). Nas quatro séries do ONS com $d = 6$ entradas, w_S nunca passa de $\sim 0,05$: as outras variáveis do balanço energético, observadas em $t-1$, não acrescentam informação útil sobre o alvo além do seu próprio passado.
- **Conclusão:** nas séries reais avaliadas, o desempenho da LEBRE é essencialmente o do especialista de memória, que é uma forma online do modelo airline / Holt-Winters com pesos aprendidos por NLMS.

10.2 Comparadores clássicos fortes

Modelo (razão geométrica contra a LEBRE v0.51)	Held-out principal	séries válidas	Segundo conjunto	séries válidas
Só M (memória sozinha)	1,034	10/10	1,006	10/10
Airline SARIMA(0,1,1)(0,1,1) _s por MLE	0,948	9/10	0,896	9/10
ETS aditivo por MLE (AIC)	1,651	9/10	1,657	10/10
RLS ($\lambda = 0,999$) nas 5 features de M	0,937	6/10	0,932	7/10

- **O modelo airline ajustado por máxima verossimilhança é mais preciso que a LEBRE** (razões 0,948 e 0,896). Ele recebeu a mesma vantagem dos outros comparadores: os parâmetros θ e Θ foram estimados nos primeiros min(15%, 5000) passos de cada série e depois mantidos fixos. Em forma recursiva, a previsão airline custa poucas dezenas de operações por passo. O que a LEBRE oferece em troca é não precisar desse ajuste por série, funcionar também em sistemas guiados por entradas, produzir intervalos adaptativos e registrar a estrutura.
- O ETS aditivo ajustado por máxima verossimilhança foi **pior** que a LEBRE e divergiu numa série: não é um comparador robusto nesse protocolo.
- O RLS com esquecimento sobre as mesmas 5 features foi $\sim 7\%$ mais preciso quando estável, mas **divergiu nas séries longas** (50 000 passos). Isso mostra que o mérito está principalmente na escolha das features; o NLMS troca um pouco de precisão por estabilidade numérica e custo $O(k)$.

10.3 O que diferencia a LEBRE da memória sozinha

	Só M	LEBRE v0.51
Precisão em séries reais sazonais	igual	igual ($\leq 3\%$ melhor, graças a 2 séries)
Sistemas guiados por entradas (atrasos, estados ocultos)	falha (NMSE ≈ 1)	funciona (NMSE 0,215)
Explicação	aditiva, com 5 parcelas fixas	aditiva, com estrutura selecionada por evidência e nomeada
Registro de mudanças de estrutura	não	sim (promoções e perdas de utilidade)
Peso que indica a hipótese vigente	não	w_S
Custo por passo	~ 47 FP	~ 121 FP

Posicionamento honesto. Para quem só precisa prever séries sazonais sem entradas relevantes, a memória sozinha — ou um modelo airline ajustado por série — é suficiente e mais barata. A LEBRE se justifica quando o mesmo previsor, sem ajuste por série, precisa servir tanto a séries sazonais quanto a sistemas guiados por entradas, e quando a estrutura descoberta e o seu registro têm valor operacional. Essa última parte ainda precisa de evidência em séries reais genuinamente guiadas por entradas (§12).

11. Garantias estatísticas e alcance da descoberta estrutural

11.1 Promoções falsas e remoções em fluxos longos

As garantias da §5.3 valem sob hipóteses idealizadas e por teste. Para saber o que acontece em fluxos longos, medimos (pós-hoc) o comportamento do especialista estrutural em fluxos de 100 000 passos, 10 sementes cada:

Fluxo	Passos totais	Promoções falsas	Remoções do átomo verdadeiro
nulo gaussiano (entradas independentes do alvo)	1.000.000	0	—
nulo com caudas pesadas (t de Student, 3 g.l.)	1.000.000	0	—
estrutura verdadeira estacionária ($y = 0,8 \times 1(t-3) + \text{ruído}$)	1.000.000	—	7

- **Promoções:** nenhuma promoção falsa em 2 milhões de passos nulos. O controle é formalmente por episódio, mas o acúmulo em fluxos longos foi desprezível nestes testes.
- **Remoções:** num fluxo estacionário, o átomo verdadeiro foi removido 7 vezes em 1 milhão de passos (e depois repromovido). Por causa do aluguel de parcimônia, não há garantia formal de taxa de alarme falso: as remoções devem ser lidas como *sinais de perda de utilidade*, não como alarmes de mudança com erro controlado.

11.2 Alcance da descoberta estrutural (diagnóstico sintético)

Para delimitar o que a descoberta estrutural consegue e o que não consegue, o código congelado da v0.51 foi executado (pós-hoc) em processos sintéticos com estrutura conhecida: $d = 5$ entradas gaussianas independentes, ruído unitário, 20 000 passos (salvo indicação) e 10 sementes cada. *Estrutura exata* é a fração das verificações (a cada 100 passos, a partir do passo 1000) em que o conjunto ativo coincide com a estrutura verdadeira; a latência é a mediana, entre as sementes, do passo da primeira promoção de cada átomo verdadeiro.

Processo	Estrutura exata	1ª promoção (passos)	Observação
Dois nulos (ruído gaussiano; t de Student com 3 g.l.), 100 000 passos	—	—	0 promoções falsas em 17.686 episódios de teste (limite superior de 95%: $1,7 \cdot 10^{-4}$ por episódio, abaixo de $\alpha/p = 3,0 \cdot 10^{-4}$)
Um atraso: $0,8 \cdot x_1(t-3)$, 100 000 passos	98%	1.680	3 remoções em 10 sementes, todas seguidas de nova promoção
Um atraso longo: $0,8 \cdot x_1(t-12)$	93%	2.255	confiável depois de descoberto
Três atrasos: $0,8 \cdot x_0(t-3) + 0,6 \cdot x_2(t-7) + 0,5 \cdot x_4(t-20)$	57%	2.565 / 2.990 / 8.635	o átomo mais fraco demora muito; sensível ao prior τ
Atraso + estado latente acionado por entrada: $x_3(t-12) + z(t)$, $z(t) = 0,8 \cdot z(t-1) + x_0(t) + \text{ruído}$	0%	2.820 / nunca	o atraso é encontrado; o latente correto, nunca
Três atrasos com ruído de caudas pesadas (t, 3 g.l.)	27%	2.635 / 3.285 / 4.705	30 remoções de átomos verdadeiros em 10 sementes

- **Um atraso:** confiável. O controle de promoções falsas e a taxa de remoções da §11.1 se confirmam.
- **Latência:** a primeira promoção leva tipicamente 1,5–3 mil passos, mas o teste em si precisa de só ~200–300 passos depois que o candidato é proposto. O tempo é gasto na *busca*: as 4 vagas de teste ficam ocupadas por candidatos sem sinal até a futilidade (até 400 passos cada), e a triagem sonda cada atraso só a cada ~80 passos.
- **Vários atrasos:** parcial. O resultado depende do prior τ da mistura: com $p = 1/50$, $1/200$ e $1/1000$, a estrutura exata passa para 58%, 28% e 0%.
- **Estado latente acionado por entrada:** falha em todas as sementes, para todo τ testado. Em 10 de 10 sementes, o primeiro latente promovido tem polo 0 ou 0,5, não 0,8. Como só um latente pode ficar ativo e o acionamento herda o polo dele, a estrutura correta, embora representável, torna-se inalcançável. O orçamento de átomos não é o gargalo: ficou cheio em só 3,5% das decisões, e nenhuma promoção foi bloqueada. A suíte interna (§9.6) contém estados latentes que são recuperados; este processo mostra que isso não se estende a todo latente acionado por uma entrada.
- **Caudas pesadas:** o CUSUM usa verossimilhança gaussiana e remove átomos verdadeiros com frequência quando há valores extremos.
- **Custo da combinação:** em todos os processos, o erro da LEBRE fica a no máximo 0,3% do erro do especialista estrutural sozinho, exceto no processo com latente (1,020×): quando S está mal especificado, o combinador custa ~2%.

12. O que este documento demonstra e o que não demonstra

Este documento contém, na prática, **dois resultados distintos**, e é importante não confundi-los:

Resultado 1 — um previsor online barato, pouco sensível à inicialização e bem avaliado

Demonstrado com rigor em dados reais: pré-registro, held-out nunca visto, comparadores calibrados, sensibilidade ao ponto de partida e cobertura. O desempenho vem principalmente do especialista de memória, construído com peças clássicas (modelo airline, suavização exponencial, NLMS, média dinâmica de modelos). O valor é de **engenharia**: uma combinação específica, sem ajuste por série, dimensionada para ~120 operações por passo e com intervalos adaptativos. **Não há novidade científica** nesta parte, e um modelo airline ajustado série a série é um pouco mais preciso.

Resultado 2 — descoberta estrutural online com testes estatísticos

O especialista estrutural decide, por testes baseados em martingales e portões previsíveis (silêncio, quarentena, dormência), quais atrasos e estados ocultos entram no modelo. É a parte mais interessante do ponto de vista científico e conecta-se com a área de inferência sempre válida (Ramdas et al., 2023). **Hoje ela só tem evidência em processos sintéticos, e mesmo ali com alcance limitado**: é confiável para um atraso, parcial para vários atrasos e falha com estado latente acionado por entrada (§11.2). Nas séries reais avaliadas, o especialista estrutural quase nunca é escolhido. Para defendê-la seriam necessárias séries reais genuinamente guiadas por entradas — processos industriais, sistemas hidráulicos com vazão a montante, identificação de sistemas.

Consequência: a afirmação "a LEBRE é competitiva em séries reais" é verdadeira, mas deve ser atribuída ao especialista de memória. A afirmação "a descoberta estrutural da LEBRE funciona em dados reais" **ainda não está demonstrada**, e em dados sintéticos ela só está demonstrada para atrasos únicos.

13. Evolução da arquitetura e lições

As versões anteriores são citadas apenas para explicar como se chegou à arquitetura atual; o leitor não precisa conhecê-las.

Etapa	Ideia central	Resultado
Organização original	Caminho-base, atrasos esparsos, estado latente, ciclo de vida com probação em sombra.	referência canônica congelada
Decisões por testes estatísticos	Toda decisão estrutural vira teste (martingale de mistura, CUSUM); latente em forma de inovações de Kalman; ≤ 100 FP.	estável, mas 2–3× pior que modelos modernos em séries sazonais
Especialista estrutural sozinho	Aprendizado proporcional, intervalos, explicação exata, guarda de contrato de entrada.	instável conforme o ponto de partida; ~2,6× o NLinear em dados reais
Variante com janela densa	Três especialistas, janela de 96–288 defasagens.	competitiva e estável, mas ~1000 FP/passos
v0.51	Dois especialistas mínimos (estrutural + memória airline) e média dinâmica de modelos.	~120 FP/passos; desempenho vindo sobretudo da memória

Lições. (1) Em séries reais sazonais, o desempenho depende de memória do próprio alvo expressa relativa ao último valor; a hipótese estrutural esparsa, sozinha, não basta. (2) Aprender o nível pelo termo de viés torna as decisões estruturais iniciais dependentes do ponto de partida. (3) Uma memória bem especificada, com 5 números aprendidos, supera uma janela densa com centenas de pesos aprendidos online — em linha com as competições M: métodos estatísticos simples e bem especificados são difíceis de superar (Makridakis et al., 2020). (4) Um modelo clássico ajustado série a série continua sendo uma referência exigente.

14. Limites e afirmações que não fazemos

- A LEBRE não pretende ser o modelo mais preciso: Chronos-2 é ~1,37× melhor e um modelo airline ajustado série a série é ~5–10% melhor.

- Nas séries reais avaliadas, o resultado vem quase todo do especialista de memória; a descoberta estrutural só tem evidência em dados sintéticos.
- Descoberta estrutural em dados sintéticos: confiável para um atraso; parcial para vários atrasos (e sensível ao prior τ); falha com estado latente acionado por entrada, porque só um latente pode ficar ativo e o primeiro polo a acumular evidência ocupa a vaga; frágil com ruído de caudas pesadas. A primeira promoção leva tipicamente 1,5–3 mil passos.
- O orçamento de 150 FP/passos vale para até ~6 entradas; cada entrada adicional custa ~8 FP. A padronização das entradas (~12 FP por entrada) não está incluída. A execução em microcontroladores não foi verificada.
- A memória de estado cresce com o período sazonal (~12 bytes por fase) e com o número de entradas (~196 bytes por entrada): ~1,3 KB é a mediana do held-out; com $s = 1440$ são ~18 KB.
- O intervalo é atualizado a cada 8 passos com um único indicador de erro; quando o período é múltiplo de 8, a cobertura por série fica entre ~0,85 e ~0,97 em vez de ~0,90 (§5.5).
- A memória não tem regularização numérica: séries com trechos longos exatamente constantes seguidos de saltos podem fazê-la divergir (§5.2).
- A "sensibilidade ao ponto de partida" mede dependência da inicialização, não estabilidade entre trechos diferentes da série.
- O controle de erro das promoções vale por episódio de teste; as remoções não têm taxa de alarme falso garantida.
- A classe é linear nos parâmetros; previsão de um passo à frente; cobertura do intervalo de longo prazo, não condicional.
- A decomposição exata, sozinha, não é diferencial: qualquer modelo linear aditivo a possui.
- Não afirmamos: estado da arte, novidade científica, causalidade física, eficiência energética (FP não é energia) nem cobertura condicional.

15. Parâmetros

Todos os valores são constantes do projeto, iguais para todas as séries; nenhum foi ajustado nos dados de avaliação.

Parâmetro	Valor	Papel
μ (S)	0,1	passo do NLMS do especialista estrutural
μ (M)	0,05	passo do NLMS da memória
a	0,1	perfil sazonal ($\Theta = 0,9$ no modelo airline)
fator da média	0,01	média exponencial para a reversão à média
η	1/2	derivado da verossimilhança gaussiana
λ	0,99	esquecimento do combinador e do σ^2 combinado (~100 passos)
limiar de dormência	0,01	peso abaixo do qual a evidência de S pausa
L	32	atraso máximo dos candidatos
M_max	4	orçamento de átomos estruturais
α	0,05	taxa de promoção falsa por episódio (limiar $\log(p/\alpha)$)
ARL	6000	$h = \log \text{ARL}$ (garantia só sem aluguel)
T_idle	500	aluguel de parcimônia $r = h/T_idle$
polos	{0; 0,5; 0,8; 0,95}	banco do estado latente; no máximo 1 latente ativo
ρ	1	prior da mistura: $\tau = \rho/(\sigma^2 \cdot m_q)$, informação unitária
T_max	200 amostras	futilidade do teste (1 amostra a cada 2 passos)
triagem	2 por passo; peso 0,2	atrasos sondados por passo; média exponencial do escore
vagas de teste	4	atrasos em teste simultâneo; decisões a cada 10 passos
substituição	$R \geq h/2$	com orçamento cheio, substitui o átomo de maior CUSUM se $\geq h/2$
ε (S / M)	10^{-6} / —	regularização do NLMS (M não tem; pula só se $\ \varphi\ ^2 = 0$)
padronização	10^{-4}	fator das médias e variâncias exponenciais das entradas (ambiente)
recorte	± 8	contrato de entrada (P6)
excitação	10%	potência mínima para acumular evidência (P4)
intervalo	$\alpha = 0,1$; $\gamma = 0,1$	cobertura alvo 90%; passo do rastreador
cadência	8	passos entre recálculos de raiz, inversa, exp e quantil (quantil com o indicador do passo corrente $\times 8$)
s	do ambiente	período de amostragem declarado (único dado externo)

16. Referências

- Angelopoulos, A. N., Candès, E. J., Tibshirani, R. J. (2023). Conformal PID control for time series prediction. *NeurIPS* 36.
- Ansari, A. F. et al. (2024). Chronos: learning the language of time series. *Transactions on Machine Learning Research*.
- Ansari, A. F. et al. (2025). Chronos-2: from univariate to universal forecasting. *arXiv preprint*.
- Benesty, J., Gay, S. L. (2002). An improved PNLMS algorithm. *Proc. IEEE ICASSP*, 1881–1884.
- Box, G. E. P., Jenkins, G. M. (1970). *Time Series Analysis: Forecasting and Control*. Holden-Day.
- Cesa-Bianchi, N., Lugosi, G. (2006). *Prediction, Learning, and Games*. Cambridge University Press.
- de la Peña, V. H. (1999). A general class of exponential inequalities for martingales and ratios. *Annals of Probability* 27(1), 537–564.
- Freund, Y., Schapire, R. E., Singer, Y., Warmuth, M. K. (1997). Using and combining predictors that specialize. *Proc. ACM STOC*, 334–343.
- Gibbs, I., Candès, E. J. (2021). Adaptive conformal inference under distribution shift. *NeurIPS* 34.
- Godahewa, R., Bergmeir, C., Webb, G. I., Hyndman, R. J., Montero-Manso, P. (2021). Monash time series forecasting archive. *NeurIPS Datasets and Benchmarks*.
- Granger, C. W. J., Ramanathan, R. (1984). Improved methods of combining forecasts. *Journal of Forecasting* 3(2), 197–204.
- Hampel, F. R., Ronchetti, E. M., Rousseeuw, P. J., Stahel, W. A. (1986). *Robust Statistics: The Approach Based on Influence Functions*. Wiley.
- Harvey, A. C. (1989). *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press.
- Hassibi, B., Sayed, A. H., Kailath, T. (1996). H_∞ optimality of the LMS algorithm. *IEEE Transactions on Signal Processing* 44(2), 267–280.
- Haykin, S. (2002). *Adaptive Filter Theory*, 4th ed. Prentice Hall.

16. Herbster, M., Warmuth, M. K. (1998). Tracking the best expert. *Machine Learning* 32(2), 151–178.
17. Holt, C. C. (1957/2004). Forecasting seasonals and trends by exponentially weighted moving averages. *International Journal of Forecasting* 20(1), 5–10.
18. Howard, S. R., Ramdas, A., McAuliffe, J., Sekhon, J. (2021). Time-uniform, nonparametric, nonasymptotic confidence sequences. *Annals of Statistics* 49(2), 1055–1080.
19. Hyndman, R. J., Koehler, A. B., Ord, J. K., Snyder, R. D. (2008). *Forecasting with Exponential Smoothing: The State Space Approach*. Springer.
20. Lin, S., Lin, W., Hu, X., Wu, W., Mo, R., Zhong, H. (2024). CycleNet: enhancing time series forecasting through modeling periodic patterns. *NeurIPS* 37.
21. Lin, S., Lin, W., Wu, W., Chen, H., Yang, J. (2024). SparseTSF: modeling long-term time series forecasting with 1k parameters. *ICML*.
22. Lorden, G. (1971). Procedures for reacting to a change in distribution. *Annals of Mathematical Statistics* 42(6), 1897–1908.
23. Makridakis, S., Spiliotis, E., Assimakopoulos, V. (2020). The M4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting* 36(1), 54–74.
24. Moustakides, G. V. (1986). Optimal stopping times for detecting changes in distributions. *Annals of Statistics* 14(4), 1379–1387.
25. Muth, J. F. (1960). Optimal properties of exponentially weighted forecasts. *Journal of the American Statistical Association* 55(290), 299–306.
26. Nagumo, J., Noda, A. (1967). A learning method for system identification. *IEEE Transactions on Automatic Control* 12(3), 282–287.
27. Page, E. S. (1954). Continuous inspection schemes. *Biometrika* 41(1/2), 100–115.
28. Raftery, A. E., Kárný, M., Ettler, P. (2010). Online prediction under model uncertainty via dynamic model averaging: application to a cold rolling mill. *Technometrics* 52(1), 52–66.
29. Ramdas, A., Grünwald, P., Vovk, V., Shafer, G. (2023). Game-theoretic statistics and safe anytime-valid inference. *Statistical Science* 38(4), 576–601.
30. Seabold, S., Perktold, J. (2010). statsmodels: econometric and statistical modeling with Python. *Proc. 9th Python in Science Conference*.
31. Rissanen, J. (1978). Modeling by shortest data description. *Automatica* 14(5), 465–471.
32. Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence* 1, 206–215.
33. Smyl, S. (2020). A hybrid method of exponential smoothing and recurrent neural networks for time series forecasting. *International Journal of Forecasting* 36(1), 75–85.
34. Ville, J. (1939). *Étude critique de la notion de collectif*. Gauthier-Villars.
35. Vovk, V. (1990). Aggregating strategies. *Proc. 3rd Annual Workshop on Computational Learning Theory*, 371–383.
36. Winters, P. R. (1960). Forecasting sales by exponentially weighted moving averages. *Management Science* 6(3), 324–342.
37. Xu, Z., Zeng, A., Xu, Q. (2024). FITS: modeling time series with 10k parameters. *ICLR*.
38. Zeng, A., Chen, M., Zhang, L., Xu, Q. (2023). Are transformers effective for time series forecasting? *AAAI*, 11121–11128.
39. Operador Nacional do Sistema Elétrico (ONS). Dados abertos: balanço de energia por subsistema, curva de carga horária.
40. Banco Central do Brasil. Sistema Gerenciador de Séries Temporais (SGS): taxas de câmbio.