

LEBRE v0.52 — Especificação e Relatório Técnico

Previsão online com mudanças de estrutura testadas estatisticamente, sob orçamento computacional mínimo

LEBRE: Lifecycle-governed Evidence-Based Resource Evolution

Arquitetura: memória + especialista estrutural + média dinâmica de modelos, com um plano de mudanças testadas por e-process

CUSTO

~415 operações/passos (analítico; contrato de 400 não cumprido por 3,7%); 3,2–6,0 mil instruções/passos num Cortex-M4F simulado

AValiação

três avaliações pré-registradas sequenciais; versão final confirmada em 40 + 60 séries nunca vistas (a primeira, com 125, revelou a falha corrigida)

Última Avaliação (60 Séries)

erro $0,81 \times$ NLinear; empate com SARIMAX-X; ~25% acima do Chronos-2; 0 falhas graves

Status

versão de pesquisa congelada, não promovida; escopo: hidrologia e prédios, um passo à frente

1. Sumário executivo

A **LEBRE** é um previsor **online** de séries temporais com entradas: a cada passo ela recebe as entradas e, quando disponível, o valor do alvo; prevê o próximo valor, aprende com o erro e segue, sem reprocessar o passado e sem treino prévio. Ela é desenhada para caber num orçamento computacional de **algumas centenas de operações de ponto flutuante por passo**; no porte testado em simulador, ela é compatível com microcontroladores Cortex-M4F com dezenas de KB de RAM (§15).

A ideia central desta versão é que **toda mudança de estrutura é um experimento**. O modelo vivo é simples (uma memória do próprio alvo e uma regressão linear nas entradas). Um desafiante, rodando em sombra, propõe acrescentar, remover, trocar ou refinar a resposta a **uma entrada inteira**. A mudança só é aceita quando um *e-process* — um teste sequencial válido a qualquer momento — acumula evidência suficiente de melhora preditiva, dentro de um procedimento online de multiplicidade. A validade dos *e-values* é garantida sob as hipóteses especificadas (§5.6–§5.7); com a referência adaptativa usada, essas hipóteses valem só aproximadamente (§7), e o controle de mudanças falsas é **verificado empiricamente** no regime operacional usado (§7 e §12). Nenhuma dessas peças é nova isoladamente; o documento descreve a combinação, as condições em que ela funciona e o que foi medido.

Premissa: a LEBRE **não pretende ser o previsor mais preciso**. O objetivo é entregar previsões úteis, sem falhas graves, com custo por passo mínimo, sem ajuste por série e com cada mudança de estrutura registrada e justificada. Modelos caros são tratados como **tetos de referência**, não como adversários.

O que foi medido (avaliação pré-registrada em 60 séries nunca vistas: 30 bacias hidrográficas brasileiras e 30 medidores de prédios):

- erro quadrático médio relativo ao NLinear online de **0,812** [IC 95% 0,752; 0,866] — o menor entre os oito comparadores de custo semelhante avaliados neste protocolo, e sem nenhuma série com falha grave;
- empate com um SARIMAX com entradas ajustado série a série (razão pareada 1,002); erro ~25% **maior** que o do Chronos-2 com covariáveis (razão 1,25), modelo de fundação de custo ~ 10^7 vezes maior;
- erro menor que o do TTM (Tiny Time Mixers), sem treino e ajustado com as entradas (razões 0,747 e 0,771);
- custo analítico médio de 415 operações por passo (máximo 1.020) — o contrato declarado antes (média ≤ 400 , pico ≤ 1.000) **não foi cumprido**: foi excedido em 3,7% na média e 2,0% no pico;
- num Cortex-M4F **simulado**, em precisão simples: 3,2–6,0 mil instruções por passo em média (~31–57 μ s a 168 MHz, estimados) e 73 KB de estado.

Limites principais: resultados em dois domínios (hidrologia e prédios) com poucas entradas, previsão de um passo; o mecanismo de testes **não melhorou a precisão** em relação a ligar todas as entradas sem testes (razão 0,988 [0,970; 1,006] em 100 séries, exploratório) e custa ~5% mais — o seu papel é produzir estrutura registrada, cuja utilidade prática não foi demonstrada; em simulação, entradas correlacionadas com a verdadeira foram às vezes aceitas como substitutas (§12); a descoberta falha em entradas muito suaves com atraso médio ou longo (limite de informação); o custo em microcontrolador foi medido em simulador, não em placa, e a energia não foi medida. O núcleo do mecanismo (mudança estrutural aceita por *e-process* de melhora preditiva) já existe na literatura em outro domínio (§17).

Guia do documento

1. Sumário executivo	§1	13. Avaliações em séries nunca vistas	§13
2. O problema, a premissa e o escopo	§2	14. Comparação com modelos ultraleves e modelos de fundação	§14
3. Princípios de projeto	§3	15. Execução em microcontrolador simulado	§15
4. Visão geral da arquitetura	§4	16. Ablações: o que cada peça contribui	§16
5. Base teórica	§5	17. Posição na literatura	§17
6. Ciclo de vida de uma mudança de estrutura	§6	18. Evolução da arquitetura	§18
7. A condição de uso: desajuste da referência	§7	19. Limites e afirmações que não fazemos	§19
8. Salvaguardas de saída	§8	20. Parâmetros	§20
9. Custo computacional analítico	§9	21. Pseudocódigo e condições de reprodutibilidade	§21
10. Observabilidade e explicabilidade	§10	22. Referências	§22
11. Metodologia de avaliação	§11	23. Histórico de revisões	§23
12. Resultados de desenvolvimento	§12		

2. O problema, a premissa e o escopo

O problema

Muitos sistemas medem continuamente um alvo (vazão de um rio, consumo de um prédio, carga de um alimentador) junto com entradas que o influenciam com atraso (chuva, temperatura, vazões a montante). Prever o próximo valor *no próprio dispositivo* exige três coisas ao mesmo tempo: custo por passo muito baixo, funcionamento sem ajuste por série e sem treino prévio, e um comportamento que não falhe de forma grave quando o fluxo tem lacunas ou mudanças. Os modelos modernos mais precisos (modelos de fundação) custam de 10^7 a 10^{10} operações por previsão; os modelos clássicos ajustados série a série precisam de otimização por máxima verossimilhança; e os modelos lineares online baratos não sabem, sozinhos, quais entradas e atrasos importam.

A premissa

A LEBRE ocupa um ponto específico do compromisso entre precisão, custo e transparência. Ela é avaliada **dentro da sua classe de orçamento** (modelos com até $\sim 10^4$ operações por previsão), com os modelos caros como tetos. “Entregar bem” significa: erro competitivo na classe, **nenhuma falha catastrófica**, custo previsível e explicação de cada mudança.

Escopo desta versão

- previsão de **um passo à frente**, online, com as entradas do instante atual disponíveis (como em controle e em previsão de curtíssimo prazo);
- séries com **poucas entradas** (1 a 5 nas avaliações) e relação aproximadamente linear com atrasos de até 31 passos;
- o único dado do ambiente é o período de amostragem (por exemplo, 24 para dados horários com ciclo diário; nos prédios, também 168 para o ciclo semanal);
- entradas padronizadas de forma causal (média e variância exponenciais), como contrato de entrada.

O que a LEBRE não é

Não é um modelo de fundação nem um previsor de longo horizonte; não modela relações fortemente não lineares; não afirma causalidade física (uma entrada aceita é uma entrada com *relevância preditiva* certificada contra a referência, e entradas quase idênticas são reportadas como grupo). O nome vem da família original de arquiteturas do projeto (*Lifecycle-governed Evidence-Based Resource Evolution*): estrutura que entra e sai do modelo por evidência, dentro de um orçamento.


3. Princípios de projeto

Princípio	Significado
Toda mudança é um experimento	A estrutura só muda quando um teste sequencial sempre válido rejeita “a mudança não melhora a previsão”; cada aceitação tem um nível de erro fixado antes.
Unidade = uma entrada inteira	A pergunta é “esta entrada ajuda?”, e não “este atraso ajuda?”: menos hipóteses, mais poder, resposta refinada depois por divisões hierárquicas.
Contrato de custo	Média ≤ 400 e máximo ≤ 1.000 operações de ponto flutuante por passo nas séries reais (revisado durante o desenvolvimento, de 250 para 400, e registrado como tal). Na avaliação final o contrato não foi cumprido por pouco (§9).
Sem ajuste por série	As mesmas constantes em qualquer série; o ambiente informa só o(s) período(s).
Silêncio e dados fora do contrato não são evidência	Sem alvo observado, com entrada recortada ($ x > 8\sigma$) ou em quarentena, nada aprende e nenhuma evidência é acumulada.
Saída dentro de contrato	A previsão nunca sai de um envelope dos valores já observados, e lacunas do alvo não fecham a malha da memória.
Observabilidade	Cada mudança é registrada com instante, tipo, evidência e grupo de entradas equivalentes; a previsão vem com intervalo adaptativo.

4. Visão geral da arquitetura

D1 — Arquitetura da LEBRE: previsão viva + experimentos em sombra


O caminho da previsão (em cima) custa pouco e é sempre ativo; o plano de mudanças (embaixo) propõe, testa e decide mudanças de estrutura



Memória (M). Prevê o alvo a partir do seu próprio passado, relativo ao último valor: reversão a uma média lenta, última diferença, termos sazonais do(s) ciclo(s) declarado(s) e um perfil de incrementos por fase do ciclo. **Especialista estrutural (S).** Regressão linear no valor atual de cada entrada (a “base”) mais os *blocos de resposta* das unidades aceitas. **Combinação.** Média dinâmica de modelos entre M e S, com peso que acompanha qual dos dois vem errando menos. **Plano de mudanças.** Uma triagem barata aponta a candidata mais promissora; até dois experimentos rodam em sombra; um e-process acumula a evidência de cada mudança; um procedimento de níveis online decide.

D2 — O que acontece em um passo de tempo

Ordem estritamente causal: tudo o que decide a previsão em t usa apenas dados até t-1



Lacuna do alvo: nada aprende; a memória recebe o último valor observado (retenção), nunca a própria previsão.

Ordem das operações num passo. A previsão em t é emitida antes de y(t) ser lido.

5. Base teórica

Esta seção reúne a base teórica usada. **Todas as ferramentas vêm da literatura** (citada em cada item); o que é específico da LEBRE é a forma de combiná-las e as condições de uso verificadas (§7).

5.1 Aprendizado linear online: NLMS e mínimos quadrados recursivos

O modelo vivo (base de S , pesos dos blocos e memória) aprende por **NLMS** (mínimos quadrados médios normalizados; Widrow & Stearns 1985; Haykin 2002):

$$w_{t+1} = w_t + \mu \frac{e_t}{\|\phi_t\|^2 + \delta} \phi_t, \quad e_t = y_t - w_t^\top \phi_t.$$

Em regime estacionário, o **desajuste** (excesso relativo de erro quadrático por causa da oscilação dos pesos) é aproximadamente $M \approx \mu / (2 - \mu)$. A LEBRE usa $\mu = 0,05$ em S e na memória.

Os **desafiantes** usam mínimos quadrados recursivos (RLS) sem esquecimento dentro de cada episódio, com $P_0 = 10 I$: com poucos parâmetros (5 a 7), o RLS converge em dezenas de amostras e dá um coeficiente praticamente constante no episódio, o que importa para a condição de uso (§7).

5.2 Memória: suavização exponencial em forma de regressão

A memória é uma regressão do incremento sobre atributos do próprio passado, inspirada no modelo *airline* (Box & Jenkins 1970) e no estado sazonal do Holt-Winters (Hyndman et al. 2008) — analogia, não equivalência:

$$\hat{y}_t^M = y_{t-1} + w_1(m_t - y_{t-1}) + w_2(y_{t-1} - y_{t-2}) + w_3(y_{t-s} - y_{t-1}) + w_4(y_{t-s+1} - y_{t-s}) + w_5 G_{t \bmod s} \\ + [w_6(y_{t-s_2} - y_{t-1}) + w_7(y_{t-s_2+1} - y_{t-s_2})]$$

m : média exponencial lenta (taxa 0,01); G : média exponencial (taxa 0,1) dos incrementos observados na mesma fase do ciclo; s_2 : segundo ciclo declarado (semana, nos prédios). A normalização do NLMS tem pisos relativos à escala (10^{-3} da potência média dos atributos e 10^{-4} da escala lenta de y), para que trechos planos não produzam passos enormes.

5.3 Combinação: média dinâmica de modelos

O peso de S segue a diferença descontada de perdas entre os dois especialistas (Raftery, Kárný & Ettler 2010; forma logística equivalente a pesos exponenciais de especialistas):

$$D_t = 0,99 D_{t-1} + \frac{(y_t - \hat{y}_t^S)^2 - (y_t - \hat{y}_t^M)^2}{\hat{\sigma}^2}, \quad w_S = \frac{1}{1 + e^{0,5 D_t}}, \quad \hat{y}_t = \hat{y}_t^M + w_S(\hat{y}_t^S - \hat{y}_t^M).$$

5.4 Representação da resposta: faixas de oitava, atraso de pico e divisões de Haar

A resposta de uma entrada é aproximada por médias do seu passado em faixas diádicas [1], [2–3], [4–7], [8–15], [16–31] — uma resolução que diminui com o atraso, como nas decomposições em multirresolução (Mallat 1989) e nos modelos de defasagem distribuída. Uma média de faixa dilui um atraso isolado (retém $\sim 1/\text{largura do efeito}$); por isso o desafiante carrega também o seu **atraso de pico** k^* , escolhido por ele mesmo pela maior correlação pré-branqueada nas primeiras 200 amostras do aquecimento — antes de qualquer evidência, o que mantém o desafiante previsível. Depois da aceitação, cada faixa pode ser **dividida** nas duas metades (um coeficiente de Haar); cada divisão é uma nova hipótese, testada só se o “pai” foi aceito, no espírito do teste hierárquico (Meinshausen 2008; Yekutieli 2008).


D3 — Unidade de mudança: uma entrada inteira, refinada por divisões

O desafiante de uma entrada usa médias do passado em faixas de oitava; divisões hierárquicas (tipo Haar) refinam a resposta depois da aceitação

atrasos da entrada $x_i \rightarrow$



atraso de pico k^*
(escolhido pelo próprio desafiante)



divisão: faixa $\rightarrow$ duas metades (nova hipótese, testada só se o "pai" foi aceito)

Desafiante da unidade: $\hat{y}_G = \hat{y}_S + \sum_b \theta_b \cdot \text{média}(x_i, \text{faixa } b) + \theta_k \cdot x_i(t-k^*) + \theta_0 \cdot x_i(t)$

Representação da resposta a uma entrada: médias em faixas de oitava, o valor atual e um atraso de pico; depois da aceitação, cada faixa pode ser dividida em metades, uma hipótese por divisão.

5.5 Triagem: pré-branqueamento e estatística de grupo

Para escolher a próxima candidata sem testar todas, cada entrada inativa tem uma estatística de grupo: correlações exponenciais (peso 0,02) entre o resíduo de S e as médias de faixa, ambos **pré-branqueados** por um AR(1) causal da entrada (Box & Jenkins 1970), somadas em quadrado e normalizadas pela variância nula. A unidade é aberta se a estatística passa do quantil 99% de χ^2_5 (15,09); uma divisão, do quantil 99% de χ^2_1 (6,63), sobre o detalhe de Haar. A triagem **não gera evidência**: ela só escolhe o que testar, e o controle de erro vem inteiro do e-process.

5.6 Evidência sempre válida: e-processes de melhora preditiva

Um **e-process** é um processo não negativo cuja esperança, sob a hipótese nula, não passa de 1 em nenhum tempo de parada; por Ville, a probabilidade de ele alguma vez ultrapassar $1/\alpha$ é $\leq \alpha$. Isso permite olhar a evidência a cada passo, pausar e retomar sem inflar o erro (Ramdas, Grünwald, Vovk & Shafer 2023; Grünwald, de Heide & Koolen 2024). A LEBRE usa a comparação sequencial de previsores de Choe & Ramdas (2024), com a nula *fraca*: em média, o desafiante não melhora a perda da referência em mais que uma margem ε .

Perda recortada e diferencial, com a escala $B_t = 2 \max(\hat{\sigma}_t^S, 0, 1 s_t^{lenta})$:

$$\ell_t(u) = \min\{(y_t - u)^2 / B_t^2, 1\}, \quad d_t = \ell_t(\hat{y}_t^S) - \ell_t(g_t) - \varepsilon.$$

E-process de mistura sub-exponencial, com centragem previsível $\gamma_i = \min(\bar{d}_{i-1}, 0)$ e 8 valores de λ :

$$E_n = \frac{1}{8} \sum_{j=0}^7 \exp \left\{ \lambda_j \sum_{i \leq n} d_i - \psi_{E,c}(\lambda_j) \sum_{i \leq n} (d_i - \gamma_i)^2 \right\}, \quad \psi_{E,c}(\lambda) = \frac{-\log(1 - c\lambda) - c\lambda}{c^2}, \quad \lambda_j = \frac{0,9 \cdot 2^{-j}}{c}.$$

A constante c unilateral. O enunciado de Choe & Ramdas supõe $|d_i - \gamma_i| \leq c$, o que daria $c = 2(1+|\varepsilon|)$. A demonstração de base (Howard et al. 2021, §A.8) usa apenas o lema de Fan, Grama & Liu (2015): $\exp(\lambda \xi - \psi_E(\lambda) \xi^2) \leq 1 + \lambda \xi$ para $\xi \geq -1$ e $\lambda \in [0, 1)$. Para o teste unilateral, sob a nula fraca $E[d_i | \text{passado}] = \mu_i \leq 0$, basta a cota **inferior** $d_i - \gamma_i \geq -c$:

$$\mathbb{E}_{i-1} \left[e^{\lambda(d_i - \gamma_i) - \psi_{E,c}(\lambda)(d_i - \gamma_i)^2} \right] e^{\lambda(\gamma_i - \mu_i)} \leq (1 + \lambda(\mu_i - \gamma_i)) e^{\lambda(\gamma_i - \mu_i)} \leq 1.$$

Como $\lambda \Sigma d_i \leq \lambda \Sigma (d_i - \mu_i)$, o processo é limitado por uma supermartingala não negativa. Como $d_i \geq -(1+\varepsilon)$ e $\gamma_i \leq 0$, vale $c = 1 + \max(\varepsilon, 0)$. A mistura de e-processes é um e-process, e as pausas entre episódios formam uma subsequência previsível.

Esta observação é uma leitura direta da demonstração publicada, não um resultado novo. Numa simulação de desenvolvimento (400 trajetórias $\times$ 5.000 passos, nula no limite) o erro tipo I ficou $\leq 0,025$ contra $\alpha = 0,05$, e o poder subiu de 0,66 (c de dois lados) para

0,77 (Figura 5). A alternativa por apostas com λ previsível (Waudby-Smith & Ramdas 2024) teve mais poder, mas aceitou substitutas quase idênticas da entrada verdadeira e não foi adotada.

5.7 Multiplicidade ao longo do fluxo: níveis tipo e-LOND

Cada hipótese de mudança recebe, ao ser criada, um nível fixo que depende apenas do número de hipóteses já criadas e de mudanças já aceitas (regra LOND de Javanmard & Montanari 2018, na versão para e-valores de Xu & Ramdas 2024). Isso controla a taxa de mudanças falsas (FDR) ao longo de um fluxo sem fim, com decisões assíncronas:

$$\alpha_n = \min(\alpha \gamma_n (R_n + 1), 0,5), \quad \gamma_n = \begin{cases} 1/(2P) & n \leq P \\ \frac{1}{2} C / ((n - P) \log^2(n - P + 1)) & n > P \end{cases}, \quad \text{aceita se } \log E \geq \log(1/\alpha_n),$$

com $\alpha = 0,05$, $P = 2 \times (\text{número de unidades})$ e C tal que $\sum \gamma_n \leq 1$. Uma hipótese é *persistente*: a sua evidência se acumula entre episódios.


5.8 Intervalo adaptativo

O intervalo de 90% é um quantil do erro absoluto atualizado por retroalimentação da cobertura, no espírito da inferência conforme adaptativa (Gibbs & Candès 2021): a cada 8 passos, $\hat{q} \leftarrow \max(0, \hat{q} + 0,1 \cdot \sigma \Sigma(\text{erro fora} - 0,1))$. Não há garantia formal de cobertura sob dependência; a cobertura empírica é reportada.


6. Ciclo de vida de uma mudança de estrutura



- **Unidades:** cada entrada (inclui o próprio passado do alvo, padronizado causalmente) e o estado latente do resíduo (dois filtros do erro padronizado, polos 0,8 e 0,95). Até 4 unidades ativas.
- **Desafiante de uma entrada:** RLS sobre [médias das 5 faixas, atraso de pico, valor atual $x_i(t)$] — o bloco é julgado líquido do que $x_i(t)$ já carrega. O alvo do RLS é o resíduo que a mudança explicaria.
- **Episódio:** aquecimento de 250 amostras sem evidência; encerra ao aceitar, pela regra de varredura (soma do episódio ≤ 0 após 100 amostras) ou em 5.000 amostras; a mesma hipótese espera 2.000 passos para voltar. Só um desafiante em aquecimento por vez (controle de pico de custo).
- **Decisões** a cada 10 passos: aceitar, encerrar, abrir. Prioridade: teste de remoção periódico das unidades ativas; depois a melhor candidata da triagem (unidade ou divisão). Com 4 unidades ativas, a candidata entra por *troca* com a de menor contribuição.
- **Julgamento na previsão de S**, não na combinação: a pergunta é se a mudança melhora o especialista estrutural.



Exemplo real (série de desenvolvimento: vazão de uma usina hidrelétrica; entrada x_0 = vazão defluente da usina a montante; x_1 = próprio passado do alvo). Log-evidência dos experimentos (linhas cheias) contra os seus limiares $\log(1/\alpha_k)$ (pontilhadas). A entrada x_0 é aceita em $t \approx 3.090$ e o estado latente do residuo em $t \approx 4.230$; depois disso, remoções e divisões são testadas e encerradas sem evidência.



Processo sintético declarado ($y = 0,8 \cdot x_0(t-12) + 0,3 \cdot \text{média}(x_1, t-4 \dots t-7) + \text{ruído}$; x_2 irrelevante). Resposta recuperada pela LEBRE (pontos) contra a verdadeira (barras): o atraso 12 de x_0 é recuperado com peso 0,81; o efeito distribuído de x_1 aparece na faixa [4–7]; x_2 não é aceita.

7. A condição de uso: desajuste da referência

Um teste de melhora preditiva compara **métodos** (modelo + procedimento de estimação), não modelos — uma distinção conhecida em econometria (Giacomini & White 2006). Durante o desenvolvimento, isso apareceu de forma concreta: com a base de S aprendendo por NLMS com passo 0,1, alvos **sem nenhuma estrutura** tiveram uma mudança aceita em ~20% das execuções. A causa é que o erro de estimação da referência é previsível pelo passado, e um desafiante pode “corrigi-lo”.

Seja $f_t^* = \mathbb{E}[y_t | \mathcal{F}_{t-1}]$, $\eta_t = f_t^* - S_t$ (erro de estimação da referência, previsível) e o desafiante $G_t = S_t + g_t$. Para a diferença de perda quadrática normalizada $\Delta_t = [(y_t - S_t)^2 - (y_t - G_t)^2]/B_t^2$:

$$\textbf{Proposição 1} \quad \mathbb{E}[\Delta_t | \mathcal{F}_{t-1}] = \frac{2g_t\eta_t - g_t^2}{B_t^2} \leq \frac{\eta_t^2}{B_t^2}, \quad \text{com igualdade em } g_t = \eta_t.$$


Demonstração: $y - S = \varepsilon + \eta$ e $y - G = \varepsilon + \eta - g$; expandindo, a diferença é $2g(\varepsilon + \eta) - g^2$, e $\mathbb{E}[\varepsilon | \text{passado}] = 0$. ■

$$\textbf{Corolário (garantia exata)} \quad \frac{1}{n} \sum_{i \leq n} \frac{\eta_i^2}{B_i^2} \leq \varepsilon \quad \forall n \Rightarrow \text{sob a nula estrutural, a nula do teste vale.}$$

Para NLMS com desajuste M , isso exige $M \lesssim 4\varepsilon$ (com $\varepsilon = 0,002$: $\mu \lesssim 0,016$).

$$\textbf{Proposição 2 (coeficiente fixo)} \quad \text{melhora média na janela} \leq D_u + \varepsilon, \quad D_u = \frac{1}{|W|} \sum_{i \in W} (P_u \eta_i)^2 / B_i^2 - \varepsilon,$$

em que P_u é a projecção de η nos atributos da unidade. **Proposição 3 (critério prático, aproximação):** a log-evidência cresce como $n \cdot D^2 / (2\sigma_d^2)$; numa série de comprimento T , aceitação falsas são improváveis se $D_u < \sigma_d \sqrt{2 \log(1/\alpha_k)/T}$.




Leitura honesta: a LEBRE usa $\mu = 0,05$, que está no **regime prático** da Proposição 3 (o desvio da nula existe, $\sim 0,0013$, mas é menor que o detectável no comprimento das séries, $\sim 0,0019$), e **não** no regime da garantia exata ($\mu \lesssim 0,016$). Por isso o controle de mudanças falsas é verificado empiricamente com lotes nulos (0/40 e 0/30 aceitaçãoes no desenvolvimento), e não apenas afirmado pela teoria. A observação relaciona-se com Giacomini & White (2006) e, em outro mecanismo, com Han & Qu (2026); não a encontramos formulada explicitamente para esta situação, mas é uma consequência simples de resultados conhecidos.

8. Salvaguardas de saída


Duas salvaguardas atuam só no caminho da saída e custam ~ 15 operações por passo. Ambas são práticas padrão de engenharia; entram aqui porque a sua ausência produziu a falha mais grave observada (§13).


- **Retenção durante lacunas do alvo:** a memória recebe o último valor observado, nunca a própria previsão. Sem isso, a memória fica em malha aberta e, com certos pesos aprendidos, a recursão é instável (raiz característica $\sim 1,75$ num caso real).
- **Contrato de saída:** a previsão é limitada ao envelope dos alvos observados (máximo e mínimo correntes que relaxam para a média lenta à taxa 10^{-3}), alargado em $0,5\times$ a sua largura; uma previsão não finita vira o último valor observado.



9. Custo computacional analítico

O custo é contado operação a operação no código (somadas, produtos, divisões, raízes, exponenciais contam 1), por componente. O custo por passo é **quase fixo**: a memória, a base e a triagem rodam sempre; os experimentos acrescentam custo apenas quando há vaga ocupada, e os picos ocorrem nos passos de decisão.






A memória de estado é de tamanho fixo, dada a quantidade de entradas e os períodos. No porte em C, com capacidades dimensionadas para até 8 entradas e 160 hipóteses, o estado ocupa ~73 KB; a maior parte é a tabela de hipóteses, que pode ser reduzida (§15).

10. Observabilidade e explicabilidade

Cada previsão pode ser decomposta em parcelas nomeadas (memória, base, cada bloco ativo), e cada mudança de estrutura fica registrada. Exemplo da série de desenvolvimento da §6:

Instante	Evento	Mudança	log E	Amostras de evidência
3.090	aceita	acrescentar entrada x0	7,18	957
4.230	aceita	acrescentar estado latente do resíduo	5,49	893

- **Grupos equivalentes:** junto da entrada aceita x0 o modelo reporta o grupo {x0, x1} (correlação causal $\geq 0,95$ entre x0, a vazão defluente da usina a montante, e x1, o próprio passado do alvo). A afirmação é “esta entrada ou uma equivalente”: aqui, a vazão a montante e o passado do alvo carregam quase a mesma informação.
- **Intervalo de 90%:** cobertura empírica de 0,906 nesta série e 0,904 em média nas 60 séries nunca vistas.
- **Registro de experimentos encerrados:** cada teste que não passou fica registrado com a sua evidência (por exemplo, testes de remoção de x0 com log E entre -1,8 e -3,2: a entrada continua útil).



11. Metodologia de avaliação

Protocolo

- **Previsão online de um passo**, sem olhar o futuro. Todos os modelos recebem **as mesmas entradas**, padronizadas de forma causal.
- **Métrica**: erro quadrático médio na região de teste (últimos 70% de cada série, alvo observado), dividido pelo do NLinear online calibrado na mesma série; média geométrica entre séries; IC 95% por bootstrap estratificado por domínio (2.000 reamostragens). Valores abaixo de 1 = melhor que o NLinear.
- **Falha catastrófica**: erro relativo > 10, desvio > 10× a amplitude observada ou previsão não finita.
- **Modelos de fundação** (caros demais para rodar em todos os passos): avaliados em 1.000 pontos por série, os mesmos para todos, com o mesmo contexto passado e as entradas atuais como covariáveis futuras conhecidas.
- **Comparadores ajustados em lote** (SARIMAX com entradas, FITS, SparseTSF, ajuste fino do TTM): ajustados nos primeiros 15% da série (até 5.000 pontos) e depois usados com pesos fixos.

Dados e divisão

Três fontes públicas: vazões e geração do Operador Nacional do Sistema Elétrico (ONS; usinas em cascata, entradas = vazões a montante), bacias do CAMELS-BR (Chagas et al. 2020; entradas = precipitação, evapotranspiração, temperatura) e medidores do Building Data Genome 2 (Miller et al. 2020; entradas = clima), além de dois benchmarks de identificação de sistemas no desenvolvimento. As séries foram divididas por **permutações com semente fixa**, antes de qualquer modelagem, em desenvolvimento e reservas; o carregador de dados impede o acesso às reservas fora de uma execução pré-registrada.

Conjunto	Séries	Uso
Desenvolvimento	29 (ONS 11, CAMELS 10, BDG2 5, Silverbox, Cascaded Tanks ×2)	todo o desenho e ajuste; semi-sintéticos e sintéticos com sementes declaradas
Reserva 1	125 (ONS 45, CAMELS 50, BDG2 30)	pré-registrada; revelou a falha das lacunas (§13.1)
Reserva 2	40 (CAMELS 20, BDG2 20)	pré-registrada; verificou a correção
Reserva 3	60 (CAMELS 30, BDG2 30)	pré-registrada; ultraleves, TTM, porte em C, microcontrolador


Classes de comparadores

Classe	Modelos	Custo por previsão
Orçamento	NLinear e DLinear online (Zeng et al. 2023), Holt-Winters online, ARX denso (NLMS), LASSO online, FITS (Xu et al. 2024), SparseTSF (Lin et al. 2024), LEBRE v0.51	20 a ~10 ⁴ operações
Referência clássica	SARIMAX com entradas (máxima verossimilhança, série a série); ARX por mínimos quadrados com ordem escolhida online	ajuste por otimização; ~4,9·10 ⁴
Modelos de fundação	TTM r2 (~1M parâmetros; Ekambaram et al. 2024) sem treino e ajustado com entradas; Chronos-2 com covariáveis (Ansari et al. 2025)	15,6·10 ⁶ / 55,6·10 ⁶ ; ~10 ⁹ –10 ¹⁰ (estimado)

Pré-registro: antes de cada acesso a uma reserva, um documento fixou perguntas, métricas, comparadores, critérios e os hashes do código; cada reserva foi executada uma única vez. Incidentes de infraestrutura (sem alteração de modelo) estão descritos junto dos resultados.

12. Resultados de desenvolvimento

Resultados usados para desenhar a arquitetura. **Não são evidência independente**: servem para mostrar o comportamento dos mecanismos em condições controladas. Cada iteração teve um conjunto de medição declarado antes de rodar, com sementes novas.




Descoberta de estrutura em processos controlados

Situação	Resultado (desenvolvimento)
Sintéticos com entradas brancas (atrasos até 12)	estrutura recuperada até o atraso exato em 500–2.200 passos (ex.: atraso 12, peso 0,84 contra 0,80)
Semi-sintéticos (entradas reais, efeito conhecido)	entrada verdadeira (ou do seu grupo) em 2 de 3 tarefas estruturadas, 3/3 sementes; latência 4–17 mil passos
Entradas muito suaves (autocorrelação ~0,99), atraso médio/longo	não descobertas ; um oráculo online (conhece o atraso, testa desde o início) precisa de 9–27 mil passos ou nunca chega em 32 mil
Alvos sem estrutura (lotes nulos com entradas reais)	0/40 e 0/30 aceitações; 0 entradas exógenas falsas em todos os conjuntos declarados
Entradas quase idênticas (correlação 0,98)	indistinguíveis por melhora preditiva; o modelo reporta o grupo

O limite em entradas suaves é conhecido em princípio: com regressores muito persistentes, a informação nova de um atraso além do valor atual é pequena (Stambaugh 1999; Campbell & Yogo 2006). Nesses casos, a previsão continua boa porque a base já usa o valor atual das entradas; o que se perde é a *explicação* do atraso.

Controle de mudanças falsas em simulação com dependência (verificação posterior ao congelamento)

Para verificar o controle de mudanças falsas além dos lotes nulos, o modelo congelado foi rodado em 700 execuções sintéticas (plano e critério declarados antes; 4 entradas correlacionadas entre si, persistência 0,5 ou 0,95, 30 mil passos): quatro nulos (ruído branco; alvo autorregressivo; ruído cuja variância depende de uma entrada; quebra de variância) e três cenários com uma entrada verdadeira com atraso 6 (simples; com uma isca de correlação 0,7 com a verdadeira; com ruído autorregressivo de cauda pesada).



- **Nulos:** 0 de 400 execuções com qualquer mudança aceita.
- **Com uma entrada verdadeira:** pelo critério declarado (por cenário, 100 execuções) os três cenários ficaram dentro de $\alpha = 0,05$ (FDR 0,045 e 0,038 nos piores). Mas, com persistência 0,5, duas células passaram de 0,05: FDR 0,090 (isca) e 0,077 (ruído dependente), com 7/50 e 10/50 execuções afetadas.
- **Mecanismo:** em todas as 17 execuções afetadas, a mudança falsa foi uma entrada *correlacionada* com a verdadeira, aceita antes dela. Enquanto a verdadeira não está no modelo, essa substituta melhora de fato a previsão da referência — o teste acerta a pergunta que faz (há melhora preditiva?), mas a resposta não é estrutural. O teste periódico de remoção retirou a substituta em 10 dos 17 casos; em 7 de 700 execuções ela ficou no modelo final.



O que isto permite afirmar: nos cenários simulados, o procedimento controlou empiricamente as falsas *melhoras preditivas* e não aceitou nada em alvos sem estrutura. Ele **não** garante estrutura verdadeira: com entradas correlacionadas, uma substituta pode ser aceita e, às vezes, permanecer. Uma entrada aceita significa “melhorou a previsão da referência vigente, com evidência”, não “é a causa”.

13. Avaliações em séries nunca vistas


13.1 Reserva 1 (125 séries): uma falha de engenharia


A primeira avaliação pré-registrada, com a versão ainda sem as salvaguardas de saída, revelou que **6 de 125 séries explodiam** (erro relativo de 13 até 10^{79}): quando o alvo faltava por muitos passos, a memória preenchia o próprio histórico com as próprias previsões. O resultado pré-registrado ficou dominado por essas séries (média geométrica 5,20). Numa vista exploratória, *não pré-registrada*, sem as 6 séries, o erro relativo foi 0,706, igual ao do desenvolvimento. A falha motivou as salvaguardas da §8, que foram verificadas no desenvolvimento e depois em novas séries nunca vistas.

13.2 Reservas 2 e 3 (40 e 60 séries)



Modelo	CAMELS	BDG2	Todas [IC 95%]	Séries > 1,5	Catastróficas	Operações/previsão
LEBRE	0,858	0,768	0,812 [0,752; 0,866]	0%	0	415
NLinear online	1,000	1,000	1,000 [1,000; 1,000]	0%	0	674
DLinear online	1,076	0,947	1,009 [0,948; 1,066]	3%	0	1.533
Holt-Winters online	1,213	1,244	1,229 [1,136; 1,323]	25%	0	20
FITS	1,362	1,137	1,244 [1,158; 1,335]	18%	0	9.757
ARX denso (NLMS)	1,008	2,711	1,653 [1,184; 2,730]	38%	2	474
LASSO online	1,015	3,048	1,759 [1,237; 2,898]	38%	4	705
LEBRE v0.51 (ablação)	2,180	2,140	2,160 [1,440; 3,723]	48%	4	108
SparseTSF	2,980	2,886	2,933 [2,512; 3,446]	87%	3	4.016
SARIMAX com entradas	0,817	0,803	0,810 [0,763; 0,851]	0%	0	ajuste por MV
ARX por mínimos quadrados	0,677	2,867	1,394 [0,998; 2,170]	20%	4	48.944






Resumo das duas avaliações com a versão final: erro relativo 0,767 (reserva 2) e 0,812 (reserva 3); nenhuma série catastrófica e nenhuma acima de 1,5 nas 100 séries; empate com o SARIMAX com entradas nas duas (razões pareadas 0,999 e 1,002); erro 16% e 25% acima do Chronos-2 com covariáveis. O intervalo de 90% teve cobertura empírica de 0,905 e 0,904. A tabela abaixo resume a reserva 2 (inclui a versão sem as salvaguardas como ablação).

Reserva 2 (40 séries)	CAMELS	BDG2	Todas [IC 95%]	Séries > 1,5	Catastróficas	Operações/previsão
LEBRE	0,703	0,836	0,767 [0,657; 0,858]	0%	0	407
LEBRE sem salvaguardas (ablação)	1,468	0,834	1,107 [0,746; 1,826]	8%	2	392
NLinear online	1,000	1,000	1,000 [1,000; 1,000]	0%	0	674
DLinear online	0,948	0,965	0,957 [0,812; 1,077]	5%	0	1.533
Holt-Winters online	1,087	1,139	1,112 [0,946; 1,275]	18%	0	20
ARX denso (NLMS)	0,916	4,345	1,995 [1,214; 3,836]	40%	4	474
LASSO online	0,888	4,576	2,016 [1,235; 3,813]	42%	3	705
LEBRE v0.51 (ablação)	1,258	5,645	2,665 [1,161; 8,462]	32%	3	110
SARIMAX com entradas	0,703	0,837	0,767 [0,646; 0,870]	0%	0	ajuste por MV
ARX por mínimos quadrados	0,595	3,387	1,419 [0,905; 2,597]	22%	3	48.944

14. Comparação com modelos ultraleves e modelos de fundação



Modelo	CAMELS	BDG2	Todas	Razão pareada LEBRE/modelo [IC 95%]	LEBRE vence	Operações/previsão
LEBRE	0,836	0,787	0,811	—	—	~415
SARIMAX com entradas	0,798	0,818	0,808	1,004 [0,956; 1,056]	28/60	ajuste por MV
TTM sem treino	1,204	0,978	1,085	0,747 [0,704; 0,795]	57/60	15,6·10 ⁶
TTM ajustado c/ entradas	1,049	1,054	1,052	0,771 [0,699; 0,844]	50/60	55,6·10 ⁶
Chronos-2 c/ covariáveis	0,782	0,539	0,649	1,250 [1,178; 1,337]	9/60	~10 ⁹ –10 ¹⁰


- Ultraleves (FITS, SparseTSF):** no protocolo online de um passo, com pesos fixos ajustados nos primeiros 15%, ficaram atrás do NLinear online (1,244 e 2,933). Esse não é o regime para o qual foram desenhados (previsão de horizonte longo, treino em lote, univariado); o resultado mostra apenas que, *neste* regime, a leveza em parâmetros não se traduz em precisão.
- TTM:** duas configurações de ajuste foram tentadas no desenvolvimento; a escolhida (taxa 10⁻³, 5 épocas) foi usada na reserva. Outras formas de ajuste podem dar resultados diferentes.
- Chronos-2 com covariáveis** é o teto de referência: erro ~25% menor que o da LEBRE no total, com a maior diferença nos prédios (0,539 contra 0,787).

15. Execução em microcontrolador simulado

Para verificar se o custo analítico corresponde a algo executável num microcontrolador, a configuração congelada foi portada para C99 e executada num **simulador** de um microcontrolador comum (STM32F4, núcleo Cortex-M4F a 168 MHz). Não houve medição em placa física.

D5 — Cadeia de medição em microcontrolador simulado

O mesmo algoritmo, portado para C99 em precisão simples, conferido contra o Python e executado num Cortex-M4F simulado




O simulador conta instruções executadas, mas não modela o pipeline; os ciclos vêm do rastreo de execução com os tempos publicados do Cortex-M4.

Cadeia de medição. A equivalência foi verificada primeiro no PC (C em precisão dupla e simples contra o Python), depois no dispositivo simulado.


15.1 Equivalência do porte

Em precisão dupla, o C reproduz exatamente as decisões do Python em 29/29 séries de desenvolvimento (diferença relativa de erro $\sim 10^{-16}$). Em **precisão simples** (a versão do microcontrolador), as sequências de mudanças aceitas são idênticas em 28/29 séries de desenvolvimento e em 54/60 séries nunca vistas; nas demais, uma decisão perto do limiar ocorre alguns passos antes ou depois (arredondamento). A diferença mediana de erro foi $\sim 10^{-6}$.




15.2 Custo por passo no dispositivo simulado


O simulador (Renode 1.17) conta instruções executadas pelo contador DWT do Cortex-M4, mas não modela o pipeline. Os ciclos foram estimados de rastreios de execução (~ 300 passos no meio de duas séries) com os tempos publicados do Cortex-M4 e da FPU, supondo memória flash sem espera (acelerador de pré-busca): **CPI 1,62 e 1,57**. Tempos em μs abaixo usam CPI 1,6 e são estimativas.





Série	Origem	Entradas	Média	Mediana	p99,9	Pico	Ciclos (×1,6)	Tempo	Padronizador	NMSE	Mudanças
ONS (dev.)	desenv.	1	3.703	3.363	12.327	42.021	~5.925	~35 µs	22	0,2826	4
CAMELS (dev.)	desenv.	3	4.560	4.599	14.387	48.447	~7.296	~43 µs	110	0,0229	3
BDG2 (dev.)	desenv.	2	5.964	5.607	16.843	45.654	~9.542	~57 µs	33	0,0305	2
CAMELS 51795000	reserva 3	3	3.203	3.003	12.223	36.771	~5.124	~31 µs	110	0,1465	0
CAMELS 64625000	reserva 3	3	3.521	3.215	12.267	36.708	~5.634	~34 µs	110	0,3249	0
BDG2 Fox education Ollie	reserva 3	2	5.806	5.587	15.375	45.402	~9.290	~55 µs	34	0,0162	3
BDG2 Panther education Vincent	reserva 3	2	5.528	5.463	16.971	45.696	~8.844	~53 µs	33	0,0584	3



Instruções por passo ao longo das séries de desenvolvimento (blocos de 64 passos): média do bloco (linha) e máximo do bloco (área). Triângulos: passos acima de 20 mil instruções — todos em passos de decisão (criação de hipóteses, aceitações).



Distribuição acumulada das instruções por passo. 99,9% dos passos ficam abaixo de 12–17 mil instruções. Os passos muito baratos são passos com alvo ausente (nada aprende).



Leitura: ~3,2–6,0 mil instruções por passo correspondem a ~9–15 instruções por operação analítica (acessos à memória, laços, índices, divisões). A ~31–57 μ s por passo, uma amostragem de 1 segundo ocuparia < 0,01% do tempo do núcleo; a energia, estimada por ordem de grandeza de folha de dados (~40 mA a 3,3 V), seria de ~5–7 μ J por passo — **não medida**. O estado de ~73 KB cabe na RAM do STM32F407, mas não em microcontroladores menores sem reduzir as capacidades (a tabela de hipóteses domina). Há espaço claro de otimização (divisões, emulação de precisão dupla, cópias de estruturas), não explorado nesta versão.

16. Ablações: o que cada peça contribui

Ablações avaliadas junto das reservas (mesmas séries, mesma máscara). As versões anteriores aparecem aqui apenas como ablações.

Variante	O que muda	Resultado
Tudo ligado, sem testes	todas as entradas e o estado latente ativos desde o início	reserva 1, sem as 6 séries com lacunas: razão pareada 0,99; reservas 2 e 3 (100 séries, versão final): razão 0,988 [0,970; 1,006], custo 395 contra 415 — ambos exploratórios; o mecanismo de testes não melhora a precisão de forma distinguível
Sem divisões hierárquicas	a resposta fica nas faixas de oitava + pico	razão 0,996 [0,988; 1,001] — sem diferença em dados reais
Hipótese por atraso ("atômica")	uma hipótese por atraso de cada entrada (~400 hipóteses)	desenvolvimento: 0,757 contra 0,645 (1.000 pontos); descoberta mais lenta
Sem salvaguardas de saída	memória em malha aberta nas lacunas	reserva 2: 1,107 contra 0,767; 2 catastróficas; razão pareada 0,693
Base com passo 0,1	desajuste maior da referência	10/40 aceitações em alvos sem estrutura (§7)
Arquitetura anterior (v0.51)	dois especialistas com descoberta por atraso, sem controle no fluxo	reserva 3: 2,160, 4 catastróficas

Consequência para o que se pode afirmar: a precisão da LEBRE vem principalmente de uma regressão linear online barata sobre as entradas atuais e de uma memória sazonal, protegidas por salvaguardas de saída. O mecanismo de mudanças testadas **não é justificado por ganho de precisão**; ele se justifica, se for o caso, pela estrutura *registrada com evidência* (quais entradas, com que atraso, desde quando, com qual evidência), com ~5% a mais de custo e sem perda de precisão. **Não demonstramos** que essa estrutura melhore alguma decisão prática (diagnóstico, controle, manutenção); isso fica como pergunta aberta.

17. Posição na literatura

Aspecto	Trabalhos relacionados	Classificação
Mudança estrutural aceita por e-process de melhora preditiva, com controle de erro no fluxo	Amoukou, Mishra & Veloso (2026), em árvores de decisão online (controle FWER); Choi (2026), correções preditivas pré-especificadas; Jha (2026), causalidade de Granger com teste sequencial; Choe & Ramdas (2024); Xu & Ramdas (2024)	não original
Unidades por entrada, refinamento hierárquico, remoção e troca testadas, controle FDR, orçamento fixo, em séries com entradas	peças conhecidas (teste hierárquico; seleção online de grupos; e-LOND; hipóteses persistentes com FDR: de Heide 2026; testes duplamente sequenciais: Yao, Gang & Sun 2025; identificação recursiva esparsa de ARMAX, com garantia assintótica)	integração/extensão
Condição de uso (desajuste da referência)	Giacomini & White (2006); Clark & West (2007); desajuste do LMS (Widrow & Stearns 1985); Han & Qu (2026); viés do incumbente na promoção de desafiantes (Fernández-Barrios et al. 2026)	observação metodológica modesta, derivada de resultados conhecidos
Limite de informação em entradas suaves	Stambaugh (1999); Campbell & Yogo (2006)	conhecido; quantificação ilustrativa
Previsão com orçamento de ~10 ² operações por passo	SparseTSF, FITS, TTM, TinyCast (em geral univariados e treinados em lote); previsão embarcada com aprendizado incremental e sensores exógenos (Lara Pinal, Das & Schlüter 2026)	contribuição empírica, no escopo testado
Retenção, contrato de saída, limites de custo	prática de engenharia	padrão

A auditoria da literatura seguiu um protocolo com afirmações e consultas fixadas antes (47 consultas no total, em duas rodadas) e classificou cada trabalho encontrado como antecipação, parcial, base ou distante. Nenhum trabalho encontrado antecipa a combinação inteira; cada peça tem precedente. **Limitações:** um mecanismo de busca geral, consultas em inglês, leitura em geral pelo resumo, sem dupla triagem; não é uma revisão sistemática no sentido formal, e trabalhos recentes podem não ter sido encontrados.

18. Evolução da arquitetura

A LEBRE começou (v0.1, referência canônica do projeto) como uma arquitetura em que estrutura entra e sai do modelo por evidência, dentro de um orçamento. A v0.51 usava dois especialistas com descoberta por atraso e testes de martingale/CUSUM; análises posteriores mostraram que, em séries reais, quase todo o resultado vinha da memória. A v0.52 manteve a memória e a combinação, e trocou a descoberta por um motor genérico de mudanças testadas. A evolução interna da v0.52 foi:

1. hipóteses por atraso (~400) → **por entrada inteira** (menos hipóteses; melhor nos reais);
2. faixas diluíam atrasos isolados → **atraso de pico** e divisões hierárquicas;
3. evidência lenta → **c unilateral** (leitura da demonstração) e estatística do pico persistente;
4. aceitações em trechos planos → **piso de escala** da perda;
5. aceitações em alvos sem estrutura → **passo 0,05** na referência (§7);
6. picos de custo → um aquecimento por vez, triagem espalhada, estatística do pico em meia janela;
7. explosões em lacunas (reserva 1) → **retenção e contrato de saída**.

19. Limites e afirmações que não fazemos

- **Domínios:** hidrologia (ONS, CAMELS-BR) e prédios (BDG2), com 1 a 5 entradas; as duas últimas reservas não têm ONS. Outros domínios não foram testados.
- **Horizonte:** só um passo à frente, com as entradas atuais disponíveis.
- **Tamanho das avaliações:** 40 e 60 séries dão intervalos de confiança largos; 4 locais do BDG2 compartilham o clima com o desenvolvimento.
- **Posição relativa:** “menor erro na classe” refere-se aos comparadores e protocolos usados aqui; outros comparadores, configurações ou protocolos podem mudar a ordem.
- **Mecanismo de testes:** não melhora a precisão; o controle de mudanças falsas está no regime prático, não no da garantia exata (§7).
- **Descoberta:** falha em entradas muito suaves com atraso médio/longo; entradas quase idênticas são indistinguíveis.
- **Custo:** contrato declarado não cumprido (excedido em 3,7% na média e 2,0% no pico); não foi revisado depois do resultado; microcontrolador apenas simulado, ciclos estimados, energia não medida; estado de ~73 KB.
- **Substitutas correlacionadas:** em simulação, entradas correlacionadas com a verdadeira foram aceitas antes dela em até 20% das execuções de um cenário; a remoção corrigiu parte dos casos. A estrutura aceita é relevância preditiva, não causa.
- **Utilidade da estrutura:** o mecanismo de testes não melhorou a precisão e custa ~5% mais; o benefício prático da estrutura registrada não foi demonstrado.
- **Comparadores ausentes:** não foram avaliados um ARMAX com filtro de Kalman online nem um SARIMAX com parâmetros atualizados online (o SARIMAX usado foi ajustado em lote nos primeiros 15%).
- **Intervalo:** cobertura empírica perto de 90%, sem garantia formal.
- **Correção pós-falha:** as salvaguardas foram desenhadas depois de ver a falha na reserva 1; foram confirmadas em duas reservas posteriores, mas o desenho não foi cego.

Não afirmamos que a LEBRE seja o melhor previsor, nem o mais econômico, nem que o seu mecanismo seja novo. Afirmamos apenas o que foi medido: nos protocolos e dados descritos, com o custo descrito, os números reportados nas §12–§15.

20. Parâmetros

Grupo	Constantes (iguais para todas as séries)
Unidades	uma por entrada (inclui o próprio passado do alvo) + estado latente do resíduo (polos 0,8 e 0,95); até 4 ativas
Resposta	faixas [1], [2–3], [4–7], [8–15], [16–31] + atraso de pico (escolha em 200 amostras) + valor atual; divisões em metades
Desafiantes	RLS no episódio, $P_0 = 10 \cdot I$; aquecimento 250; 2 vagas; um aquecimento por vez
Evidência	perda $\min\{e^2/B^2, 1\}$, $B = 2 \cdot \max(\sigma_S, 0,1 \cdot s_{\text{lenta}})$; $c = 1 + \max(\epsilon, 0)$; $8 \lambda = 0,9 \cdot 2^{-1/c}$; $\epsilon = +0,002$ (acrescentar, trocar, dividir), $-0,002$ (remover)
Multiplicidade	$\alpha = 0,05$; $\gamma = 1/(2P)$ nas primeiras $P = 2 \cdot \text{unidades} $, depois $0,5 \cdot \gamma_k \propto 1/(k \log^2 k)$; nível $\alpha \cdot \gamma \cdot (R+1) \leq 0,5$
Episódios	varredura após 100 amostras; limite 5.000; espera 2.000; remoção periódica a cada 2.000; decisões a cada 10 passos
Triagem	pré-branqueada AR(1), peso 0,02, a cada 4 passos por parte; limiares 15,09 (χ^2_s) e 6,63 (χ^2_{s-1})
Base de S	NLMS $\mu = 0,05$; contrato de entrada $\pm 8\sigma$ com quarentena de 31 passos
Memória	NLMS $\mu = 0,05$; média lenta 0,01; perfil 0,1; pisos 10^{-3} e 10^{-4} ; ciclo(s) declarado(s); retenção nas lacunas
Combinação e saída	$\lambda = 0,99$, $\eta = 0,5$, a cada 8 passos; envelope com taxa 10^{-3} e margem 0,5×
Intervalo	$\alpha = 0,1$, $\gamma = 0,1$, a cada 8 passos
Grupos	correlação causal $\geq 0,95$ reportada junto da entrada aceita (não afeta decisões)

21. Pseudocódigo e condições de reprodutibilidade

Pseudocódigo simplificado de um passo, suficiente para reimplementar a configuração avaliada. Onde o texto e o pseudocódigo diferirem, vale o pseudocódigo junto da tabela de parâmetros (§20).

```

CONSTANTES # iguais para qualquer série; nada é ajustado por série
BANDS = [1], [2-3], [4-7], [8-15], [16-31]      POLES = 0.8, 0.95      L = 31
M_MAX = 4  SLOTS = 2  WARM = 250  PEAK_N = 200  N_MIN = 100  T_MAX = 5000  COOL = 2000  REM_PERIOD = 2000
DECIDE_EVERY = 10  SCREEN_EVERY = 4  SCREEN_W = 0.02  Q_UNIT = 15.09 ( $\chi^2_s$ , 99%)  Q_SPLIT = 6.63 ( $\chi^2_1$ , 99%)
 $\epsilon$ : add = swap = split = +0.002, remove = -0.002   $\alpha$  = 0.05   $\mu_S$  = 0.05   $\mu_M$  = 0.05  CLIP_X = 8
 $\lambda_{DMA}$  = 0.99   $\eta$  = 0.5  EVERY = 8   $\alpha_{int}$  = 0.10   $\gamma_{int}$  = 0.10  SCALE_FLOOR = 0.1  OUT_MARGIN = 0.5  OUT_RHO = 1e-3

ESTADO # tamanho fixo, dado o número de entradas d e o(s) período(s) s, s2
H[0..L+1][d+1] histórico das entradas (inclui o próprio passado do alvo, padronizado)
band_sum[5][d+1], seg_sum{(i,lo,hi)} somas correntes das faixas e dos segmentos ativos
base[d+2] active{unit → (segments, weights)} r[2] estados latentes do residuo
M: buffer, w_M, G[s], m_slow      hyps{key → e-process}      slots[≤ 2]

PASSO(x_t, y_t ou lacuna, quarantine):
# 1. ler
 $\bar{x} \leftarrow [x_t, \text{std\_causal}(y_{last})]$  # média/variância EMA 1e-4, início (0, 1)
se any | $\bar{x}$ | > CLIP_X: quar_until ← t + L;  $\bar{x} \leftarrow \text{clip}(\bar{x}, \pm \text{CLIP\_X})$ ; shift H, band_sum, seg_sum
# 2. prever
 $\hat{y}_M \leftarrow M.\text{predict}()$  # último valor + w_M· $\phi$  (reversão, diferença, sazonal, perfil)
 $\hat{y}_S \leftarrow \text{base} \cdot [1, \bar{x}] + \Sigma_u w_u \cdot \text{block}(u)$  # block: médias dos segmentos ativos
 $\hat{y} \leftarrow \hat{y}_M + w_S (\hat{y}_S - \hat{y}_M)$ 
se n_obs ≥ 50:  $\hat{y} \leftarrow \text{clip}(\hat{y}, \text{env\_lo} - 0.5 \cdot W, \text{env\_hi} + 0.5 \cdot W)$ , W = env_hi - env_lo; se  $\hat{y}$  não finito:  $\hat{y} \leftarrow y_{last}$ 
para cada experimento e: g_e ←  $\hat{y}_S + \theta_e \cdot z_e$  - (contribuição removida)
retorna  $\hat{y}$ , [ $\hat{y} - \hat{q}$ ,  $\hat{y} + \hat{q}$ ]
# 3. observar e aprender (só se y_t observado)
learn ← y_t observado  $\wedge$  ¬quarantine  $\wedge$  t > quar_until
B ← 2·max( $\sigma_r$ , SCALE_FLOOR·sd_slow(y));  $\ell(u) = \min((y_t - u)^2/B^2, 1)$ 
se learn:
  para cada e: k_e += 1
    se k_e > WARM: e.hyp.observe( $\ell(\hat{y}_S) - \ell(g_e) - \epsilon_e$ ) # evidência
    se k_e ≤ PEAK_N: acumula correlação pré-branqueada por atraso (metade dos atrasos por passo)
    se k_e = PEAK_N: k* ← argmax_k c_xy²/c_xx; se k* > 1: insere x_i(t-k*) no desafiante
    RLS( $\theta_e$ , P_e; z_e, alvo = y_t -  $\hat{y}_S$  + contribuição removida) # P_0 = 10·I
    NLMS(base, w_u; res = y_t -  $\hat{y}_S$ ,  $\mu_S$ , norma =  $\|[1, \bar{x}]\|^2 + \Sigma \|\text{block}(u)\|^2$ )
    screen_spread(res) # cada parte na sua fase, a cada 4 passos
D ←  $\lambda_{DMA} \cdot D + ((y_t - \hat{y}_S)^2 - (y_t - \hat{y}_M)^2)/\sigma^2$ ; a cada EVERY: w_S ← 1/(1 + exp( $\eta \cdot D$ ))
intervalo: miss ← |y_t -  $\hat{y}$ | >  $\hat{q}$ ; a cada EVERY:  $\hat{q} \leftarrow \max(0, \hat{q} + \gamma_{int} \cdot \sigma \cdot \Sigma(\text{miss} - \alpha_{int}))$ 
M.update(y_t se observado; senão o último valor observado (retenção), sem aprender)
env ← envelope dos observados (máx./mín. que relaxam para a média, taxa OUT_RHO)
r ← POLES·r + (1 - POLES)·(y_t -  $\hat{y}$ )/ $\sigma$ 
se t mod DECIDE_EVERY = 0: DECIDIR()

DECIDIR():
para cada e: se log E(e.hyp) ≥ log(1/ $\alpha_{hyp}$ ): ACEITAR(e)
senão se n_e ≥ T_MAX ou (n_e ≥ N_MIN e  $\Sigma \text{episode } d \leq 0$ ): encerra (a evidência fica na hipótese)
encerra experimentos sobre unidades que mudaram; PREENCHER()

PREENCHER(): enquanto houver vaga livre:
1. unidade ativa sem teste de remoção há ≥ REM_PERIOD → abre remove
2. se algum desafiante em aquecimento: pare # um aquecimento por vez
3. u* ← argmax stat(u) entre unidades inativas, livres, fora da espera; s* ← argmax stat(divisões)
4. escolhe o maior entre stat(u*)/Q_UNIT e stat(s*)/Q_SPLIT (se ≥ 1):
   divisão → split; |active| < M_MAX → add; senão → swap (com a unidade de menor contribuição)
# hipótese nova n recebe nível fixo:  $\alpha_n = \min(\alpha \cdot \gamma_n \cdot (R+1), 0.5)$ ,
#  $\gamma_n = 1/(2P)$  para n ≤ P = 2·|units|, depois 0.5·C/((n-P)·log²(n-P+1)); R = mudanças já aceitas

e-process( $\epsilon$ ): c = 1 + max( $\epsilon$ , 0);  $\lambda_j = 0.9 \cdot 2^{-(j)}/c$ , j = 0..7;  $\psi_j = (-\log(1 - c\lambda_j) - c\lambda_j)/c^2$ 
observe(d):  $\gamma \leftarrow \text{clip}(\text{média passada de } d, -c, 0)$ ; S += d; V += (d -  $\gamma$ )²
log E = log( (1/8)· $\Sigma_j \exp(\lambda_j \cdot S - \psi_j \cdot V)$  )

ACEITAR(e): add/swap → active[i] ← (BANDS U {[k*]},  $\theta_e[-1]$ ); base[i] +=  $\theta_e[-1]$ ; remove → apaga active[u]
split → troca a faixa [lo,hi] pelas duas metades com os pesos do desafiante; R += 1

```

Condições de reprodutibilidade

- **Entradas:** padronizar cada entrada de forma causal antes do modelo: $z = (x - m)/\sqrt{v + 10^{-6}}$, com m e v exponenciais de taxa 10^{-4} a partir de $(0, 1)$, atualizadas *depois* de padronizar o valor atual; valores ausentes viram 0 após a padronização.
- **Alvo:** passado em unidades originais; ausências são passadas como lacuna (sem aprendizado); uma marca externa de quarentena suspende o aprendizado.
- **Metadados:** período sazonal s (24 para dados horários; nenhum se não houver ciclo) e, opcionalmente, um segundo ciclo s_2 (168 nos prédios).
- **Determinismo:** o algoritmo não usa números aleatórios; dada a mesma sequência de entradas, a saída é determinística. Em precisão simples, decisões perto do limiar podem mudar de passo ($\approx 10\%$ das séries), sem efeito material no erro.
- **Avaliação:** divisão de séries por permutação com semente fixa antes de qualquer modelagem; região de teste = últimos 70%; métrica relativa ao NLinear online calibrado na mesma série; média geométrica e bootstrap estratificado (semente fixa).
- **Disponibilidade:** o código (Python e C99), os pré-registros, os scripts de análise e as previsões por série estão arquivados com hashes SHA-256 registrados no congelamento; **ainda não foram publicados** em repositório público.
- **Ambiente usado:** Python 3.11, NumPy, pandas 2.2.3 (versões posteriores mudaram o comportamento de arrays somente leitura); C99 com GCC para Arm 15.2 (–O2, FPU de precisão simples, sem contração FMA); Renode 1.17.

22. Referências

1. Amoukou, S. I., Mishra, S., Veloso, M. (2026). Correcting split selection in online decision trees via anytime-valid inference. *arXiv:2605.31239*.
2. Ansari, A. F. et al. (2025). Chronos-2: from univariate to universal forecasting. *arXiv preprint*.
3. Box, G. E. P., Jenkins, G. M. (1970). *Time Series Analysis: Forecasting and Control*. Holden-Day.
4. Campbell, J. Y., Yogo, M. (2006). Efficient tests of stock return predictability. *Journal of Financial Economics* 81(1), 27–60.
5. Chagas, V. B. P. et al. (2020). CAMELS-BR: hydrometeorological time series and landscape attributes for 897 catchments in Brazil. *Earth System Science Data* 12, 2075–2096.
6. Choe, Y. J., Ramdas, A. (2024). Comparing sequential forecasters. *Operations Research* 72(4), 1368–1387.
7. Choi, S. (2026). Anytime-valid evidence for prespecified predictive corrections. *arXiv:2608.08174*.
8. Clark, T. E., West, K. D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics* 138(1), 291–311.
9. Ekambaram, V. et al. (2024). Tiny Time Mixers (TTMs): fast pre-trained models for enhanced zero/few-shot forecasting of multivariate time series. *NeurIPS* 37.
10. Fan, X., Grama, I., Liu, Q. (2015). Exponential inequalities for martingales with applications. *Electronic Journal of Probability* 20, 1–22.
11. Fernández-Barrios, R., Pastor-López, I., Pikatza-Huerga, A., García Bringas, P. (2026). Candidate comparability before promotion: conditional validation in adaptive network intrusion detection. *arXiv:2609.04388*.
12. Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica* 74(6), 1545–1578.
13. Gibbs, I., Candès, E. J. (2021). Adaptive conformal inference under distribution shift. *NeurIPS* 34.
14. Grünwald, P., de Heide, R., Koolen, W. M. (2024). Safe testing. *Journal of the Royal Statistical Society B* 86(5), 1091–1128.
15. Han, W., Qu, L. (2026). When the martingale never stops firing: anytime-valid gating on real forecast streams. *arXiv:2608.30502*.
16. Haykin, S. (2002). *Adaptive Filter Theory*, 4th ed. Prentice Hall.
17. de Heide, R. (2026). Dynamic e-closure for online hypotheses with any-time-valid evidence: closure principles and projective mergers. *arXiv:2608.09927*.
18. Howard, S. R., Ramdas, A., McAuliffe, J., Sekhon, J. (2021). Time-uniform, nonparametric, nonasymptotic confidence sequences. *Annals of Statistics* 49(2), 1055–1080.
19. Hyndman, R. J., Koehler, A. B., Ord, J. K., Snyder, R. D. (2008). *Forecasting with Exponential Smoothing: The State Space Approach*. Springer.
20. Javanmard, A., Montanari, A. (2018). Online rules for control of false discovery rate and false discovery exceedance. *Annals of Statistics* 46(2), 526–554.
21. Jha, A. (2026). Distributional Granger causality: identification, sequential inference, and adaptive testing. *arXiv:2606.22230*.
22. Lara Pinal, E. M., Das, A., Schlüter, S. (2026). A low-cost IoT device for environmental monitoring and embedded solar forecasting with on-device incremental learning. *arXiv:2608.14698*.
23. Lin, S. et al. (2024). SparseTSF: modeling long-term time series forecasting with 1k parameters. *ICML*.
24. Mallat, S. (1989). A theory for multiresolution signal decomposition: the wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 11(7), 674–693.
25. Meinshausen, N. (2008). Hierarchical testing of variable importance. *Biometrika* 95(2), 265–278.
26. Miller, C. et al. (2020). The Building Data Genome Project 2, energy meter data from the ASHRAE Great Energy Predictor III competition. *Scientific Data* 7, 368.
27. Raftery, A. E., Kárný, M., Ettler, P. (2010). Online prediction under model uncertainty via dynamic model averaging. *Technometrics* 52(1), 52–66.
28. Ramdas, A., Grünwald, P., Vovk, V., Shafer, G. (2023). Game-theoretic statistics and safe anytime-valid inference. *Statistical Science* 38(4), 576–601.
29. Recursive sparse parameter identification of multivariate ARMAX systems with non-stationary observations and colored noise (2025). *arXiv:2505.00323*.
30. Stambaugh, R. F. (1999). Predictive regressions. *Journal of Financial Economics* 54(3), 375–421.
31. Waudby-Smith, I., Ramdas, A. (2024). Estimating means of bounded random variables by betting. *Journal of the Royal Statistical Society B* 86(1), 1–27.
32. Widrow, B., Stearns, S. D. (1985). *Adaptive Signal Processing*. Prentice Hall.
33. Xu, Z., Ramdas, A. (2024). Online multiple testing with e-values. *AISTATS*.

34. Xu, Z., Zeng, A., Xu, Q. (2024). FITS: modeling time series with 10k parameters. *ICLR*.
35. Yao, Z., Gang, B., Sun, W. (2025). Safe, always-valid alpha-investing rules for doubly sequential online inference. *arXiv:2512.12244*.
36. Yekutieli, D. (2008). Hierarchical false discovery rate-controlling methodology. *Journal of the American Statistical Association* 103(481), 309–316.
37. Zeng, A., Chen, M., Zhang, L., Xu, Q. (2023). Are transformers effective for time series forecasting? (DLinear, NLinear). *AAAI*.

23. Histórico de revisões

- **Revisão 0** (27/09/2026): primeira edição.
- **Revisão 1** (27/09/2026): linguagem sobre validade estatística (e-values válidos sob as hipóteses especificadas; controle de mudanças falsas verificado empiricamente); contrato de custo declarado como *não cumprido* (+3,7% na média, +2,0% no pico); compatibilidade com microcontroladores limitada ao porte e ao núcleo testados; capa com as avaliações sequenciais; *acréscimos* posteriores ao congelamento, com o mesmo código: simulação do controle de mudanças falsas (§12), ablação exploratória nas reservas 2 e 3 (§16), segunda rodada da auditoria de literatura (§17), limites e disponibilidade (§19, §21). Nenhum resultado anterior foi alterado.