

LEBRE v0.53 — Especificação e Relatório Técnico

Consolidação da v0.52: especialista de precisão e ponto de partida na referência trivial, sob orçamento declarado

LEBRE: Lifecycle-governed Evidence-Based Resource Evolution

v0.53: v0.52 inalterada + M1 (especialista de precisão) + M2 (referência trivial)

STATUS

versão de pesquisa promovida por regra pré-registrada (09/10/2026); a v0.52 continua congelada e inalterada

AValiação FINAL

104 séries reservadas; $v0.53 \div v0.52 = 0,955$ [IC 95% 0,951; 0,960]; nenhuma piora por família

CUSTO

acréscimo mediano de 476 operações por passo sobre a v0.52 na avaliação final (limite de 1.100); memória estimada 83,1 KB

ESCOPO

ganho em bacias e câmbio; idêntica à v0.52 em solar, eólica e carga; um passo à frente

Sumário

1. Sumário executivo	\$1	9. Validações em dados novos	\$9
2. Ponto de partida: a v0.52 e dois modos de falha	\$2	10. Avaliação final pré-registrada	\$10
3. Visão geral da arquitetura	\$3	11. Limites e afirmações que não fazemos	\$11
4. M1: especialista de precisão	\$4	12. Posição na literatura	\$12
5. M2: ponto de partida na referência trivial	\$5	13. Parâmetros	\$13
6. Custo computacional	\$6	14. Pseudocódigo e reprodutibilidade	\$14
7. Metodologia de avaliação	\$7	15. Referências	\$15
8. Desenvolvimento: desenhos e falhas	\$8	16. Histórico de revisões	\$16

1. Sumário executivo

A **LEBRE v0.53** é a v0.52 **inalterada** com dois componentes novos por cima. A **M1** combina a previsão da v0.52 com um especialista de precisão (uma regressão recursiva sobre o passado do alvo e médias de defasagem das entradas), para os casos em que a v0.52 fica abaixo da fronteira precisão × custo. A **M2** faz a previsão partir de uma referência trivial declarada (zero, persistência ou sazonal ingênuo) e só confiar na parte adaptativa quando ela se mostra melhor, para os casos em que a v0.52 perde para essa referência.

Resultado da avaliação final pré-registrada (104 séries reservadas antes de qualquer código da v0.53):

- **promovida** pela regra fixada antes: nenhuma piora em nenhuma família e melhora clara no conjunto;
- erro quadrático médio v0.53 ÷ v0.52 de **0,955** [IC 95% 0,951; 0,960] nas 104 séries;
- o ganho vem de Bacias (CAMELS-BR) 0,879, Câmbio: níveis 0,952, Câmbio: retornos 0,966, Prédios (BDG2) 0,993; em solar, eólica e carga a v0.53 é idêntica à v0.52;
- custo: acréscimo mediano de 476 operações por passo sobre a v0.52 (máximo 918; limite pré-registrado de 1.100); memória estimada de 83,1 KB.

Premissa: como na v0.52, a LEBRE não pretende ser o previsor mais preciso; pretende entregar bem sob orçamento mínimo e sem falhas graves. A v0.53 custa mais que a v0.52 em todas as séries e só ganha em parte dos domínios; esse é o principal limite desta versão (§11).

2. Ponto de partida: a v0.52 e dois modos de falha

A v0.52 (especificação, revisão 1) é um previsor online com um modelo vivo simples (memória do próprio alvo, regressão nas entradas e média dinâmica dos dois) e um plano de mudanças de estrutura testadas por e-process. Ela foi congelada sem promoção em 27/09/2026. O LEBRE Lab, banco de testes público, levantou falhas da v0.52 em domínios novos; a v0.53 trata duas delas, sem ampliar o espaço de hipóteses (as demais ficaram para a v0.54).

F8: perder para a referência trivial

Em séries quase imprevisíveis (retornos e níveis de câmbio), a parte adaptativa da v0.52 erra mais que prever zero ou repetir o último valor. Na própria reserva final, a referência foi melhor que a v0.52, com intervalo de confiança inteiro acima de 1, em 5 de 8 séries de retornos e 6 de 8 de níveis.

F6: abaixo da fronteira precisão × custo

Em 8 famílias do desenvolvimento um comparador linear completo (todas as entradas e defasagens estimadas juntas, de alguns milhares a dezenas de milhares de operações por passo) vence a v0.52 por mais de 5%. O que importa sob orçamento é se a v0.52 perde para algo *do mesmo custo*. O diagnóstico mediu 8 regressões de custos variados em cada família: a v0.52 está abaixo da fronteira (uma regressão de custo menor ou igual erra 5% menos) em 4 delas, todas com a mesma causa, a falta de estimação conjunta da dinâmica do alvo e do efeito das entradas.


Família	v0.52 ÷ completo	melhor com custo ≤ v0.52	custo v0.52 (FP)	situação
B03	2,076	1,574	731	abaixo
VB07	1,170	1,005	435	abaixo
XB07	1,141	1,010	417	abaixo
B07	1,067	1,004	431	abaixo
YB06	1,095	1,048	640	na fronteira
YB03	1,225	1,397	830	na fronteira
VC05	1,138	1,381	262	na fronteira
A05	1,077	1,777	385	na fronteira

Erro = MSE ÷ MSE do comparador linear online completo (média geométrica da família). B03: qualidade do ar; B07, VB07, XB07: maré meteorológica (três conjuntos independentes); VC05: inflação; YB03: qualidade do ar de Pequim; YB06: eólica; A05: sintético.

3. Visão geral da arquitetura

D1 — Arquitetura da v0.53: a v0.52 inalterada + M1 + M2

A v0.52 continua calculando sua previsão L ; a M1 a combina com um especialista de precisão; a M2 parte da referência trivial R



A v0.52 roda como antes e é a única dona das mudanças de estrutura; a v0.53 só muda como a previsão final é formada.

- **Nada da v0.52 muda.** Os quatro arquivos da base são cópias byte a byte de `lebre==0.1.0`; a estrutura que a v0.52 aceita dentro da v0.53 é a mesma de quando ela roda sozinha (verificado em todas as séries avaliadas).
- **M1** produz L' a partir de L e do especialista E . Onde E não ajuda, o peso dele vai a zero e $L' = L$.
- **M2** mistura R e L' por dois caminhos (D , conservador; M , que troca de R para L' uma vez) e combina os dois por um (A,B) -Prod, que garante não ficar muito atrás de D .
- Todo o custo novo é fixo por passo, dado o número de entradas; nada cresce com o tempo.

4. M1: especialista de precisão

O especialista

Variáveis: o próprio alvo nas defasagens 1 e 2 e, para cada uma das $m = \min(d, 5)$ entradas de maior correlação absoluta com o alvo, as médias padronizadas nas bandas de defasagem [0], [1], [2–3], [4–7] e [8–15]:

$$z_t = [1, \tilde{y}_{t-1}, \tilde{y}_{t-2}, \bar{x}_{i,b}(t)]_{i \leq m, b \leq 5}, \quad k = 3 + 5m, \quad E_t = w_t^\top z_t$$

Os pesos vêm de mínimos quadrados recursivos com esquecimento $\lambda = 0,999$ e $P_0 = 100 \cdot I$, atualizados a cada 8 alvos observados. A escolha das entradas usa médias exponenciais (só passado), é feita depois de 100 alvos e refeita a cada 5.000; se o conjunto muda, a regressão e a combinação recomeçam. A previsão é recortada em $L \pm 2 \cdot \max(\hat{\sigma}_L, \text{piso})$, $\hat{\sigma}_L$ o erro recente da v0.52, o que limita o estrago de uma regressão mal condicionada.

A combinação com a v0.52

AdaHedge (de Rooij et al., 2014) com dois especialistas, v0.52 e E, sobre o **erro quadrático sem recorte nem normalização**: os pesos seguem o erro quadrático acumulado, que é o que o MSE mede, e a taxa de aprendizado se ajusta sozinha à escala. Entrada em sombra: até 100 atualizações, $L' = L$.

$$L'_t = (1 - \omega_t) L_t + \omega_t E_t, \quad \omega_t = \frac{e^{-\eta_t S_{t-1}^E}}{e^{-\eta_t S_{t-1}^L} + e^{-\eta_t S_{t-1}^E}}, \quad S_{t-1}^\bullet = \sum_{\tau < t} (y_\tau - \bullet_\tau)^2$$

Por que não um (A,B)-Prod, como na M2: o Prod exige perdas em [0, 1]. Três formas de pôr o erro quadrático nesse intervalo foram medidas e falharam por razões diferentes (§8): recortar em 2σ deixa o Prod cego aos erros grandes; dividir pelo maior erro já visto o congela depois de um recorde; dividir pelo maior erro recente dá peso pequeno aos passos de erro grande, justamente onde o especialista ganha. Trocar a garantia constante do Prod pela do AdaHedge (arrependimento que, relativo ao MSE total, some com o tamanho da série) foi o que funcionou.

5. M2: ponto de partida na referência trivial

A referência R é declarada com os dados: zero para retornos financeiros, sazonal ingênuo quando há ciclo, persistência nos demais casos. Enquanto R não está definida (antes de um ciclo completo), a saída é L' .

- **D** — AdaHedge entre R e L' sobre o erro quadrático (só nos passos com R definida): confiança, sem trocas.
- **M** — troca num só sentido (switch distribution, van Erven et al., 2012): posterior sobre “sempre R ”, “sempre L' ” e “ R até um instante, L' depois”, com risco de troca $1/t$, sobre perdas gaussianas na escala recente; um caminho em escala logarítmica evita 0/0 quando toda a massa está de um lado.
- **Combinação** — (A,B)-Prod anytime (Sani et al., 2014) com $B = D$ (confiança) e $A = M$ (oportunista); perdas $(y - \cdot)^2/N(t)$, com $N(t) = \max(\text{perdas do passo}, 0,99 \cdot N(t-1))$.

$$\hat{y}_t = s_t M_t + (1 - s_t) D_t, \quad s_t = \frac{\eta_t w_t^A}{\eta_t w_t^A + w^B/2}, \quad \eta_t = \min\left(\frac{1}{2}, \sqrt{1/(1 + \sum_{\tau < t} \delta_\tau^2)}\right)$$

Garantias e o limite dos choques

Para as perdas normalizadas, o Prod garante arrependimento constante contra D e da ordem de $\sqrt{T \log \log T}$ contra M ; na escala original não há limite formal limpo, porque a normalização muda com o tempo. Há um limite que nenhum combinador online contorna: as garantias para perdas sem limite valem em unidades da maior perda de um passo, e em séries financeiras um único dia pode responder por boa parte de todo o erro (nas 521 séries medidas, 32 têm o maior passo acima de 5% do erro total da referência; o maior, baht_1990, 25,9%). Por isso a régua de avaliação trata essas séries como indecíveis (§7).


6. Custo computacional

Contagem pela regra da v0.52 (uma operação elementar = 1 FP), auditada: a implementação faz exatamente as contas declaradas (cada par da matriz da RLS simetrizado uma vez; só a linha nova das entradas padronizada), com as previsões idênticas às validadas em 813 de 813 séries; a auditoria elevou a contagem em 3,2% (mediana).

Parte	FP por passo (mediana, uma série por família, antes da auditoria)
v0.52	453
M2	137
M1: atualização da RLS	513
M1: resto	146
Total	1.257

RLS: $6k^2 + 5k$ por atualização (a cada 8 alvos); previsão do especialista: $2k + 18m + 4$; AdaHedge: 48; M2: ~132 a 137. No desenvolvimento e na validação 5 (813 séries), o acréscimo sobre a v0.52 teve mediana de 538 e máximo de 974 FP; a razão $v0.53 \div v0.52$, mediana de 2,32 e máximo de 3,93.

A meta preliminar da nota de desenho (custo $\leq 1,25$ vez o da v0.52) é incompatível com M1 + M2: com a v0.52 em ~450 FP, o acréscimo máximo seria ~110 FP, menos que a M2 sozinha. Antes da avaliação final, o responsável pelo projeto a substituiu por um teto de **acréscimo absoluto de 1.100 FP por passo** em cada série (o custo novo é quase fixo; uma razão pune as séries em que a v0.52 é barata), mais 2,5 vezes nas famílias do tipo F6.



7. Metodologia de avaliação

Disciplina

- Os dados da avaliação final foram reservados em 05/10/2026, antes de qualquer código da v0.53, com hashes e travas nos dois repositórios.
- Cada medição tem plano e critérios commitados antes; nada é ajustado depois; as falhas ficam declaradas.
- Cada conjunto de validação é escolhido só por metadados, congelado com SHA-256 e usado uma única vez.

Régua por decidibilidade

Cada série é classificada pelo IC 95% de $v0.52 \div R$ (bootstrap de blocos pareado, 2.000 réplicas): “v0.52 melhor”, “referência melhor” ou “indecidível”. Critérios: (1) nas “referência melhor”, $v0.53 \div R$ com limite superior $\leq 1,01$; (2) nas “v0.52 melhor”, $v0.53 \div v0.52$ com limite superior $\leq 1,02$; (4) nos testes negativos, nenhuma entrada falsa a mais que a v0.52; (6) a estrutura da v0.52 preservada; (7) nas séries curtas (360 passos), $\leq 1,05$ do melhor de v0.52 e R. Três adendos, decididos durante o desenvolvimento e antes da validação 5: uma série em que o maior passo isolado passa de $\max(5\%, 5 \cdot 2 \ln(n)/n)$ do erro de R fica indecidível nos critérios 1 e 2 (n = passos avaliados).


F6 e promoção

F6, nas famílias abaixo da fronteira: custo $\leq 2,5$ vezes o da v0.52 e erro $\leq 1,05$ vez o menor erro entre as 8 regressões do diagnóstico com custo $\leq$ o da v0.53. Promoção (pré-registro, decisões do responsável pelo projeto): (A) nenhuma piora por família, (B) $v0.53 \div v0.52$ em todas as séries com limite superior do IC 95% abaixo de 1 e (C) memória estimada ≤ 128 KB.

8. Desenvolvimento: desenhos e falhas

D2 — Como se chegou à v0.53: desenhos, falhas e o que cada uma ensinou

Cada caixa é um desenho medido com plano registrado antes; vermelho = reprovado, verde = aprovado e confirmado



Lição comum: o Prod exige perdas em $[0, 1]$; as três formas de pôr o erro quadrático nesse intervalo distorceram o que ele otimizava. A M1 passou a combinar direto no erro quadrático.

Os desenhos que importaram para a decisão; a lista completa (6 desenhos da M1, 14 configurações da M2) está no LEBRE Lab.

O banco de desenvolvimento cresceu até 64 famílias e 728 séries (desenvolvimento original e as validações 1 a 4, já gastas, mais as famílias curtas). Nele, a combinação final (M1 rascunho 5 + M2 Q2) atendeu a todos os critérios da M2 e a F6 nas quatro famílias abaixo da fronteira:

Familia	v0.52 ÷ completo	v0.53 ÷ completo	meta	custo ÷ v0.52
B03	2,076	1,365	1,652	2,01
B07	1,067	1,020	1,054	2,17
VB07	1,170	1,053	1,056	2,13
XB07	1,141	1,044	1,061	2,21

Achados de processo, todos registrados: um defeito numérico no componente M (0/0 por underflow) foi achado num teste, corrigido e auditado (nunca disparou em medição registrada; desde então uma previsão não finita conta como falha); um erro de construção nas validações 4 e 5 (ciclo de 30 h em vez de 24 h em solar, eólica e carga) restringiu o alcance da validação 5 (§9).

9. Validações em dados novos

As validações 1 e 2 serviram a desenhos anteriores da M2; a validação 3 confirmou a candidata P. A **validação 4** reprovou a M1 rascunho 2 com a P: critério 1 em YB07, YC01 e critério 2 em YB01. O diagnóstico separou as causas (a falha da solar era da M1; as do câmbio e da maré, da M2) e levou aos desenhos do §8.


A **validação 5** (43 séries novas, medição única) confirmou a M1 rascunho 5 com a M2 Q2: F6 atendida em qualidade do ar de Pequim (Chen, 2017) e em seis estações de maré novas, e todos os critérios da M2 em todas as famílias.

Família	v0.52 ÷ completo	v0.53 ÷ completo	meta	custo ÷ v0.52
Z-B03	1,169	1,118	1,410	1,97
Z-B07	1,017	0,925	1,068	2,20

Errata: nas validações 4 e 5, as famílias solar, eólica e carga foram montadas com ciclo de 30 h em vez de 24 h. As comparações entre v0.52 e v0.53 nessas famílias valem para a tarefa como montada, não para a análoga declarada; a evidência fresca da v0.53 com o ciclo certo nesses domínios é a avaliação final (§10).

10. Avaliação final pré-registrada

Execução única em 104 séries reservadas (30 bacias do CAMELS-BR, Chagas et al., 2020; 30 medidores do BDG2, Miller et al., 2020; 8 usinas solares, 8 eólicas, a carga de 2026 dos 4 subsistemas e 8 pares de câmbio em 3 tarefas). O pré-registro foi aprovado depois de um ensaio em 55 séries já gastas de bacias e prédios (0 erros).



Família	séries	v0.52 melhor / ref. / indec. / choque	v0.53 ÷ v0.52	crit. 1	crit. 2	+custo máx. (FP)
Bacias (CAMELS-BR)	30	15/2/7/6	0,879	0,845 [0,814; 0,878]	0,911 [0,899; 0,924]	495
Prédios (BDG2)	30	30/0/0/0	0,993	-	0,993 [0,988; 1,000]	385
Usinas solares (ONS)	8	8/0/0/0	1,000	-	1,000 [1,000; 1,000]	696
Usinas eólicas (ONS)	8	8/0/0/0	1,000	-	1,000 [1,000; 1,000]	918
Carga 2026 (ONS)	4	4/0/0/0	1,000	-	1,000 [1,000; 1,000]	831
Câmbio: retornos	8	0/5/1/2	0,966	1,000 [1,000; 1,000]	-	894
Câmbio: volatilidade	8	6/0/0/2	1,000	-	1,000 [1,000; 1,000]	894
Câmbio: níveis	8	0/6/0/2	0,952	1,001 [1,000; 1,002]	-	894

- Melhora geral: **0,955 [0,951; 0,960]**; séries curtas contra o melhor de v0.52 e R: 1,007 [0,995; 1,017].
- Nenhuma previsão não finita; entradas falsas nos retornos iguais às da v0.52; estrutura preservada em todas as séries; memória estimada de 85.092 B.
- Em solar, eólica e carga, a M1 terminou com peso zero em todas as 20 séries e a v0.53 ficou idêntica à v0.52.
- Duas correções durante a execução, sem efeito em modelo ou critério: a leitura da carga de 2026 pelo código do subsistema (o ONS renomeou o Sudeste) e o tratamento de uma série curta degenerada (empate exato com erro zero).

Tetos de referência (só reportados)

Modelos fora da classe de orçamento, só como referência: Chronos-2 com covariáveis (Ansari et al., 2025), modelo de fundação de ~10⁹ operações por previsão, nos 1.000 pontos do protocolo da v0.52; e SARIMAX com entradas.

Família	v0.53 ÷ Chronos-2 (1.000 pontos)	v0.52 ÷ Chronos-2	SARIMAX-X ÷ v0.53
Bacias (CAMELS-BR)	0,885	1,008	1,134
Prédios (BDG2)	1,248	1,241	1,034
Usinas solares (ONS)	1,237	1,237	1,096
Usinas eólicas (ONS)	1,051	1,051	1,049
Carga 2026 (ONS)	1,433	1,433	0,968
Câmbio: retornos	0,954	0,979	1,123*
Câmbio: volatilidade	0,983	0,983	1,058*
Câmbio: níveis	0,881	0,921	1,065*

* Câmbio: o SARIMAX com entradas não rodou na execução (entradas com feriados faltantes); valores do adendo com as entradas preenchidas pela regra da v0.52, feito depois do resultado.

11. Limites e afirmações que não fazemos

- **Custo sem ganho em parte dos domínios:** a v0.53 custa mais em todas as séries; em solar, eólica e carga é idêntica à v0.52.
- **F6 sem família na reserva final:** a evidência de F6 em dados novos é só a validação 5; uma família do desenvolvimento passou com margem pequena (VB07).
- **Régua decidida durante o desenvolvimento:** os adendos do choque foram decididos depois de ver dados de desenvolvimento, antes da validação 5 e da avaliação final.
- **Sem garantia formal na escala original:** o Prod garante em perdas normalizadas; o AdaHedge da M1 não dá arrependimento constante contra a v0.52.
- **Memória estimada, não medida;** sem porte para C nem medição em microcontrolador.
- **Incerteza:** o IC do conjunto trata as séries como independentes; a carga tem 4 séries.
- **Erratas** nas validações 4 e 5 e duas correções na execução final, todas declaradas.
- **Originalidade:** nenhum componente é novo; a contribuição é a integração sob orçamento declarado e a evidência pré-registrada.
- **Fora desta versão:** remoções que acontecem, custo proporcional ao uso e ciclo como hipótese (v0.54).

12. Posição na literatura

Cada peça tem antecedente direto: AdaHedge e FlipFlop (de Rooij et al., 2014); (A,B)-Prod e o arrependimento constante contra um especialista de confiança (Sani et al., 2014; Even-Dar et al., 2008; Koolen, 2013); switch distribution (van Erven et al., 2012) e Fixed Share (Adamskiy et al., 2016; Cesa-Bianchi et al., 2012); regressão recursiva com defasagens (Ljung, 1999). Os limites de garantia em perdas sem limite e caudas pesadas estão em Cesa-Bianchi et al. (2007), Hazan e Kale (2010), Orabona e Pál (2018), Mhammedi et al. (2019), V'yugin e Trunov (2019), Alquier (2021) e Moulin et al. (2025); sequências de confiança robustas a caudas pesadas, em Wang e Ramdas (2023), ficaram como direção para a M2. A contribuição desta versão é a **integração** desses componentes sob um orçamento declarado e a avaliação pré-registrada.

13. Parâmetros

Parte	Parâmetro	Valor	Observação
M1	entradas	$m = \min(d, 5)$	maior correlação absoluta (médias exponenciais, só passado)
M1	bandas	[0], [1], [2–3], [4–7], [8–15]	médias padronizadas
M1	RLS	$\lambda = 0,999; \delta = 100$	a cada 8 alvos observados
M1	seleção	após 100; a cada 5.000	recomeça regressão e combinação
M1	recorte	$L \pm 2 \cdot \max(\hat{\sigma}_L, \text{ piso})$	$\hat{\sigma}_L$: erro recente da v0.52
M1	combinação	AdaHedge	erro quadrático; sombra de 100 atualizações
M2	R	zero / sazonal / persistência	declarada com os dados
M2	D	AdaHedge	erro quadrático, só com R definida
M2	M	troca única, risco 1/t	perdas gaussianas na escala recente
M2	Prod	$\eta \leq 1/2; w_B = 1/2$	$\text{perdas} \div \max(\text{perdas}, 0,99 \cdot N)$
M2	porta	$\varepsilon = 0,002; \alpha = 0,01$	auditoria das decisões; recriada a cada decisão

Os parâmetros da base v0.52 são os da especificação v0.52, revisão 1, §20. Nada é ajustado por série.

14. Pseudocódigo e reprodutibilidade

```

CONSTANTES  M_MAX = 5    BANDS = [0], [1], [2-3], [4-7], [8-15]    λ_RLS = 0.999    δ_RLS = 100    EVERY = 8
               CLIP_K = 2    N_MIN = 100    T_MAX = 5000    LAM = 0.99    ε_gate = 0.002    α_gate = 0.01

PASSO(x_t, y_{t-1}):
  L ← v052.predict(x_t)                                # a base congelada, inalterada
  # M1: especialista de precisão
  z ← [1, ŷ_{t-1}, ŷ_{t-2}], médias padronizadas das BANDS das m = min(d, 5) entradas escolhidas]
  E ← clip(w·z, L ± CLIP_K·max(σ̂, piso))                # se RLS determinada (k atualizações)
  L' ← L se AdaHedge.n < N_MIN senão w_L·L + w_E·E      # sombra na entrada
  # M2: ponto de partida na referência trivial
  R ← 0 | y_last | y_{t-s}                             # zero, persistência ou sazonal ingênuo
  D ← w_D·[R, L']; M ← w_M·[R, L']; s ← η·w_A / (η·w_A + w_B/2)
  ŷ ← L' se R indefinida senão s·M + (1 - s)·D
  retorna ŷ

OBSERVAR(y_t):
  v052.observe(y_t); triagem a cada EVERY; RLS a cada EVERY alvos; nova seleção depois de N_MIN e a cada T_MAX
  AdaHedge.update((y_t - L)², (y_t - E)²)              # erro quadrático sem recorte
  AdaHedge_D.update((y_t - R)², (y_t - L')²)
  Switch_M.update((y_t - R)²/2σ², (y_t - L')²/2σ²)      # σ² recente; reserva em escala log contra 0/0
  N ← max((y_t - D)², (y_t - M)², LAM·N); Prod.update((y_t - D)²/N, (y_t - M)²/N)

```

- **Código promovido:** repositório de pesquisa (lebre-research), commit 4a2620e, pasta do protótipo da v0.53; configuração canônica no registro de congelamento da v0.53.
- **Integridade:** o manifesto SHA-256 da v0.53 cobre 177 arquivos; o verificador de integridade do repositório confere todas as versões congeladas.
- **Avaliação final:** pasta da avaliação final da v0.53 no repositório de pesquisa (pré-registro, scripts, notas da execução, resultados).
- **Desenvolvimento e validações:** LEBRE Lab, github.com/lquitim/lebre-lab (planos antes de cada medição, resultados, diagnósticos, erratas); este documento leu os resultados do Lab no commit 6f328bb.
- **Ambiente:** Python 3.11, numpy 2.2.5, pandas 2.2.3, statsmodels 0.15.0; Chronos-2 com o pacote chronos 2.3.2.
- **Determinismo:** sem números aleatórios no modelo; a mesma sequência de entradas dá a mesma saída.

15. Referências

1. Adamskiy, D., Koolen, W. M., Chernov, A., Vovk, V. (2016). A closer look at adaptive regret. *Journal of Machine Learning Research* 17(23), 1–21.
2. Alquier, P. (2021). Non-exponentially weighted aggregation: regret bounds for unbounded loss functions. *ICML*.
3. Ansari, A. F. et al. (2025). Chronos-2: from univariate to universal forecasting. *arXiv preprint*.
4. Cesa-Bianchi, N., Gaillard, P., Lugosi, G., Stoltz, G. (2012). Mirror descent meets fixed share (and feels no regret). *NeurIPS* 25.
5. Cesa-Bianchi, N., Mansour, Y., Stoltz, G. (2007). Improved second-order bounds for prediction with expert advice. *Machine Learning* 66, 321–352.
6. Chagas, V. B. P. et al. (2020). CAMELS-BR: hydrometeorological time series and landscape attributes for 897 catchments in Brazil. *Earth System Science Data* 12, 2075–2096.
7. Chen, S. (2017). Beijing Multi-Site Air Quality. *UCI Machine Learning Repository*, doi:10.24432/C5RK5G.
8. de Rooij, S., van Erven, T., Grünwald, P. D., Koolen, W. M. (2014). Follow the leader if you can, hedge if you must. *Journal of Machine Learning Research* 15, 1281–1316.
9. Even-Dar, E., Kearns, M., Mansour, Y., Wortman, J. (2008). Regret to the best vs. regret to the average. *Machine Learning* 72, 21–37.
10. Hazan, E., Kale, S. (2010). Extracting certainty from uncertainty: regret bounded by variation in costs. *Machine Learning* 80, 165–188.
11. Koolen, W. M. (2013). The Pareto regret frontier. *NeurIPS* 26.
12. Ljung, L. (1999). *System Identification: Theory for the User*, 2nd ed. Prentice Hall.
13. Mhammedi, Z., Koolen, W. M., van Erven, T. (2019). Lipschitz adaptivity with multiple learning rates in online learning. *COLT*.
14. Miller, C. et al. (2020). The Building Data Genome Project 2. *Scientific Data* 7, 368.
15. Moulin, A., Esposito, E., van der Hoeven, D. (2025). When lower-order terms dominate: adaptive expert algorithms for heavy-tailed losses. *arXiv:2506.01722*.
16. Orabona, F., Pál, D. (2018). Scale-free online learning. *Theoretical Computer Science* 716, 50–69.
17. Sani, A., Neu, G., Lazaric, A. (2014). Exploiting easy data in online optimization. *NeurIPS* 27.
18. van Erven, T., Grünwald, P., de Rooij, S. (2012). Catching up faster by switching sooner: a predictive approach to adaptive estimation with an application to the AIC–BIC dilemma. *Journal of the Royal Statistical Society B* 74(3), 361–417.

19. V'yugin, V., Trunov, V. (2019). Online aggregation of unbounded losses using shifting experts with confidence. *Machine Learning*; arXiv:1808.00741.
20. Wang, H., Ramdas, A. (2023). Catoni-style confidence sequences for heavy-tailed mean estimation. *Stochastic Processes and their Applications*.

16. Histórico de revisões

- **Revisão 0** (09/10/2026): primeira edição, depois da promoção.