

LEBRE v0.53 — Especificação e Relatório Técnico

Previsão online com mudanças de estrutura testadas estatisticamente, especialista de precisão e ponto de partida na referência trivial, sob orçamento computacional declarado

LEBRE: Lifecycle-governed Evidence-Based Resource Evolution

Arquitetura: núcleo estrutural (memória + especialista estrutural + média dinâmica, com mudanças testadas por e-process) + M1 (especialista de precisão) + M2 (referência trivial)

STATUS

versão de pesquisa promovida por regra pré-registrada (09/10/2026); escopo: previsão de um passo à frente com entradas

AVALIAÇÃO FINAL

104 séries reservadas; $LEBRE \div \text{núcleo sozinho} = 0,955$ [IC 95% 0,951; 0,960]; nenhuma piora por família

CUSTO

mediana de 919 operações por passo (M1 + M2: +476, teto de 1.100); memória estimada 83,1 KB

ESCOPO DA EVIDÊNCIA

ganho de M1 + M2 em bacias e câmbio; idêntica ao núcleo em solar, eólica e carga; núcleo avaliado na classe de orçamento em hidrologia e prédios

Sumário

1. Sumário executivo	\$1	14. Metodologia de avaliação	\$14
2. O problema, a premissa e o escopo	\$2	15. Evidência do núcleo estrutural	\$15
3. Princípios de projeto	\$3	16. O núcleo em microcontrolador simulado	\$16
4. Visão geral da arquitetura	\$4	17. Desenvolvimento de M1 e M2	\$17
5. Base teórica do núcleo estrutural	\$5	18. Validações em dados novos	\$18
6. Base teórica de M1 e M2: agregação de previsores	\$6	19. Avaliação final pré-registrada	\$19
7. Ciclo de vida de uma mudança de estrutura	\$7	20. Evolução da arquitetura e ablações	\$20
8. A condição de uso: desajuste da referência	\$8	21. Posição na literatura	\$21
9. M1: especialista de precisão	\$9	22. Limites e afirmações que não fazemos	\$22
10. M2: ponto de partida na referência trivial	\$10	23. Parâmetros	\$23
11. Salvaguardas de saída e intervalo	\$11	24. Pseudocódigo e condições de reprodutibilidade	\$24
12. Custo computacional e memória	\$12	25. Referências	\$25
13. Observabilidade e explicabilidade	\$13	26. Histórico de revisões	\$26

1. Sumário executivo

A **LEBRE** é um previsor **online** de séries temporais com entradas: a cada passo ela recebe as entradas e, quando disponível, o valor do alvo; prevê o próximo valor, aprende com o erro e segue, sem reproprocessar o passado e sem treino prévio. O custo por passo é fixo, dado o número de entradas, e é contado operação a operação: nas 104 séries da avaliação final, mediana de 919 e máximo de 1.637 operações de ponto flutuante por passo.

Ela tem três camadas (§4). O **núcleo estrutural** é um modelo vivo simples (uma memória do próprio alvo e uma regressão linear nas entradas) cuja estrutura só muda por experimento: um desafiante em sombra propõe acrescentar, remover, trocar ou refinar a resposta a uma entrada inteira, e a mudança só é aceita quando um *e-process* — um teste sequencial válido a qualquer momento — acumula evidência suficiente de melhora preditiva, dentro de um procedimento online de multiplicidade. A **M1** combina a previsão do núcleo com um especialista de precisão (uma regressão recursiva sobre o passado do alvo e médias de defasagem das entradas). A **M2** faz a previsão partir de uma referência trivial declarada (zero, persistência ou sazonal ingênuo) e só confiar na parte adaptativa quando ela se mostra melhor. Nenhuma dessas peças é nova isoladamente; o documento descreve a combinação, as condições em que ela funciona e o que foi medido.

Premissa: a LEBRE **não pretende ser o previsor mais preciso**. O objetivo é entregar previsões úteis, sem falhas graves, com custo por passo baixo e previsível, sem ajuste por série e com cada mudança de estrutura registrada e justificada. Modelos caros são tratados como **tetos de referência**, não como adversários.

O que foi medido

- **Avaliação final pré-registrada** (104 séries reservadas antes de qualquer código de M1 e M2; bacias, prédios, usinas solares e eólicas, carga elétrica e câmbio): o erro quadrático médio da LEBRE dividido pelo do núcleo sozinho foi **0,955** [IC 95% 0,951; 0,960], sem piora em nenhuma família; o ganho vem de Bacias (CAMELS-BR) 0,879, Câmbio: níveis 0,952, Câmbio: retornos 0,966, Prédios (BDG2) 0,993; em solar, eólica e carga, a LEBRE é idêntica ao núcleo (§19).
- **Tetos de referência** na mesma avaliação: contra o Chronos-2 com covariáveis (modelo de fundação de $\sim 10^9$ operações por previsão), razão de 0,88 a 1,43 por família — menor que 1 em bacias e câmbio, maior em prédios, solar, eólica e carga (§19).
- **O núcleo na sua classe de orçamento** (avaliação pré-registrada própria, 60 séries de bacias e prédios): erro relativo ao NLinear online de 0,812 [0,752; 0,866], o menor entre os oito comparadores de custo semelhante avaliados, sem nenhuma série com falha grave; empate com um SARIMAX com entradas e erro $\sim 25\%$ maior que o do Chronos-2 (§15).
- **Custo:** M1 e M2 acrescentam ao núcleo uma mediana de 476 operações por passo (máximo 918; teto pré-registrado de 1.100); memória estimada de 83,1 KB. O núcleo, portado para C, rodou num Cortex-M4F **simulado** com 3,2–6,0 mil instruções por passo em média; M1 e M2 não foram portados (§12, §16).

Limites principais: previsão de um passo; M1 e M2 custam em todas as séries e só ganham em parte dos domínios; o mecanismo de testes do núcleo **não melhorou a precisão** em relação a ligar todas as entradas sem testes (razão 0,988 [0,970; 1,006] em 100 séries, exploratório) — o seu papel é produzir estrutura registrada, cuja utilidade prática não foi demonstrada; entradas correlacionadas com a verdadeira podem ser aceitas como substitutas; não há garantia formal de erro na escala original para M1 e M2; o microcontrolador foi simulado e só para o núcleo. Nenhum componente é original (§21, §22).

2. O problema, a premissa e o escopo

O problema

Muitos sistemas medem continuamente um alvo (vazão de um rio, consumo de um prédio, geração de uma usina, carga elétrica, uma taxa de câmbio) junto com entradas que o influenciam, muitas vezes com atraso (chuva, temperatura, vazões a montante, outras moedas). Prever o próximo valor *no próprio dispositivo* exige três coisas ao mesmo tempo: custo por passo muito baixo, funcionamento sem ajuste por série e sem treino prévio, e um comportamento que não falhe de forma grave quando o fluxo tem lacunas, mudanças ou é quase imprevisível. Os modelos modernos mais precisos (modelos de fundação) custam de 10^7 a 10^{10} operações por previsão; os modelos clássicos ajustados série a série precisam de otimização por máxima verossimilhança; e os modelos lineares online baratos não sabem, sozinhos, quais entradas e atrasos importam, nem quando é melhor não arriscar nada além de uma previsão trivial.

A premissa

A LEBRE ocupa um ponto específico do compromisso entre precisão, custo e transparência. Ela é avaliada **dentro da sua classe de orçamento** (modelos com até $\sim 10^4$ operações por previsão), com os modelos caros como tetos. “Entregar bem” significa: erro competitivo na classe, **nenhuma falha catastrófica**, não perder para uma previsão trivial declarada, custo previsível e explicação de cada mudança.

Escopo

- previsão de **um passo à frente**, online, com as entradas do instante atual disponíveis (como em controle e em previsão de curtíssimo prazo);
- séries com **poucas entradas** e relação aproximadamente linear, com atrasos de até 31 passos no núcleo e até 15 no especialista de precisão;
- o ambiente informa apenas o período de amostragem (por exemplo, 24 para dados horários com ciclo diário; nos prédios, também 168 para o ciclo semanal) e a referência trivial adequada ao alvo (zero para variações como retornos financeiros, sazonal ingênuo quando há ciclo, persistência nos demais casos);
- entradas padronizadas de forma causal (média e variância exponenciais), como contrato de entrada.

O que a LEBRE não é

Não é um modelo de fundação nem um previsor de longo horizonte; não modela relações fortemente não lineares; não afirma causalidade física (uma entrada aceita é uma entrada com *relevância preditiva* certificada contra a referência, e entradas quase idênticas são reportadas como grupo). O nome vem da família original de arquiteturas do projeto (*Lifecycle-governed Evidence-Based Resource Evolution*): estrutura que entra e sai do modelo por evidência, dentro de um orçamento.


3. Princípios de projeto

Princípio	Significado
Toda mudança de estrutura é um experimento	A estrutura só muda quando um teste sequencial sempre válido rejeita “a mudança não melhora a previsão”; cada aceitação tem um nível de erro fixado antes.
Unidade = uma entrada inteira	A pergunta é “esta entrada ajuda?”, e não “este atraso ajuda?”: menos hipóteses, mais poder, resposta refinada depois por divisões hierárquicas.
Partir do trivial	A previsão final parte de uma referência trivial declarada e só passa a confiar na parte adaptativa quando ela se mostra melhor nos próprios dados.
Camadas que não mexem no núcleo	M1 e M2 só mudam como a previsão final é formada; as decisões de estrutura são as mesmas com ou sem elas (verificado em todas as séries avaliadas).
Custo fixo e declarado	Custo por passo fixo dado o número de entradas, contado operação a operação, com limites declarados antes de cada avaliação; o resultado é reportado mesmo quando o limite não é cumprido (§12).
Sem ajuste por série	As mesmas constantes em qualquer série; o ambiente informa só o(s) período(s) e a referência trivial.
Silêncio e dados fora do contrato não são evidência	Sem alvo observado, com entrada recortada ($ x > 8\sigma$) ou em quarentena, nada da estrutura aprende e nenhuma evidência é acumulada.
Saída dentro de contrato	A previsão do núcleo nunca sai de um envelope dos valores já observados, e lacunas do alvo não fecham a malha da memória.
Observabilidade	Cada mudança é registrada com instante, tipo, evidência e grupo de entradas equivalentes; os pesos de M1 e M2 são legíveis a cada passo; a previsão vem com intervalo adaptativo.

4. Visão geral da arquitetura

D1 — Arquitetura completa da LEBRE: núcleo estrutural + M1 + M2

O núcleo calcula a previsão L e é o único dono das mudanças de estrutura; M1 e M2 só mudam como a previsão final é formada




Visão completa de um passo de previsão. O núcleo roda inteiro por baixo; M1 forma L' a partir de L; M2 forma a saída a partir de L' e da referência R.

A LEBRE tem três camadas, executadas nesta ordem a cada passo:

- Núcleo estrutural (D2):** produz a previsão L e é o único dono das mudanças de estrutura. Tem dois especialistas e uma combinação no caminho da previsão, e um plano de mudanças em sombra.
- M1 — especialista de precisão (§9):** uma regressão recursiva E sobre o passado do alvo e médias de defasagem das entradas mais correlacionadas, combinada com L por AdaHedge no erro quadrático: $L' = (1 - \omega) \cdot L + \omega \cdot E$. Onde E não ajuda, ω vai a zero e $L' = L$.
- M2 — ponto de partida na referência trivial (§10):** mistura R e L' por dois caminhos — H, conservador (AdaHedge), e W, que troca de R para L' uma única vez (switch distribution) — e combina os dois por um (A,B)-Prod, que garante não ficar muito atrás de H.

D2 — Núcleo estrutural: previsão viva + experimentos em sombra

O caminho da previsão (em cima) é barato e sempre ativo; o plano de mudanças (embaixo) propõe, testa e decide mudanças de estrutura




Núcleo estrutural. Os dois especialistas e a combinação formam o caminho da previsão L. O plano de mudanças roda em sombra e só altera S quando uma mudança é aceita.

Memória (M). Prevê o alvo a partir do seu próprio passado, relativo ao último valor: reversão a uma média lenta, última diferença, termos sazonais do(s) ciclo(s) declarado(s) e um perfil de incrementos por fase do ciclo. **Especialista estrutural (S).** Regressão linear

no valor atual de cada entrada (a “base”) mais os *blocos de resposta* das unidades aceitas. **Combinação.** Média dinâmica de modelos entre M e S, com peso que acompanha qual dos dois vem errando menos. **Plano de mudanças.** Uma triagem barata aponta a candidata mais promissora; até dois experimentos rodam em sombra; um e-process acumula a evidência de cada mudança; um procedimento de níveis online decide.

D3 — O que acontece em um passo de tempo

Ordem estritamente causal: tudo o que decide a previsão em t usa apenas dados até $t-1$



Lacuna do alvo: nada aprende; a memória recebe o último valor observado (retenção), nunca a própria previsão.

Ordem das operações num passo. A previsão em t é emitida antes de $y(t)$ ser lido; M1 e M2 aprendem depois do núcleo, com o mesmo $y(t)$.

5. Base teórica do núcleo estrutural

Esta seção reúne a base teórica do núcleo. **Todas as ferramentas vêm da literatura** (citada em cada item); o que é específico da LEBRE é a forma de combiná-las e as condições de uso verificadas (§8).

5.1 Aprendizado linear online: NLMS e mínimos quadrados recursivos

O modelo vivo (base de S, pesos dos blocos e memória) aprende por **NLMS** (mínimos quadrados médios normalizados; Widrow & Stearns 1985; Haykin 2002):

$$w_{t+1} = w_t + \mu \frac{e_t}{\|\phi_t\|^2 + \delta} \phi_t, \quad e_t = y_t - w_t^\top \phi_t.$$

Em regime estacionário, o **desajuste** (excesso relativo de erro quadrático por causa da oscilação dos pesos) é aproximadamente $M \approx \mu / (2 - \mu)$. O núcleo usa $\mu = 0,05$ em S e na memória.

Os **desafiantes** usam mínimos quadrados recursivos (RLS) sem esquecimento dentro de cada episódio, com $P_0 = 10 I$: com poucos parâmetros (5 a 7), o RLS converge em dezenas de amostras e dá um coeficiente praticamente constante no episódio, o que importa para a condição de uso (§8). O especialista de precisão da M1 também usa RLS, com esquecimento (§9).

5.2 Memória: suavização exponencial em forma de regressão

A memória é uma regressão do incremento sobre atributos do próprio passado, inspirada no modelo *airline* (Box & Jenkins 1970) e no estado sazonal do Holt-Winters (Hyndman et al. 2008) — analogia, não equivalência:

$$\hat{y}_t^M = y_{t-1} + w_1(m_t - y_{t-1}) + w_2(y_{t-1} - y_{t-2}) + w_3(y_{t-s} - y_{t-1}) + w_4(y_{t-s+1} - y_{t-s}) + w_5 G_{t \bmod s} + [w_6(y_{t-s_2} - y_{t-1}) + w_7(y_{t-s_2+1} - y_{t-s_2})]$$

m: média exponencial lenta (taxa 0,01); G: média exponencial (taxa 0,1) dos incrementos observados na mesma fase do ciclo; s_2 : segundo ciclo declarado (semana, nos prédios). A normalização do NLMS tem pisos relativos à escala (10^{-3} da potência média dos atributos e 10^{-4} da escala lenta de y), para que trechos planos não produzam passos enormes.

5.3 Combinação no núcleo: média dinâmica de modelos

O peso de S segue a diferença descontada de perdas entre os dois especialistas (Raftery, Kárný & Ettler 2010; forma logística equivalente a pesos exponenciais de especialistas):


$$D_t = 0,99 D_{t-1} + \frac{(y_t - \hat{y}_t^S)^2 - (y_t - \hat{y}_t^M)^2}{\hat{\sigma}^2}, \quad w_S = \frac{1}{1 + e^{0,5 D_t}}, \quad L_t = \hat{y}_t^M + w_S(\hat{y}_t^S - \hat{y}_t^M).$$

5.4 Representação da resposta: faixas de oitava, atraso de pico e divisões de Haar

A resposta de uma entrada é aproximada por médias do seu passado em faixas diádicas [1], [2–3], [4–7], [8–15], [16–31] — uma resolução que diminui com o atraso, como nas decomposições em multirresolução (Mallat 1989) e nos modelos de defasagem distribuída. Uma média de faixa dilui um atraso isolado (retém $\sim 1/\text{largura do efeito}$); por isso o desafiante carrega também o seu **atraso de pico** k^* , escolhido por ele mesmo pela maior correlação pré-branqueada nas primeiras 200 amostras do aquecimento — antes de qualquer evidência, o que mantém o desafiante previsível. Depois da aceitação, cada faixa pode ser **dividida** nas duas metades (um coeficiente de Haar); cada divisão é uma nova hipótese, testada só se o “pai” foi aceito, no espírito do teste hierárquico (Meinshausen 2008; Yekutieli 2008).

D4 — Unidade de mudança: uma entrada inteira, refinada por divisões

O desafiante de uma entrada usa médias do passado em faixas de oitava; divisões hierárquicas (tipo Haar) refinam a resposta depois da aceitação



Desafiante da unidade: $\hat{y}_G = \hat{y}_S + \sum_b \theta_b \cdot \text{média}(x_i, \text{faixa } b) + \theta_k \cdot x_i(t-k^*) + \theta_0 \cdot x_i(t)$

Representação da resposta a uma entrada: médias em faixas de oitava, o valor atual e um atraso de pico; depois da aceitação, cada faixa pode ser dividida em metades, uma hipótese por divisão.

5.5 Triagem: pré-branqueamento e estatística de grupo

Para escolher a próxima candidata sem testar todas, cada entrada inativa tem uma estatística de grupo: correlações exponenciais (peso 0,02) entre o resíduo de S e as médias de faixa, ambos **pré-branqueados** por um AR(1) causal da entrada (Box & Jenkins 1970), somadas em quadrado e normalizadas pela variância nula. A unidade é aberta se a estatística passa do quantil 99% de χ^2_5 (15,09); uma divisão, do quantil 99% de χ^2_1 (6,63), sobre o detalhe de Haar. A triagem **não gera evidência**: ela só escolhe o que testar, e o controle de erro vem inteiro do e-process.

5.6 Evidência sempre válida: e-processes de melhora preditiva

Um **e-process** é um processo não negativo cuja esperança, sob a hipótese nula, não passa de 1 em nenhum tempo de parada; por Ville, a probabilidade de ele alguma vez ultrapassar $1/\alpha$ é $\leq \alpha$. Isso permite olhar a evidência a cada passo, pausar e retomar sem inflar o erro (Ramdas, Grünwald, Vovk & Shafer 2023; Grünwald, de Heide & Koolen 2024). O núcleo usa a comparação sequencial de previsores de Choe & Ramdas (2024), com a nula *fraca*: em média, o desafiante não melhora a perda da referência em mais que uma margem ϵ .

Perda recortada e diferencial, com a escala $B_t = 2 \max(\hat{\sigma}_t^S, 0, 1 s_t^{lenta})$:

$$\ell_t(u) = \min\{(y_t - u)^2 / B_t^2, 1\}, \quad d_t = \ell_t(\hat{y}_t^S) - \ell_t(g_t) - \varepsilon.$$

E-process de mistura sub-exponencial, com centragem previsível $\gamma_i = \min(\bar{d}_{i-1}, 0)$ e 8 valores de λ :

$$E_n = \frac{1}{8} \sum_{j=0}^7 \exp \left\{ \lambda_j \sum_{i \leq n} d_i - \psi_{E,c}(\lambda_j) \sum_{i \leq n} (d_i - \gamma_i)^2 \right\}, \quad \psi_{E,c}(\lambda) = \frac{-\log(1 - c\lambda) - c\lambda}{c^2}, \quad \lambda_j = \frac{0,9 \cdot 2^{-j}}{c}.$$

A constante c unilateral. O enunciado de Choe & Ramdas supõe $|d_i - \gamma_i| \leq c$, o que daria $c = 2(1+|\varepsilon|)$. A demonstração de base (Howard et al. 2021, §A.8) usa apenas o lema de Fan, Grama & Liu (2015): $\exp(\lambda\xi - \psi_E(\lambda)\xi^2) \leq 1 + \lambda\xi$ para $\xi \geq -1$ e $\lambda \in [0,1)$. Para o teste unilateral, sob a nula fraca $E[d_i | \text{passado}] = \mu_i \leq 0$, basta a cota **inferior** $d_i - \gamma_i \geq -c$:

$$\mathbb{E}_{i-1} \left[e^{\lambda(d_i - \gamma_i) - \psi_{E,c}(\lambda)(d_i - \gamma_i)^2} \right] e^{\lambda(\gamma_i - \mu_i)} \leq (1 + \lambda(\mu_i - \gamma_i)) e^{\lambda(\gamma_i - \mu_i)} \leq 1.$$

Como $\lambda \Sigma d_i \leq \lambda \Sigma (d_i - \mu_i)$, o processo é limitado por uma supermartingala não negativa. Como $d_i \geq -(1+\varepsilon)$ e $\gamma_i \leq 0$, vale $c = 1 + \max(\varepsilon, 0)$. A mistura de e-processes é um e-process, e as pausas entre episódios formam uma subsequência previsível.

Esta observação é uma leitura direta da demonstração publicada, não um resultado novo. Numa simulação de desenvolvimento (400 trajetórias $\times$ 5.000 passos, nula no limite) o erro tipo I ficou $\leq 0,025$ contra $\alpha = 0,05$, e o poder subiu de 0,66 (c de dois lados) para 0,77 (§15). A alternativa por apostas com λ previsível (Waudby-Smith & Ramdas 2024) teve mais poder, mas aceitou substitutas quase idênticas da entrada verdadeira e não foi adotada.

5.7 Multiplicidade ao longo do fluxo: níveis tipo e-LOND

Cada hipótese de mudança recebe, ao ser criada, um nível fixo que depende apenas do número de hipóteses já criadas e de mudanças já aceitas (regra LOND de Javanmard & Montanari 2018, na versão para e-valores de Xu & Ramdas 2024). Isso controla a taxa de mudanças falsas (FDR) ao longo de um fluxo sem fim, com decisões assíncronas:

$$\alpha_n = \min(\alpha \gamma_n (R_n + 1), 0,5), \quad \gamma_n = \begin{cases} 1/(2P) & n \leq P \\ \frac{1}{2} C / ((n - P) \log^2(n - P + 1)) & n > P \end{cases}, \quad \text{aceita se } \log E \geq \log(1/\alpha_n),$$

com $\alpha = 0,05$, $P = 2 \times$ (número de unidades) e C tal que $\Sigma \gamma_n \leq 1$. Uma hipótese é *persistente*: a sua evidência se acumula entre episódios.

5.8 Intervalo adaptativo

O intervalo de 90% é um quantil do erro absoluto atualizado por retroalimentação da cobertura, no espírito da inferência conforme adaptativa (Gibbs & Candès 2021): a cada 8 passos, $\hat{q} \leftarrow \max(0, \hat{q} + 0,1 \cdot \sigma \cdot \Sigma(\text{erro fora} - 0,1))$. A mesma regra é aplicada ao erro da saída final (§11). Não há garantia formal de cobertura sob dependência; a cobertura empírica é reportada.

6. Base teórica de M1 e M2: agregação de previsores

M1 e M2 são problemas de **previsão com especialistas**: a cada passo há duas previsões disponíveis e é preciso decidir quanto peso dar a cada uma, só com o passado. Três algoritmos da literatura são usados, sem modificação dos seus núcleos; as escolhas da LEBRE são quais perdas eles recebem e como são encadeados.

6.1 AdaHedge

Pesos exponenciais nas perdas acumuladas com taxa de aprendizado ajustada pelos próprios dados (de Rooij et al. 2014): ela é o logaritmo do número de especialistas dividido pela soma acumulada das *lacunas de mistura* (quanto a perda da mistura excedeu a perda “de mistura” ideal). O arrependimento contra o melhor especialista cresce como a raiz da variação das perdas, e o algoritmo é **invariante a translação e escala** das perdas: não precisa saber a escala do erro, o que permite usar o erro quadrático sem recorte nem normalização.

$$w_{k,t} = \frac{e^{-\eta_t S_{k,t-1}}}{\sum_j e^{-\eta_t S_{j,t-1}}}, \quad \eta_t = \frac{\ln K}{\Delta_{t-1}}, \quad \Delta_t = \Delta_{t-1} + \left(\sum_k w_{k,t} \ell_{k,t} + \frac{1}{\eta_t} \ln \sum_k w_{k,t} e^{-\eta_t \ell_{k,t}} \right),$$

com S_k a perda acumulada do especialista k e $K = 2$. Quando $\Delta = 0$, os pesos seguem o líder.

6.2 Switch distribution com uma troca

A *switch distribution* (van Erven, Grünwald & de Rooij 2012) é uma mistura bayesiana sobre sequências de especialistas que permite trocar de especialista ao longo do tempo. A LEBRE usa a versão mais simples: três hipóteses — “sempre R”, “sempre L” e “R até algum instante, L’ depois” —, com prioris iguais e risco de troca $1/(n+1)$ no instante n . A posterior é atualizada pelas verossimilhanças gaussianas das duas previsões, com variância comum igual ao menor erro quadrático recente das duas (com piso). Ela concentra peso rapidamente na referência quando a parte adaptativa não ajuda, e troca uma vez quando a parte adaptativa passa a ser claramente melhor. Quando toda a massa está de um lado, a atualização direta pode dar 0/0 por *underflow*; nesse caso a mesma conta é feita em escala logarítmica.

6.3 (A,B)-Prod: não ficar muito atrás de um especialista de confiança

O (A,B)-Prod (Sani, Neu & Lazaric 2014) combina um algoritmo *oportunist* A com um algoritmo de *confiança* B. O peso de B é fixo em $1/2$ e o de A é atualizado multiplicativamente pela diferença de perdas; a fração dada a A é s_t . Para perdas em $[0, 1]$, ele garante arrependimento **constante** contra B e da ordem de $\sqrt{T \log \log T}$ contra A, na versão sem horizonte conhecido. Esse tipo de garantia assimétrica — quase nada a perder contra a escolha segura — vem da fronteira de Pareto do arrependimento (Even-Dar et al. 2008; Koolen 2013).

$$s_t = \frac{\eta_t w_t^A}{\eta_t w_t^A + w^B/2}, \quad w_{t+1}^A = w_t^A (1 + \eta_t \delta_t)^{\eta_{t+1}/\eta_t}, \quad \delta_t = \ell_t^B - \ell_t^A, \quad \eta_t = \min \left(\frac{1}{2}, \sqrt{1/(1 + \sum_{\tau < t} \delta_\tau^2)} \right).$$


6.4 O limite das perdas sem limite

O erro quadrático não tem limite superior. As garantias conhecidas para perdas sem limite e de cauda pesada (Cesa-Bianchi, Mansour & Stoltz 2007; Hazan & Kale 2010; Orabona & Pál 2018; Mhammedi, Koolen & van Erven 2019; V'yugin & Trunov 2019; Alquier 2021; Moulin, Esposito & van der Hoeven 2025) valem em unidades da **maior perda de um passo**. Quando um único passo responde por boa parte de todo o erro de uma série — como num choque de câmbio —, nenhum combinador online consegue garantir que acompanha o melhor especialista com folga pequena em relação ao erro total. Esse limite é uma propriedade dos dados, não do algoritmo, e é tratado explicitamente na avaliação (§10, §14).

7. Ciclo de vida de uma mudança de estrutura

D5 — Ciclo de vida de uma hipótese de mudança


Hipóteses persistentes: a evidência de uma mudança se acumula entre episódios; cada decisão usa um nível fixado na criação




Tipos: acrescentar (ε = 0,002) · remover (ε = -0,002) · trocar (com 4 unidades ativas) · dividir (ε = 0,002)

Estados de uma hipótese de mudança. A evidência só é acumulada fora do aquecimento, com alvo observado e fora de quarentena.

- **Unidades:** cada entrada (inclui o próprio passado do alvo, padronizado causalmente) e o estado latente do resíduo (dois filtros do erro padronizado, polos 0,8 e 0,95). Até 4 unidades ativas.
- **Desafiante de uma entrada:** RLS sobre [médias das 5 faixas, atraso de pico, valor atual $x_i(t)$] — o bloco é julgado líquido do que $x_i(t)$ já carrega. O alvo do RLS é o resíduo que a mudança explicaria.
- **Episódio:** aquecimento de 250 amostras sem evidência; encerra ao aceitar, pela regra de varredura (soma do episódio ≤ 0 após 100 amostras) ou em 5.000 amostras; a mesma hipótese espera 2.000 passos para voltar. Só um desafiante em aquecimento por vez (controle de pico de custo).
- **Decisões** a cada 10 passos: aceitar, encerrar, abrir. Prioridade: teste de remoção periódico das unidades ativas; depois a melhor candidata da triagem (unidade ou divisão). Com 4 unidades ativas, a candidata entra por *troca* com a de menor contribuição.
- **Julgamento na previsão de S**, não na combinação nem na saída final: a pergunta é se a mudança melhora o especialista estrutural. M1 e M2 não participam das decisões de estrutura.



Exemplo real (série de desenvolvimento: vazão de uma usina hidrelétrica; entrada x_0 = vazão defluente da usina a montante; x_1 = próprio passado do alvo). Log-evidência dos experimentos (linhas cheias) contra os seus limiares $\log(1/\alpha_k)$ (pontilhadas). A entrada x_0 é aceita em $t \approx 3.090$ e o estado latente do resíduo em $t \approx 4.230$; depois disso, remoções e divisões são testadas e encerradas sem evidência.



Processo sintético declarado ($y = 0,8 \cdot x_0(t-12) + 0,3 \cdot \text{média}(x_1, t-4 \dots t-7) + \text{ruído}$; x_2 irrelevante). Resposta recuperada pelo núcleo (pontos) contra a verdadeira (barras): o atraso 12 de x_0 é recuperado com peso 0,81; o efeito distribuído de x_1 aparece na faixa [4–7]; x_2 não é aceita.

8. A condição de uso: desajuste da referência

Um teste de melhora preditiva compara **métodos** (modelo + procedimento de estimação), não modelos — uma distinção conhecida em econometria (Giacomini & White 2006). Durante o desenvolvimento, isso apareceu de forma concreta: com a base de S

aprendendo por NLMS com passo 0,1, alvos **sem nenhuma estrutura** tiveram uma mudança aceita em ~20% das execuções. A causa é que o erro de estimação da referência é previsível pelo passado, e um desafiante pode “corrigi-lo”.

Seja $f_t^* = \mathbb{E}[y_t | \mathcal{F}_{t-1}]$, $\eta_t = f_t^* - S_t$ (erro de estimação da referência, previsível) e o desafiante $G_t = S_t + g_t$. Para a diferença de perda quadrática normalizada $\Delta_t = [(y_t - S_t)^2 - (y_t - G_t)^2]/B_t^2$:

$$\textbf{Proposição 1} \quad \mathbb{E}[\Delta_t | \mathcal{F}_{t-1}] = \frac{2g_t\eta_t - g_t^2}{B_t^2} \leq \frac{\eta_t^2}{B_t^2}, \quad \text{com igualdade em } g_t = \eta_t.$$


Demonstração: $y - S = \varepsilon + \eta$ e $y - G = \varepsilon + \eta - g$; expandindo, a diferença é $2g(\varepsilon + \eta) - g^2$, e $\mathbb{E}[\varepsilon | \text{passado}] = 0$. ■

$$\textbf{Corolário (garantia exata)} \quad \frac{1}{n} \sum_{i=1}^n \frac{\eta_i^2}{B_i^2} \leq \varepsilon \quad \forall n \Rightarrow \text{sob a nula estrutural, a nula do teste vale.}$$

Para NLMS com desajuste M , isso exige $M \lesssim 4\varepsilon$ (com $\varepsilon = 0,002$: $\mu \lesssim 0,016$).

$$\textbf{Proposição 2 (coeficiente fixo)} \quad \text{melhora média na janela} \leq D_u + \varepsilon, \quad D_u = \frac{1}{|W|} \sum_{i \in W} (P_u \eta_i)^2 / B_i^2 - \varepsilon,$$

em que P_u é a projeção de η nos atributos da unidade. **Proposição 3 (critério prático, aproximação):** a log-evidência cresce como $n \cdot D^2 / (2\sigma_d^2)$; numa série de comprimento T , aceitações falsas são improváveis se $D_u < \sigma_d \sqrt{2 \log(1/\alpha_k) / T}$.



Verificação em desenvolvimento (120 execuções com alvos sem estrutura, entradas reais). Esquerda: log-evidência do melhor desafiante possível (oráculo de projeção) contra o limiar; aceitações reais em vermelho. Com $\mu = 0,1$ o oráculo cruza o limiar (mediana 18,2) e houve 10/40 aceitações; com $\mu = 0,05$ (máx. 5,2) e $\mu = 0,03$, nenhuma. Nas execuções que aceitaram, o oráculo foi medido depois da aceitação e pode ficar baixo (pontos no piso). Direita: desajuste medido e teórico.

Leitura honesta: o núcleo usa $\mu = 0,05$, que está no **regime prático** da Proposição 3 (o desvio da nula existe, ~0,0013, mas é menor que o detectável no comprimento das séries, ~0,0019), e **não** no regime da garantia exata ($\mu \lesssim 0,016$). Por isso o controle de mudanças falsas é verificado empiricamente com lotes nulos (0/40 e 0/30 aceitações no desenvolvimento), e não apenas afirmado pela teoria. A observação relaciona-se com Giacomini & White (2006) e, em outro mecanismo, com Han & Qu (2026); não a encontramos formulada explicitamente para esta situação, mas é uma consequência simples de resultados conhecidos.

9. M1: especialista de precisão

Motivação. O núcleo estima a dinâmica do alvo (memória) e o efeito das entradas (estrutura) separadamente, com aprendizado barato. Em algumas famílias isso o deixa **abaixo da fronteira precisão × custo**: uma regressão de custo igual ou menor, que estima as duas coisas juntas, erra 5% menos (§17). A M1 acrescenta essa estimação conjunta como um segundo especialista, sem tocar no núcleo.

O especialista E

Variáveis: o próprio alvo nas defasagens 1 e 2 e, para cada uma das $m = \min(d, 5)$ entradas de maior correlação absoluta com o alvo (d = número de entradas), as médias nas bandas de defasagem $[0]$, $[1]$, $[2-3]$, $[4-7]$ e $[8-15]$:

$$z_t = [1, \tilde{y}_{t-1}, \tilde{y}_{t-2}, \tilde{x}_{i,b}(t)]_{i \leq m, b \leq 5}, \quad k = 3 + 5m, \quad E_t = \text{clip}(w_t^\top z_t, L_t \pm 2 \max(\hat{\sigma}_L, \text{piso}))$$

- **Seleção das entradas:** médias exponenciais (taxa 0,01, só passado) de x , x^2 , $x \cdot y$, y e y^2 , atualizadas a cada 8 alvos aprendidos; a seleção é feita depois de 100 alvos e refeita a cada 5.000. As médias e desvios do momento da seleção padronizam as entradas escolhidas e o alvo. Se o conjunto muda, a regressão e a combinação recomeçam.
- **Entradas ausentes** são trocadas pelo último valor visto (0 antes do primeiro).
- **Pesos:** mínimos quadrados recursivos com esquecimento $\lambda = 0,999$ e $P_0 = 100 \cdot I$, atualizados a cada 8 alvos aprendidos (fora de quarentena e com entradas dentro do contrato); a matriz é simetrizada a cada atualização e reiniciada se perder a definição positiva. E só existe depois de k atualizações (regressão determinada).
- **Recorte:** E fica em $L \pm 2 \cdot \max(\hat{\sigma}_L, \text{piso})$, com $\hat{\sigma}_L$ o erro quadrático médio recente do núcleo (média exponencial, taxa 0,01) e o piso de 0,1 vez a escala lenta do alvo; isso limita o estrago de uma regressão mal condicionada.

A combinação com o núcleo

AdaHedge (§6.1) com dois especialistas, L e E, sobre o **erro quadrático sem recorte nem normalização**: os pesos seguem o erro quadrático acumulado, que é o que o erro quadrático médio mede, e a taxa de aprendizado se ajusta sozinha à escala. A combinação observa todo alvo observado em que E existe. **Entrada em sombra:** até 100 atualizações, $L' = L$.

$$L'_t = (1 - \omega_t) L_t + \omega_t E_t, \quad \omega_t = \frac{e^{-\eta_t S_{t-1}^E}}{e^{-\eta_t S_{t-1}^L} + e^{-\eta_t S_{t-1}^E}}, \quad S_{t-1}^\bullet = \sum_{\tau < t} (y_\tau - \bullet_\tau)^2$$

Por que AdaHedge e não um (A,B)-Prod: o Prod exige perdas em $[0, 1]$. Três formas de pôr o erro quadrático nesse intervalo foram medidas e falharam por razões diferentes (§17): recortar em 2σ deixa o Prod cego aos erros grandes; dividir pelo maior erro já visto o congela depois de um recorde; dividir pelo maior erro recente dá peso pequeno aos passos de erro grande, justamente onde o especialista ganha. Trocar a garantia constante do Prod pela do AdaHedge (arrependimento que, relativo ao erro total, some com o tamanho da série) foi o que funcionou.

10. M2: ponto de partida na referência trivial

Motivação. Em séries quase imprevisíveis (por exemplo, retornos e níveis de câmbio), uma parte adaptativa pode errar mais que prever zero ou repetir o último valor: ela aprende ruído. A M2 faz a saída partir de uma **referência trivial R** declarada com os dados — zero para variações como retornos financeiros, sazonal ingênuo (o valor de um ciclo atrás) quando há ciclo, persistência (o último valor) nos demais casos — e só passar a confiar em L' quando ele se mostra melhor. Enquanto R não está definida (antes de um ciclo completo, no caso sazonal), a saída é L' .

- **H** — AdaHedge entre R e L' sobre o erro quadrático (§6.1): confiança, sem trocas.
- **W** — troca num só sentido, de R para L' (§6.2), sobre perdas gaussianas $(y - \cdot)^2 / 2s^2$, com $s^2 = \max(\min(\sigma_R^2, \sigma_{L'}^2), \text{piso}^2)$ e σ^2 médias exponenciais (taxa 0,01) dos erros quadráticos de cada lado, só do passado.
- **Combinação** — (A,B)-Prod sem horizonte (§6.3) com $B = H$ (confiança) e $A = W$ (oportunista); as perdas são $(y - \cdot)^2 / N_t$, com $N_t = \max(\text{perdas do passo}, 0,99 \cdot N_{t-1})$ — o maior erro recente, com esquecimento, para pôr as perdas em $[0, 1]$ sem congelar depois de um recorde.
- H, W e o Prod só aprendem nos passos com alvo observado, fora de quarentena do alvo e com R definida.

$$\hat{y}_t = s_t W_t + (1 - s_t) H_t, \quad H_t = w_{R,t}^H R_t + w_{L',t}^H L'_t, \quad W_t = w_{R,t}^W R_t + w_{L',t}^W L'_t$$

Auditoria da porta. Em paralelo, um e-process (§5.6) com orçamento próprio $\alpha = 0,01$ e margem $\varepsilon = 0,002$ testa se a parte adaptativa melhora a referência vigente (e, depois de uma troca, o contrário); cada aceitação é registrada como evento e a hipótese é

recriada. Esse teste **não decide a saída**: ele só documenta quando a evidência mudou de lado, com o mesmo tipo de garantia das mudanças de estrutura.


Garantias e o limite dos choques

Para as perdas normalizadas, o Prod garante arrependimento constante contra H e da ordem de $\sqrt{T \log \log T}$ contra W ; na escala original não há limite formal limpo, porque a normalização muda com o tempo. O limite da §6.4 aparece nos dados: em séries financeiras um único dia pode responder por boa parte de todo o erro (nas 521 séries de desenvolvimento medidas, 32 têm o maior passo acima de 5% do erro total da referência; o maior, baht_1990, 25,9%). Por isso a régua de avaliação trata essas séries como indecíveis (§14).

11. Salvaguardas de saída e intervalo

Duas salvaguardas atuam no caminho da saída do núcleo e custam ~ 15 operações por passo. Ambas são práticas padrão de engenharia; entram aqui porque a sua ausência produziu a falha mais grave observada (§15).

- **Retenção durante lacunas do alvo**: a memória recebe o último valor observado, nunca a própria previsão. Sem isso, a memória fica em malha aberta e, com certos pesos aprendidos, a recursão é instável (raiz característica $\sim 1,75$ num caso real).
- **Contrato de saída**: a previsão do núcleo é limitada ao envelope dos alvos observados (máximo e mínimo correntes que relaxam para a média lenta à taxa 10^{-3}), alargado em $0,5\times$ a sua largura; uma previsão não finita vira o último valor observado.
- **M1 e M2 herdam a contenção**: E fica a no máximo $2 \cdot \max(\sigma_L, \text{piso})$ de L ; R é um valor já observado (ou zero); toda saída de M1 e M2 é média ponderada de previsões contidas. Uma perda não finita nunca entra nos pesos.



Intervalo da saída

A saída final $\hat{y}$ vem com um intervalo de 90% calculado pela regra da §5.8 aplicada ao erro de $\hat{y}$ (início em 1,645 vezes o erro quadrático médio recente). A cobertura do intervalo do núcleo foi medida nas avaliações próprias do núcleo (§13); a cobertura do intervalo da saída completa **não foi reportada** na avaliação final.

12. Custo computacional e memória

O custo é contado operação a operação no código (somas, produtos, divisões, raízes, exponenciais e logaritmos contam 1 FP), por componente. O custo por passo é **quase fixo**: memória, base, triagem, M1 e M2 rodam sempre; os experimentos do núcleo acrescentam custo apenas quando há vaga ocupada, e os picos ocorrem nos passos de decisão. Nada cresce com o tempo.

Núcleo


O núcleo foi desenhado com um contrato de média ≤ 400 e máximo ≤ 1.000 FP por passo nas séries reais. Na sua avaliação pré-registrada própria (60 séries), a média foi 415 e o máximo 1.020: o contrato **não foi cumprido** por 3,7% na média e 2,0% no pico, e não foi revisado depois do resultado. Na avaliação final da LEBRE, o núcleo custou mediana de 461 FP por passo.

M1 + M2

A contagem de M1 e M2 foi auditada: a implementação faz exatamente as contas declaradas (cada par da matriz da RLS simetrizado uma vez; só a linha nova das entradas padronizada), com as previsões idênticas às validadas em 813 de 813 séries; a auditoria elevou a contagem em 3,2% (mediana). Por atualização da RLS: $6k^2 + 5k$ (a cada 8 alvos); previsão do especialista: $2k + 18m + 4$; AdaHedge: 48; M2: ~ 132 a 137.

Parte	FP por passo (mediana, uma série por família do desenvolvimento, antes da auditoria)
núcleo	453
M2	137
M1: atualização da RLS	513
M1: resto	146
Total	1.257

Teto de custo de M1 + M2. A meta preliminar de desenho (custo total $\leq 1,25$ vez o do núcleo) mostrou-se incompatível com M1 + M2: com o núcleo em ~ 450 FP, o acréscimo máximo seria ~ 110 FP, menos que a M2 sozinha. Antes da avaliação final, o responsável pelo projeto a substituiu por um teto de **acréscimo absoluto de 1.100 FP por passo** em cada série (o custo novo é quase fixo; uma razão puniria as séries em que o núcleo é barato), mais 2,5 vezes o custo do núcleo nas famílias abaixo da fronteira. No desenvolvimento (813 séries) o acréscimo teve mediana de 538 e máximo de 974 FP; na avaliação final, mediana de 476 e máximo de 918 FP, com custo total entre 667 e 1.637 FP.



Memória


O estado tem tamanho fixo, dados o número de entradas e os períodos. O estado do núcleo foi medido no porte em C (capacidades para até 8 entradas e 160 hipóteses): 74.988 bytes; a maior parte é a tabela de hipóteses, que pode ser reduzida. M1 e M2 guardam 1.263 números ($k = 28$ no pior caso: 1056 na M1, 207 na M2), 10.104 bytes em precisão dupla. Total **estimado**: 85.092 bytes (83,1 KB), dentro do limite pré-registrado de 128 KB; M1 e M2 não foram portados nem medidos.

13. Observabilidade e explicabilidade

Cada previsão pode ser decomposta em parcelas nomeadas: no núcleo, memória, base e cada bloco ativo; depois, o peso ω da M1 e, na M2, os pesos de R e L' em H e em W e a fração s_t . Cada mudança de estrutura e cada aceitação da auditoria da porta ficam registradas. Exemplo de uma série de desenvolvimento do núcleo:

Instante	Evento	Mudança	log E	Amostras de evidência
3.090	aceita	acrescentar entrada x0	7,18	957
4.230	aceita	acrescentar estado latente do resíduo	5,49	893

- **Grupos equivalentes:** junto da entrada aceita x0 o modelo reporta o grupo {x0, x1} (correlação causal $\geq 0,95$ entre x0, a vazão defluente da usina a montante, e x1, o próprio passado do alvo). A afirmação é “esta entrada ou uma equivalente”.
- **Intervalo de 90% do núcleo:** cobertura empírica de 0,906 nesta série e 0,904 em média nas 60 séries da avaliação própria do núcleo.
- **Registro de experimentos encerrados:** cada teste que não passou fica registrado com a sua evidência (por exemplo, testes de remoção de x0 com log E entre $-1,8$ e $-3,2$: a entrada continua útil).
- **M1 e M2:** o peso final ω da M1 é lido por série (§19: $\omega = 0$ em todas as séries de solar, eólica e carga); quais entradas a M1 escolheu também fica disponível.



14. Metodologia de avaliação

Duas perguntas foram avaliadas com protocolos próprios, ambos pré-registrados: (a) o núcleo é competitivo na sua classe de orçamento? (b) M1 e M2 melhoram o núcleo sem piorar nenhum domínio?

Disciplina comum

- **Previsão online de um passo**, sem olhar o futuro; todos os modelos recebem as mesmas entradas, padronizadas de forma causal.
- **Pré-registro**: antes de cada acesso a dados reservados, um documento fixou perguntas, métricas, comparadores, critérios e os hashes do código; cada reserva foi executada uma única vez; o carregador de dados impede o acesso às reservas fora de uma execução pré-registrada. Incidentes de infraestrutura (sem alteração de modelo) estão descritos junto dos resultados.
- **Divisão das séries** por permutações com semente fixa, antes de qualquer modelagem; cada conjunto de validação foi escolhido só por metadados, congelado com SHA-256 e usado uma vez.

(a) O núcleo na classe de orçamento

- **Métrica**: erro quadrático médio na região de teste (últimos 70% de cada série, alvo observado), dividido pelo do NLinear online calibrado na mesma série; média geométrica entre séries; IC 95% por bootstrap estratificado por domínio (2.000 reamostragens). **Falha catastrófica**: erro relativo > 10, desvio > 10× a amplitude observada ou previsão não finita.
- **Dados**: vazões e geração do Operador Nacional do Sistema Elétrico (ONS; usinas em cascata), bacias do CAMELS-BR (Chagas et al. 2020; precipitação, evapotranspiração, temperatura) e medidores do Building Data Genome 2 (Miller et al. 2020; clima), mais dois benchmarks de identificação de sistemas no desenvolvimento.
- **Modelos de fundação** (caros demais para rodar em todos os passos): avaliados em 1.000 pontos por série, os mesmos para todos, com o mesmo contexto e as entradas atuais como covariáveis futuras conhecidas. **Comparadores ajustados em lote** (SARIMAX com entradas, FITS, SparseTSF, ajuste fino do TTM): ajustados nos primeiros 15% da série (até 5.000 pontos), depois com pesos fixos.

Conjunto	Séries	Uso
Desenvolvimento	29 (ONS 11, CAMELS 10, BDG2 5, Silverbox, Cascaded Tanks ×2)	todo o desenho e ajuste do núcleo
Reserva 1	125 (ONS 45, CAMELS 50, BDG2 30)	revelou a falha das lacunas (§15)
Reserva 2	40 (CAMELS 20, BDG2 20)	verificou a correção
Reserva 3	60 (CAMELS 30, BDG2 30)	comparadores ultraleves, TTM, porte em C, microcontrolador

(b) M1 e M2 contra o núcleo


Os dados da avaliação final foram reservados em 05/10/2026, antes de qualquer código de M1 e M2, com hashes e travas. A métrica é a razão de erros quadráticos médios $LEBRE \div \text{núcleo}$, série a série. **Régua por decidibilidade**: cada série é classificada pelo IC 95% de núcleo $\div R$ (bootstrap de blocos pareado, 2.000 réplicas) como “núcleo melhor”, “referência melhor” ou “indecidível”. Critérios: (1) nas “referência melhor”, $LEBRE \div R$ com limite superior $\leq 1,01$; (2) nas “núcleo melhor”, $LEBRE \div \text{núcleo}$ com limite superior $\leq 1,02$; (4) nos testes negativos, nenhuma entrada falsa a mais que o núcleo; (6) a estrutura do núcleo preservada; (7) nas séries curtas (360 passos), $\leq 1,05$ do melhor entre núcleo e R. **Adendos do choque** (decididos durante o desenvolvimento, antes da validação 5 e da avaliação final): uma série em que o maior passo isolado passa de $\max(5\%, 5 \cdot 2 \ln(n)/n)$ do erro de R fica indecível nos critérios 1 e 2 (n = passos avaliados), porque nela nenhum combinador tem garantia útil (§6.4).

F6, nas famílias em que o núcleo está abaixo da fronteira precisão × custo: custo $\leq 2,5$ vezes o do núcleo e erro $\leq 1,05$ vez o menor erro entre as 8 regressões do diagnóstico com custo $\leq$ o da LEBRE. **Promoção** (pré-registro; decisões do responsável pelo projeto): (A) nenhuma piora por família, (B) $LEBRE \div \text{núcleo}$ em todas as séries com limite superior do IC 95% abaixo de 1 e (C) memória estimada ≤ 128 KB.

15. Evidência do núcleo estrutural

O núcleo foi desenvolvido e avaliado antes de M1 e M2 existirem, com o protocolo (a) da §14. Como M1 e M2 não alteram nenhuma decisão do núcleo (estrutura idêntica verificada em todas as séries do desenvolvimento, das validações e da avaliação final), essas evidências continuam valendo para o núcleo dentro da LEBRE.

15.1 Desenvolvimento: validade e descoberta




Situação	Resultado (desenvolvimento)
Sintéticos com entradas brancas (atrasos até 12)	estrutura recuperada até o atraso exato em 500–2.200 passos (ex.: atraso 12, peso 0,84 contra 0,80)
Semi-sintéticos (entradas reais, efeito conhecido)	entrada verdadeira (ou do seu grupo) em 2 de 3 tarefas estruturadas, 3/3 sementes; latência 4–17 mil passos
Entradas muito suaves (autocorrelação ~0,99), atraso médio/longo	não descobertas ; um oráculo online (conhece o atraso, testa desde o início) precisa de 9–27 mil passos ou nunca chega em 32 mil
Alvos sem estrutura (lotes nulos com entradas reais)	0/40 e 0/30 aceitações; 0 entradas exógenas falsas em todos os conjuntos declarados
Entradas quase idênticas (correlação 0,98)	indistinguíveis por melhora preditiva; o modelo reporta o grupo

O limite em entradas suaves é conhecido em princípio: com regressores muito persistentes, a informação nova de um atraso além do valor atual é pequena (Stambaugh 1999; Campbell & Yogo 2006). Nesses casos, a previsão continua boa porque a base já usa o valor atual das entradas; o que se perde é a *explicação* do atraso.

15.2 Controle de mudanças falsas em simulação com dependência

O núcleo congelado foi rodado em 700 execuções sintéticas (plano e critério declarados antes; 4 entradas correlacionadas entre si, persistência 0,5 ou 0,95, 30 mil passos): quatro nulos (ruído branco; alvo autorregressivo; ruído cuja variância depende de uma entrada; quebra de variância) e três cenários com uma entrada verdadeira com atraso 6 (simples; com uma isca de correlação 0,7 com a verdadeira; com ruído autorregressivo de cauda pesada).




- **Nulos:** 0 de 400 execuções com qualquer mudança aceita.
- **Com uma entrada verdadeira:** pelo critério declarado (por cenário, 100 execuções) os três cenários ficaram dentro de $\alpha = 0,05$ (FDR 0,045 e 0,038 nos piores). Mas, com persistência 0,5, duas células passaram de 0,05: FDR 0,090 (isca) e 0,077 (ruído dependente), com 7/50 e 10/50 execuções afetadas.
- **Mecanismo:** em todas as 17 execuções afetadas, a mudança falsa foi uma entrada *correlacionada* com a verdadeira, aceita antes dela. Enquanto a verdadeira não está no modelo, essa substituta melhora de fato a previsão da referência — o teste acerta a pergunta que faz, mas a resposta não é estrutural. O teste periódico de remoção retirou a substituta em 10 dos 17 casos; em 7 de 700 execuções ela ficou no modelo final.

O que isto permite afirmar: nos cenários simulados, o procedimento controlou empiricamente as falsas *melhoras preditivas* e não aceitou nada em alvos sem estrutura. Ele **não** garante estrutura verdadeira: com entradas correlacionadas, uma substituta pode ser aceita e, às vezes, permanecer. Uma entrada aceita significa “melhorou a previsão da referência vigente, com evidência”, não “é a causa”.

15.3 Avaliações em séries nunca vistas

Reserva 1 (125 séries): uma falha de engenharia. A primeira avaliação pré-registrada, com o núcleo ainda sem as salvaguardas de saída, revelou que **6 de 125 séries explodiam** (erro relativo de 13 até 10^{79}): quando o alvo faltava por muitos passos, a memória preenchia o próprio histórico com as próprias previsões. O resultado pré-registrado ficou dominado por essas séries (média geométrica 5,20); numa vista exploratória, não pré-registrada, sem as 6 séries, o erro relativo foi 0,706, igual ao do desenvolvimento. A falha motivou as salvaguardas da §11, verificadas no desenvolvimento e depois em séries nunca vistas.



Modelo	CAMELS	BDG2	Todas [IC 95%]	Séries > 1,5	Catastróficas	Operações/previsão
LEBRE: núcleo	0,858	0,768	0,812 [0,752; 0,866]	0%	0	415
NLinear online	1,000	1,000	1,000 [1,000; 1,000]	0%	0	674
DLinear online	1,076	0,947	1,009 [0,948; 1,066]	3%	0	1.533
Holt-Winters online	1,213	1,244	1,229 [1,136; 1,323]	25%	0	20
FITS	1,362	1,137	1,244 [1,158; 1,335]	18%	0	9.757
ARX denso (NLMS)	1,008	2,711	1,653 [1,184; 2,730]	38%	2	474
LASSO online	1,015	3,048	1,759 [1,237; 2,898]	38%	4	705
arquitetura anterior (v0.51)	2,180	2,140	2,160 [1,440; 3,723]	48%	4	108
SparseTSF	2,980	2,886	2,933 [2,512; 3,446]	87%	3	4.016
SARIMAX com entradas	0,817	0,803	0,810 [0,763; 0,851]	0%	0	ajuste por MV
ARX por mínimos quadrados	0,677	2,867	1,394 [0,998; 2,170]	20%	4	48.944

Teto (1.000 pontos)	CAMELS	BDG2	Todas	Razão pareada núcleo/modelo [IC 95%]	Operações/previsão
SARIMAX com entradas	0,798	0,818	0,808	1,004 [0,956; 1,056]	ajuste por MV
TTM sem treino	1,204	0,978	1,085	0,747 [0,704; 0,795]	15,6·10 ⁶
TTM ajustado c/ entradas	1,049	1,054	1,052	0,771 [0,699; 0,844]	55,6·10 ⁶
Chronos-2 c/ covariáveis	0,782	0,539	0,649	1,250 [1,178; 1,337]	~10 ⁹ –10 ¹⁰

Resumo das avaliações do núcleo com as salvaguardas: erro relativo ao NLinear de 0,767 (reserva 2, 40 séries) e 0,812 (reserva 3, 60 séries); nenhuma série catastrófica e nenhuma acima de 1,5 nas 100 séries; empate com o SARIMAX com entradas nas duas (razões pareadas 0,999 e 1,002); erro menor que o do TTM sem treino e ajustado; erro 16% e 25% acima do Chronos-2 com covariáveis. Os ultraleves FITS e SparseTSF, ajustados em lote nos primeiros 15%, ficaram atrás do NLinear online neste regime de um passo, para o qual não foram desenhados. O intervalo de 90% teve cobertura empírica de 0,905 e 0,904.

16. O núcleo em microcontrolador simulado

Para verificar se o custo analítico corresponde a algo executável num microcontrolador, o núcleo congelado foi portado para C99 e executado num **simulador** de um microcontrolador comum (STM32F4, núcleo Cortex-M4F a 168 MHz). Não houve medição em placa física. **M1 e M2 não foram portados**: para eles há só a contagem analítica (§12).

D6 — Cadeia de medição do núcleo em microcontrolador simulado


O núcleo, portado para C99 em precisão simples, conferido contra o Python e executado num Cortex-M4F simulado



O simulador conta instruções executadas, mas não modela o pipeline; os ciclos vêm do rastreamento de execução com os tempos publicados do Cortex-M4.


Cadeia de medição. A equivalência foi verificada primeiro no PC (C em precisão dupla e simples contra o Python), depois no dispositivo simulado.

Equivalência. Em precisão dupla, o C reproduz exatamente as decisões do Python em 29/29 séries de desenvolvimento. Em **precisão simples** (a versão do microcontrolador), as sequências de mudanças aceitas são idênticas em 28/29 séries de desenvolvimento e em 54/60 séries nunca vistas; nas demais, uma decisão perto do limiar ocorre alguns passos antes ou depois (arredondamento), com diferença mediana de erro de $\sim 10^{-6}$. **Custo.** O simulador (Renode 1.17) conta instruções executadas pelo contador DWT, mas não modela o pipeline; os ciclos foram estimados de rastreios de execução com os tempos publicados do Cortex-M4 e da FPU: CPI 1,62 e 1,57. Tempos abaixo usam CPI 1,6 e são estimativas.



Instruções por passo do núcleo em 7 séries (3 de desenvolvimento, 4 da reserva 3 pré-registrada): média (barra), p99,9 (traço) e máximo (triângulo). Eixo direito: tempo estimado a 168 MHz.

Série	Origem	Entradas	Média	Mediana	p99,9	Pico	Tempo	NMSE	Mudanças
ONS (dev.)	desenv.	1	3.703	3.363	12.327	42.021	~35 μs	0,2826	4
CAMELS (dev.)	desenv.	3	4.560	4.599	14.387	48.447	~43 μs	0,0229	3
BDG2 (dev.)	desenv.	2	5.964	5.607	16.843	45.654	~57 μs	0,0305	2
CAMELS 51795000	reserva 3	3	3.203	3.003	12.223	36.771	~31 μs	0,1465	0
CAMELS 64625000	reserva 3	3	3.521	3.215	12.267	36.708	~34 μs	0,3249	0
BDG2 Fox education Ollie	reserva 3	2	5.806	5.587	15.375	45.402	~55 μs	0,0162	3
BDG2 Panther education Vincent	reserva 3	2	5.528	5.463	16.971	45.696	~53 μs	0,0584	3



Leitura: ~3,2–6,0 mil instruções por passo correspondem a ~9–15 instruções por operação analítica (acessos à memória, laços, índices, divisões). A ~31–57 μ s por passo, uma amostragem de 1 segundo ocuparia < 0,01% do tempo do núcleo do processador; a energia não foi medida. Com M1 e M2, que dobram aproximadamente a contagem analítica (§12), a ordem de grandeza esperada continua a mesma, mas **não foi medida**. O estado cabe na RAM do STM32F407, mas não em microcontroladores menores sem reduzir as capacidades.

17. Desenvolvimento de M1 e M2

Um banco de testes público (o LEBRE Lab) rodou o núcleo congelado em domínios novos e levantou modos de falha. M1 e M2 tratam dois deles, sem ampliar o espaço de hipóteses do núcleo; os demais ficaram fora desta versão (§22).

Modo de falha 1: perder para a referência trivial (motiva a M2)


Em séries quase imprevisíveis, a parte adaptativa do núcleo erra mais que a referência trivial. Na própria reserva final, a referência foi melhor que o núcleo, com intervalo de confiança inteiro acima de 1, em 5 de 8 séries de retornos de câmbio e 6 de 8 de níveis.

Modo de falha 2: abaixo da fronteira precisão × custo (motiva a M1)

Em 8 famílias do desenvolvimento um comparador linear completo (todas as entradas e defasagens estimadas juntas, de milhares a dezenas de milhares de operações por passo) vence o núcleo por mais de 5%. O que importa sob orçamento é se o núcleo perde para algo *do mesmo custo*. O diagnóstico mediu 8 regressões de custos variados em cada família: o núcleo está abaixo da fronteira (uma regressão de custo menor ou igual erra 5% menos) em 4 delas, todas com a mesma causa, a falta de estimação conjunta da dinâmica do alvo e do efeito das entradas.

Família	núcleo ÷ completo	melhor com custo ≤ núcleo	custo do núcleo (FP)	situação
B03	2,076	1,574	731	abaixo
VB07	1,170	1,005	435	abaixo
XB07	1,141	1,010	417	abaixo
B07	1,067	1,004	431	abaixo
YB06	1,095	1,048	640	na fronteira
YB03	1,225	1,397	830	na fronteira
VC05	1,138	1,381	262	na fronteira
A05	1,077	1,777	385	na fronteira

Erro = MSE ÷ MSE do comparador linear online completo (média geométrica da família). B03: qualidade do ar; B07, VB07, XB07: maré meteorológica (três conjuntos independentes); VC05: inflação; YB03: qualidade do ar de Pequim; YB06: eólica; A05: sintético.



Família	núcleo ÷ completo	LEBRE ÷ completo	meta	custo ÷ núcleo
B03	2,076	1,365	1,652	2,01
B07	1,067	1,020	1,054	2,17
VB07	1,170	1,053	1,056	2,13
XB07	1,141	1,044	1,061	2,21

Achados de processo, todos registrados: um defeito numérico no caminho W (0/0 por *underflow*) foi achado num teste, corrigido com a reserva em escala logarítmica e auditado (nunca disparou em medição registrada; desde então uma previsão não finita conta como falha); um erro de construção nas validações 4 e 5 (ciclo de 30 h em vez de 24 h em solar, eólica e carga) restringiu o alcance da validação 5 (§18).

18. Validações em dados novos

As validações 1 e 2 serviram a desenhos anteriores da M2; a validação 3 confirmou a candidata P. A **validação 4** reprovou a M1 rascunho 2 com a P: critério 1 em YB07, YC01 e critério 2 em YB01. O diagnóstico separou as causas (a falha da solar era da M1; as do câmbio e da maré, da M2) e levou aos desenhos da §17.


A **validação 5** (43 séries novas, medição única) confirmou a M1 rascunho 5 com a M2 Q2: F6 atendida em qualidade do ar de Pequim (Chen, 2017) e em seis estações de maré novas, e todos os critérios da M2 em todas as famílias.

Família	núcleo ÷ completo	LEBRE ÷ completo	meta	custo ÷ núcleo
Z-B03	1,169	1,118	1,410	1,97
Z-B07	1,017	0,925	1,068	2,20

Errata: nas validações 4 e 5, as famílias solar, eólica e carga foram montadas com ciclo de 30 h em vez de 24 h. As comparações entre núcleo e LEBRE nessas famílias valem para a tarefa como montada, não para a análoga declarada; a evidência fresca da LEBRE com o ciclo certo nesses domínios é a avaliação final (§19).

19. Avaliação final pré-registrada

Execução única em 104 séries reservadas (30 bacias do CAMELS-BR; 30 medidores do BDG2; 8 usinas solares, 8 eólicas, a carga de 2026 dos 4 subsistemas do ONS e 8 pares de câmbio em 3 tarefas: retornos, volatilidade e níveis). O pré-registro foi aprovado depois de um ensaio em 55 séries já gastas de bacias e prédios (0 erros). Resultado: **promovida** pela regra fixada antes.



Família	séries	núcleo melhor / ref. / indec. / choque	LEBRE ÷ núcleo	crit. 1	crit. 2	+custo máx. (FP)
Bacias (CAMELS-BR)	30	15/2/7/6	0,879	0,845 [0,814; 0,878]	0,911 [0,899; 0,924]	495
Prédios (BDG2)	30	30/0/0/0	0,993	-	0,993 [0,988; 1,000]	385
Usinas solares (ONS)	8	8/0/0/0	1,000	-	1,000 [1,000; 1,000]	696
Usinas eólicas (ONS)	8	8/0/0/0	1,000	-	1,000 [1,000; 1,000]	918
Carga 2026 (ONS)	4	4/0/0/0	1,000	-	1,000 [1,000; 1,000]	831
Câmbio: retornos	8	0/5/1/2	0,966	1,000 [1,000; 1,000]	-	894
Câmbio: volatilidade	8	6/0/0/2	1,000	-	1,000 [1,000; 1,000]	894
Câmbio: níveis	8	0/6/0/2	0,952	1,001 [1,000; 1,002]	-	894

- Melhora geral: **0,955 [0,951; 0,960]**; séries curtas contra o melhor de núcleo e R: 1,007 [0,995; 1,017].
- Nenhuma previsão não finita; entradas falsas nos retornos iguais às do núcleo; estrutura preservada em todas as séries; memória estimada de 85.092 B.
- Em solar, eólica e carga, a M1 terminou com peso zero em todas as 20 séries e a LEBRE ficou idêntica ao núcleo.
- Duas correções durante a execução, sem efeito em modelo ou critério: a leitura da carga de 2026 pelo código do subsistema (o ONS renomeou o Sudeste) e o tratamento de uma série curta degenerada (empate exato com erro zero).

Tetos de referência (só reportados)

Modelos fora da classe de orçamento, só como referência: Chronos-2 com covariáveis (Ansari et al., 2025), nos mesmos 1.000 pontos por série do protocolo (a); e SARIMAX com entradas, ajustado nos primeiros 15%.

Família	LEBRE ÷ Chronos-2	núcleo ÷ Chronos-2	SARIMAX-X ÷ LEBRE
Bacias (CAMELS-BR)	0,885	1,008	1,134
Prédios (BDG2)	1,248	1,241	1,034
Usinas solares (ONS)	1,237	1,237	1,096
Usinas eólicas (ONS)	1,051	1,051	1,049
Carga 2026 (ONS)	1,433	1,433	0,968
Câmbio: retornos	0,954	0,979	1,123*
Câmbio: volatilidade	0,983	0,983	1,058*
Câmbio: níveis	0,881	0,921	1,065*

* Câmbio: o SARIMAX com entradas não rodou na execução (entradas com feriados faltantes); valores de um adendo posterior ao resultado, com as entradas preenchidas pelo último valor.

20. Evolução da arquitetura e ablações

Evolução

A LEBRE evoluiu por versões congeladas, cada uma com os seus hashes. A v0.1 (referência canônica do projeto) definiu a ideia: estrutura que entra e sai do modelo por evidência, dentro de um orçamento. A v0.51 usava dois especialistas com descoberta por atraso e testes de martingale/CUSUM; análises posteriores mostraram que, em séries reais, quase todo o resultado vinha da memória. A v0.52 manteve a memória e a combinação e trocou a descoberta por um motor genérico de mudanças testadas — é o **núcleo estrutural** deste documento, congelado em 27/09/2026 sem promoção. A v0.53 (este documento) acrescentou M1 e M2 sem mudar um byte do núcleo e foi promovida em 09/10/2026. Os passos internos do núcleo foram:

1. hipóteses por atraso (~400) → **por entrada inteira** (menos hipóteses; melhor nos dados reais);
2. faixas diluíam atrasos isolados → **atraso de pico** e divisões hierárquicas;
3. evidência lenta → **c unilateral** e estatística do pico persistente;
4. aceitações em trechos planos → **piso de escala** da perda;
5. aceitações em alvos sem estrutura → **passo 0,05** na referência (§8);
6. picos de custo → um aquecimento por vez, triagem espalhada, estatística do pico em meia janela;
7. explosões em lacunas → **retenção e contrato de saída** (§11).

Ablações

Variante	O que muda	Resultado
Núcleo sozinho (sem M1 e M2)	a saída é L	avaliação final: LEBRE ÷ núcleo = 0,955 [0,951; 0,960]; a M1 tem peso zero em solar, eólica e carga
Núcleo: tudo ligado, sem testes	todas as entradas e o estado latente ativos desde o início	reservas 2 e 3 (100 séries): razão 0,988 [0,970; 1,006], custo ~5% menor — exploratório; o mecanismo de testes não melhora a precisão de forma distinguível
Núcleo sem divisões hierárquicas	a resposta fica nas faixas de oitava + pico	razão 0,996 [0,988; 1,001] — sem diferença em dados reais
Hipótese por atraso ("atômica")	uma hipótese por atraso de cada entrada (~400 hipóteses)	desenvolvimento: 0,757 contra 0,645 (1.000 pontos); descoberta mais lenta
Sem salvaguardas de saída	memória em malha aberta nas lacunas	reserva 2: 1,107 contra 0,767; 2 catastróficas; razão pareada 0,693
Base com passo 0,1	desajuste maior da referência	10/40 aceitações em alvos sem estrutura (§8)
Arquitetura anterior (v0.51)	dois especialistas com descoberta por atraso, sem controle no fluxo	reserva 3: 2,160, 4 catastróficas
M1 e M2 com outros combinadores	Prod recortado, Prod normalizado, outros desenhos (§17)	reprovados no desenvolvimento ou na validação 4

Consequência para o que se pode afirmar: a precisão do núcleo vem principalmente de uma regressão linear online barata sobre as entradas atuais e de uma memória sazonal, protegidas por salvaguardas de saída; o ganho da LEBRE sobre o núcleo vem de M1 e M2 (§19). O mecanismo de mudanças testadas **não é justificado por ganho de precisão**; ele se justifica, se for o caso, pela estrutura *registrada com evidência* (quais entradas, com que atraso, desde quando, com qual evidência). **Não demonstramos** que essa estrutura melhore alguma decisão prática (diagnóstico, controle, manutenção).

21. Posição na literatura

Aspecto	Trabalhos relacionados	Classificação
Mudança estrutural aceita por e-process de melhora preditiva, com controle de erro no fluxo	Amoukou, Mishra & Veloso (2026), em árvores de decisão online (controle FWER); Choi (2026), correções preditivas pré-especificadas; Jha (2026), causalidade de Granger com teste sequencial; Choe & Ramdas (2024); Xu & Ramdas (2024)	não original
Unidades por entrada, refinamento hierárquico, remoção e troca testadas, controle FDR, orçamento fixo	peças conhecidas (teste hierárquico; e-LOND; hipóteses persistentes com FDR: de Heide 2026; testes duplamente sequenciais: Yao, Gang & Sun 2025)	integração/extensão
Agregação de previsores (M1, M2)	AdaHedge (de Rooij et al. 2014); (A,B)-Prod e arrependimento constante contra um especialista de confiança (Sani et al. 2014; Even-Dar et al. 2008; Koolen 2013); switch distribution (van Erven et al. 2012) e Fixed Share (Adamskiy et al. 2016; Cesa-Bianchi et al. 2012); regressão recursiva com defasagens (Ljung 1999)	não original; escolha das perdas e encadeamento
Perdas sem limite e caudas pesadas	Cesa-Bianchi et al. (2007); Hazan & Kale (2010); Orabona & Pál (2018); Mhammedi et al. (2019); V'yugin & Trunov (2019); Alquier (2021); Moulin et al. (2025); sequências de confiança robustas (Wang & Ramdas 2023), direção futura	limite conhecido; tratado na régua
Condição de uso (desajuste da referência)	Giacomini & White (2006); Clark & West (2007); desajuste do LMS (Widrow & Stearns 1985); Han & Qu (2026); viés do incumbente na promoção de desafiantes (Fernández-Barrios et al. 2026)	observação metodológica modesta
Previsão com orçamento de $\sim 10^2$ – 10^3 operações por passo	SparseTSF, FITS, TTM (em geral univariados e treinados em lote); previsão embarcada com aprendizado incremental e sensores exógenos (Lara Pinal, Das & Schlüter 2026)	contribuição empírica, no escopo testado
Retenção, contrato de saída, limites de custo	prática de engenharia	padrão

A auditoria da literatura do núcleo seguiu um protocolo com afirmações e consultas fixadas antes (47 consultas, em duas rodadas) e classificou cada trabalho como antecipação, parcial, base ou distante; nenhum trabalho encontrado antecipa a combinação inteira, e cada peça tem precedente. **Limitações:** um mecanismo de busca geral, consultas em inglês, leitura em geral pelo resumo, sem dupla triagem; não é uma revisão sistemática no sentido formal. A contribuição da LEBRE é a **integração** desses componentes sob um orçamento declarado e a avaliação pré-registrada.

22. Limites e afirmações que não fazemos

- **Horizonte:** só um passo à frente, com as entradas atuais disponíveis.
- **Domínios:** o núcleo foi avaliado contra a classe de orçamento em hidrologia e prédios; M1 e M2, em bacias, prédios, solar, eólica, carga e câmbio, mais qualidade do ar e maré nas validações. Outros domínios não foram testados.
- **Custo sem ganho em parte dos domínios:** M1 e M2 custam em todas as séries; em solar, eólica e carga a LEBRE é idêntica ao núcleo.
- **Contrato de custo do núcleo** não cumprido (3,7% na média e 2,0% no pico), sem revisão posterior; o teto de M1 + M2 foi redefinido antes da avaliação final (§12).
- **Mecanismo de testes do núcleo:** não melhora a precisão; o controle de mudanças falsas está no regime prático, não no da garantia exata (§8); entradas correlacionadas com a verdadeira podem ser aceitas como substitutas e, às vezes, permanecer (§15).
- **Descoberta:** falha em entradas muito suaves com atraso médio/longo; entradas quase idênticas são indistinguíveis.
- **Sem garantia formal na escala original para M1 e M2:** o Prod garante em perdas normalizadas; o AdaHedge da M1 não dá arrependimento constante contra o núcleo; com choques, nenhum combinador tem garantia útil (§6.4).
- **Régua decidida durante o desenvolvimento:** os adendos do choque foram decididos depois de ver dados de desenvolvimento, antes da validação 5 e da avaliação final.
- **F6 sem família na reserva final:** a evidência de F6 em dados novos é só a validação 5; uma família do desenvolvimento passou com margem pequena (VB07).
- **Microcontrolador:** só o núcleo, só em simulador, ciclos estimados, energia não medida; memória de M1 e M2 estimada.
- **Incerteza:** os IC de conjunto tratam as séries como independentes; a carga tem 4 séries; 4 locais do BDG2 compartilham o clima com o desenvolvimento do núcleo.
- **Comparadores ausentes:** um ARMAX com filtro de Kalman online e um SARIMAX com parâmetros atualizados online.
- **Intervalo:** cobertura empírica perto de 90% no núcleo, sem garantia formal; não reportada para a saída completa.
- **Correções depois de falhas:** as salvaguardas e os desenhos finais de M1 e M2 vieram depois de ver falhas; foram confirmados em dados novos, mas o desenho não foi cego. Erratas e correções de execução estão declaradas.
- **Fora desta versão:** remoções que efetivamente acontecem, custo proporcional ao uso e o ciclo tratado como hipótese.

Não afirmamos que a LEBRE seja o melhor previsor, nem o mais econômico, nem que algum componente seja novo. Afirmamos apenas o que foi medido: nos protocolos e dados descritos, com o custo descrito, os números reportados nas §15–§19.

23. Parâmetros

Todas as constantes são as mesmas para qualquer série; nada é ajustado por série.

Núcleo	Constantes
Unidades	uma por entrada (inclui o próprio passado do alvo) + estado latente do resíduo (polos 0,8 e 0,95); até 4 ativas
Resposta	faixas [1], [2–3], [4–7], [8–15], [16–31] + atraso de pico (escolha em 200 amostras) + valor atual; divisões em metades
Desafiantes	RLS no episódio, $P_0 = 10 \cdot I$; aquecimento 250; 2 vagas; um aquecimento por vez
Evidência	perda $\min\{e^2/B^2, 1\}$, $B = 2 \cdot \max(\sigma_S^2, 0,1 \cdot s_{\text{lenta}})$; $c = 1 + \max(\epsilon, 0)$; $8\lambda = 0,9 \cdot 2^{-1/c}$; $\epsilon = +0,002$ (acrescentar, trocar, dividir), $-0,002$ (remover)
Multiplicidade	$\alpha = 0,05$; $\gamma = 1/(2P)$ nas primeiras $P = 2 \cdot \lfloor \text{unidades} \rfloor$, depois $0,5 \cdot \gamma_k \propto 1/(k \log^2 k)$; nível $\alpha \cdot \gamma \cdot (R+1) \leq 0,5$
Episódios	varredura após 100 amostras; limite 5.000; espera 2.000; remoção periódica a cada 2.000; decisões a cada 10 passos
Triagem	pré-branqueada AR(1), peso 0,02, a cada 4 passos por parte; limiares 15,09 ($\chi^2_{1,1}$) e 6,63 ($\chi^2_{1,1}$)
Base de S	NLMS $\mu = 0,05$; contrato de entrada $\pm 8\sigma$ com quarentena de 31 passos
Memória	NLMS $\mu = 0,05$; média lenta 0,01; perfil 0,1; pisos 10^{-3} e 10^{-4} ; ciclo(s) declarado(s); retenção nas lacunas
Combinação e saída	$\lambda = 0,99$, $\eta = 0,5$, a cada 8 passos; envelope com taxa 10^{-3} e margem $0,5 \times$
Intervalo	$\alpha = 0,1$, $\gamma = 0,1$, a cada 8 passos (também na saída final)
Grupos	correlação causal $\geq 0,95$ reportada junto da entrada aceita (não afeta decisões)

Parte	Parâmetro	Valor	Observação
M1	entradas	$m = \min(d, 5)$	maior correlação absoluta (médias exponenciais 0,01, só passado)
M1	bandas	[0], [1], [2–3], [4–7], [8–15]	médias; + alvo nas defasagens 1 e 2; $k = 3 + 5m$
M1	RLS	$\lambda = 0,999$; $\delta = 100$	a cada 8 alvos aprendidos; E só depois de k atualizações
M1	seleção	após 100; a cada 5.000	recomeça regressão e combinação
M1	recorte	$L \pm 2 \cdot \max(\sigma_L, \text{piso})$	piso: $0,1 \times$ escala lenta do alvo
M1	combinação	AdaHedge	erro quadrático; sombra de 100 atualizações
M2	R	zero / sazonal / persistência	declarada com os dados
M2	H	AdaHedge	erro quadrático, só com R definida
M2	W	troca única, risco $1/(n+1)$	perdas gaussianas na escala recente (0,01)
M2	Prod	$\eta \leq 1/2$; $w_B = 1/2$	perdas $\div$ $\max(\text{perdas}, 0,99 \cdot N)$
M2	porta	$\varepsilon = 0,002$; $\alpha = 0,01$	só auditoria; recriada a cada decisão

24. Pseudocódigo e condições de reprodutibilidade

Pseudocódigo simplificado de um passo, suficiente para reimplementar a configuração avaliada. Onde o texto e o pseudocódigo diferirem, vale o pseudocódigo junto da tabela de parâmetros (§23).

Núcleo estrutural

```

CONSTANTES # iguais para qualquer série; nada é ajustado por série
BANDS = [1], [2-3], [4-7], [8-15], [16-31]      POLES = 0.8, 0.95      L = 31
M_MAX = 4      SLOTS = 2      WARM = 250      PEAK_N = 200      N_MIN = 100      T_MAX = 5000      COOL = 2000      REM_PERIOD = 2000
DECIDE_EVERY = 10      SCREEN_EVERY = 4      SCREEN_W = 0.02      Q_UNIT = 15.09 ( $\chi^2_s$ , 99%)      Q_SPLIT = 6.63 ( $\chi^2_1$ , 99%)
 $\epsilon$ : add = swap = split = +0.002, remove = -0.002       $\alpha$  = 0.05       $\mu_S$  = 0.05       $\mu_M$  = 0.05      CLIP_X = 8
 $\lambda_{DMA}$  = 0.99       $\eta$  = 0.5      EVERY = 8       $\alpha_{int}$  = 0.10       $\gamma_{int}$  = 0.10      SCALE_FLOOR = 0.1      OUT_MARGIN = 0.5      OUT_RHO = 1e-3

ESTADO # tamanho fixo, dado o número de entradas d e o(s) período(s) s, s2
H[0..L+1][d+1] histórico das entradas (inclui o próprio passado do alvo, padronizado)
band_sum[5][d+1], seg_sum{(i,lo,hi)} somas correntes das faixas e dos segmentos ativos
base[d+2] active{unit  $\rightarrow$  (segments, weights)} r[2] estados latentes do residuo
M: buffer, w_M, G[s], m_slow      hyps{key  $\rightarrow$  e-process}      slots[ $\leq 2$ ]

PASSO(x_t, y_t ou lacuna, quarantine):
# 1. ler
 $\bar{x} \leftarrow [x_t, \text{std\_causal}(y_{last})]$  # média/variância EMA 1e-4, início (0, 1)
se any | $\bar{x}$ | > CLIP_X: quar_until  $\leftarrow t + L$ ;  $\bar{x} \leftarrow \text{clip}(\bar{x}, \pm \text{CLIP\_X})$ ; shift H, band_sum, seg_sum
# 2. prever
 $\hat{y}_M \leftarrow M.\text{predict}()$  # último valor +  $w_M \cdot \phi$  (reversão, diferença, sazonal, perfil)
 $\hat{y}_S \leftarrow \text{base} \cdot [1, \bar{x}] + \sum u \cdot w_u \cdot \text{block}(u)$  # block: médias dos segmentos ativos
 $\hat{y} \leftarrow \hat{y}_M + w_S (\hat{y}_S - \hat{y}_M)$ 
se n_obs  $\geq 50$ :  $\hat{y} \leftarrow \text{clip}(\hat{y}, \text{env\_lo} - 0.5 \cdot W, \text{env\_hi} + 0.5 \cdot W)$ ,  $W = \text{env\_hi} - \text{env\_lo}$ ; se  $\hat{y}$  não finito:  $\hat{y} \leftarrow y_{last}$ 
para cada experimento e:  $g_e \leftarrow \hat{y}_S + \theta_e \cdot z_e - (\text{contribuição removida})$ 
retorna  $\hat{y}$ , [ $\hat{y} - \hat{q}$ ,  $\hat{y} + \hat{q}$ ]
# 3. observar e aprender (só se y_t observado)
learn  $\leftarrow y_t$  observado  $\wedge \neg \text{quarantine}$   $\wedge t > \text{quar\_until}$ 
 $B \leftarrow 2 \cdot \max(\sigma_r, \text{SCALE\_FLOOR} \cdot \text{sd\_slow}(y))$ ;  $\ell(u) = \min((y_t - u)^2/B^2, 1)$ 
se learn:
  para cada e:  $k_e \leftarrow k_e + 1$ 
    se  $k_e > \text{WARM}$ : e.hyp.observe( $\ell(\hat{y}_S) - \ell(g_e) - \epsilon_e$ ) # evidência
    se  $k_e \leq \text{PEAK\_N}$ : acumula correlação pré-branqueada por atraso (metade dos atrasos por passo)
    se  $k_e = \text{PEAK\_N}$ :  $k^* \leftarrow \text{argmax}_k c_{xy^2}/c_{xx}$ ; se  $k^* > 1$ : insere  $x_i(t-k^*)$  no desafiante
     $\text{RLS}(\theta_e, P_e; z_e, \text{alvo} = y_t - \hat{y}_S + \text{contribuição removida})$  #  $P_0 = 10 \cdot I$ 
     $\text{NLMS}(\text{base}, w_u; \text{res} = y_t - \hat{y}_S, \mu_S, \text{norma} = \|[1, \bar{x}]\|^2 + \sum \|\text{block}(u)\|^2)$ 
    screen_spread(res) # cada parte na sua fase, a cada 4 passos
 $D \leftarrow \lambda_{DMA} \cdot D + ((y_t - \hat{y}_S)^2 - (y_t - \hat{y}_M)^2)/\sigma^2$ ; a cada EVERY:  $w_S \leftarrow 1/(1 + \exp(\eta \cdot D))$ 
intervalo: miss  $\leftarrow |y_t - \hat{y}| > \hat{q}$ ; a cada EVERY:  $\hat{q} \leftarrow \max(0, \hat{q} + \gamma_{int} \cdot \sigma \cdot \Sigma(\text{miss} - \alpha_{int}))$ 
M.update(y_t se observado; senão o último valor observado (retenção), sem aprender)
env  $\leftarrow$  envelope dos observados (máx./mín. que relaxam para a média, taxa OUT_RHO)
 $r \leftarrow \text{POLES} \cdot r + (1 - \text{POLES}) \cdot (y_t - \hat{y})/\sigma$ 
se t mod DECIDE_EVERY = 0: DECIDIR()

DECIDIR():
para cada e: se log E(e.hyp)  $\geq \log(1/\alpha_{hyp})$ : ACEITAR(e)
  senão se  $n_e \geq T_{MAX}$  ou ( $n_e \geq N_{MIN}$  e  $\sum \text{episodo } d \leq 0$ ): encerra (a evidência fica na hipótese)
encerra experimentos sobre unidades que mudaram; PREENCHER()

PREENCHER(): enquanto houver vaga livre:
1. unidade ativa sem teste de remoção há  $\geq \text{REM\_PERIOD}$   $\rightarrow$  abre remove
2. se algum desafiante em aquecimento: pare # um aquecimento por vez
3.  $u^* \leftarrow \text{argmax stat}(u)$  entre unidades inativas, livres, fora da espera;  $s^* \leftarrow \text{argmax stat}(\text{divisões})$ 
4. escolha o maior entre  $\text{stat}(u^*)/Q_{UNIT}$  e  $\text{stat}(s^*)/Q_{SPLIT}$  (se  $\geq 1$ ):
  divisão  $\rightarrow$  split; |active| < M_MAX  $\rightarrow$  add; senão  $\rightarrow$  swap (com a unidade de menor contribuição)
# hipótese nova n recebe nível fixo:  $\alpha_n = \min(\alpha \cdot \gamma_n \cdot (R+1), 0.5)$ ,
#  $\gamma_n = 1/(2P)$  para  $n \leq P = 2 \cdot |\text{units}|$ , depois  $0.5 \cdot C/((n-P) \cdot \log^2(n-P+1))$ ; R = mudanças já aceitas

e-process( $\epsilon$ ):  $c = 1 + \max(\epsilon, 0)$ ;  $\lambda_j = 0.9 \cdot 2^{(-j)/c}$ ,  $j = 0..7$ ;  $\psi_j = (-\log(1 - c\lambda_j) - c\lambda_j)/c^2$ 
observe(d):  $\gamma \leftarrow \text{clip}(\text{média passada de } d, -c, 0)$ ;  $S \leftarrow S + d$ ;  $V \leftarrow (d - \gamma)^2$ 
log E = log(  $(1/8) \cdot \sum_j \exp(\lambda_j \cdot S - \psi_j \cdot V)$  )

ACEITAR(e): add/swap  $\rightarrow$  active[i]  $\leftarrow$  (BANDS  $\cup \{[k^*], \theta_e[-1]\}$ ); base[i]  $\leftarrow \theta_e[-1]$ ; remove  $\rightarrow$  apaga active[u]
split  $\rightarrow$  troca a faixa [lo,hi] pelas duas metades com os pesos do desafiante; R  $\leftarrow R + 1$ 

```

M1 e M2 (sobre a previsão L do núcleo)

```

CONSTANTES de M1 e M2  M_MAX = 5  BANDS_E = [0], [1], [2-3], [4-7], [8-15]  λ_RLS = 0.999  δ_RLS = 100
EVERY = 8  CLIP_K = 2  N_MIN = 100  T_MAX = 5000  LAM = 0.99  SCALE_FLOOR = 0.1  ε_gate = 0.002  α_gate = 0.01

PREVER(x_t):
  L ← núcleo.prever(x_t)                                # pseudocódigo do núcleo acima
  # M1: especialista de precisão
  x ← x_t com ausentes trocados pelo último valor visto
  z ← [1,  $\hat{y}_t(t-1)$ ,  $\hat{y}_t(t-2)$ ], médias das BANDS_E das m = min(d, M_MAX) entradas escolhidas, padronizadas]
  E ← clip(w·z, L ± CLIP_K·max(σ_L, piso))                # se RLS determinada (n_RLS ≥ k = 3 + 5m)
  L' ← L # se E indefinido ou AdaHedge1.n < N_MIN; senão (1 - w)·L + w·E # sombra
  # M2: ponto de partida na referência trivial
  R ← 0 | y_last | y_t(t-s)                                # zero, persistência ou sazonal ingênuo, declarada
  # se R indefinida:  $\hat{y} \leftarrow L'$ 
  senão: H ← w_H·[R, L']; W ← w_W·[R, L']; s ← η·w_A / (η·w_A + w_B/2);  $\hat{y} \leftarrow s·W + (1 - s)·H$ 
  retorna  $\hat{y}$ , [ $\hat{y} - \hat{q}_o$ ,  $\hat{y} + \hat{q}_o$ ]

OBSERVAR(y_t, quarantine):
  núcleo.observe(y_t, quarantine)
  # se y_t observado:
  AdaHedge1.update((y_t - L)2, (y_t - E)2)                # erro quadrático sem recorte
  learn ← ~quarantine ∧ entradas dentro do contrato
  # se learn: a cada EVERY alvos: triagem (médias exponenciais 1 - LAM) e RLS(z, y_t)
  seleção das m entradas depois de N_MIN alvos e a cada T_MAX; se mudar: RLS e AdaHedge1 recomeçam
  # se ~quarantine ∧ R definida:
  AdaHedge_H.update((y_t - R)2, (y_t - L')2)
  s2 ← max(min(σ2R, σ2L'), piso2); Switch_W.update((y_t - R)2/2s2, (y_t - L')2/2s2) # reserva em escala log contra 0/0
  N ← max(LAM·N, (y_t - H)2, (y_t - W)2); Prod.update((y_t - H)2/N, (y_t - W)2/N)
  gate.observe(...) # auditoria: registra eventos, não decide a saída
  intervalo da saída: miss ← |y_t -  $\hat{y}$ | >  $\hat{q}_o$ ; a cada EVERY:  $\hat{q}_o \leftarrow \max(0, \hat{q}_o + 0.1·\sigma_o·\Sigma(\text{miss} - 0.1))$ 

```

Condições de reprodutibilidade

- **Entradas:** padronizar cada entrada de forma causal antes do núcleo: $z = (x - m)/\sqrt{v + 10^{-6}}$, com m e v exponenciais de taxa 10^{-4} a partir de (0, 1), atualizadas *depois* de padronizar o valor atual; valores ausentes viram 0 após a padronização (na M1, o último valor visto).
- **Alvo:** passado em unidades originais; ausências são passadas como lacuna (sem aprendizado); uma marca externa de quarentena suspende o aprendizado.
- **Metadados:** período sazonal s (24 para dados horários; nenhum se não houver ciclo), opcionalmente um segundo ciclo s₂ (168 nos prédios), e a referência trivial (zero, persistência ou sazonal; sem declaração: sazonal se houver ciclo, senão persistência).
- **Determinismo:** o algoritmo não usa números aleatórios; dada a mesma sequência de entradas, a saída é determinística.
- **Disponibilidade:** o código promovido (Python), o porte em C do núcleo, os pré-registros, os scripts de análise, as previsões por série e os manifestos SHA-256 de cada versão congelada estão no repositório público github.com/Iqitim/lebre-research (código da LEBRE completa no commit 4a2620e); o desenvolvimento e as validações de M1 e M2 estão no banco de testes público github.com/Iqitim/lebre-lab (este documento leu os seus resultados no commit 6f328bb).
- **Ambiente usado:** Python 3.11, numpy 2.2.5, pandas 2.2.3 (versões posteriores mudaram o comportamento de arrays somente leitura), statsmodels 0.15.0; Chronos-2 com o pacote chronos 2.3.2; C99 com GCC para Arm 15.2 (-O2, FPU de precisão simples, sem contração FMA); Renode 1.17.

25. Referências

1. Adamskiy, D., Koolen, W. M., Chernov, A., Vovk, V. (2016). A closer look at adaptive regret. *Journal of Machine Learning Research* 17(23), 1–21.
2. Alquier, P. (2021). Non-exponentially weighted aggregation: regret bounds for unbounded loss functions. *ICML*.
3. Amoukou, S. I., Mishra, S., Veloso, M. (2026). Correcting split selection in online decision trees via anytime-valid inference. *arXiv:2605.31239*.
4. Ansari, A. F. et al. (2025). Chronos-2: from univariate to universal forecasting. *arXiv preprint*.
5. Box, G. E. P., Jenkins, G. M. (1970). *Time Series Analysis: Forecasting and Control*. Holden-Day.
6. Campbell, J. Y., Yogo, M. (2006). Efficient tests of stock return predictability. *Journal of Financial Economics* 81(1), 27–60.
7. Cesa-Bianchi, N., Gaillard, P., Lugosi, G., Stoltz, G. (2012). Mirror descent meets fixed share (and feels no regret). *NeurIPS* 25.
8. Cesa-Bianchi, N., Mansour, Y., Stoltz, G. (2007). Improved second-order bounds for prediction with expert advice. *Machine Learning* 66, 321–352.
9. Chagas, V. B. P. et al. (2020). CAMELS-BR: hydrometeorological time series and landscape attributes for 897 catchments in Brazil. *Earth System Science Data* 12, 2075–2096.
10. Chen, S. (2017). Beijing Multi-Site Air Quality. *UCI Machine Learning Repository*, doi:10.24432/C5RK5G.

11. Choe, Y. J., Ramdas, A. (2024). Comparing sequential forecasters. *Operations Research* 72(4), 1368–1387.
12. Choi, S. (2026). Anytime-valid evidence for prespecified predictive corrections. *arXiv:2608.08174*.
13. Clark, T. E., West, K. D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics* 138(1), 291–311.
14. de Heide, R. (2026). Dynamic e-closure for online hypotheses with any-time-valid evidence: closure principles and projective mergers. *arXiv:2608.09927*.
15. de Rooij, S., van Erven, T., Grünwald, P. D., Koolen, W. M. (2014). Follow the leader if you can, hedge if you must. *Journal of Machine Learning Research* 15, 1281–1316.
16. Ekambaram, V. et al. (2024). Tiny Time Mixers (TTMs): fast pre-trained models for enhanced zero/few-shot forecasting of multivariate time series. *NeurIPS* 37.
17. Even-Dar, E., Kearns, M., Mansour, Y., Wortman, J. (2008). Regret to the best vs. regret to the average. *Machine Learning* 72, 21–37.
18. Fan, X., Grama, I., Liu, Q. (2015). Exponential inequalities for martingales with applications. *Electronic Journal of Probability* 20, 1–22.
19. Fernández-Barrios, R., Pastor-López, I., Pikatza-Huerga, A., García Bringas, P. (2026). Candidate comparability before promotion: conditional validation in adaptive network intrusion detection. *arXiv:2609.04388*.
20. Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica* 74(6), 1545–1578.
21. Gibbs, I., Candès, E. J. (2021). Adaptive conformal inference under distribution shift. *NeurIPS* 34.
22. Grünwald, P., de Heide, R., Koolen, W. M. (2024). Safe testing. *Journal of the Royal Statistical Society B* 86(5), 1091–1128.
23. Han, W., Qu, L. (2026). When the martingale never stops firing: anytime-valid gating on real forecast streams. *arXiv:2608.30502*.
24. Haykin, S. (2002). *Adaptive Filter Theory*, 4th ed. Prentice Hall.
25. Hazan, E., Kale, S. (2010). Extracting certainty from uncertainty: regret bounded by variation in costs. *Machine Learning* 80, 165–188.
26. Howard, S. R., Ramdas, A., McAuliffe, J., Sekhon, J. (2021). Time-uniform, nonparametric, nonasymptotic confidence sequences. *Annals of Statistics* 49(2), 1055–1080.
27. Hyndman, R. J., Koehler, A. B., Ord, J. K., Snyder, R. D. (2008). *Forecasting with Exponential Smoothing: The State Space Approach*. Springer.
28. Javanmard, A., Montanari, A. (2018). Online rules for control of false discovery rate and false discovery exceedance. *Annals of Statistics* 46(2), 526–554.
29. Jha, A. (2026). Distributional Granger causality: identification, sequential inference, and adaptive testing. *arXiv:2606.22230*.
30. Koolen, W. M. (2013). The Pareto regret frontier. *NeurIPS* 26.
31. Lara Pinal, E. M., Das, A., Schlüter, S. (2026). A low-cost IoT device for environmental monitoring and embedded solar forecasting with on-device incremental learning. *arXiv:2608.14698*.
32. Lin, S. et al. (2024). SparseTSF: modeling long-term time series forecasting with 1k parameters. *ICML*.
33. Ljung, L. (1999). *System Identification: Theory for the User*, 2nd ed. Prentice Hall.
34. Mallat, S. (1989). A theory for multiresolution signal decomposition: the wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 11(7), 674–693.
35. Meinshausen, N. (2008). Hierarchical testing of variable importance. *Biometrika* 95(2), 265–278.
36. Mhammedi, Z., Koolen, W. M., van Erven, T. (2019). Lipschitz adaptivity with multiple learning rates in online learning. *COLT*.
37. Miller, C. et al. (2020). The Building Data Genome Project 2, energy meter data from the ASHRAE Great Energy Predictor III competition. *Scientific Data* 7, 368.
38. Moulin, A., Esposito, E., van der Hoeven, D. (2025). When lower-order terms dominate: adaptive expert algorithms for heavy-tailed losses. *arXiv:2506.01722*.
39. Orabona, F., Pál, D. (2018). Scale-free online learning. *Theoretical Computer Science* 716, 50–69.
40. Raftery, A. E., Kárný, M., Ettler, P. (2010). Online prediction under model uncertainty via dynamic model averaging. *Technometrics* 52(1), 52–66.
41. Ramdas, A., Grünwald, P., Vovk, V., Shafer, G. (2023). Game-theoretic statistics and safe anytime-valid inference. *Statistical Science* 38(4), 576–601.
42. Sani, A., Neu, G., Lazaric, A. (2014). Exploiting easy data in online optimization. *NeurIPS* 27.
43. Stambaugh, R. F. (1999). Predictive regressions. *Journal of Financial Economics* 54(3), 375–421.
44. van Erven, T., Grünwald, P., de Rooij, S. (2012). Catching up faster by switching sooner: a predictive approach to adaptive estimation with an application to the AIC–BIC dilemma. *Journal of the Royal Statistical Society B* 74(3), 361–417.
45. V'yugin, V., Trunov, V. (2019). Online aggregation of unbounded losses using shifting experts with confidence. *Machine Learning*; *arXiv:1808.00741*.
46. Wang, H., Ramdas, A. (2023). Catoni-style confidence sequences for heavy-tailed mean estimation. *Stochastic Processes and their Applications*.
47. Waudby-Smith, I., Ramdas, A. (2024). Estimating means of bounded random variables by betting. *Journal of the Royal Statistical Society B* 86(1), 1–27.
48. Widrow, B., Stearns, S. D. (1985). *Adaptive Signal Processing*. Prentice Hall.
49. Xu, Z., Ramdas, A. (2024). Online multiple testing with e-values. *AISTATS*.
50. Xu, Z., Zeng, A., Xu, Q. (2024). FITS: modeling time series with 10k parameters. *ICLR*.
51. Yao, Z., Gang, B., Sun, W. (2025). Safe, always-valid alpha-investing rules for doubly sequential online inference. *arXiv:2512.12244*.
52. Yekutieli, D. (2008). Hierarchical false discovery rate-controlling methodology. *Journal of the American Statistical Association* 103(481), 309–316.
53. Zeng, A., Chen, M., Zhang, L., Xu, Q. (2023). Are transformers effective for time series forecasting? (DLinear, NLinear). *AAAI*.

26. Histórico de revisões

- **Revisão 0** (09/10/2026): primeira edição, depois da promoção; descrevia só os componentes novos.
- **Revisão 1** (09/10/2026): documento autocontido — descreve a LEBRE inteira (núcleo, M1 e M2: arquitetura, teoria, ciclo de vida, condição de uso, salvaguardas, custo, evidência, parâmetros e pseudocódigo) sem supor a leitura de nenhum outro documento. Nenhum resultado foi alterado.