ESPECIFICAÇÃO V0.55 · REVISÃO 0

LEBRE v0.55 — Especificação e Relatório Técnico

Previsão online com mudanças de estrutura testadas estatisticamente contra a previsão que cada unidade pode melhorar, estrutura de inovação, especialista de precisão que dorme sem uso e ponto de partida na referência trivial, sob orçamento computacional declarado

LEBRE: Lifecycle-governed Evidence-Based Resource Evolution
Arquitetura: núcleo estrutural ancorado (memória + estruturas de nível e de inovação + médias dinâmicas aninhadas, com mudanças testadas por e-process, remoção disparada e relatório de equivalentes) + M1 (especialista de precisão, dormente sem uso) + M2 (referência trivial)

STATUS

versão de pesquisa promovida por regra pré-registrada e vinculante (17/10/2026); escopo: previsão de um passo à frente com entradas

AVALIAÇÃO FINAL

84 séries reservadas; nenhuma piora por família além da margem contra a versão anterior (razão de erro 0,993 a 1,008); entradas placebo na estrutura final em 0 de 84 séries (anterior: 4)

CUSTO

0,989 vez o da versão anterior por série (mediana); memória estimada 84,2 KB

ESCOPO DA EVIDÊNCIA

entradas espúrias barradas em séries de níveis (sintéticos e placebo real); nas bacias, piora pequena e um ARX de mínimos quadrados recursivos do mesmo custo é melhor; ganho em séries integradas só nos sintéticos

Sumário

1. Sumário executivo §1
2. O problema, a premissa e o escopo §2
3. Princípios de projeto §3
4. Visão geral da arquitetura §4
5. Base teórica do núcleo estrutural §5
6. Base teórica de M1 e M2: agregação de previsores §6
7. Ciclo de vida de uma mudança de estrutura §7
8. A condição de uso: desajuste da referência §8
9. M1: especialista de precisão e dormência §9
10. M2: ponto de partida na referência trivial §10
11. Salvaguardas de saída e intervalo §11
12. Custo computacional e memória §12
13. Observabilidade e explicabilidade §13
14. Metodologia de avaliação §14
15. Evidência do núcleo estrutural §15
16. O núcleo em microcontrolador simulado §16
17. Desenvolvimento das camadas e das versões v0.54 e v0.55 §17
18. Validações em dados novos §18
19. Avaliações finais pré-registradas, comparação externa, auditoria e erratas §19
20. Evolução da arquitetura e ablações §20
21. Posição na literatura §21
22. Limites e afirmações que não fazemos §22
23. Parâmetros §23
24. Pseudocódigo e condições de reprodutibilidade §24
25. Referências §25
26. Histórico de revisões §26

1. Sumário executivo

A **LEBRE** é um previsor **online** de séries temporais com entradas: a cada passo ela recebe as entradas e, quando disponível, o valor do alvo; prevê o próximo valor, aprende com o erro e segue, sem reprocessar o passado e sem treino prévio. O custo por passo é contado operação a operação: mediana de 870 operações de ponto flutuante por passo na avaliação final da versão anterior, e 0,989 vez isso, por série, na desta versão.

Ela tem três camadas (§4). O **núcleo estrutural** é um modelo vivo simples (uma memória do próprio alvo e uma regressão linear nas entradas) cuja estrutura só muda por experimento: um desafiante em sombra propõe acrescentar, remover, trocar ou refinar a resposta a uma entrada inteira, e a mudança só é aceita quando um *e-process* — um teste sequencial válido a qualquer momento — acumula evidência suficiente, dentro de um procedimento online de multiplicidade. A **M1** combina a previsão do núcleo com um especialista de precisão (uma regressão recursiva sobre o passado do alvo e médias de defasagem das entradas). A **M2** faz a previsão partir de uma referência trivial declarada (zero, persistência ou sazonal ingênuo) e só confiar na parte adaptativa quando ela se mostra melhor.

Esta versão (v0.55) muda **a pergunta** que a evidência responde (§5.10). Uma entrada externa passa a ser aceita só se melhorar **a previsão do núcleo**, que já contém a memória do próprio alvo, e não apenas a estrutura de nível; o passado do próprio alvo e o estado do resíduo continuam testados contra a estrutura de nível. Uma **estrutura de inovação**, com as mesmas unidades aceitas, leva a informação delas à previsão quando o alvo é integrado; um **portão suave** na triagem só dá vaga de teste a uma unidade interna se ela explica o que o núcleo ainda erra; e a escala dos testes passa a ser previsível e medida na escala de uma passada. O efeito foi medido com um controle novo: entradas *placebo* (passeios aleatórios sem relação nenhuma com a série) acrescentadas às séries reais da avaliação final.

A versão anterior (v0.54) estendeu o princípio "mudar só com evidência, a custo conhecido" a duas coisas: o **custo**, que passa a ser gasto só onde há uso — a M1 *dorme* enquanto o seu peso é desprezível (§9) e o relatório de entradas equivalentes passa a ser barato (§12, §13) —, e a **saída** de estrutura — um teste de remoção com evidência própria abre quando a contribuição de uma unidade cai (§5.9, §7). Nenhuma dessas peças é nova isoladamente; o documento descreve a combinação, as condições em que ela funciona e o que foi medido.

Premissa: a LEBRE **não pretende ser o previsor mais preciso**. O objetivo é entregar previsões úteis, sem falhas graves, com custo por passo baixo e previsível, sem ajuste por série e com cada mudança de estrutura registrada e justificada. Modelos caros são tratados como **tetos de referência**, não como adversários.

O que foi medido

- **Avaliação final pré-registrada da v0.55** (84 séries reservadas: bacias, prédios, usinas eólicas e solares e taxas do euro do BCE): nenhuma família com piora além da margem (razão de 0,993 a 1,008 contra a versão anterior); **entradas placebo na estrutura final em 0 de 84 séries, contra 4 na versão anterior**; custo mediano por série 0,989 vez o anterior (§19.1).
- **Banco sintético fixo e confirmação** (23 cenários com verdade conhecida, sementes nunca usadas): entradas espúrias em passeios aleatórios 0 de 60 (versão anterior: 22); retenção da entrada verdadeira igual ou melhor em todos os cenários; nas séries integradas com entrada verdadeira, erro 0,913 [0,907; 0,918] vez o da versão anterior (§17).
- **Comparação com 12 modelos externos** nas mesmas séries (correção de Holm): melhor que o SARIMAX com entradas em todas as famílias; o Chronos-2 com covariáveis, ~10^6 vezes mais caro, é melhor em prédios, solar e eólica; nas bacias, um ARX com mínimos quadrados recursivos, da mesma classe de custo, é melhor (§19.2).
- **Avaliação final pré-registrada da v0.54** (93 séries reservadas antes de qualquer código da v0.54; bacias, prédios, usinas eólicas e solares e níveis de preços e juros): sem piora em nenhuma família em relação à versão anterior (erro de 0,989 a 1,000 vez o dela por família) e custo mediano por série de **0,905** vez o dela [IC 95% 0,857; 0,932] (§19).
- **M1 e M2 sobre o núcleo** (avaliação final anterior, pré-registrada, 104 séries): erro 0,955 [0,951; 0,960] vez o do núcleo sozinho, sem piora em nenhuma família; o ganho vem de Bacias (CAMELS-BR) 0,879, Câmbio: níveis 0,952, Câmbio: retornos 0,966, Prédios (BDG2) 0,993 (§19.6).
- **Tetos de referência:** contra o Chronos-2 com covariáveis (modelo de fundação de ~10^9 operações por previsão), razão de 0,84 a 1,34 por família na avaliação final — menor que 1 em bacias e níveis, maior em prédios, solar e eólica (§19).
- **O núcleo na sua classe de orçamento** (avaliação pré-registrada própria, 60 séries de bacias e prédios): erro relativo ao NLinear online de 0,812 [0,752; 0,866], o menor entre os oito comparadores de custo semelhante avaliados, sem nenhuma série com falha grave (§15).
- **Auditoria de estresse** depois da promoção (10 testes, de identidade a 200 mil passos): nenhum defeito de correção nem falha catastrófica; dois defeitos achados — um corrigido na errata 01 (pico de custo), outro declarado como limite (relações que somem e voltam) (§19.7).

Limites principais: previsão de um passo; nas bacias, piora pequena e significativa contra a versão anterior (1,008) e um ARX de mínimos quadrados recursivos do mesmo custo erra menos; o ganho em séries integradas aparece nos sintéticos, mas não nas séries de níveis reais testadas; relações reais fracas são registradas como estrutura mais devagar; a remoção de uma relação que some por mais de ~5.200 passos e

volta custa 5% a 10% de erro em séries com esse padrão; o ciclo precisa ser declarado; o mecanismo de testes do núcleo **não melhorou a precisão** em relação a ligar todas as entradas sem testes (razão 0,988 [0,970; 1,006] em 100 séries, exploratório); não há garantia formal de erro na escala original para M1 e M2; o microcontrolador foi simulado e só para o núcleo. Nenhum componente é original (§21, §22).

2. O problema, a premissa e o escopo

O problema

Muitos sistemas medem continuamente um alvo (vazão de um rio, consumo de um prédio, geração de uma usina, carga elétrica, uma taxa de câmbio) junto com entradas que o influenciam, muitas vezes com atraso (chuva, temperatura, vazões a montante, outras moedas). Prever o próximo valor *no próprio dispositivo* exige três coisas ao mesmo tempo: custo por passo muito baixo, funcionamento sem ajuste por série e sem treino prévio, e um comportamento que não falhe de forma grave quando o fluxo tem lacunas, mudanças ou é quase imprevisível. Os modelos modernos mais precisos (modelos de fundação) custam de 10^7 a 10^{10} operações por previsão; os modelos clássicos ajustados série a série precisam de otimização por máxima verossimilhança; e os modelos lineares online baratos não sabem, sozinhos, quais entradas e atrasos importam, nem quando é melhor não arriscar nada além de uma previsão trivial.

A premissa

A LEBRE ocupa um ponto específico do compromisso entre precisão, custo e transparência. Ela é avaliada **dentro da sua classe de orçamento** (modelos com até ~10^4 operações por previsão), com os modelos caros como tetos. "Entregar bem" significa: erro competitivo na classe, **nenhuma falha catastrófica**, não perder para uma previsão trivial declarada, custo previsível e explicação de cada mudança.

Escopo

- previsão de **um passo à frente**, online, com as entradas do instante atual disponíveis (como em controle e em previsão de curtíssimo prazo);
- séries com **poucas entradas** e relação aproximadamente linear, com atrasos de até 31 passos no núcleo e até 15 no especialista de precisão;
- o ambiente informa apenas o período de amostragem (por exemplo, 24 para dados horários com ciclo diário; nos prédios, também 168 para o ciclo semanal) e a referência trivial adequada ao alvo (zero para variações como retornos financeiros, sazonal ingênuo quando há ciclo, persistência nos demais casos);
- entradas padronizadas de forma causal (média e variância exponenciais), como contrato de entrada.

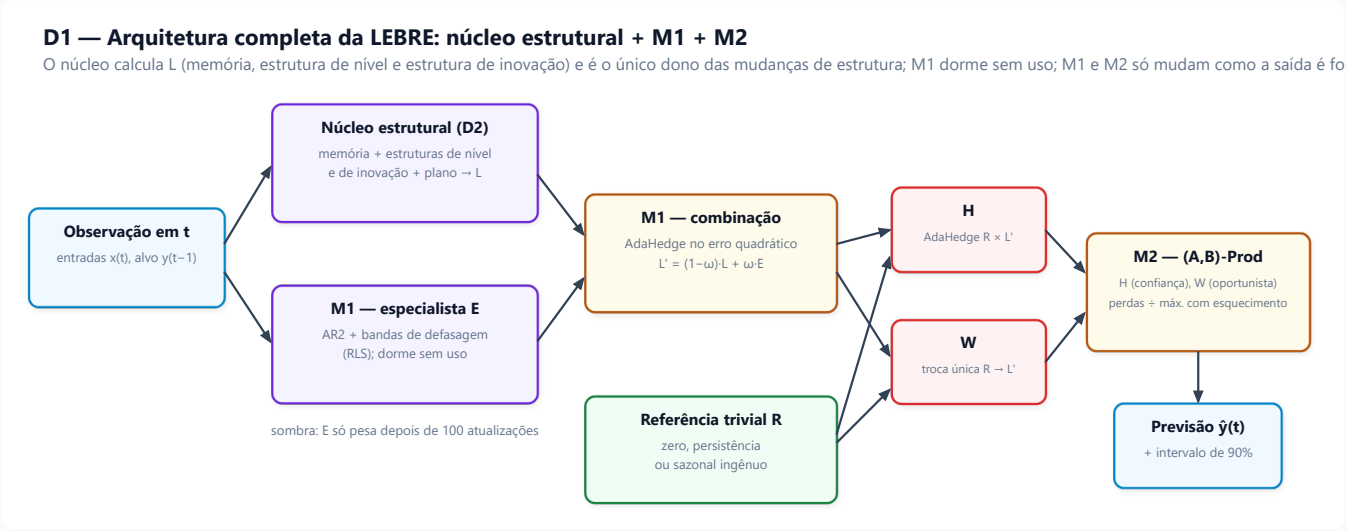
O que a LEBRE não é

Não é um modelo de fundação nem um previsor de longo horizonte; não modela relações fortemente não lineares; não afirma causalidade física (uma entrada aceita é uma entrada com *relevância preditiva* certificada contra a referência, e entradas quase idênticas são reportadas como grupo). O nome vem da família original de arquiteturas do projeto (*Lifecycle-governed Evidence-Based Resource Evolution*): estrutura que entra e sai do modelo por evidência, dentro de um orçamento.

3. Princípios de projeto

Princípio	Significado
Toda mudança de estrutura é um experimento	A estrutura só muda quando um teste sequencial sempre válido rejeita "a mudança não melhora a previsão"; cada aceitação tem um nível de erro fixado antes.
Unidade = uma entrada inteira	A pergunta é "esta entrada ajuda?", e não "este atraso ajuda?": menos hipóteses, mais poder, resposta refinada depois por divisões hierárquicas.
Partir do trivial	A previsão final parte de uma referência trivial declarada e só passa a confiar na parte adaptativa quando ela se mostra melhor nos próprios dados.
Camadas que não mexem no núcleo	M1 e M2 só mudam como a previsão final é formada; as decisões de estrutura são as mesmas com ou sem elas (verificado em todas as séries avaliadas).
Gastar só onde há uso	Uma parte que não está contribuindo passa a custar pouco, mas continua medindo se voltou a ser útil: a M1 dorme enquanto o seu peso é desprezível e desperta pela evidência; o relatório de equivalentes usa uma amostra a cada 31 passos.
A estrutura também sai	Quando a contribuição de uma unidade cai, um teste de remoção com evidência própria (só dos passos do episódio) decide se ela ainda se sustenta; remover exige pelo menos tanto tempo de evidência quanto uma adição pode usar.
A pergunta certa para cada unidade (v0.55)	Uma entrada externa só entra se melhorar a previsão do núcleo, que já contém o passado do próprio alvo; o passado do alvo e o estado do resíduo são testados contra a estrutura de nível, que é a previsão que eles podem melhorar.
O que é aceito chega à saída (v0.55)	A estrutura de inovação usa as mesmas unidades aceitas para prever o que a memória não prevê, e ganha peso só onde ajuda; um teste que não pode mudar a previsão não recebe vaga.
Custo fixo e declarado	Custo por passo fixo dado o número de entradas, contado operação a operação, com limites declarados antes de cada avaliação; o resultado é reportado mesmo quando o limite não é cumprido (§12).
Sem ajuste por série	As mesmas constantes em qualquer série; o ambiente informa só o(s) período(s) e a referência trivial.
Silêncio e dados fora do contrato não são evidência	Sem alvo observado, com entrada recortada ($\|x\| > 8\sigma$) ou em quarentena, nada da estrutura aprende e nenhuma evidência é acumulada.
Saída dentro de contrato	A previsão do núcleo nunca sai de um envelope dos valores já observados, e lacunas do alvo não fecham a malha da memória.
Observabilidade	Cada mudança é registrada com instante, tipo, evidência e grupo de entradas equivalentes; os pesos de M1 e M2 são legíveis a cada passo; a previsão vem com intervalo adaptativo.

4. Visão geral da arquitetura



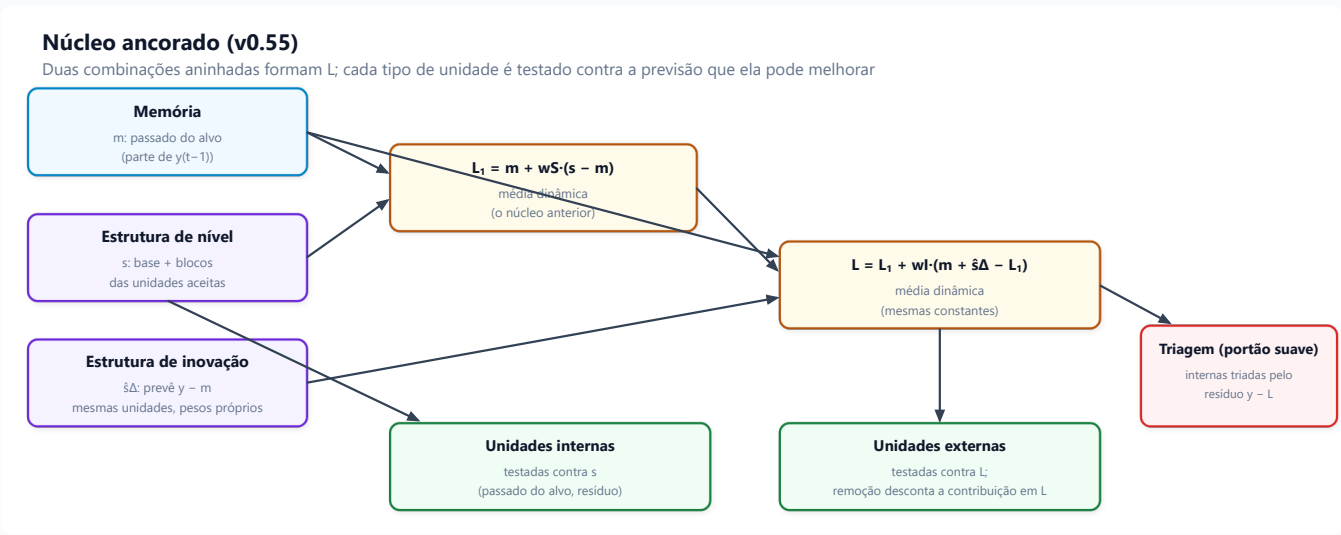
Visão completa de um passo de previsão. O núcleo roda inteiro por baixo; M1 forma L' a partir de L; M2 forma a saída a partir de L' e da referência R.

A LEBRE tem três camadas, executadas nesta ordem a cada passo:

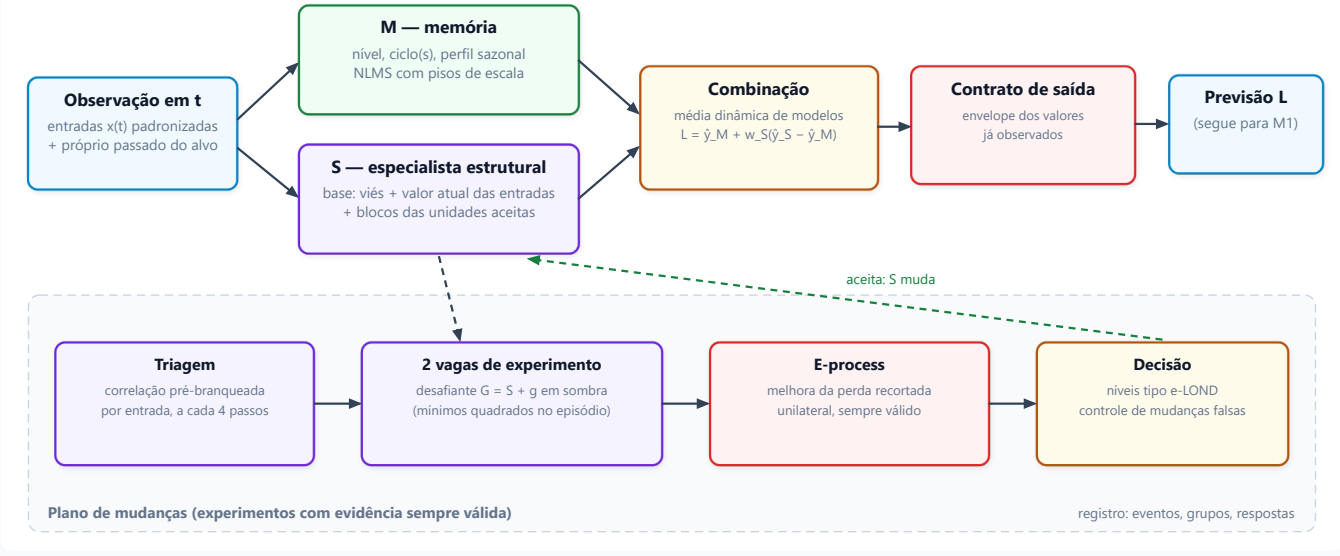
1. **Núcleo estrutural** (D2): produz a previsão L e é o único dono das mudanças de estrutura. Tem dois especialistas e uma combinação no caminho da previsão, e um plano de mudanças em sombra.
2. **M1 — especialista de precisão** (§9): uma regressão recursiva E sobre o passado do alvo e médias de defasagem das entradas mais correlacionadas, combinada com L por AdaHedge no erro quadrático: L' = (1 − ω)·L + ω·E. Onde E não ajuda, ω vai a zero e L' = L.
3. **M2 — ponto de partida na referência trivial** (§10): mistura R e L' por dois caminhos — H, conservador (AdaHedge), e W, que troca de R para L' uma única vez (switch distribution) — e combina os dois por um (A,B)-Prod, que garante não ficar muito atrás de H.

Três mecanismos atuam dentro dessas camadas e não mudam o que a LEBRE prevê onde a parte em questão está sendo útil: a **dormência da M1** (§9), a **remoção disparada** no plano de mudanças do núcleo (§5.9, §7) e o **relatório de equivalentes barato** no núcleo (§12, §13). Enquanto a M1 não dorme e nenhuma remoção disparada abre, as previsões são idênticas às da arquitetura sem esses mecanismos.

O núcleo ancorado (v0.55, §5.10). O núcleo tem agora três previsões internas: a memória m, a estrutura de nível s e a **estrutura de inovação** ŝΔ, que prevê o que a memória não prevê (y − m) com as mesmas unidades aceitas e pesos próprios. Duas médias dinâmicas aninhadas formam a previsão: $L_1 = m + wS\cdot(s - m)$, como antes, e $L = L_1 + wI\cdot((m + \hat{s}\Delta) - L_1)$. As unidades externas são testadas contra L; as internas, contra s.



Núcleo ancorado: as duas combinações aninhadas e a referência de cada tipo de teste.



Núcleo estrutural. Os dois especialistas e a combinação formam o caminho da previsão L. O plano de mudanças roda em sombra e só altera S quando uma mudança é aceita.

Memória (M). Prevê o alvo a partir do seu próprio passado, relativo ao último valor: reversão a uma média lenta, última diferença, termos sazonais do(s) ciclo(s) declarado(s) e um perfil de incrementos por fase do ciclo. **Especialista estrutural (S).** Regressão linear no valor atual de cada entrada (a "base") mais os *blocos de resposta* das unidades aceitas. **Combinação.** Média dinâmica de modelos entre M e S, com peso que acompanha qual dos dois vem errando menos. **Plano de mudanças.** Uma triagem barata aponta a candidata mais promissora; até dois experimentos rodam em sombra; um e-process acumula a evidência de cada mudança; um procedimento de níveis online decide.



Ordem das operações num passo. A previsão em t é emitida antes de y(t) ser lido; M1 e M2 aprendem depois do núcleo, com o mesmo y(t).

5. Base teórica do núcleo estrutural

Esta seção reúne a base teórica do núcleo. **Todas as ferramentas vêm da literatura** (citada em cada item); o que é específico da LEBRE é a forma de combiná-las e as condições de uso verificadas (§8).

5.1 Aprendizado linear online: NLMS e mínimos quadrados recursivos

O modelo vivo (base de S, pesos dos blocos e memória) aprende por **NLMS** (mínimos quadrados médios normalizados; Widrow & Stearns 1985; Haykin 2002):

$$w_{t+1} = w_t + \mu \, \frac{e_t}{\|\phi_t\|^2 + \delta} \, \phi_t, \qquad e_t = y_t - w_t^\top \phi_t.$$

Em regime estacionário, o **desajuste** (excesso relativo de erro quadrático por causa da oscilação dos pesos) é aproximadamente $M \approx \mu/(2-\mu)$. O núcleo usa μ = 0,05 em S e na memória.

Os **desafiantes** usam mínimos quadrados recursivos (RLS) sem esquecimento dentro de cada episódio, com $P_0 = 10\,I$: com poucos parâmetros (5 a 7), o RLS converge em dezenas de amostras e dá um coeficiente praticamente constante no episódio, o que importa para a condição de uso (§8). O especialista de precisão da M1 também usa RLS, com esquecimento (§9).

5.2 Memória: suavização exponencial em forma de regressão

A memória é uma regressão do incremento sobre atributos do próprio passado, inspirada no modelo *airline* (Box & Jenkins 1970) e no estado sazonal do Holt-Winters (Hyndman et al. 2008) — analogia, não equivalência:

$$\begin{aligned}\hat{y}_t^M = {} & y_{t-1} + w_1(m_t - y_{t-1}) + w_2(y_{t-1} - y_{t-2}) + w_3(y_{t-s} - y_{t-1}) + w_4(y_{t-s+1} - y_{t-s}) + w_5 G_{t \bmod s} \\ & + \left[\, w_6(y_{t-s_2} - y_{t-1}) + w_7(y_{t-s_2+1} - y_{t-s_2}) \,\right]\end{aligned}$$

m: média exponencial lenta (taxa 0,01); G: média exponencial (taxa 0,1) dos incrementos observados na mesma fase do ciclo; s_2: segundo ciclo declarado (semana, nos prédios). A normalização do NLMS tem pisos relativos à escala (10^{-3} da potência média dos atributos e 10^{-4} da escala lenta de y), para que trechos planos não produzam passos enormes.

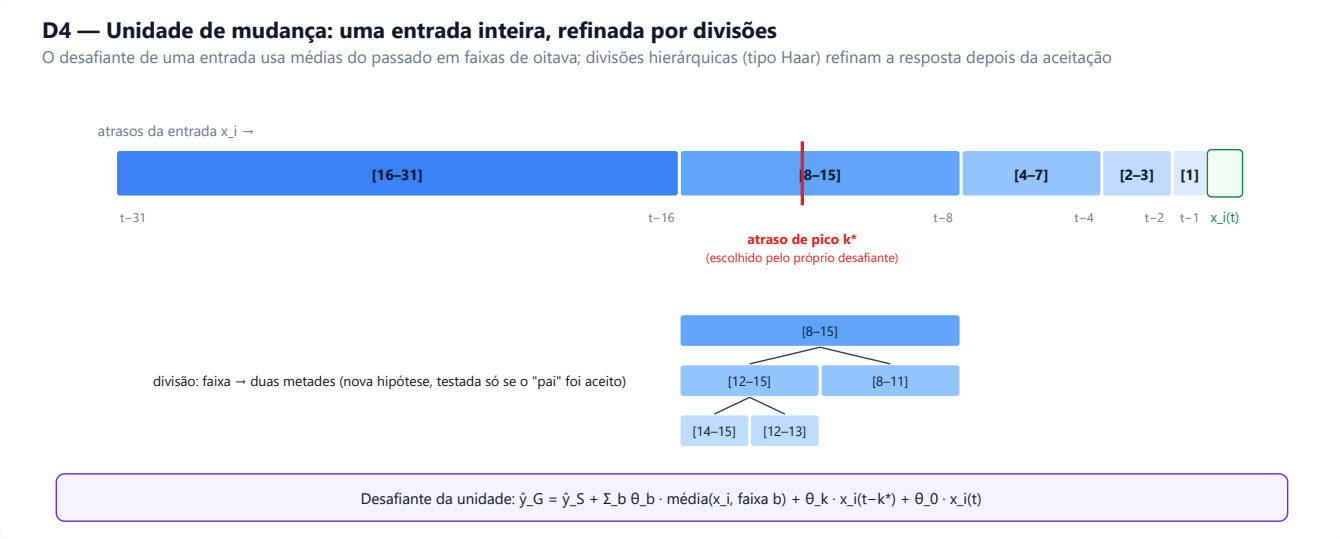
5.3 Combinação no núcleo: média dinâmica de modelos

O peso de S segue a diferença descontada de perdas entre os dois especialistas (Raftery, Kárný & Ettler 2010; forma logística equivalente a pesos exponenciais de especialistas):

$$D_t = 0{,}99\, D_{t-1} + \frac{(y_t - \hat{y}_t^S)^2 - (y_t - \hat{y}_t^M)^2}{\hat{\sigma}^2}, \qquad w_S = \frac{1}{1 + e^{\,0{,}5\, D_t}}, \qquad L_t = \hat{y}_t^M + w_S(\hat{y}_t^S - \hat{y}_t^M).$$

5.4 Representação da resposta: faixas de oitava, atraso de pico e divisões de Haar

A resposta de uma entrada é aproximada por médias do seu passado em faixas diádicas [1], [2–3], [4–7], [8–15], [16–31] — uma resolução que diminui com o atraso, como nas decomposições em multirresolução (Mallat 1989) e nos modelos de defasagem distribuída. Uma média de faixa dilui um atraso isolado (retém ~1/largura do efeito); por isso o desafiante carrega também o seu **atraso de pico** k*, escolhido por ele mesmo pela maior correlação pré-branqueada nas primeiras 200 amostras do aquecimento — antes de qualquer evidência, o que mantém o desafiante previsível. Depois da aceitação, cada faixa pode ser **dividida** nas duas metades (um coeficiente de Haar); cada divisão é uma nova hipótese, testada só se o "pai" foi aceito, no espírito do teste hierárquico (Meinshausen 2008; Yekutieli 2008).



Representação da resposta a uma entrada: médias em faixas de oitava, o valor atual e um atraso de pico; depois da aceitação, cada faixa pode ser dividida em metades, uma hipótese por divisão.

5.5 Triagem: pré-branqueamento e estatística de grupo

Para escolher a próxima candidata sem testar todas, cada entrada inativa tem uma estatística de grupo: correlações exponenciais (peso 0,02) entre o resíduo de S e as médias de faixa, ambos **pré-branqueados** por um AR(1) causal da entrada (Box & Jenkins 1970), somadas em quadrado e normalizadas pela variância nula. A unidade é aberta se a estatística passa do quantil 99% de χ^2_5 (15,09); uma divisão, do quantil 99% de χ^2_1 (6,63), sobre o detalhe de Haar. A triagem **não gera evidência**: ela só escolhe o que testar, e o controle de erro vem inteiro do e-process.

5.6 Evidência sempre válida: e-processes de melhora preditiva

Um **e-process** é um processo não negativo cuja esperança, sob a hipótese nula, não passa de 1 em nenhum tempo de parada; por Ville, a probabilidade de ele alguma vez ultrapassar 1/α é ≤ α. Isso permite olhar a evidência a cada passo, pausar e retomar sem inflar o erro (Ramdas, Grünwald, Vovk & Shafer 2023; Grünwald, de Heide & Koolen 2024). O núcleo usa a comparação sequencial de previsores de Choe & Ramdas (2024), com a nula *fraca*: em média, o desafiante não melhora a perda da referência em mais que uma margem ε.

Perda recortada e diferencial, com a referência R_t do teste (§5.10: a previsão do núcleo L para unidades externas, a estrutura de nível s para as internas) e a escala, calculada antes de ver y_t, $B_t = 2\max(\hat{\sigma}_t^R,\ 0{,}1\, s_t^{passo})$, $s_t^{passo} = \sqrt{\min(v_t^{nível},\ v_t^{\Delta y})}$:

$$\ell_t(u) = \min\{(y_t - u)^2 / B_t^2,\ 1\}, \qquad d_t = \ell_t(R_t) - \ell_t(g_t) - \varepsilon.$$

E-process de mistura sub-exponencial, com centragem previsível $\gamma_i = \min(\bar{d}_{i-1}, 0)$ e 8 valores de λ:

$$E_n = \frac{1}{8}\sum_{j=0}^{7} \exp\left\{\lambda_j \sum_{i\le n} d_i - \psi_{E,c}(\lambda_j) \sum_{i\le n} (d_i - \gamma_i)^2\right\}, \quad \psi_{E,c}(\lambda) = \frac{-\log(1-c\lambda) - c\lambda}{c^2}, \quad \lambda_j = \frac{0{,}9 \cdot 2^{-j}}{c}.$$

A constante c unilateral. O enunciado de Choe & Ramdas supõe |d_i − γ_i| ≤ c, o que daria c = 2(1+|ε|). A demonstração de base (Howard et al. 2021, §A.8) usa apenas o lema de Fan, Grama & Liu (2015): exp{λξ − ψ_E(λ)ξ²} ≤ 1 + λξ para ξ ≥ −1 e λ ∈ [0,1). Para o

teste unilateral, sob a nula fraca E[d_i | passado] = μ_i ≤ 0, basta a cota **inferior** d_i − γ_i ≥ −c:

$$\mathbb{E}_{i-1}\left[e^{\lambda(d_i-\gamma_i)-\psi_{E,c}(\lambda)(d_i-\gamma_i)^2}\right] e^{\lambda(\gamma_i-\mu_i)} \le \big(1+\lambda(\mu_i-\gamma_i)\big)e^{\lambda(\gamma_i-\mu_i)} \le 1.$$

Como λΣd_i ≤ λΣ(d_i − μ_i), o processo é limitado por uma supermartingala não negativa. Como d_i ≥ −(1+ε) e γ_i ≤ 0, vale $c = 1 + \max(\varepsilon, 0)$. A mistura de e-processes é um e-process, e as pausas entre episódios formam uma subsequência previsível.

Validade com qualquer aprendiz previsível (nota formal F1). A dedução acima não usa nada sobre como R_t e g_t são aprendidos: basta que R_t, g_t, B_t e a escolha dos passos testados sejam conhecidos antes de y_t. Então o processo é um e-process sob a nula fraca qualquer que seja o passo do NLMS, o seu desajuste, a dependência temporal ou uma quebra de regime; pausas, episódios e durações mínimas são escolhas previsíveis ou tempos de parada. A prova foi escrita por extenso, com uma conferência numérica das desigualdades nas faixas usadas, e **ainda não teve conferência independente**. **Errata 01 da nota:** no núcleo da v0.54, o piso da escala era calculado depois de atualizar a variância com o próprio y_t, e B_t não era estritamente previsível (efeito de ordem 1/n por passo); a v0.55 calcula o piso antes de ver y_t.

Esta observação é uma leitura direta da demonstração publicada, não um resultado novo. Numa simulação de desenvolvimento (400 trajetórias × 5.000 passos, nula no limite) o erro tipo I ficou ≤ 0,025 contra α = 0,05, e o poder subiu de 0,66 (c de dois lados) para 0,77 (§15). A alternativa por apostas com λ previsível (Waudby-Smith & Ramdas 2024) teve mais poder, mas aceitou substitutas quase idênticas da entrada verdadeira e não foi adotada.

5.7 Multiplicidade ao longo do fluxo: níveis tipo e-LOND

Cada hipótese de mudança recebe, ao ser criada, um nível fixo que depende apenas do número de hipóteses já criadas e de mudanças já aceitas (regra LOND de Javanmard & Montanari 2018, na versão para e-valores de Xu & Ramdas 2024). Isso controla a taxa de mudanças falsas (FDR) ao longo de um fluxo sem fim, com decisões assíncronas:

$$\alpha_n = \min\big(\alpha\,\gamma_n\,(R_n+1),\ 0{,}5\big), \qquad \gamma_n = \begin{cases} 1/(2P) & n \le P \\ \tfrac{1}{2}\,C/\big((n-P)\log^2(n-P+1)\big) & n > P \end{cases}, \qquad \text{aceita se } \log E \ge \log(1/\alpha_n),$$

com α = 0,05, P = 2 × (número de unidades) e C tal que Σγ_n ≤ 1. Uma hipótese é *persistente*: a sua evidência se acumula entre episódios.

Por que vale com decisões assíncronas: o nível de cada hipótese depende só do seu índice de criação e das aceitações anteriores à criação; se ela é aceita, o total final de aceitações é pelo menos esse número mais um, e a desigualdade de Markov em cada e-value parado limita a contribuição dela a α·γ_n. Somando, FDR ≤ α por motor, sob dependência arbitrária. **Os motores juntos:** as remoções disparadas (§5.9) têm motor e orçamento próprios; o limite conjunto das mudanças de estrutura é, portanto, 2α = 0,10, e não α.

5.8 Intervalo adaptativo

O intervalo de 90% é um quantil do erro absoluto atualizado por retroalimentação da cobertura, no espírito da inferência conforme adaptativa (Gibbs & Candès 2021): a cada 8 passos, q̂ ← max(0, q̂ + 0,1·σ̂Σ(erro fora − 0,1)). A mesma regra é aplicada ao erro da saída final (§11). Não há garantia formal de cobertura sob dependência; a cobertura empírica é reportada.

5.9 Remoção com evidência por episódio

A hipótese de remoção de uma unidade é persistente (§5.7): acumula a evidência de todos os episódios desde a aceitação. Numa série com troca de regime, a evidência de antes da troca, quando remover era claramente pior, pesa para sempre, e a remoção nunca chega ao limiar. A nula "em média sobre todo o passado testado" é a nula errada para remover. Por isso, além do calendário periódico (que continua igual), o plano de mudanças abre um **teste de remoção disparado** quando a contribuição média da unidade cai abaixo da metade da sua referência, com uma hipótese nova por episódio: "nos passos deste episódio, remover não melhora a perda recortada em mais que a margem".

- **Validade.** A regra de abertura usa só o passado; o e-process começa do zero em cada episódio e é o mesmo da §5.6. Aceitar só depois de um número mínimo de passos de evidência é um tempo de parada válido: a desigualdade de Ville vale em qualquer tempo de parada.
- **Orçamento próprio.** Cada teste disparado recebe um nível α·γ_k·(R^rem + 1), com α = 0,05, γ_k = C/(k·log²(k+1)) e R^rem as remoções disparadas já aceitas; k conta só esses testes. As hipóteses de adição, troca e divisão continuam com o orçamento da

§5.7, sem contar remoções: a garantia sobre remoções falsas (remover o que piora mais que a margem) é separada da garantia sobre adições falsas.

- **Por que demora.** Depois de uma troca, o ganho por passo de remover é pequeno na escala da perda recortada (~0,002 além da margem), e o λ ótimo fica acima da grade do e-process; a evidência cresce ~0,001 por passo. Por isso o episódio de remoção pode durar até 10.000 passos, e a aceitação exige pelo menos 5.000 (o tempo máximo de um episódio de adição).

5.10 Núcleo ancorado: a pergunta de cada teste, a estrutura de inovação e o portão

O defeito que motiva a mudança. Pela Proposição 1 (§8), um desafiante ganha evidência sempre que se correlaciona com o erro previsível da referência. Numa série de níveis (um passeio aleatório), a estrutura s não acompanha o nível, porque o passado do alvo entra padronizado por uma média lenta; o seu erro é grande e previsível, e qualquer entrada que também passeia o projeta. A aceitação era válida para a pergunta "melhora s?", mas não para a interpretação "a entrada explica o alvo além do seu próprio passado". A memória tem raiz unitária (parte de y(t−1)), mas os testes não perguntavam se a candidata melhora a previsão que já contém a memória.

- **Referência por tipo de unidade.** Unidades externas (cada entrada e as suas divisões) são testadas contra a previsão do núcleo L; a remoção de uma delas desconta a sua contribuição exata em L. Unidades internas (o passado do próprio alvo, o estado do resíduo e as divisões do passado do alvo) são testadas contra s, porque a pergunta "melhora além do próprio passado?" não faz sentido para o próprio passado. Numa troca, vale o tipo da unidade que entra. A escala B vem do erro de L.
- **Estrutura de inovação.** Numa série integrada, s perde para a memória (wS ≈ 0), e a informação de uma entrada verdadeira sobre as diferenças nunca chegava à previsão. A estrutura de inovação $\hat{s}\Delta$ prevê y − m com as mesmas unidades e atributos de s, pesos próprios e NLMS com o mesmo passo e o mesmo denominador; uma descoberta serve às duas. Onde ela não ajuda (por exemplo, quando seria preciso cancelar o nível), wI vai a zero e o núcleo volta a ser L_1.
- **Pesos de quem aprendeu.** Uma unidade aceita entra em s com os pesos do desafiante. Em $\hat{s}\Delta$, ela entra com os mesmos pesos se for externa (o desafiante aprendeu o resíduo de L) e com zero se for interna (ele aprendeu o resíduo de s, que numa série integrada é enorme); uma divisão interna dá às duas metades o peso da mãe.
- **Portão suave pela triagem.** A triagem das unidades internas passa a usar o resíduo de L, como a das externas. Uma unidade interna só recebe vaga de teste se explica o que o núcleo ainda erra. Um portão rígido, que bloqueava os testes internos enquanto wS < 0,05, foi medido e rejeitado: ele se trava sozinho onde a memória é fraca, porque bloqueia justamente a unidade que faria wS subir.
- **Escala de uma passada.** O piso da escala era 0,1 vez o desvio do *nível* do alvo, que numa série integrada cresce sem limite (no desenvolvimento, o piso chegou a 8 vezes o erro real e escondia entradas verdadeiras). Ele passa a ser 0,1·√(mín(variância do nível, variância de Δy)), com as duas variâncias estimadas causalmente e o piso calculado antes de ver y_t. Nas séries estacionárias, o piso já fica muito abaixo do erro, e nada muda na prática.

$$L_t^{(1)} = m_t + w_t^S\,(s_t - m_t), \qquad L_t = L_t^{(1)} + w_t^I\big((m_t + \hat{s}_t^{\Delta}) - L_t^{(1)}\big), \qquad c_{u,t} = (1 - w_t^I)\,w_t^S\,w_u^\top b_{u,t} + w_t^I\,w_{\Delta,u}^\top b_{u,t},$$

com wI pela mesma média dinâmica de wS (λ = 0,99, η = 0,5, a cada 8 passos) entre L_1 e m + $\hat{s}\Delta$, e c_u a contribuição de uma unidade externa em L.

O que a teoria diz, e o que não diz. A validade do e-process (§5.6) continua valendo: L, s e os pesos são previsíveis. O que muda é a nula estrutural que a nula testada passa a implicar: num passeio aleatório sem estrutura, f* = y(t−1) ≈ m e wS → 0, então o erro previsível de L é pequeno, e pela Proposição 1 as entradas espúrias deixam de ter melhora esperada. Isso **não cobre** entradas substitutas (aceitas enquanto a verdadeira ainda não está no modelo), relações não lineares nem um ciclo não declarado; para esses casos, a evidência é empírica (§17, §19).

6. Base teórica de M1 e M2: agregação de previsores

M1 e M2 são problemas de **previsão com especialistas**: a cada passo há duas previsões disponíveis e é preciso decidir quanto peso dar a cada uma, só com o passado. Três algoritmos da literatura são usados, sem modificação dos seus núcleos; as escolhas da LEBRE são quais perdas eles recebem e como são encadeados.

6.1 AdaHedge

Pesos exponenciais nas perdas acumuladas com taxa de aprendizado ajustada pelos próprios dados (de Rooij et al. 2014): ela é o logaritmo do número de especialistas dividido pela soma acumulada das *lacunas de mistura* (quanto a perda da mistura excedeu a

perda "de mistura" ideal). O arrependimento contra o melhor especialista cresce como a raiz da variação das perdas, e o algoritmo é **invariante a translação e escala** das perdas: não precisa saber a escala do erro, o que permite usar o erro quadrático sem recorte nem normalização.

$$w_{k,t} = \frac{e^{-\eta_t S_{k,t-1}}}{\sum_j e^{-\eta_t S_{j,t-1}}}, \qquad \eta_t = \frac{\ln K}{\Delta_{t-1}}, \qquad \Delta_t = \Delta_{t-1} + \left(\sum_k w_{k,t}\ell_{k,t} + \tfrac{1}{\eta_t} \ln \sum_k w_{k,t} e^{-\eta_t \ell_{k,t}} \right),$$

com S_k a perda acumulada do especialista k e K = 2. Quando Δ = 0, os pesos seguem o líder.

6.2 Switch distribution com uma troca

A *switch distribution* (van Erven, Grünwald & de Rooij 2012) é uma mistura bayesiana sobre sequências de especialistas que permite trocar de especialista ao longo do tempo. A LEBRE usa a versão mais simples: três hipóteses — "sempre R", "sempre L'" e "R até algum instante, L' depois" —, com prioris iguais e risco de troca 1/(n+1) no instante n. A posterior é atualizada pelas verossimilhanças gaussianas das duas previsões, com variância comum igual ao menor erro quadrático recente das duas (com piso). Ela concentra peso rapidamente na referência quando a parte adaptativa não ajuda, e troca uma vez quando a parte adaptativa passa a ser claramente melhor. Quando toda a massa está de um lado, a atualização direta pode dar 0/0 por *underflow*; nesse caso a mesma conta é feita em escala logarítmica.

6.3 (A,B)-Prod: não ficar muito atrás de um especialista de confiança

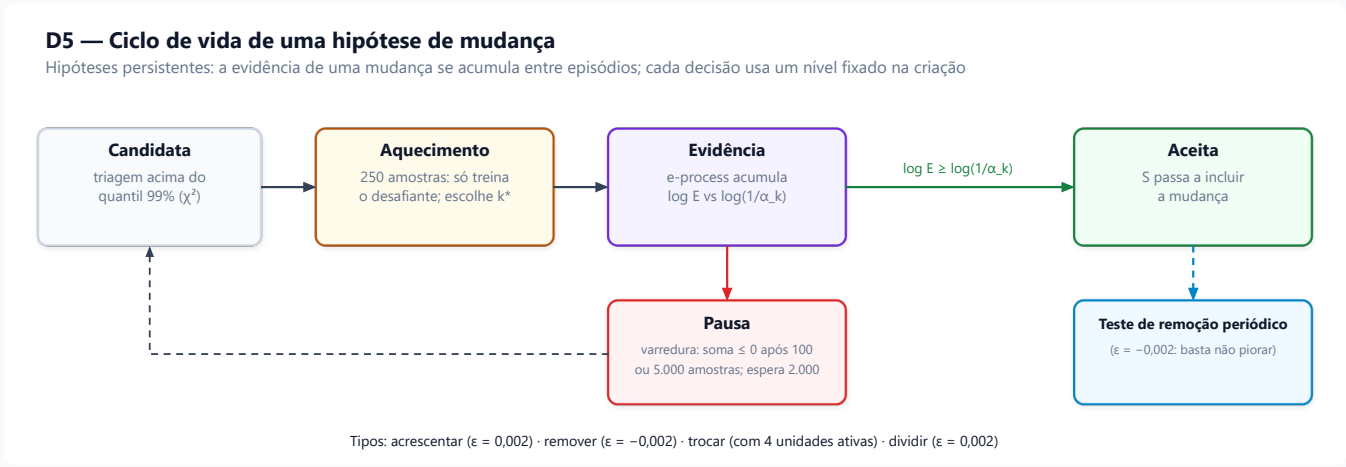
O (A,B)-Prod (Sani, Neu & Lazaric 2014) combina um algoritmo *oportunista* A com um algoritmo de *confiança* B. O peso de B é fixo em 1/2 e o de A é atualizado multiplicativamente pela diferença de perdas; a fração dada a A é s_t. Para perdas em [0, 1], ele garante arrependimento **constante** contra B e da ordem de √(T log log T) contra A, na versão sem horizonte conhecido. Esse tipo de garantia assimétrica — quase nada a perder contra a escolha segura — vem da fronteira de Pareto do arrependimento (Even-Dar et al. 2008; Koolen 2013).

$$s_t = \frac{\eta_t w_t^A}{\eta_t w_t^A + w^B/2}, \qquad w_{t+1}^A = w_t^A \left(1 + \eta_t \delta_t\right)^{\eta_{t+1}/\eta_t}, \qquad \delta_t = \ell_t^B - \ell_t^A, \qquad \eta_t = \min\left(\tfrac{1}{2}, \sqrt{1/(1 + \textstyle\sum_{\tau<t} \delta_\tau^2)}\right).$$

6.4 O limite das perdas sem limite

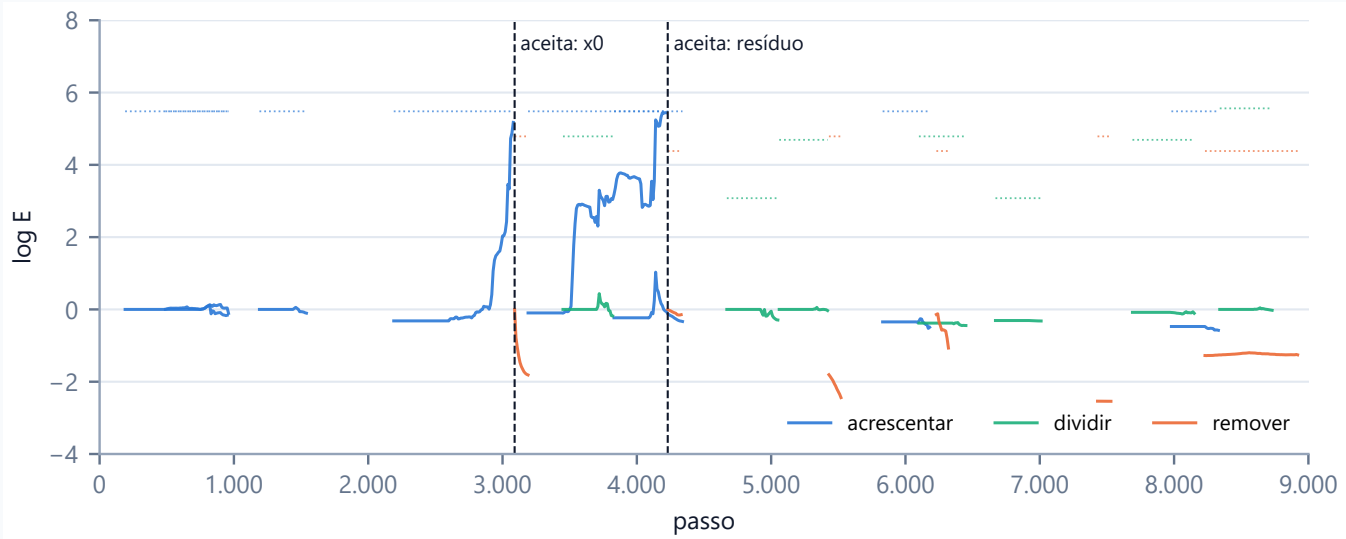
O erro quadrático não tem limite superior. As garantias conhecidas para perdas sem limite e de cauda pesada (Cesa-Bianchi, Mansour & Stoltz 2007; Hazan & Kale 2010; Orabona & Pál 2018; Mhammedi, Koolen & van Erven 2019; V'yugin & Trunov 2019; Alquier 2021; Moulin, Esposito & van der Hoeven 2025) valem em unidades da **maior perda de um passo**. Quando um único passo responde por boa parte de todo o erro de uma série — como num choque de câmbio —, nenhum combinador online consegue garantir que acompanha o melhor especialista com folga pequena em relação ao erro total. Esse limite é uma propriedade dos dados, não do algoritmo, e é tratado explicitamente na avaliação (§10, §14).

7. Ciclo de vida de uma mudança de estrutura

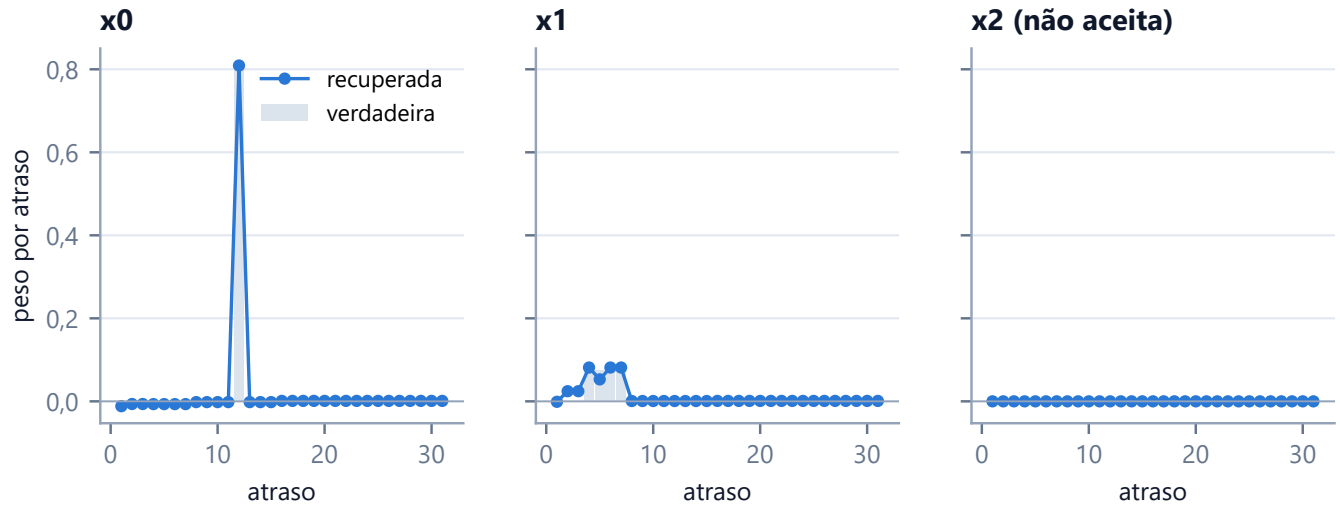


Estados de uma hipótese de mudança. A evidência só é acumulada fora do aquecimento, com alvo observado e fora de quarentena.

- **Unidades:** cada entrada (inclui o próprio passado do alvo, padronizado causalmente) e o estado latente do resíduo (dois filtros do erro padronizado, polos 0,8 e 0,95). Até 4 unidades ativas.
- **Desafiante de uma entrada:** RLS sobre [médias das 5 faixas, atraso de pico, valor atual x_i(t)] — o bloco é julgado líquido do que x_i(t) já carrega. O alvo do RLS é o resíduo que a mudança explicaria.
- **Episódio:** aquecimento de 250 amostras sem evidência; encerra ao aceitar, pela regra de varredura (soma do episódio ≤ 0 após 100 amostras) ou em 5.000 amostras; a mesma hipótese espera 2.000 passos para voltar. Só um desafiante em aquecimento por vez (controle de pico de custo).
- **Decisões** a cada 10 passos: aceitar, encerrar, abrir. Prioridade: teste de remoção disparado (§5.9), quando a contribuição de uma unidade ativa caiu abaixo de 0,5 vez a sua referência (o pico desde a aceitação, que volta ao valor atual a cada teste disparado), com pelo menos 2.000 passos entre testes disparados da mesma unidade — ele encerra um teste periódico de remoção da mesma unidade, cuja hipótese persistente fica guardada; depois o teste de remoção periódico; depois a melhor candidata da triagem (unidade ou divisão). Com 4 unidades ativas, a candidata entra por *troca* com a de menor contribuição.
- **Julgamento na previsão certa para cada unidade** (§5.10): unidades externas na previsão do núcleo L, internas na estrutura de nível s; nunca na saída final. M1 e M2 não participam das decisões de estrutura.



Exemplo real (série de desenvolvimento: vazão de uma usina hidrelétrica; entrada x0 = vazão defluente da usina a montante; x1 = próprio passado do alvo). Log-evidência dos experimentos (linhas cheias) contra os seus limiares log(1/α_k) (pontilhadas). A entrada x0 é aceita em t ≈ 3.090 e o estado latente do resíduo em t ≈ 4.230; depois disso, remoções e divisões são testadas e encerradas sem evidência.



Processo sintético declarado (y = 0,8·x0(t−12) + 0,3·média(x1, t−4…t−7) + ruído; x2 irrelevante). Resposta recuperada pelo núcleo (pontos) contra a verdadeira (barras): o atraso 12 de x0 é recuperado com peso 0,81; o efeito distribuído de x1 aparece na faixa [4–7]; x2 não é aceita.

8. A condição de uso: desajuste da referência

Um teste de melhora preditiva compara **métodos** (modelo + procedimento de estimação), não modelos — uma distinção conhecida em econometria (Giacomini & White 2006). Durante o desenvolvimento, isso apareceu de forma concreta: com a base de S aprendendo por NLMS com passo 0,1, alvos **sem nenhuma estrutura** tiveram uma mudança aceita em ~20% das execuções. A causa é que o erro de estimação da referência é previsível pelo passado, e um desafiante pode "corrigi-lo".

Seja $f_t^* = \mathbb{E}[y_t \mid \mathcal{F}_{t-1}]$, $\eta_t = f_t^* - S_t$ (erro de estimação da referência, previsível) e o desafiante $G_t = S_t + g_t$. Para a diferença de perda quadrática normalizada $\Delta_t = [(y_t - S_t)^2 - (y_t - G_t)^2]/B_t^2$:

$$\textbf{Proposição 1} \quad \mathbb{E}[\Delta_t \mid \mathcal{F}_{t-1}] = \frac{2g_t\eta_t - g_t^2}{B_t^2} \;\le\; \frac{\eta_t^2}{B_t^2}, \quad \text{com igualdade em } g_t = \eta_t.$$

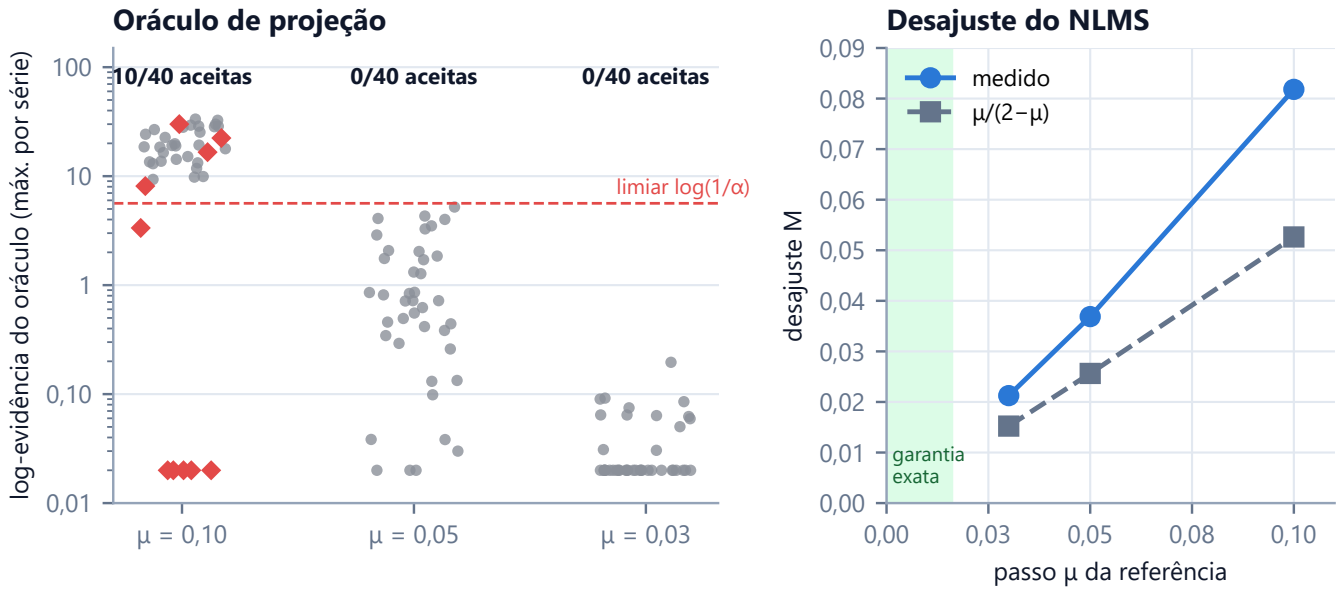
Demonstração: y − S = ε + η e y − G = ε + η − g; expandindo, a diferença é 2g(ε+η) − g², e E[ε | passado] = 0. ■

$$\textbf{Corolário (garantia exata)} \quad \frac{1}{n}\sum_{i\le n}\frac{\eta_i^2}{B_i^2} \le \varepsilon \;\; \forall n \;\Rightarrow\; \text{sob a nula estrutural, a nula do teste vale.}$$

Para NLMS com desajuste M, isso exige $M \lesssim 4\varepsilon$ (com ε = 0,002: μ ≲ 0,016).

$$\textbf{Proposição 2 (coeficiente fixo)} \quad \text{melhora média na janela} \le D_u + \varepsilon, \quad D_u = \tfrac{1}{|W|}\textstyle\sum_{i\in W}(P_u\eta_i)^2/B_i^2 - \varepsilon,$$

em que P_u é a projeção de η nos atributos da unidade. **Proposição 3 (critério prático, aproximação):** a log-evidência cresce como n·D²/(2σ_d²); numa série de comprimento T, aceitações falsas são improváveis se $D_u < \sigma_d\sqrt{2\log(1/\alpha_k)/T}$.



Verificação em desenvolvimento (120 execuções com alvos sem estrutura, entradas reais). Esquerda: log-evidência do melhor desafiante possível (oráculo de projeção) contra o limiar; aceitações reais em vermelho. Com μ = 0,1 o oráculo cruza o limiar (mediana 18,2) e houve 10/40 aceitações; com μ = 0,05 (máx. 5,2) e μ = 0,03, nenhuma. Nas execuções que aceitaram, o oráculo foi medido depois da aceitação e pode ficar baixo (pontos no piso). Direita: desajuste medido e teórico.

Leitura honesta: o núcleo usa μ = 0,05, que está no **regime prático** da Proposição 3 (o desvio da nula existe, ~0,0013, mas é menor que o detectável no comprimento das séries, ~0,0019), e **não** no regime da garantia exata (μ ≲ 0,016). Por isso o controle de mudanças falsas é verificado empiricamente com lotes nulos (0/40 e 0/30 aceitações no desenvolvimento), e não apenas afirmado pela teoria. A observação relaciona-se com Giacomini & White (2006) e, em outro mecanismo, com Han & Qu (2026); não a encontramos formulada explicitamente para esta situação, mas é uma consequência simples de resultados conhecidos.

9. M1: especialista de precisão e dormência

Motivação. O núcleo estima a dinâmica do alvo (memória) e o efeito das entradas (estrutura) separadamente, com aprendizado barato. Em algumas famílias isso o deixa **abaixo da fronteira precisão × custo**: uma regressão de custo igual ou menor, que estima as duas coisas juntas, erra 5% menos (§17). A M1 acrescenta essa estimação conjunta como um segundo especialista, sem tocar no núcleo.

O especialista E

Variáveis: o próprio alvo nas defasagens 1 e 2 e, para cada uma das m = mín(d, 5) entradas de maior correlação absoluta com o alvo (d = número de entradas), as médias nas bandas de defasagem [0], [1], [2–3], [4–7] e [8–15]:

$$z_t = \left[1,\ \tilde{y}_{t-1},\ \tilde{y}_{t-2},\ \bar{x}_{i,b}(t)\right]_{i\le m,\ b\le 5}, \qquad k = 3 + 5m, \qquad E_t = \operatorname{clip}\left(w_t^{\top} z_t,\ L_t \pm 2\max(\hat{\sigma}_L, \text{piso})\right)$$

- **Seleção das entradas:** médias exponenciais (taxa 0,01, só passado) de x, x^2, x·y, y e y^2, atualizadas a cada 8 alvos aprendidos; a seleção é feita depois de 100 alvos e refeita a cada 5.000. As médias e desvios do momento da seleção padronizam as entradas escolhidas e o alvo. Se o conjunto muda, a regressão e a combinação recomeçam.
- **Entradas ausentes** são trocadas pelo último valor visto (0 antes do primeiro).
- **Pesos:** mínimos quadrados recursivos com esquecimento λ = 0,999 e P_0 = 100·I, atualizados a cada 8 alvos aprendidos (fora de quarentena e com entradas dentro do contrato); a matriz é simetrizada a cada atualização e reiniciada se perder a definição positiva. E só existe depois de k atualizações (regressão determinada).
- **Recorte:** E fica em L ± 2·máx($\hat{\sigma}_L$, piso), com $\hat{\sigma}_L$ o erro quadrático médio recente do núcleo (média exponencial, taxa 0,01) e o piso de 0,1 vez a escala lenta do alvo; isso limita o estrago de uma regressão mal condicionada.

A combinação com o núcleo

AdaHedge (§6.1) com dois especialistas, L e E, sobre o **erro quadrático sem recorte nem normalização**: os pesos seguem o erro quadrático acumulado, que é o que o erro quadrático médio mede, e a taxa de aprendizado se ajusta sozinha à escala. A combinação observa todo alvo observado em que E existe. **Entrada em sombra:** até 100 atualizações, L' = L.

$$L'_t = (1-\omega_t)\,L_t + \omega_t\,E_t, \qquad \omega_t = \frac{e^{-\eta_t S^E_{t-1}}}{e^{-\eta_t S^L_{t-1}} + e^{-\eta_t S^E_{t-1}}}, \qquad S^{\bullet}_{t-1} = \sum_{\tau<t}(y_\tau - \bullet_\tau)^2$$

Por que AdaHedge e não um (A,B)-Prod: o Prod exige perdas em [0, 1]. Três formas de pôr o erro quadrático nesse intervalo foram medidas e falharam por razões diferentes (§17): recortar em 2σ deixa o Prod cego aos erros grandes; dividir pelo maior erro já visto o congela depois de um recorde; dividir pelo maior erro recente dá peso pequeno aos passos de erro grande, justamente onde o especialista ganha. Trocar a garantia constante do Prod pela do AdaHedge (arrependimento que, relativo ao erro total, some com o tamanho da série) foi o que funcionou.

Dormência: custo só onde há uso

Em boa parte das séries reais, o peso ω da M1 vai a zero: a M1 é paga em todos os passos sem mudar a saída. Na avaliação final da versão anterior, isso aconteceu em 70 de 104 séries. A M1 passa então a ter dois modos.

- **Ativa:** exatamente como descrito acima.
- **Dormindo:** entra depois da sombra, quando ω < 10^{-3} por 2.000 alvos aprendidos seguidos. A saída é L' = L e o AdaHedge fica congelado. A previsão E é calculada só a cada 8 alvos, para medir o ganho relativo g = ((y − L)² − (y − E)²)/(y − L)², e a regressão é atualizada só a cada 64 alvos, para E não envelhecer.
- **Despertar:** quando a média exponencial (taxa 0,01) de g passa de 0,05 depois de pelo menos 100 amostras. O AdaHedge recomeça com nova sombra de 100 atualizações, como um especialista novo.
- **Teste curto na reseleção:** se a seleção de entradas da M1 muda durante o sono, o especialista é novo; a M1 desperta em teste e volta a dormir depois de 500 alvos seguidos com ω < 10^{-3}, a menos que ω chegue a 10^{-3}.

A regra usa só o passado. Enquanto a M1 não dorme, a saída é idêntica à da M1 sem dormência. Dormir é uma aposta de que a M1 continuaria sem peso; o custo de errar essa aposta é o atraso até o despertar, medido no desenvolvimento e na auditoria (§17, §19.7).

10. M2: ponto de partida na referência trivial

Motivação. Em séries quase imprevisíveis (por exemplo, retornos e níveis de câmbio), uma parte adaptativa pode errar mais que prever zero ou repetir o último valor: ela aprende ruído. A M2 faz a saída partir de uma **referência trivial R** declarada com os dados — zero para variações como retornos financeiros, sazonal ingênuo (o valor de um ciclo atrás) quando há ciclo, persistência (o último valor) nos demais casos — e só passar a confiar em L' quando ele se mostra melhor. Enquanto R não está definida (antes de um ciclo completo, no caso sazonal), a saída é L'.

- **H** — AdaHedge entre R e L' sobre o erro quadrático (§6.1): confiança, sem trocas.
- **W** — troca num só sentido, de R para L' (§6.2), sobre perdas gaussianas (y − ·)²/2s², com s² = máx(mín(σ^2_R, $\sigma^2_{L'}$), piso²) e σ^2 médias exponenciais (taxa 0,01) dos erros quadráticos de cada lado, só do passado.
- **Combinação** — (A,B)-Prod sem horizonte (§6.3) com B = H (confiança) e A = W (oportunista); as perdas são (y − ·)²/N_t, com N_t = máx(perdas do passo, 0,99·N_{t−1}) — o maior erro recente, com esquecimento, para pôr as perdas em [0, 1] sem congelar depois de um recorde.
- H, W e o Prod só aprendem nos passos com alvo observado, fora de quarentena do alvo e com R definida.

$$\hat{y}_t = s_t\,W_t + (1-s_t)\,H_t, \qquad H_t = w^H_{R,t}R_t + w^H_{L',t}L'_t, \qquad W_t = w^W_{R,t}R_t + w^W_{L',t}L'_t$$

Auditoria da porta. Em paralelo, um e-process (§5.6) com orçamento próprio α = 0,01 e margem ε = 0,002 testa se a parte adaptativa melhora a referência vigente (e, depois de uma troca, o contrário); cada aceitação é registrada como evento e a hipótese é recriada. Esse teste **não decide a saída**: ele só documenta quando a evidência mudou de lado, com o mesmo tipo de garantia das mudanças de estrutura.

Garantias e o limite dos choques

Para as perdas normalizadas, o Prod garante arrependimento constante contra H e da ordem de √(T log log T) contra W; na escala original não há limite formal limpo, porque a normalização muda com o tempo. O limite da §6.4 aparece nos dados: em séries financeiras um único dia pode responder por boa parte de todo o erro (nas 521 séries de desenvolvimento medidas, 32 têm o maior passo acima de 5% do erro total da referência; o maior, baht_1990, 25,9%). Por isso a régua de avaliação trata essas séries como indecidíveis (§14).

11. Salvaguardas de saída e intervalo

Duas salvaguardas atuam no caminho da saída do núcleo e custam ~15 operações por passo. Ambas são práticas padrão de engenharia; entram aqui porque a sua ausência produziu a falha mais grave observada (§15).

- **Retenção durante lacunas do alvo:** a memória recebe o último valor observado, nunca a própria previsão. Sem isso, a memória fica em malha aberta e, com certos pesos aprendidos, a recursão é instável (raiz característica ~1,75 num caso real).
- **Contrato de saída:** a previsão do núcleo é limitada ao envelope dos alvos observados (máximo e mínimo correntes que relaxam para a média lenta à taxa 10^{-3}), alargado em 0,5× a sua largura; uma previsão não finita vira o último valor observado.
- **M1 e M2 herdam a contenção:** E fica a no máximo 2·máx($\hat{\sigma}_L$, piso) de L; R é um valor já observado (ou zero); toda saída de M1 e M2 é média ponderada de previsões contidas. Uma perda não finita nunca entra nos pesos.



Teste de estresse do núcleo no desenvolvimento: quatro lacunas artificiais no alvo (24, 100, 400 e 1.500 passos) em 29 séries. Desvio máximo da previsão em relação à amplitude observada. Pelo critério declarado antes do teste (desvio > 10×, previsão não finita ou erro > 1,5× o da mesma série sem lacunas) foram 10, 2 e 2 séries; as duas restantes com a correção são uma série curta (1.024 passos) em que as lacunas cobrem quase toda a região de teste, com desvio < 0,4 da amplitude.

Intervalo da saída

A saída final ŷ vem com um intervalo de 90% calculado pela regra da §5.8 aplicada ao erro de ŷ (início em 1,645 vezes o erro quadrático médio recente). A cobertura do intervalo do núcleo foi medida nas avaliações próprias do núcleo (§13); a cobertura do intervalo da saída completa **não foi reportada** nas avaliações finais.

12. Custo computacional e memória

O custo é contado operação a operação no código (somas, produtos, divisões, raízes, exponenciais e logaritmos contam 1 FP), por componente. O custo por passo é **quase fixo**: memória, base, triagem, M1 e M2 rodam sempre; os experimentos do núcleo acrescentam custo apenas quando há vaga ocupada, e os picos ocorrem nos passos de decisão. Nada cresce com o tempo.

Núcleo

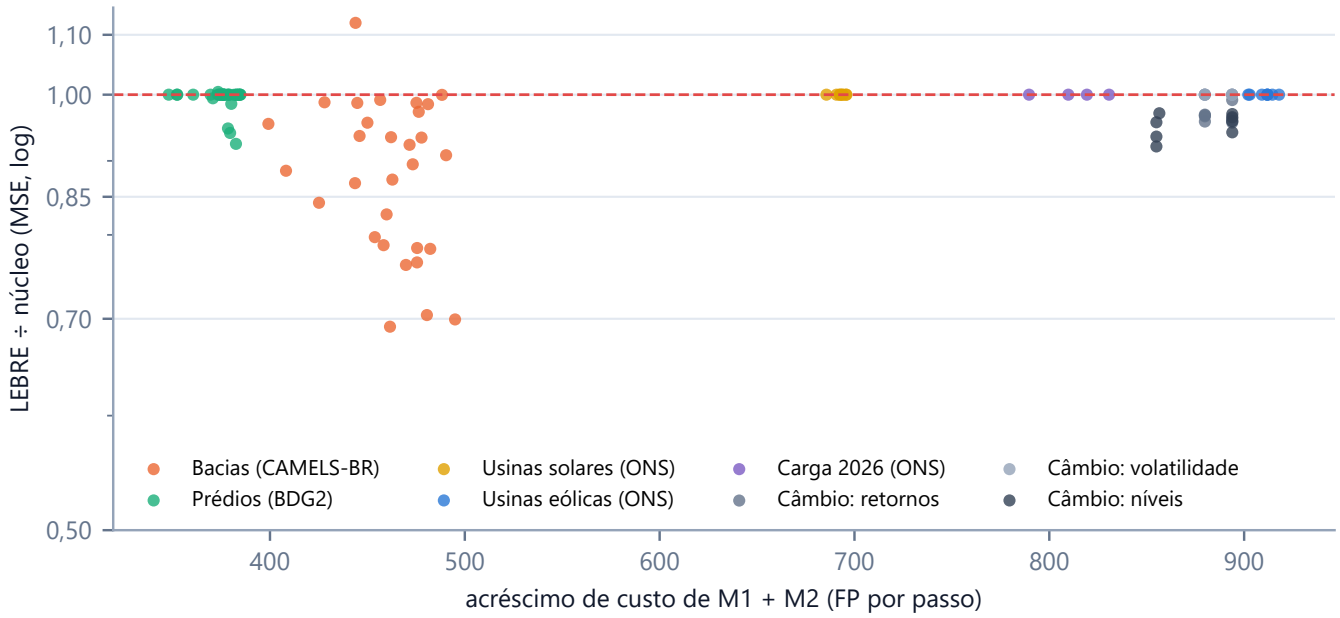
O núcleo foi desenhado com um contrato de média ≤ 400 e máximo ≤ 1.000 FP por passo nas séries reais. Na sua avaliação pré-registrada própria (60 séries), a média foi 415 e o máximo 1.020: o contrato **não foi cumprido** por 3,7% na média e 2,0% no pico, e não foi revisado depois do resultado. Na avaliação final anterior (§19.6), o núcleo custou mediana de 461 FP por passo.

M1 + M2

A contagem de M1 e M2 foi auditada: a implementação faz exatamente as contas declaradas (cada par da matriz da RLS simetrizado uma vez; só a linha nova das entradas padronizada), com as previsões idênticas às validadas em 813 de 813 séries; a auditoria elevou a contagem em 3,2% (mediana). Por atualização da RLS: $6k^2 + 5k$ (a cada 8 alvos); previsão do especialista: $2k + 18m + 4$; AdaHedge: 48; M2: ~132 a 137.

Parte	FP por passo (mediana, uma série por família do desenvolvimento, antes da auditoria)
núcleo	453
M2	137
M1: atualização da RLS	513
M1: resto	146
Total	**1.257**

Teto de custo de M1 + M2. A meta preliminar de desenho (custo total ≤ 1,25 vez o do núcleo) mostrou-se incompatível com M1 + M2: com o núcleo em ~450 FP, o acréscimo máximo seria ~110 FP, menos que a M2 sozinha. Antes da avaliação final anterior, o responsável pelo projeto a substituiu por um teto de **acréscimo absoluto de 1.100 FP por passo** em cada série (o custo novo é quase fixo; uma razão puniria as séries em que o núcleo é barato), mais 2,5 vezes o custo do núcleo nas famílias abaixo da fronteira. No desenvolvimento (813 séries) o acréscimo teve mediana de 538 e máximo de 974 FP; na avaliação final anterior, mediana de 476 e máximo de 918 FP, com custo total entre 667 e 1.637 FP.



Avaliação final da versão anterior (§19.6): acréscimo de custo de M1 + M2 e razão de erro LEBRE ÷ núcleo, por série. Sem dormência, o custo era pago em todas as séries; o ganho aparecia em bacias e câmbio.

Memória

O estado tem tamanho fixo, dados o número de entradas e os períodos. O estado do núcleo foi medido no porte em C (capacidades para até 8 entradas e 160 hipóteses): 74.988 bytes; a maior parte é a tabela de hipóteses, que pode ser reduzida. M1 e M2 guardam 1.263 números (k = 28 no pior caso: 1056 na M1, 207 na M2), 10.104 bytes em precisão dupla. Total **estimado**: 85.092 bytes (83,1 KB), dentro do limite pré-registrado de 128 KB; M1 e M2 não foram portados nem medidos.

A v0.54 acrescenta 22 números ao estado (sono e despertar da M1; referência e último teste disparado por unidade ativa; o vetor da amostra do relatório de equivalentes não muda a ordem de grandeza): memória estimada de 85.268 bytes (83,3 KB).

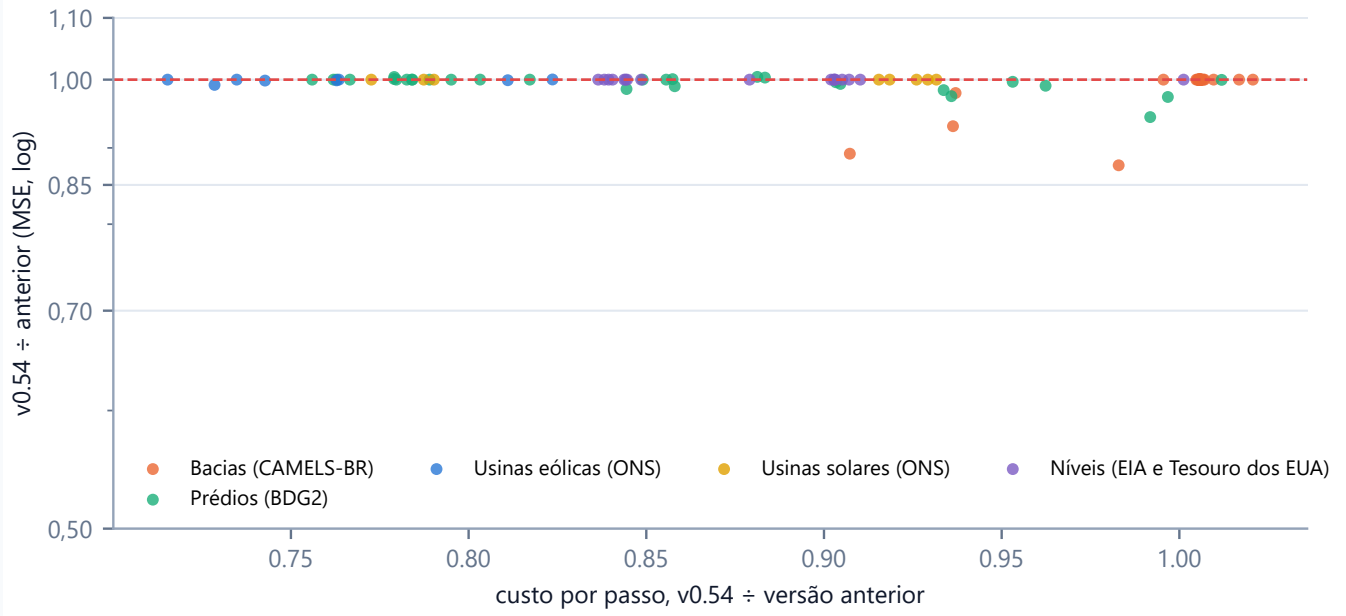
Custo proporcional ao uso (v0.54)

- **M1 dormente:** dormindo, a M1 calcula E a cada 8 alvos e atualiza a regressão a cada 64, em vez de prever e atualizar a cada passo e a cada 8.

- **Relatório de equivalentes:** a matriz de covariâncias das entradas, que serve só ao relatório, tinha custo quadrático em d a cada 4 passos (~1.000 operações por passo com 50 entradas). Ela passa a usar uma amostra a cada 31 passos (primo, para percorrer todas as fases de ciclos como 7, 12, 24 e 168), aplicada uma linha por vez nos passos seguintes. A economia é (3d(d+1)/2 + 2d)·(1/4 − 1/31) operações por passo; com 50 entradas, o custo do núcleo caiu para 0,719 vez o anterior na validação 7.
- **Remoção disparada:** 2 operações por unidade ativa a cada decisão, mais o teste quando abre.

Família	séries	custo por passo, versão anterior (mediana)	v0.54 (mediana)	razão por série (mediana)	séries em que a M1 dormiu
Bacias (CAMELS-BR)	30	863	867	1,006	4
Prédios (BDG2)	30	809	675	0,847	28
Usinas eólicas (ONS)	8	1.521	1.187	0,753	8
Usinas solares (ONS)	8	1.207	1.081	0,917	8
Níveis (EIA e Tesouro dos EUA)	17	1.105	966	0,879	16

Na avaliação final, a razão mediana de custo por série foi 0,905 [0,857; 0,932]. Onde a M1 é útil (bacias), o custo é o mesmo da versão anterior; onde não é, cai. Na auditoria, o tempo de relógio acompanhou a contagem (mediana de 0,845 vez o da versão anterior).



Avaliação final da v0.54: razão de custo e razão de erro v0.54 ÷ versão anterior, por série.

v0.55. A estrutura de inovação acrescenta uma previsão e uma atualização NLMS sobre os mesmos atributos da estrutura de nível (cerca de 6p operações por passo, com p o número de atributos), e a segunda média dinâmica, ~15 operações. O portão suave e a escala de uma passada não mudam a ordem de grandeza. Na avaliação final da v0.55, a razão mediana de custo por série foi 0,989 (a v0.55 ficou ligeiramente mais barata, porque o portão evita testes internos sem uso); no banco sintético de confirmação, 1,043. O estado cresce 70 números (pesos e base da estrutura de inovação, atributos da memória e escalares): memória estimada de 86.180 bytes (84,2 KB).

Pico por passo (errata 01). Na versão promovida, a atualização inteira da matriz do relatório, a cada 31 passos, coincidia periodicamente com a regressão da M1 e elevava o pico por passo: até 1,522 vez o da versão anterior com 50 entradas. A correção espalha a mesma atualização por linhas; previsões, decisões, relatório e custo total ficam idênticos, e o pico ficou em no máximo 1,054 vez (§19.7).

13. Observabilidade e explicabilidade

Cada previsão pode ser decomposta em parcelas nomeadas: no núcleo, memória, base e cada bloco ativo; depois, o peso ω da M1 e, na M2, os pesos de R e L' em H e em W e a fração s_t. Cada mudança de estrutura e cada aceitação da auditoria da porta ficam registradas. Exemplo de uma série de desenvolvimento do núcleo:

Instante	Evento	Mudança	log E	Amostras de evidência
3.090	aceita	acrescentar entrada x0	7,18	957
4.230	aceita	acrescentar estado latente do resíduo	5,49	893

- **Grupos equivalentes:** junto da entrada aceita x0 o modelo reporta o grupo {x0, x1} (correlação causal ≥ 0,95 entre x0, a vazão defluente da usina a montante, e x1, o próprio passado do alvo). A afirmação é "esta entrada ou uma equivalente".
- **Intervalo de 90% do núcleo:** cobertura empírica de 0,906 nesta série e 0,904 em média nas 60 séries da avaliação própria do núcleo.
- **Registro de experimentos encerrados:** cada teste que não passou fica registrado com a sua evidência (por exemplo, testes de remoção de x0 com log E entre −1,8 e −3,2: a entrada continua útil).
- **M1 e M2:** o peso ω da M1 é lido a cada passo, junto do seu estado (ativa, dormindo, em teste; quantas vezes dormiu e despertou; custo da M1 por passo); quais entradas a M1 escolheu também fica disponível.
- **Remoções:** cada teste de remoção disparado é registrado como os demais experimentos, e um teste periódico encerrado por ele aparece como substituído.
- **Relatório de equivalentes:** a consulta aplica antes as linhas pendentes da última amostra; o relatório é o mesmo em qualquer momento. Com uma amostra a cada 31 passos, a correlação estimada perto do limiar de 0,95 é mais ruidosa (erro padrão ~0,017 contra ~0,006); longe do limiar nada muda (§17).



Janela de 400 passos da mesma série: valor observado, previsão do núcleo e intervalo de 90%.

14. Metodologia de avaliação

Duas perguntas foram avaliadas com protocolos próprios, ambos pré-registrados: (a) o núcleo é competitivo na sua classe de orçamento? (b) M1 e M2 melhoram o núcleo sem piorar nenhum domínio?

Disciplina comum

- **Previsão online de um passo**, sem olhar o futuro; todos os modelos recebem as mesmas entradas, padronizadas de forma causal.
- **Pré-registro:** antes de cada acesso a dados reservados, um documento fixou perguntas, métricas, comparadores, critérios e os hashes do código; cada reserva foi executada uma única vez; o carregador de dados impede o acesso às reservas fora de uma execução pré-registrada. Incidentes de infraestrutura (sem alteração de modelo) estão descritos junto dos resultados.
- **Divisão das séries** por permutações com semente fixa, antes de qualquer modelagem; cada conjunto de validação foi escolhido só por metadados, congelado com SHA-256 e usado uma vez.

(a) O núcleo na classe de orçamento

- **Métrica:** erro quadrático médio na região de teste (últimos 70% de cada série, alvo observado), dividido pelo do NLinear online calibrado na mesma série; média geométrica entre séries; IC 95% por bootstrap estratificado por domínio (2.000 reamostragens). **Falha catastrófica:** erro relativo > 10, desvio > 10× a amplitude observada ou previsão não finita.
- **Dados:** vazões e geração do Operador Nacional do Sistema Elétrico (ONS; usinas em cascata), bacias do CAMELS-BR (Chagas et al. 2020; precipitação, evapotranspiração, temperatura) e medidores do Building Data Genome 2 (Miller et al. 2020; clima), mais dois benchmarks de identificação de sistemas no desenvolvimento.
- **Modelos de fundação** (caros demais para rodar em todos os passos): avaliados em 1.000 pontos por série, os mesmos para todos, com o mesmo contexto e as entradas atuais como covariáveis futuras conhecidas. **Comparadores ajustados em lote** (SARIMAX com entradas, FITS, SparseTSF, ajuste fino do TTM): ajustados nos primeiros 15% da série (até 5.000 pontos), depois com pesos fixos.

Conjunto	Séries	Uso
Desenvolvimento	29 (ONS 11, CAMELS 10, BDG2 5, Silverbox, Cascaded Tanks ×2)	todo o desenho e ajuste do núcleo
Reserva 1	125 (ONS 45, CAMELS 50, BDG2 30)	revelou a falha das lacunas (§15)
Reserva 2	40 (CAMELS 20, BDG2 20)	verificou a correção
Reserva 3	60 (CAMELS 30, BDG2 30)	comparadores ultraleves, TTM, porte em C, microcontrolador

(b) M1 e M2 contra o núcleo

Os dados da avaliação final foram reservados em 05/10/2026, antes de qualquer código de M1 e M2, com hashes e travas. A métrica é a razão de erros quadráticos médios LEBRE ÷ núcleo, série a série. **Régua por decidibilidade:** cada série é classificada pelo IC 95% de núcleo ÷ R (bootstrap de blocos pareado, 2.000 réplicas) como "núcleo melhor", "referência melhor" ou "indecidível". Critérios: (1) nas "referência melhor", LEBRE ÷ R com limite superior ≤ 1,01; (2) nas "núcleo melhor", LEBRE ÷ núcleo com limite superior ≤ 1,02; (4) nos testes negativos, nenhuma entrada falsa a mais que o núcleo; (6) a estrutura do núcleo preservada; (7) nas séries curtas (360 passos), ≤ 1,05 do melhor entre núcleo e R. **Adendos do choque** (decididos durante o desenvolvimento, antes da validação 5 e da avaliação final anterior): uma série em que o maior passo isolado passa de máx(5%, 5·2 ln(n)/n) do erro de R fica indecidível nos critérios 1 e 2 (n = passos avaliados), porque nela nenhum combinador tem garantia útil (§6.4).

F6, nas famílias em que o núcleo está abaixo da fronteira precisão × custo: custo ≤ 2,5 vezes o do núcleo e erro ≤ 1,05 vez o menor erro entre as 8 regressões do diagnóstico com custo ≤ o da LEBRE. **Promoção** (pré-registro; decisões do responsável pelo projeto): (A) nenhuma piora por família, (B) LEBRE ÷ núcleo em todas as séries com limite superior do IC 95% abaixo de 1 e (C) memória estimada ≤ 128 KB.

(c) A v0.54 contra a versão anterior

Os dados da avaliação final da v0.54 foram reservados em 10/10/2026, antes de qualquer código da v0.54: 93 séries (30 bacias, 30 prédios, 8 usinas eólicas, 8 solares em jan–set/2026, 17 níveis de preços da EIA e de juros do Tesouro dos EUA). A régua é a mesma de (b), com a versão anterior (núcleo + M1 + M2) no papel do núcleo: (A1) nas séries "referência melhor", v0.54 ÷ R com limite superior ≤ 1,01; (A2) nas "versão anterior melhor", v0.54 ÷ versão anterior com limite superior ≤ 1,02; (A3) nos níveis, nenhuma série

a mais com entrada externa aceita; (A4) séries curtas ≤ 1,05; (A5) nenhuma previsão não finita. **Promoção:** A, mais (B) razão mediana de custo por série com limite superior do IC 95% abaixo de 1 e (C) memória estimada ≤ 128 KB. Cada mudança da v0.54 foi antes medida no banco de desenvolvimento e, depois de revista, validada em dados novos, usados uma vez (§17, §18).

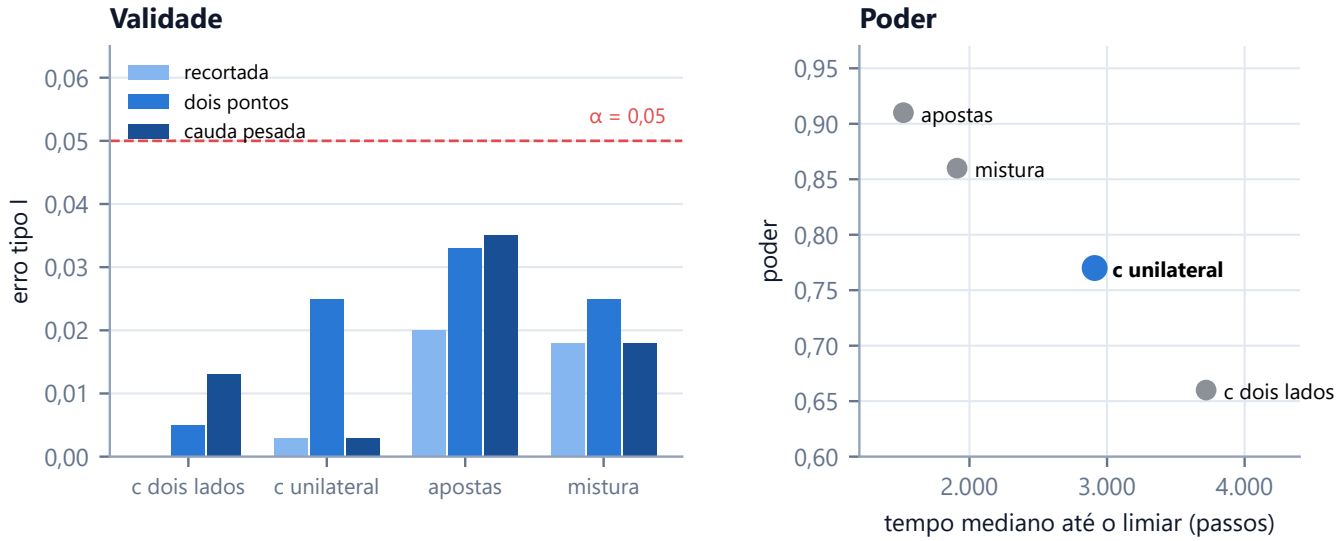
(d) A v0.55 contra a versão anterior

- **Desenvolvimento em sintéticos com verdade conhecida.** As primeiras quatro rodadas (cada uma com plano commitado antes e sementes novas) foram feitas rascunho a rascunho. Para conter o risco de ajustar o desenho aos próprios cenários, o desenvolvimento passou a um **banco fixo** de 23 cenários (8 deles desenhados antes de qualquer rascunho rodar neles) com critérios fixos para todas as rodadas: entradas espúrias em séries integradas, nulos estacionários, retenção da entrada verdadeira, atraso de detecção, precisão por cenário (limite superior ≤ 1,02), custo e a chegada da informação à previsão nas séries integradas.
- **Confirmação:** a candidata que passou foi congelada e medida uma única vez com sementes nunca usadas, sem nenhuma mudança.
- **Validação e avaliação final em séries reais nunca usadas**, sorteadas só por metadados, com regras e dados (com SHA-256) fixados antes. Regra de promoção vinculante: (R1) em cada família, limite superior do IC 95% da razão contra a versão anterior ≤ 1,02 (bootstrap pareado de blocos); (R2) **controle negativo**: cada série roda também com duas entradas placebo (passeios aleatórios gaussianos independentes); a fração de séries com alguma placebo na estrutura final precisa ter limite superior de Clopper–Pearson ≤ 0,10 e não passar da versão anterior; (R3) nenhuma previsão não finita; (R4) custo mediano por série ≤ 1,25 vez o anterior; (R5) memória estimada ≤ 128 KB.
- **Comparação externa** (só referência, fora da promoção): 12 modelos com a mesma informação a cada passo, protocolo fixado antes, razões de MSE com bootstrap pareado de blocos, p-valores bilaterais e correção de Holm por janela (janela completa a partir de 30% da série; 1.000 pontos para os modelos de fundação).

15. Evidência do núcleo estrutural

O núcleo foi desenvolvido e avaliado antes de M1 e M2 existirem, com o protocolo (a) da §14. Como M1 e M2 não alteram nenhuma decisão do núcleo (estrutura idêntica verificada em todas as séries do desenvolvimento, das validações e da avaliação final anterior), essas evidências continuam valendo para o núcleo dentro da LEBRE. Duas mudanças da v0.54 ficam dentro do núcleo: o relatório de equivalentes barato não muda nenhuma previsão nem decisão; a remoção disparada muda as trajetórias só quando abre um teste. Enquanto nenhum teste disparado abre, o núcleo é idêntico ao avaliado nesta seção (verificado nos testes de identidade do desenvolvimento e da auditoria).

15.1 Desenvolvimento: validade e descoberta



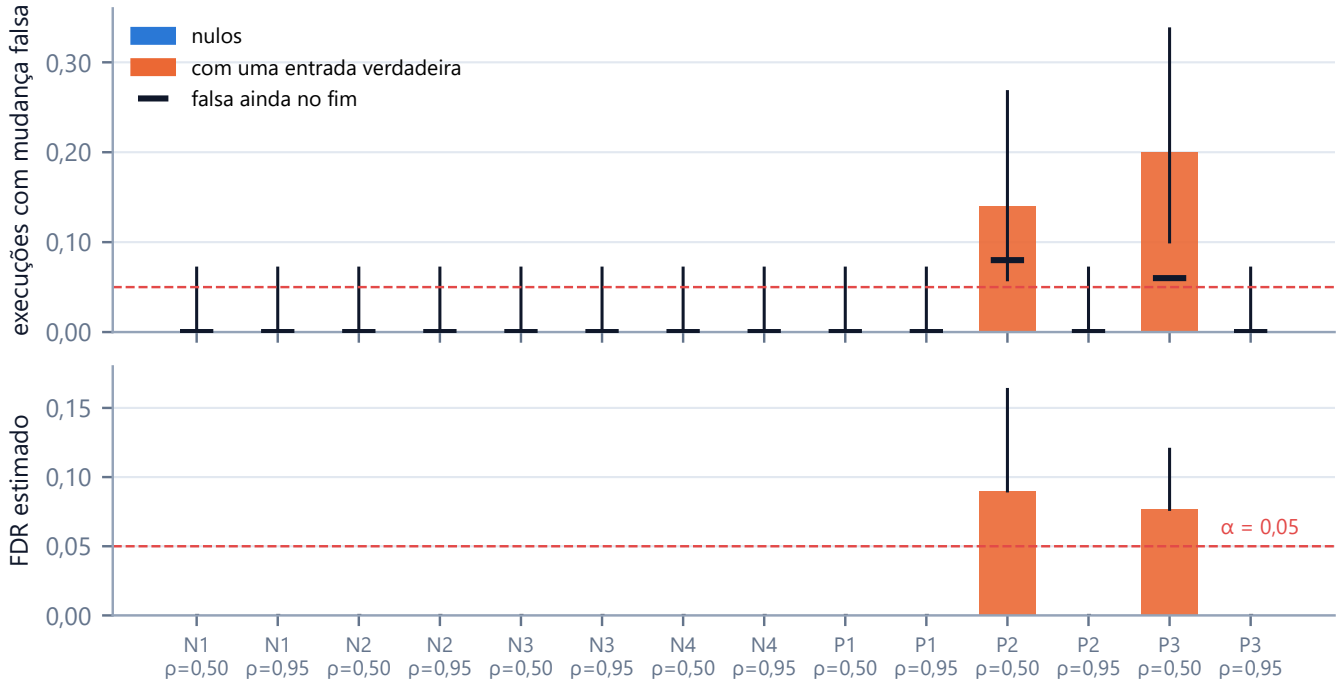
Simulação do e-process (400 trajetórias × 5.000 passos). Esquerda: erro tipo I sob três formas de incremento (recortado, dois pontos, cauda pesada) na nula no limite, contra α = 0,05. Direita: poder e tempo mediano até o limiar para uma melhora de +0,0072 por amostra. A variante adotada é a de c unilateral.

Situação	Resultado (desenvolvimento)
Sintéticos com entradas brancas (atrasos até 12)	estrutura recuperada até o atraso exato em 500–2.200 passos (ex.: atraso 12, peso 0,84 contra 0,80)
Semi-sintéticos (entradas reais, efeito conhecido)	entrada verdadeira (ou do seu grupo) em 2 de 3 tarefas estruturadas, 3/3 sementes; latência 4–17 mil passos
Entradas muito suaves (autocorrelação ~0,99), atraso médio/longo	**não descobertas**; um oráculo online (conhece o atraso, testa desde o início) precisa de 9–27 mil passos ou nunca chega em 32 mil
Alvos sem estrutura (lotes nulos com entradas reais)	0/40 e 0/30 aceitações; 0 entradas exógenas falsas em todos os conjuntos declarados
Entradas quase idênticas (correlação 0,98)	indistinguíveis por melhora preditiva; o modelo reporta o grupo

O limite em entradas suaves é conhecido em princípio: com regressores muito persistentes, a informação nova de um atraso além do valor atual é pequena (Stambaugh 1999; Campbell & Yogo 2006). Nesses casos, a previsão continua boa porque a base já usa o valor atual das entradas; o que se perde é a *explicação* do atraso.

15.2 Controle de mudanças falsas em simulação com dependência

O núcleo congelado foi rodado em 700 execuções sintéticas (plano e critério declarados antes; 4 entradas correlacionadas entre si, persistência 0,5 ou 0,95, 30 mil passos): quatro nulos (ruído branco; alvo autorregressivo; ruído cuja variância depende de uma entrada; quebra de variância) e três cenários com uma entrada verdadeira com atraso 6 (simples; com uma isca de correlação 0,7 com a verdadeira; com ruído autorregressivo de cauda pesada).



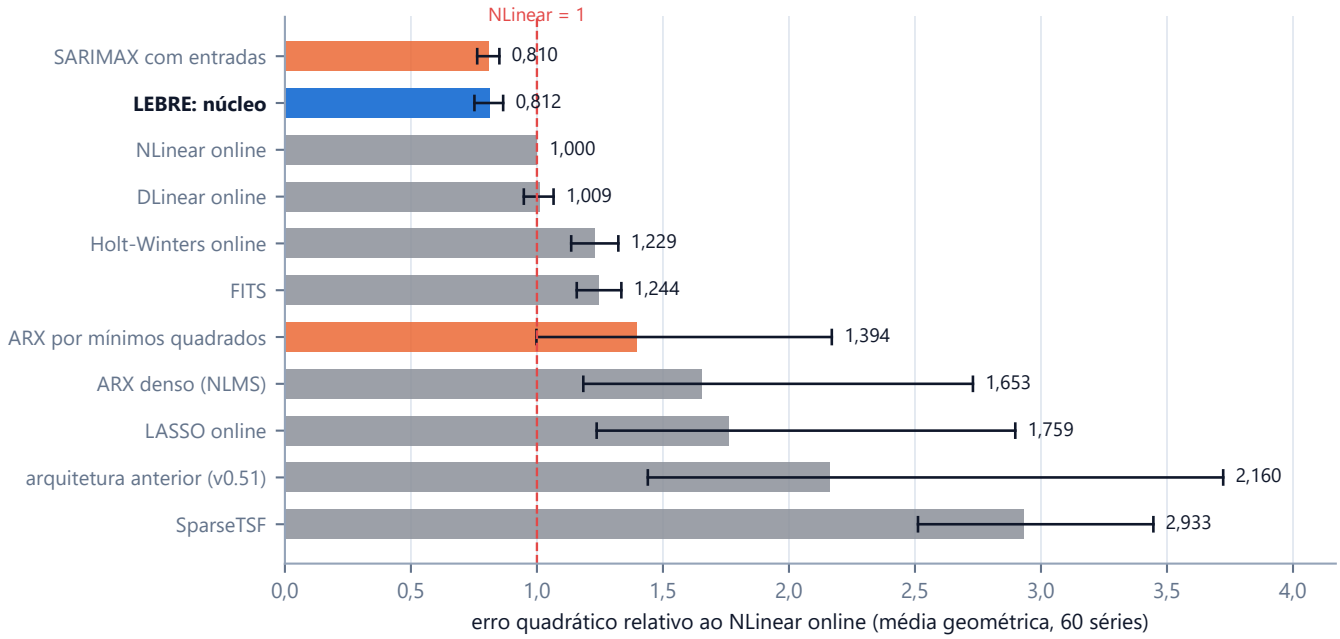
Em cima: fração de execuções com pelo menos uma mudança falsa (IC 95% de Clopper-Pearson) e fração em que a mudança falsa ainda estava no modelo no fim (traço). Embaixo: taxa estimada de mudanças falsas (FDR) com limite superior de bootstrap. Azul: nulos; laranja: cenários com uma entrada verdadeira.

- **Nulos:** 0 de 400 execuções com qualquer mudança aceita.
- **Com uma entrada verdadeira:** pelo critério declarado (por cenário, 100 execuções) os três cenários ficaram dentro de α = 0,05 (FDR 0,045 e 0,038 nos piores). Mas, com persistência 0,5, duas células passaram de 0,05: FDR 0,090 (isca) e 0,077 (ruído dependente), com 7/50 e 10/50 execuções afetadas.
- **Mecanismo:** em todas as 17 execuções afetadas, a mudança falsa foi uma entrada *correlacionada* com a verdadeira, aceita antes dela. Enquanto a verdadeira não está no modelo, essa substituta melhora de fato a previsão da referência — o teste acerta a pergunta que faz, mas a resposta não é estrutural. O teste periódico de remoção retirou a substituta em 10 dos 17 casos; em 7 de 700 execuções ela ficou no modelo final.

O que isto permite afirmar: nos cenários simulados, o procedimento controlou empiricamente as falsas *melhoras preditivas* e não aceitou nada em alvos sem estrutura. Ele **não** garante estrutura verdadeira: com entradas correlacionadas, uma substituta pode ser aceita e, às vezes, permanecer. Uma entrada aceita significa "melhorou a previsão da referência vigente, com evidência", não "é a causa".

15.3 Avaliações em séries nunca vistas

Reserva 1 (125 séries): uma falha de engenharia. A primeira avaliação pré-registrada, com o núcleo ainda sem as salvaguardas de saída, revelou que **6 de 125 séries explodiam** (erro relativo de 13 até 10^{79}): quando o alvo faltava por muitos passos, a memória preenchia o próprio histórico com as próprias previsões. O resultado pré-registrado ficou dominado por essas séries (média geométrica 5,20); numa vista exploratória, não pré-registrada, sem as 6 séries, o erro relativo foi 0,706, igual ao do desenvolvimento. A falha motivou as salvaguardas da §11, verificadas no desenvolvimento e depois em séries nunca vistas.



Reserva 3 (60 séries nunca vistas). Média geométrica do erro quadrático relativo ao NLinear online, com IC 95%. Azul: núcleo da LEBRE; cinza: outros modelos da classe de orçamento; laranja: referências clássicas.

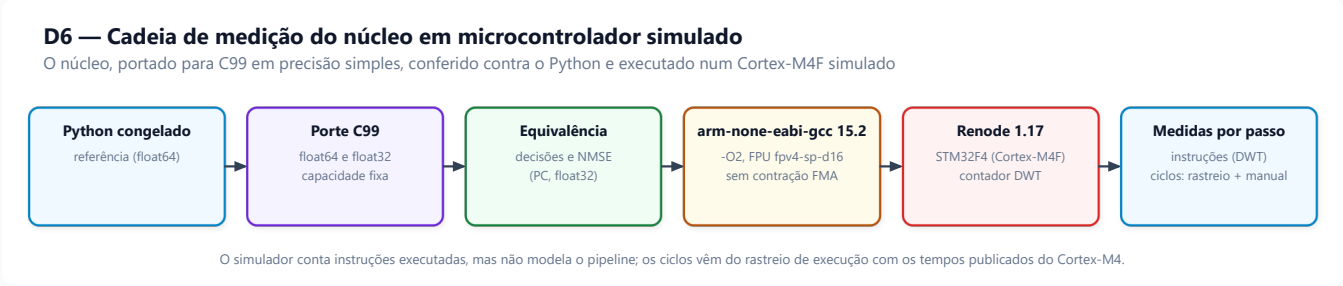
Modelo	CAMELS	BDG2	Todas [IC 95%]	Séries > 1,5	Catastróficas	Operações/previsão
LEBRE: núcleo	**0,858**	**0,768**	**0,812 [0,752; 0,866]**	**0%**	**0**	**415**
NLinear online	1,000	1,000	1,000 [1,000; 1,000]	0%	0	674
DLinear online	1,076	0,947	1,009 [0,948; 1,066]	3%	0	1.533
Holt-Winters online	1,213	1,244	1,229 [1,136; 1,323]	25%	0	20
FITS	1,362	1,137	1,244 [1,158; 1,335]	18%	0	9.757
ARX denso (NLMS)	1,008	2,711	1,653 [1,184; 2,730]	38%	2	474
LASSO online	1,015	3,048	1,759 [1,237; 2,898]	38%	4	705
arquitetura anterior (v0.51)	2,180	2,140	2,160 [1,440; 3,723]	48%	4	108
SparseTSF	2,980	2,886	2,933 [2,512; 3,446]	87%	3	4.016
SARIMAX com entradas	0,817	0,803	0,810 [0,763; 0,851]	0%	0	ajuste por MV
ARX por mínimos quadrados	0,677	2,867	1,394 [0,998; 2,170]	20%	4	48.944

Teto (1.000 pontos)	CAMELS	BDG2	Todas	Razão pareada núcleo/modelo [IC 95%]	Operações/previsão
SARIMAX com entradas	0,798	0,818	0,808	1,004 [0,956; 1,056]	ajuste por MV
TTM sem treino	1,204	0,978	1,085	0,747 [0,704; 0,795]	$15{,}6 \cdot 10^6$
TTM ajustado c/ entradas	1,049	1,054	1,052	0,771 [0,699; 0,844]	$55{,}6 \cdot 10^6$
Chronos-2 c/ covariáveis	0,782	0,539	0,649	1,250 [1,178; 1,337]	$\sim 10^9$–10^{10}

Resumo das avaliações do núcleo com as salvaguardas: erro relativo ao NLinear de 0,767 (reserva 2, 40 séries) e 0,812 (reserva 3, 60 séries); nenhuma série catastrófica e nenhuma acima de 1,5 nas 100 séries; empate com o SARIMAX com entradas nas duas (razões pareadas 0,999 e 1,002); erro menor que o do TTM sem treino e ajustado; erro 16% e 25% acima do Chronos-2 com covariáveis. Os ultraleves FITS e SparseTSF, ajustados em lote nos primeiros 15%, ficaram atrás do NLinear online neste regime de um passo, para o qual não foram desenhados. O intervalo de 90% teve cobertura empírica de 0,905 e 0,904.

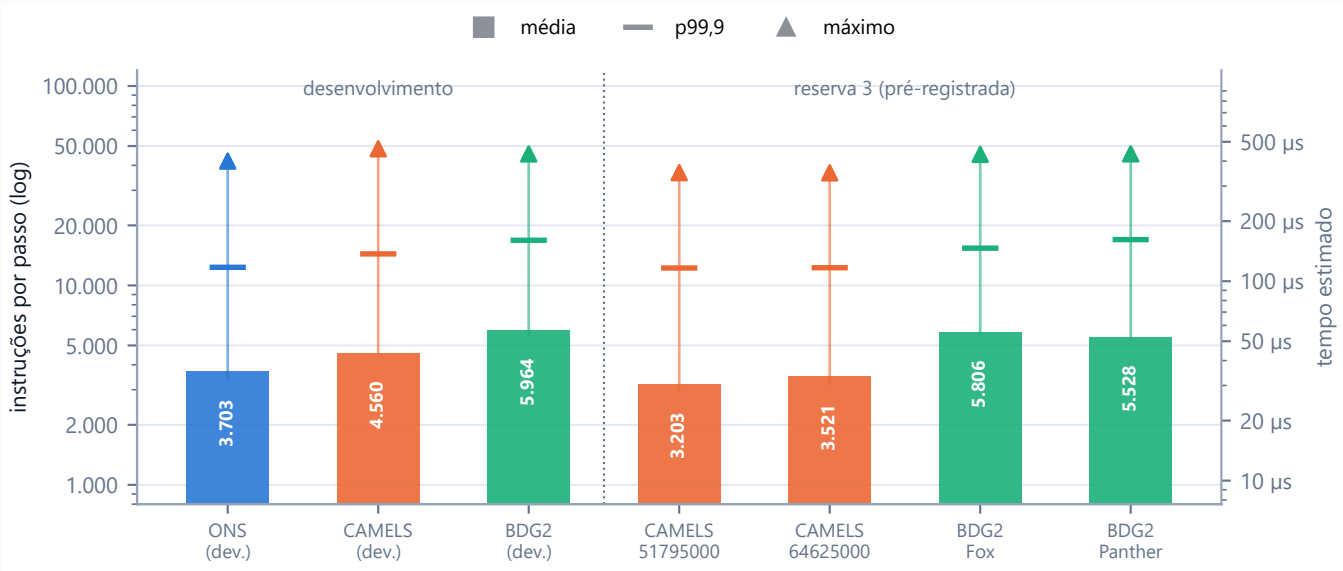
16. O núcleo em microcontrolador simulado

Para verificar se o custo analítico corresponde a algo executável num microcontrolador, o núcleo congelado foi portado para C99 e executado num **simulador** de um microcontrolador comum (STM32F4, núcleo Cortex-M4F a 168 MHz). Não houve medição em placa física. **M1 e M2 não foram portados**: para eles há só a contagem analítica (§12).



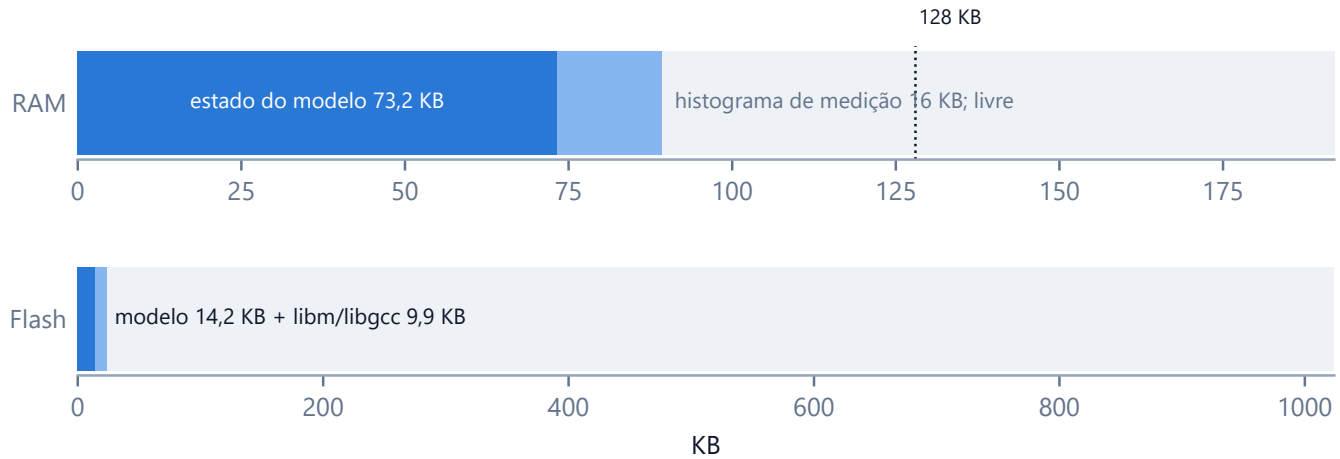
Cadeia de medição. A equivalência foi verificada primeiro no PC (C em precisão dupla e simples contra o Python), depois no dispositivo simulado.

Equivalência. Em precisão dupla, o C reproduz exatamente as decisões do Python em 29/29 séries de desenvolvimento. Em **precisão simples** (a versão do microcontrolador), as sequências de mudanças aceitas são idênticas em 28/29 séries de desenvolvimento e em 54/60 séries nunca vistas; nas demais, uma decisão perto do limiar ocorre alguns passos antes ou depois (arredondamento), com diferença mediana de erro de ~10^{-6}. **Custo.** O simulador (Renode 1.17) conta instruções executadas pelo contador DWT, mas não modela o pipeline; os ciclos foram estimados de rastreios de execução com os tempos publicados do Cortex-M4 e da FPU: CPI 1,62 e 1,57. Tempos abaixo usam CPI 1,6 e são estimativas.



Instruções por passo do núcleo em 7 séries (3 de desenvolvimento, 4 da reserva 3 pré-registrada): média (barra), p99,9 (traço) e máximo (triângulo). Eixo direito: tempo estimado a 168 MHz.

Série	Origem	Entradas	Média	Mediana	p99,9	Pico	Tempo	NMSE	Mudanças
ONS (dev.)	desenv.	1	3.703	3.363	12.327	42.021	~35 µs	0,2826	4
CAMELS (dev.)	desenv.	3	4.560	4.599	14.387	48.447	~43 µs	0,0229	3
BDG2 (dev.)	desenv.	2	5.964	5.607	16.843	45.654	~57 µs	0,0305	2
CAMELS 51795000	reserva 3	3	3.203	3.003	12.223	36.771	~31 µs	0,1465	0
CAMELS 64625000	reserva 3	3	3.521	3.215	12.267	36.708	~34 µs	0,3249	0
BDG2 Fox education Ollie	reserva 3	2	5.806	5.587	15.375	45.402	~55 µs	0,0162	3
BDG2 Panther education Vincent	reserva 3	2	5.528	5.463	16.971	45.696	~53 µs	0,0584	3



Memória no STM32F407 (192 KB de RAM, 1 MB de flash). RAM: estado do núcleo e demais variáveis do firmware de medição. Flash: código do núcleo e da biblioteca matemática.

Leitura: ~3,2–6,0 mil instruções por passo correspondem a ~9–15 instruções por operação analítica (acessos à memória, laços, índices, divisões). A ~31–57 µs por passo, uma amostragem de 1 segundo ocuparia < 0,01% do tempo do núcleo do processador; a energia não foi medida. Com M1 e M2, que dobram aproximadamente a contagem analítica (§12), a ordem de grandeza esperada continua a mesma, mas **não foi medida**. O estado cabe na RAM do STM32F407, mas não em microcontroladores menores sem reduzir as capacidades.

17. Desenvolvimento das camadas e das versões v0.54 e v0.55

Um banco de testes público (o LEBRE Lab) rodou o núcleo congelado em domínios novos e levantou modos de falha. M1 e M2 tratam dois deles, sem ampliar o espaço de hipóteses do núcleo; os demais ficaram para versões seguintes (§22).

Modo de falha 1: perder para a referência trivial (motiva a M2)

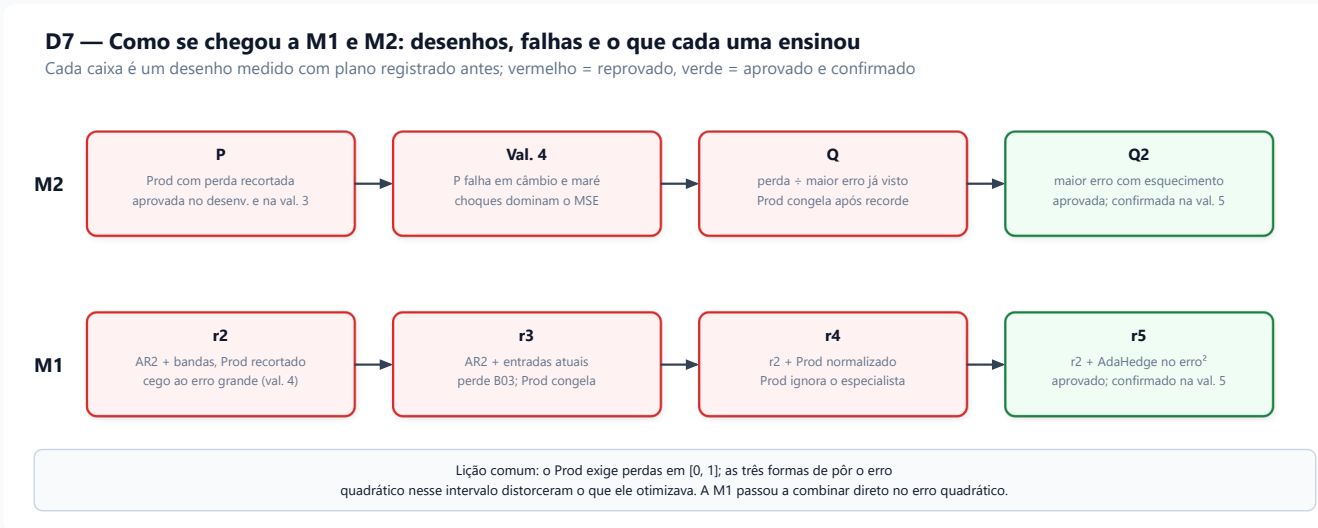
Em séries quase imprevisíveis, a parte adaptativa do núcleo erra mais que a referência trivial. Na própria reserva final, a referência foi melhor que o núcleo, com intervalo de confiança inteiro acima de 1, em 5 de 8 séries de retornos de câmbio e 6 de 8 de níveis.

Modo de falha 2: abaixo da fronteira precisão × custo (motiva a M1)

Em 8 famílias do desenvolvimento um comparador linear completo (todas as entradas e defasagens estimadas juntas, de milhares a dezenas de milhares de operações por passo) vence o núcleo por mais de 5%. O que importa sob orçamento é se o núcleo perde para algo *do mesmo custo*. O diagnóstico mediu 8 regressões de custos variados em cada família: o núcleo está abaixo da fronteira (uma regressão de custo menor ou igual erra 5% menos) em 4 delas, todas com a mesma causa, a falta de estimação conjunta da dinâmica do alvo e do efeito das entradas.

Família	núcleo ÷ completo	melhor com custo ≤ núcleo	custo do núcleo (FP)	situação
B03	2,076	1,574	731	**abaixo**
VB07	1,170	1,005	435	**abaixo**
XB07	1,141	1,010	417	**abaixo**
B07	1,067	1,004	431	**abaixo**
YB06	1,095	1,048	640	na fronteira
YB03	1,225	1,397	830	na fronteira
VC05	1,138	1,381	262	na fronteira
A05	1,077	1,777	385	na fronteira

Erro = MSE ÷ MSE do comparador linear online completo (média geométrica da família). B03: qualidade do ar; B07, VB07, XB07: maré meteorológica (três conjuntos independentes); VC05: inflação; YB03: qualidade do ar de Pequim; YB06: eólica; A05: sintético.



Os desenhos que importaram para a decisão (a lista completa — 6 desenhos da M1 e 14 configurações da M2 — está no banco de testes).

O banco de desenvolvimento cresceu até 64 famílias e 728 séries (o desenvolvimento original, as validações 1 a 4, já gastas, e as famílias curtas). Nele, a combinação final (M1 rascunho 5 + M2 Q2) atendeu a todos os critérios da M2 e a F6 nas quatro famílias abaixo da fronteira:

Família	núcleo ÷ completo	LEBRE ÷ completo	meta	custo ÷ núcleo
B03	2,076	1,365	1,652	2,01
B07	1,067	1,020	1,054	2,17
VB07	1,170	1,053	1,056	2,13
XB07	1,141	1,044	1,061	2,21

Achados de processo, todos registrados: um defeito numérico no caminho W (0/0 por *underflow*) foi achado num teste, corrigido com a reserva em escala logarítmica e auditado (nunca disparou em medição registrada; desde então uma previsão não finita conta como falha); um erro de construção nas validações 4 e 5 (ciclo de 30 h em vez de 24 h em solar, eólica e carga) restringiu o alcance da validação 5 (§18).

Desenvolvimento da v0.54

A linha de base medida antes da v0.54 mostrou três problemas além dos tratados por M1 e M2: (1) a M1 trabalhava com peso zero em boa parte das séries e custava em todas; (2) o custo do núcleo crescia com entradas nunca aceitas; (3) remoções nunca aconteciam — depois de uma troca de regime, a entrada antiga continuava na estrutura em 20 de 20 séries. Também foram olhados (4) entradas espúrias em níveis e (5) o ciclo que precisa ser declarado. Cada mudança foi medida no banco de 64 famílias contra a configuração anterior, com plano commitado antes; um desenho revisto depois de uma medição só foi aceito depois de passar em dados novos.

Mudança	Desenhos medidos	O que aconteceu	Situação
M1 dormente	3	custo da M1 em cenários de muitas entradas: 0,570, 0,264 e 0,373 do anterior; o 2º desenho piorou a qualidade do ar (+5% numa série), o 3º atendeu a tudo menos a meta de corte de 75%, revista para 60% pelo responsável pelo projeto e declarada	aceita (validação 6)
Núcleo barato com muitas entradas	3	dormência das entradas na triagem descartada antes de medir (atrasava ou impedia a descoberta de entradas fracas); o 1º desenho do relatório barato tinha *aliasing* com o ciclo de 24 h; o 2º atendeu; a auditoria achou o pico de custo (errata 01)	aceita (validação 7 e errata 01)
Remoções que acontecem	2	o 1º desenho removia relações intermitentes nos blocos desligados (+14% de erro, limite superior 1,145) e mudava o calendário de testes; o 2º, acrescentado ao calendário e com duração mínima, ficou com pior limite superior 1,006	aceita (validação 7)
Entradas espúrias em níveis	0	diagnóstico: os testes comparam com a previsão estrutural, que não parte do último valor; num passeio aleatório, qualquer entrada que também passeia parece ajudar; a remoção não resolve, porque a contribuição dela não cai	fora da v0.54; tratado na v0.55 (§5.10)
Ciclo como hipótese	2	a evidência teve de ser o perfil por fase (atributos de defasagem dão ciclos falsos em séries AR); sem declarar o ciclo, a carga chegou a 1,04 vez a versão com o ciclo declarado, mas a solar ficou em 1,20 (aceitação tardia); nenhum ciclo falso em séries sem ciclo	fora da v0.54 e da v0.55

Os números de cada medição, com planos e resultados, estão no banco de testes.

Desenvolvimento da v0.55

Cada rascunho foi medido com plano commitado antes e sementes novas; os negativos ficaram registrados. Um teste de fumaça nos cenários dos testes do protótipo (sem valor de evidência) descartou antes de qualquer medição: a estrutura aprendida sobre a inovação da memória *no lugar* da estrutura de nível (perde precisão: o NLMS precisa cancelar y(t−1) e faz isso mal) e uma referência lenta separada para os testes (piora os níveis: 8 de 8 passeios com entrada espúria).

Rodada	Desenho	Resultado
D1	testes contra a previsão do núcleo (todas as unidades)	espúrias em passeios: 26/60 → 0/60; reprovado na precisão no banco de 64 famílias (pior limite superior 1,127: barra o passado do próprio alvo quando a memória é fraca)
D2	externas contra o núcleo, internas contra s	precisão ok em todos os cenários; reprovado na retenção numa série integrada (a estrutura não tinha peso, e a entrada não chegava à previsão)
D3	+ estrutura de inovação aninhada	primeira vez que a informação de uma entrada verdadeira chega à previsão numa série integrada (0,984); reprovado na retenção com passeios concorrentes e, numa segunda série integrada, a informação não chegou à previsão
D4	+ portão rígido (sem testes internos enquanto wS < 0,05)	retenção e informação ok; reprovado: o portão se trava onde a memória é fraca (1,36)
D5	portão suave pela triagem, pesos de quem aprendeu, escala de uma passada (banco fixo)	passou em todos os critérios
C1	confirmação, candidata congelada, sementes nunca usadas	passou: espúrias 0/60 (anterior 22) e passeios na Q7 0/40 (anterior 22); retenção na P6 60/60 (anterior 48); integradas com entrada 0,913 [0,907; 0,918]

Dois diagnósticos nas séries já gastas mudaram o desenho, e estão registrados: (1) uma unidade interna entrava na estrutura de inovação com pesos aprendidos contra s, e podia desestabilizá-la; (2) o piso da escala, medido no nível, chegava a 8 vezes o erro real em séries integradas e escondia as entradas verdadeiras. O segundo revelou também a errata 01 da nota formal (§5.6).

Nos 8 cenários novos do banco fixo (desenhados antes de qualquer rascunho rodar neles), a confirmação deu: Q1 0,869, Q2 0,932, Q3 0,830, Q4 0,850, Q5 0,977, Q6 0,965, Q7 0,683, Q8 0,994 (razão contra a versão anterior; Q1 integrada sazonal, Q2 AR(2) forte, Q3 troca de regime, Q4 relação intermitente, Q5 duas entradas verdadeiras, Q6 caudas pesadas, Q7 dez entradas com iscas e passeios, Q8 quase integrada).

18. Validações em dados novos

As validações 1 e 2 serviram a desenhos anteriores da M2; a validação 3 confirmou a candidata P. A **validação 4** reprovou a M1 rascunho 2 com a P: critério 1 em YB07, YC01 e critério 2 em YB01. O diagnóstico separou as causas (a falha da solar era da M1; as do câmbio e da maré, da M2) e levou aos desenhos da §17.

A **validação 5** (43 séries novas, medição única) confirmou a M1 rascunho 5 com a M2 Q2: F6 atendida em qualidade do ar de Pequim (Chen, 2017) e em seis estações de maré novas, e todos os critérios da M2 em todas as famílias.

Família	núcleo ÷ completo	LEBRE ÷ completo	meta	custo ÷ núcleo
Z-B03	1,169	1,118	1,410	1,97
Z-B07	1,017	0,925	1,068	2,20

> **Errata:** nas validações 4 e 5, as famílias solar, eólica e carga foram montadas com ciclo de 30 h em vez de 24 h. As comparações entre núcleo e LEBRE nessas famílias valem para a tarefa como montada, não para a análoga declarada; a evidência fresca da LEBRE com o ciclo certo nesses domínios é a avaliação final anterior (§19.6).

Validações da v0.54

- **Validação 6** (M1 dormente; 70 séries nunca vistas: 20 reais de carga, qualidade do ar, eólica e maré e 50 sintéticas): custo da M1 com razão 0,377 e 0,229 nos cenários de custo; nenhuma família com limite superior acima de 1,01 (pior 1,006). Aceita.
- **Validação 7** (relatório barato e remoção disparada; 100 séries nunca vistas: 90 sintéticas, 4 de qualidade do ar de uma estação nova e 6 eólicas nunca usadas): relatório idêntico e previsões idênticas; custo do núcleo com 50 entradas 0,719 do anterior; a entrada antiga removida depois da troca de regime em 20 de 20 séries; nenhuma remoção de entrada verdadeira; pior limite superior 1,005. Ambas aceitas; em 2 séries com relação intermitente, a remoção aconteceu no retorno da relação (declarado).
- **Errata 01** (relatório espalhado por linhas): no banco, identidade com a versão promovida em 728 de 728 séries e pico corrigido, mas não aceita pela redação do critério de custo (em 70 séries, a diferença era exatamente o custo das linhas ainda pendentes no fim da série); com o critério reescrito e declarado, aceita em 60 séries novas, com pico de no máximo 1,054 vez o da versão anterior.

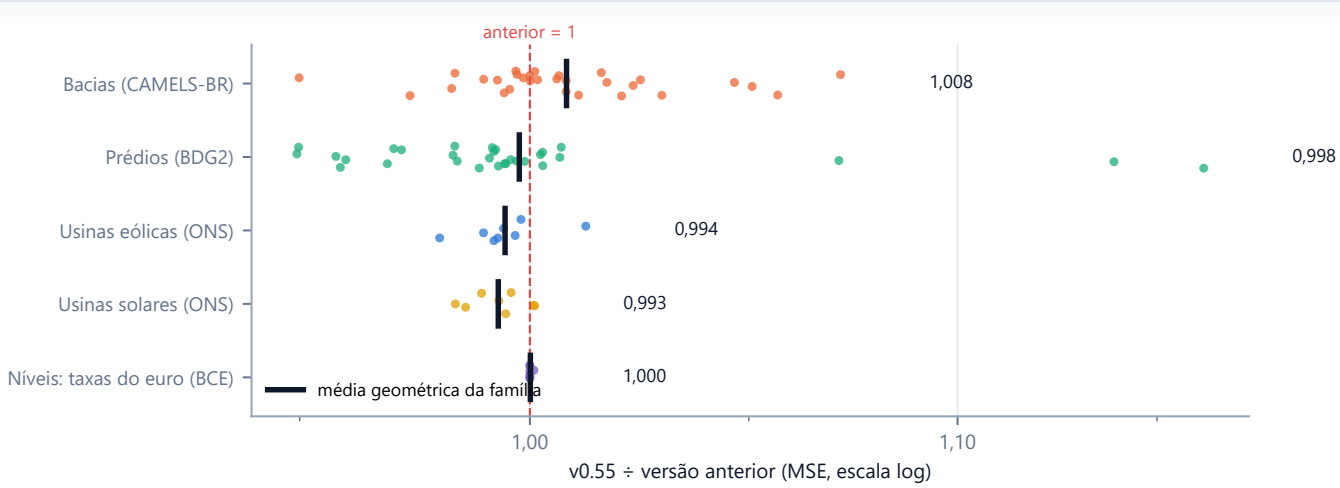
Validação da v0.55

Pré-registrada, em 50 séries reais nunca usadas (20 bacias e 30 medidores, sorteados só por metadados): bacias 1,003 [0,991; 1,018], prédios 0,993 [0,984; 1,002], custo 1,022. Aceita. Descritivo: a v0.55 terminou com entrada externa na estrutura em 0 de 20 bacias (anterior: 6) e 3 de 30 prédios (anterior: 16); numa bacia, a precipitação acumulou evidência parecida nas duas versões, mas o episódio longo começou mais tarde e a série acabou antes da aceitação: descoberta mais lenta, não recusa.

19. Avaliações finais pré-registradas, comparação externa, auditoria e erratas

19.1 A avaliação final da v0.55

Execução única, pela régua (d) da §14, em 84 séries de uma reserva nova: 30 bacias do CAMELS-BR, 30 medidores do BDG2, 8 usinas eólicas e 8 solares do ONS (as solares em jan–set/2026, separação no tempo) e 8 taxas de referência do euro publicadas pelo BCE para moedas fora do H.10 do Fed (zloty, coroa tcheca, florim, leu, lira turca, rupia, peso filipino e shekel), com o euro contra dólar, libra, iene e franco suíço, com um dia útil de atraso, como entradas. Seis taxas de commercial paper do Fed e a coroa islandesa ficaram de fora pela regra de cobertura fixada antes. Resultado: **promovida**.



v0.55 ÷ versão anterior por série (pontos) e média geométrica da família (traço).

Família	séries	v0.55 ÷ anterior [IC 95%]	janela curta (passos 200–2.000)	com entrada externa no fim (anterior / v0.55)	com placebo no fim (anterior / v0.55)	custo (mediana da razão)
Bacias (CAMELS-BR)	30	1,008 [1,003; 1,014]	1,052 [0,998; 1,058]	13 / 7	0 / 0	1,031
Prédios (BDG2)	30	0,998 [0,988; 1,009]	1,007 [0,979; 1,041]	18 / 1	3 / 0	0,987
Usinas eólicas (ONS)	8	0,994 [0,992; 0,997]	0,992 [0,988; 0,996]	2 / 0	0 / 0	1,004
Usinas solares (ONS)	8	0,993 [0,988; 0,998]	1,020 [1,013; 1,028]	1 / 0	0 / 0	0,942
Níveis: taxas do euro (BCE)	8	1,000 [1,000; 1,000]	1,000 [1,000; 1,001]	8 / 0	1 / 0	0,819

- **Controle negativo (R2):** 0 de 84 séries com placebo na estrutura final (limite superior 0,043), contra 4 na versão anterior (limite superior 0,117).
- Nenhuma previsão não finita; custo mediano 0,989; memória estimada 86.180 B.
- **Leitura honesta:** nas bacias, piora pequena e estatisticamente clara (1,008, dentro da margem), maior no início das séries; nos níveis do BCE, nenhum ganho de precisão (1,000): a versão anterior terminou com entrada externa nas 8 moedas e a v0.55 em 0, com precisão idêntica; com o controle placebo, isso sugere que ao menos parte dessa estrutura era espúria, mas não o demonstra. O ganho em séries integradas visto nos sintéticos não apareceu aqui: as entradas destas séries não parecem trazer informação incremental.

19.2 Comparação com modelos externos (só referência)

Nas mesmas 84 séries, com a mesma informação a cada passo: referência trivial; ARX denso (NLMS), NLinear e DLinear online e um ARX com mínimos quadrados recursivos (classe de custo da LEBRE, 10^2–10^3 operações); SARIMAX com entradas (ajuste por máxima verossimilhança na calibração); gradient boosting com reajustes em janela crescente; e, nos 1.000 pontos, Chronos-2 com e sem

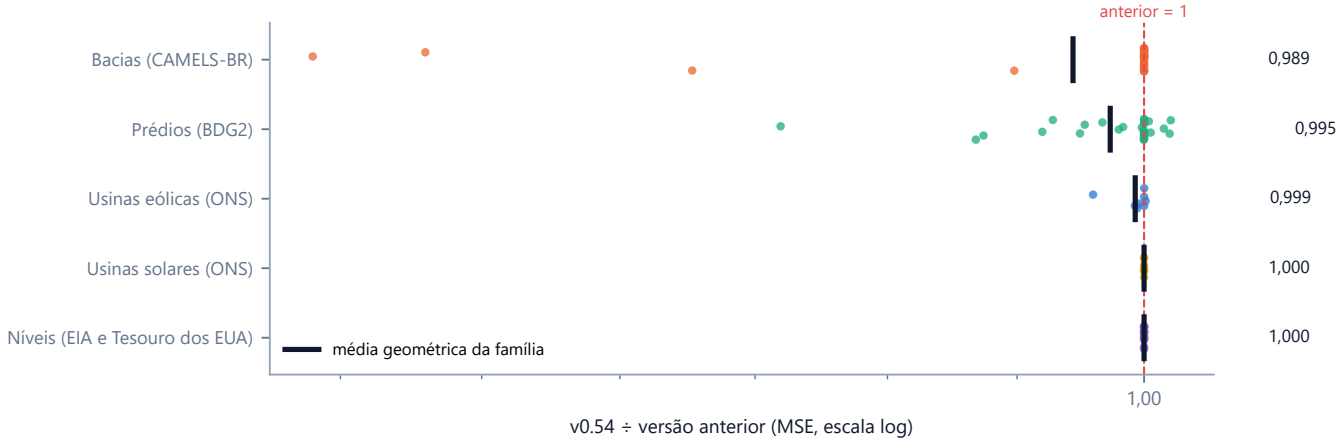
covariáveis, Chronos-Bolt e TTM sem treino e ajustado com as entradas (10^7–10^{10} operações). Razão = erro da v0.55 ÷ erro do modelo; só entram diferenças significativas depois da correção de Holm.

Família	Significativamente melhores que a v0.55 (janela completa)	Significativamente melhores (1.000 pontos, com os de fundação)
Bacias (CAMELS-BR)	versão anterior (v0.54) (1,010), ARX (mínimos quadrados recursivos) (1,125), gradient boosting (1,152)	ARX (mínimos quadrados recursivos) (1,155), gradient boosting (1,105)
Prédios (BDG2)	–	Chronos-2 c/ covariáveis (1,227), Chronos-2 (1,165), Chronos-Bolt (1,084)
Usinas eólicas (ONS)	–	Chronos-2 c/ covariáveis (1,055), Chronos-2 (1,052)
Usinas solares (ONS)	gradient boosting (1,099)	gradient boosting (1,115), Chronos-2 c/ covariáveis (1,363), Chronos-2 (1,316), Chronos-Bolt (1,237)
Níveis: taxas do euro (BCE)	–	–

- A v0.55 é significativamente melhor que o SARIMAX com entradas em todas as famílias, que o NLinear, o DLinear e o TTM em quase todas, e que o Chronos nas bacias e nos níveis; nos níveis do BCE, ela empata com a persistência e todos os outros modelos perdem para ela.
- **Na mesma classe de custo,** um ARX com mínimos quadrados recursivos (~1.700 operações por passo nas bacias) erra cerca de 11% a 13% menos que a v0.55 nas bacias; nas demais famílias, a v0.55 é melhor ou empata.
- Cuidados: o ARX denso (NLMS) diverge em algumas séries (o resultado da família fica dominado por elas; pela mediana por série, ele continua pior que a v0.55); o TTM ajustado falha nos níveis (a padronização na calibração não serve a séries integradas); eólica, solar e níveis têm 8 séries cada. Os modelos de fundação rodaram em GPU, todos no mesmo dispositivo.

19.3 A avaliação final da v0.54

Execução única, pela régua (c) da §14, em 93 séries reservadas antes de qualquer código da v0.54: 30 bacias do CAMELS-BR, 30 medidores do BDG2, 8 usinas eólicas e 8 solares do ONS (as solares em jan–set/2026, separação no tempo) e 17 níveis diários (10 preços à vista da EIA e 7 taxas do Tesouro dos EUA, com WTI, Brent e as taxas nominais de 2 e 10 anos como entradas). O pré-registro foi escrito antes do acesso e passou por um ensaio em séries já gastas. Resultado: **promovida** pela regra fixada antes.



v0.54 ÷ versão anterior por série (pontos) e média geométrica da família (traço).

Família	séries	anterior melhor / ref. / indec. / choque	v0.54 ÷ anterior	A1	A2	custo (mediana da razão)	remoções
Bacias (CAMELS-BR)	30	16/0/3/11	0,989	-	0,992 [0,989; 0,994]	1,006	0
Prédios (BDG2)	30	30/0/0/0	0,995	-	0,995 [0,993; 0,997]	0,847	1
Usinas eólicas (ONS)	8	8/0/0/0	0,999	-	0,999 [0,997; 1,000]	0,753	0
Usinas solares (ONS)	8	8/0/0/0	1,000	-	1,000 [1,000; 1,000]	0,917	0
Níveis (EIA e Tesouro dos EUA)	17	0/2/15/0	1,000	1,000 [1,000; 1,000]	-	0,879	0

- Custo (B): **0,905** [0,857; 0,932]; séries curtas contra o melhor da versão anterior e de R: 1,007 [0,998; 1,008]; memória estimada 85.268 B.
- Nenhuma previsão não finita; nos níveis, entradas externas aceitas em 3 séries, como na versão anterior (3) — a M4 não resolve a interpretação em níveis (§22); a M1 dormiu em 64 das 93 séries; em toda a reserva houve 1 remoção aceita, de um teste periódico (que já existia), e nenhuma remoção disparada; a unidade removida voltou depois, e a estrutura final é a da versão anterior.
- Uma falha de infraestrutura na primeira passada (os processos paralelos importaram o leitor de dados da versão anterior, que tem o mesmo nome) foi corrigida sem mudança de modelo ou critério; 4 resultados calculados com dados errados (2024–2025 em vez de 2026, já gastos) foram retirados antes de qualquer análise. O Chronos-2 foi completado depois de uma falha de ambiente, e o SARIMAX com entradas não rodou nos níveis (entradas com lacunas), como no câmbio em nível antes.

19.4 Tetos de referência (só reportados)

Modelos fora da classe de orçamento, só como referência: Chronos-2 com covariáveis (Ansari et al., 2025), nos mesmos 1.000 pontos por série do protocolo (a); e SARIMAX com entradas, ajustado nos primeiros 15%.

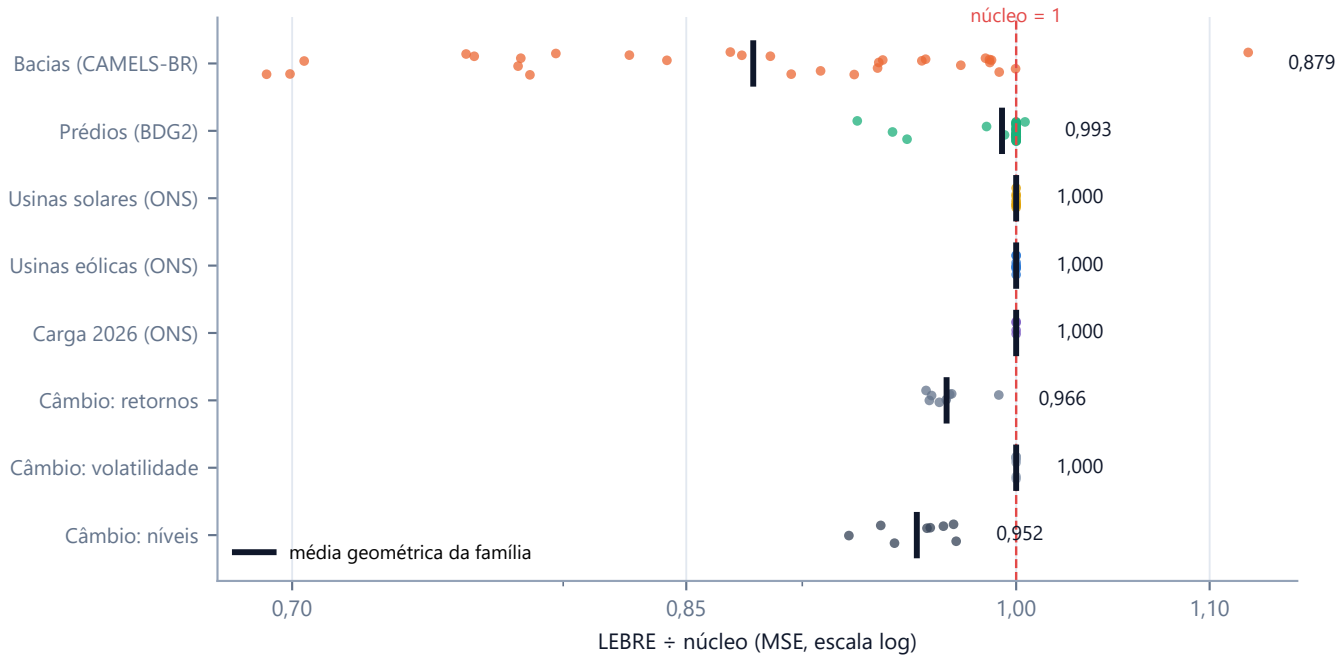
Família	v0.54 ÷ Chronos-2	anterior ÷ Chronos-2	SARIMAX-X ÷ v0.54
Bacias (CAMELS-BR)	0,943	0,962	1,089
Prédios (BDG2)	1,338	1,342	1,042
Usinas eólicas (ONS)	1,060	1,061	1,057
Usinas solares (ONS)	1,319	1,319	1,106
Níveis (EIA e Tesouro dos EUA)	0,835	0,835	–

19.5 O que a avaliação não cobre

Não há verdade conhecida sobre trocas de regime nas séries reais: a avaliação verifica que remover não piora, e a evidência de que a remoção acontece quando deve vem do desenvolvimento e das validações. A reserva não tinha carga elétrica nem câmbio (esgotados) nem séries longas com relações que somem e voltam.

19.6 A avaliação final anterior: M1 e M2 sobre o núcleo

A versão anterior (núcleo + M1 + M2, sem os mecanismos da v0.54) teve a sua própria avaliação final pré-registrada, que é a evidência de que M1 e M2 melhoram o núcleo. Execução única em 104 séries reservadas (30 bacias do CAMELS-BR; 30 medidores do BDG2; 8 usinas solares, 8 eólicas, a carga de 2026 dos 4 subsistemas do ONS e 8 pares de câmbio em 3 tarefas: retornos, volatilidade e níveis). O pré-registro foi aprovado depois de um ensaio em 55 séries já gastas de bacias e prédios (0 erros). Resultado: **promovida** pela regra fixada antes.



LEBRE ÷ núcleo por série (pontos) e média geométrica da família (traço).

Família	séries	núcleo melhor / ref. / indec. / choque	LEBRE ÷ núcleo	crit. 1	crit. 2	+custo máx. (FP)
Bacias (CAMELS-BR)	30	15/2/7/6	0,879	0,845 [0,814; 0,878]	0,911 [0,899; 0,924]	495
Prédios (BDG2)	30	30/0/0/0	0,993	-	0,993 [0,988; 1,000]	385
Usinas solares (ONS)	8	8/0/0/0	1,000	-	1,000 [1,000; 1,000]	696
Usinas eólicas (ONS)	8	8/0/0/0	1,000	-	1,000 [1,000; 1,000]	918
Carga 2026 (ONS)	4	4/0/0/0	1,000	-	1,000 [1,000; 1,000]	831
Câmbio: retornos	8	0/5/1/2	0,966	1,000 [1,000; 1,000]	-	894
Câmbio: volatilidade	8	6/0/0/2	1,000	-	1,000 [1,000; 1,000]	894
Câmbio: níveis	8	0/6/0/2	0,952	1,001 [1,000; 1,002]	-	894

- Melhora geral: **0,955 [0,951; 0,960]**; séries curtas contra o melhor de núcleo e R: 1,007 [0,995; 1,017].
- Nenhuma previsão não finita; entradas falsas nos retornos iguais às do núcleo; estrutura preservada em todas as séries; memória estimada de 85.092 B.
- Em solar, eólica e carga, a M1 terminou com peso zero em todas as 20 séries e a LEBRE ficou idêntica ao núcleo.
- Duas correções durante a execução, sem efeito em modelo ou critério: a leitura da carga de 2026 pelo código do subsistema (o ONS renomeou o Sudeste) e o tratamento de uma série curta degenerada (empate exato com erro zero).

Tetos de referência nessa avaliação (só reportados):

Família	LEBRE ÷ Chronos-2	núcleo ÷ Chronos-2	SARIMAX-X ÷ LEBRE
Bacias (CAMELS-BR)	0,885	1,008	1,134
Prédios (BDG2)	1,248	1,241	1,034
Usinas solares (ONS)	1,237	1,237	1,096
Usinas eólicas (ONS)	1,051	1,051	1,049
Carga 2026 (ONS)	1,433	1,433	0,968
Câmbio: retornos	0,954	0,979	1,123*
Câmbio: volatilidade	0,983	0,983	1,058*
Câmbio: níveis	0,881	0,921	1,065*

* Câmbio: o SARIMAX com entradas não rodou na execução (entradas com feriados faltantes); valores de um adendo posterior ao resultado, com as entradas preenchidas pelo último valor.

19.7 Auditoria de estresse depois da promoção e errata 01

A pedido do responsável pelo projeto, a v0.54 promovida passou por uma auditoria com plano e sinais de alerta fixados antes, que não refaz a promoção: procura defeitos que a avaliação não cobria.

Teste	Resultado
Identidade e determinismo (6 casos)	com os mecanismos desligados, idêntica à versão anterior; determinística; passo único igual a prever + observar
Robustez (12 tipos de estresse)	nenhuma previsão não finita; razões de erro de 0,974 a 1,005 (o alvo constante deu MSE ~10^{-32}, arredondamento)
Nulos (100 séries)	entradas externas na estrutura: 0, como na versão anterior (0)
Entradas verdadeiras fracas (80 séries)	nenhuma remoção de entrada verdadeira; razões de 0,982 a 1,001
Despertar da M1 (40 séries)	razões no trecho depois da troca de 0,997 a 1,003
Estado (até 200 mil passos)	nenhum contêiner novo que cresça; a lista de eventos cresce sem limite, como já na versão anterior
Combinação inteira no banco (64 famílias)	nenhum limite superior acima de 1,02 (pior: YB03, 1,007)
Intermitência	**alerta:** com blocos ligado/desligado de 7.500, 10.000 e 15.000 passos, erro 1,100, 1,055 e 1,046 vez o da versão anterior; até 5.000 passos, sem efeito
Custo de pico	**alerta:** pico por passo até 1,522 vez o da versão anterior com 50 entradas; custo médio menor em quase todos os grupos e tempo de relógio 0,845

Errata 01. (1) O pico vinha da atualização inteira do relatório de equivalentes coincidindo com a regressão da M1; a correção aplica a mesma amostra linha por linha, com previsões, decisões, relatório e custo total idênticos, e o pico ficou em no máximo 1,054 vez (validada em dados novos, §18). As previsões avaliadas na §19.3 são, portanto, as da versão corrigida. (2) A remoção de relações que somem por mais de ~5.200 passos e voltam fica declarada como limite (§22): a remoção é válida para o episódio, mas a LEBRE não guarda memória de que a relação existiu e precisa redetectá-la (mediana de ~700 a ~900 passos).

20. Evolução da arquitetura e ablações

Evolução

A LEBRE evoluiu por versões congeladas, cada uma com os seus hashes. A v0.1 (referência canônica do projeto) definiu a ideia: estrutura que entra e sai do modelo por evidência, dentro de um orçamento. A v0.51 usava dois especialistas com descoberta por atraso e testes de martingale/CUSUM; análises posteriores mostraram que, em séries reais, quase todo o resultado vinha da memória. A v0.52 manteve a memória e a combinação e trocou a descoberta por um motor genérico de mudanças testadas — é o **núcleo estrutural** deste documento, congelado em 27/09/2026 sem promoção. A v0.53 acrescentou M1 e M2 sem mudar um byte do núcleo e foi promovida em 09/10/2026. A v0.54 acrescentou a dormência da M1, o relatório de equivalentes barato e a remoção disparada, e foi promovida em 13/10/2026 (com a errata 01 de 14/10/2026). A v0.55 (este documento) ancorou os testes de estrutura na previsão do núcleo, acrescentou a estrutura de inovação, o portão suave e a escala de uma passada, e foi promovida em 17/10/2026. Os passos internos do núcleo foram:

1. hipóteses por atraso (~400) → **por entrada inteira** (menos hipóteses; melhor nos dados reais);
2. faixas diluíam atrasos isolados → **atraso de pico** e divisões hierárquicas;
3. evidência lenta → **c unilateral** e estatística do pico persistente;
4. aceitações em trechos planos → **piso de escala** da perda;
5. aceitações em alvos sem estrutura → **passo 0,05** na referência (§8);
6. picos de custo → um aquecimento por vez, triagem espalhada, estatística do pico em meia janela;
7. explosões em lacunas → **retenção e contrato de saída** (§11).

Ablações

Variante	O que muda	Resultado
Núcleo sozinho (sem M1 e M2)	a saída é L	avaliação final anterior: LEBRE ÷ núcleo = 0,955 [0,951; 0,960]; a M1 tem peso zero em solar, eólica e carga
Núcleo: tudo ligado, sem testes	todas as entradas e o estado latente ativos desde o início	reservas 2 e 3 (100 séries): razão 0,988 [0,970; 1,006], custo ~5% menor — exploratório; **o mecanismo de testes não melhora a precisão** de forma distinguível
Núcleo sem divisões hierárquicas	a resposta fica nas faixas de oitava + pico	razão 0,996 [0,988; 1,001] — sem diferença em dados reais
Hipótese por atraso ("atômica")	uma hipótese por atraso de cada entrada (~400 hipóteses)	desenvolvimento: 0,757 contra 0,645 (1.000 pontos); descoberta mais lenta
Sem salvaguardas de saída	memória em malha aberta nas lacunas	reserva 2: 1,107 contra 0,767; 2 catastróficas; razão pareada 0,693
Base com passo 0,1	desajuste maior da referência	10/40 aceitações em alvos sem estrutura (§8)
Arquitetura anterior (v0.51)	dois especialistas com descoberta por atraso, sem controle no fluxo	reserva 3: 2,160, 4 catastróficas
M1 e M2 com outros combinadores	Prod recortado, Prod normalizado, outros desenhos (§17)	reprovados no desenvolvimento ou na validação 4
Sem dormência da M1	a M1 roda inteira em todos os passos	validação 6: mesma precisão (pior limite superior 1,006), custo da M1 2,7 vez maior no cenário de muitas entradas
Sem remoção disparada	só o calendário periódico com hipótese persistente	validação 7: depois da troca de regime, a entrada antiga não é removida (0 de 20 na linha de base; 20 de 20 com ela)
Testes contra a estrutura de nível (v0.54)	todas as unidades testadas contra s	avaliação final da v0.55: placebo na estrutura em 4/84 séries reais (v0.55: 0); banco de confirmação: espúrias em 22/60 passeios (v0.55: 0)
Todas as unidades contra a previsão do núcleo	também o passado do alvo e o resíduo	D1: barra o passado do próprio alvo quando a memória é fraca (reprovado na precisão)
Estrutura sobre a inovação no lugar da de nível	cascata memória → estrutura	perde precisão: o NLMS precisa cancelar y(t−1) (teste de fumaça)
Sem estrutura de inovação	só L_1	D2: a informação de uma entrada verdadeira não chega à previsão numa série integrada
Portão rígido	sem testes internos enquanto wS < 0,05	D4: trava onde a memória é fraca (1,36)
Relatório de equivalentes a cada 4 passos	matriz inteira de covariâncias a cada 4 passos	previsões idênticas; custo do núcleo com 50 entradas 1,39 vez maior

Consequência para o que se pode afirmar: a precisão do núcleo vem principalmente de uma regressão linear online barata sobre as entradas atuais e de uma memória sazonal, protegidas por salvaguardas de saída; o ganho da LEBRE sobre o núcleo vem de M1 e M2 (§19). O mecanismo de mudanças testadas **não é justificado por ganho de precisão**; ele se justifica, se for o caso, pela estrutura *registrada com evidência* (quais entradas, com que atraso, desde quando, com qual evidência). A v0.55 acrescentou a primeira medida direta da validade dessa estrutura em dados reais, o controle placebo (§19.1). **Não demonstramos** que essa estrutura melhore alguma decisão prática (diagnóstico, controle, manutenção).

21. Posição na literatura

Aspecto	Trabalhos relacionados	Classificação
Mudança estrutural aceita por e-process de melhora preditiva, com controle de erro no fluxo	Amoukou, Mishra & Veloso (2026), em árvores de decisão online (controle FWER); Choi (2026), correções preditivas pré-especificadas; Jha (2026), causalidade de Granger com teste sequencial; Choe & Ramdas (2024); Xu & Ramdas (2024)	**não original**
Unidades por entrada, refinamento hierárquico, remoção e troca testadas, controle FDR, orçamento fixo	peças conhecidas (teste hierárquico; e-LOND; hipóteses persistentes com FDR: de Heide 2026; testes duplamente sequenciais: Yao, Gang & Sun 2025)	integração/extensão
Agregação de previsores (M1, M2)	AdaHedge (de Rooij et al. 2014); (A,B)-Prod e arrependimento constante contra um especialista de confiança (Sani et al. 2014; Even-Dar et al. 2008; Koolen 2013); switch distribution (van Erven et al. 2012) e Fixed Share (Adamskiy et al. 2016; Cesa-Bianchi et al. 2012); regressão recursiva com defasagens (Ljung 1999)	**não original**; escolha das perdas e encadeamento
Perdas sem limite e caudas pesadas	Cesa-Bianchi et al. (2007); Hazan & Kale (2010); Orabona & Pál (2018); Mhammedi et al. (2019); V'yugin & Trunov (2019); Alquier (2021); Moulin et al. (2025); sequências de confiança robustas (Wang & Ramdas 2023), direção futura	limite conhecido; tratado na régua
Condição de uso (desajuste da referência)	Giacomini & White (2006); Clark & West (2007); desajuste do LMS (Widrow & Stearns 1985); Han & Qu (2026); viés do incumbente na promoção de desafiantes (Fernández-Barrios et al. 2026)	observação metodológica modesta
Previsão com orçamento de ~10^2–10^3 operações por passo	SparseTSF, FITS, TTM (em geral univariados e treinados em lote); previsão embarcada com aprendizado incremental e sensores exógenos (Lara Pinal, Das & Schlüter 2026)	contribuição empírica, no escopo testado
Teste de inclusão "além do próprio passado" (v0.55)	causalidade de Granger e as suas versões sequenciais (Jha 2026); comparação sequencial de previsores com aprendizes arbitrários (Choe & Ramdas 2024); validade sob qualquer aprendiz previsível pela desigualdade de Fan (Howard et al. 2021)	**não original**; integração no regime de evidência da LEBRE
Retenção, contrato de saída, limites de custo	prática de engenharia	padrão

A auditoria da literatura do núcleo seguiu um protocolo com afirmações e consultas fixadas antes (47 consultas, em duas rodadas) e classificou cada trabalho como antecipação, parcial, base ou distante; nenhum trabalho encontrado antecipa a combinação inteira, e cada peça tem precedente. **Limitações:** um mecanismo de busca geral, consultas em inglês, leitura em geral pelo resumo, sem dupla triagem; não é uma revisão sistemática no sentido formal. A contribuição da LEBRE é a **integração** desses componentes sob um orçamento declarado e a avaliação pré-registrada.

22. Limites e afirmações que não fazemos

- **Horizonte:** só um passo à frente, com as entradas atuais disponíveis.
- **Domínios:** o núcleo foi avaliado contra a classe de orçamento em hidrologia e prédios; M1 e M2, em bacias, prédios, solar, eólica, carga e câmbio, mais qualidade do ar e maré nas validações. Outros domínios não foram testados.
- **Custo sem ganho em parte dos domínios:** onde a M1 não ajuda, ela agora dorme e custa pouco, mas a M2 e a M1 dormente ainda custam em todas as séries; a meta de custo com muitas entradas (≤ 2 vezes o custo com 5) não foi atingida: o relatório barato corta só a parte quadrática.
- **Relações que somem e voltam:** uma relação ausente por mais de ~5.200 passos é removida e precisa ser redetectada quando volta; com blocos de 7.500 a 15.000 passos, o erro fica 1,046 a 1,100 vez o da versão anterior (§19.7). Relações sazonais em dados horários podem ter esse formato.
- **Bacias (v0.55):** piora pequena e significativa contra a versão anterior (1,008, maior no início das séries), e um ARX com mínimos quadrados recursivos do mesmo custo erra 11% a 13% menos (§19.2).
- **Séries integradas reais:** o ganho de levar a informação de uma entrada verdadeira à previsão foi demonstrado em sintéticos (§17), mas não apareceu nas séries de níveis reais testadas (§19.1).
- **Descoberta mais lenta de relações reais fracas** (v0.55): nas bacias e nos prédios, menos séries terminam com entrada externa na estrutura; numa bacia, a precipitação foi aceita pela versão anterior e não pela v0.55 dentro do comprimento da série. Não se sabe quanto do que a versão anterior aceitava era genuíno.
- **Interpretação em níveis:** corrigida na v0.55 para entradas que só passeiam (controle placebo e banco sintético); entradas substitutas, relações não lineares e um ciclo não declarado continuam fora do alcance da garantia (§5.10).
- **Nota formal e controle de erro:** a prova de validade com qualquer aprendiz previsível tem um único autor e ainda não teve conferência independente; o limite conjunto das mudanças de estrutura é 2α (dois motores); o controle de mudanças falsas estruturais continua empírico.
- **Ciclo declarado:** o ciclo continua precisando ser declarado; tratá-lo como hipótese não atingiu a meta na solar.
- **Lista de eventos:** cresce sem limite (já na versão anterior); num dispositivo embarcado, precisa ser limitada.
- **Contrato de custo do núcleo** não cumprido (3,7% na média e 2,0% no pico), sem revisão posterior; o teto de M1 + M2 foi redefinido antes da avaliação final anterior (§12).
- **Mecanismo de testes do núcleo:** não melhora a precisão; o controle de mudanças falsas está no regime prático, não no da garantia exata (§8); entradas correlacionadas com a verdadeira podem ser aceitas como substitutas e, às vezes, permanecer (§15).
- **Descoberta:** falha em entradas muito suaves com atraso médio/longo; entradas quase idênticas são indistinguíveis.
- **Sem garantia formal na escala original para M1 e M2:** o Prod garante em perdas normalizadas; o AdaHedge da M1 não dá arrependimento constante contra o núcleo; com choques, nenhum combinador tem garantia útil (§6.4).
- **Régua decidida durante o desenvolvimento:** os adendos do choque foram decididos depois de ver dados de desenvolvimento, antes da validação 5 e da avaliação final anterior.
- **F6 sem família na reserva final:** a evidência de F6 em dados novos é só a validação 5; uma família do desenvolvimento passou com margem pequena (VB07).
- **Microcontrolador:** só o núcleo, só em simulador, ciclos estimados, energia não medida; memória de M1 e M2 estimada.
- **Incerteza:** os IC de conjunto tratam as séries como independentes; a carga tem 4 séries; 4 locais do BDG2 compartilham o clima com o desenvolvimento do núcleo.
- **Comparadores ausentes:** um ARMAX com filtro de Kalman online e um SARIMAX com parâmetros atualizados online.
- **Intervalo:** cobertura empírica perto de 90% no núcleo, sem garantia formal; não reportada para a saída completa.
- **Correções depois de falhas:** as salvaguardas e os desenhos finais de M1 e M2 vieram depois de ver falhas; foram confirmados em dados novos, mas o desenho não foi cego. Erratas e correções de execução estão declaradas.
- **Metas revistas e critérios reescritos:** a meta de corte de custo da M1 foi revista (de 75% para 60%) depois de medições no desenvolvimento e o critério de custo da errata 01 foi reescrito depois da primeira medição; em ambos os casos a aceitação exigiu uma validação nova em dados nunca vistos, e as revisões estão declaradas.
- **Fora desta versão:** ciclo como hipótese, memória de relações que somem e voltam, e várias saídas ou vários passos.

> **Não afirmamos** que a LEBRE seja o melhor previsor, nem o mais econômico, nem que algum componente seja novo. Afirmamos apenas o que foi medido: nos protocolos e dados descritos, com o custo descrito, os números reportados nas §15–§19.

23. Parâmetros

Todas as constantes são as mesmas para qualquer série; nada é ajustado por série.

Núcleo	Constantes
Unidades	uma por entrada (inclui o próprio passado do alvo) + estado latente do resíduo (polos 0,8 e 0,95); até 4 ativas
Resposta	faixas [1], [2–3], [4–7], [8–15], [16–31] + atraso de pico (escolha em 200 amostras) + valor atual; divisões em metades
Desafiantes	RLS no episódio, $P_0 = 10 \cdot I$; aquecimento 250; 2 vagas; um aquecimento por vez
Evidência	perda $\min\{e^2/B^2, 1\}$, $B = 2 \cdot \max(\hat{\sigma}_S, 0{,}1 \cdot s_lenta)$; $c = 1 + \max(\varepsilon, 0)$; $8\ \lambda = 0{,}9 \cdot 2^{-j}/c$; $\varepsilon = +0{,}002$ (acrescentar, trocar, dividir), $-0{,}002$ (remover)
Multiplicidade	$\alpha = 0{,}05$; $\gamma = 1/(2P)$ nas primeiras $P = 2 \cdot \lvert\text{unidades}\rvert$, depois $0{,}5 \cdot \gamma_k \propto 1/(k \log^2 k)$; nível $\alpha \cdot \gamma \cdot (R+1) \le 0{,}5$
Episódios	varredura após 100 amostras; limite 5.000; espera 2.000; remoção periódica a cada 2.000; decisões a cada 10 passos
Triagem	pré-branqueada AR(1), peso 0,02, a cada 4 passos por parte; limiares 15,09 (χ^2_5) e 6,63 (χ^2_1)
Base de S	NLMS $\mu = 0{,}05$; contrato de entrada $\pm 8\sigma$ com quarentena de 31 passos
Memória	NLMS $\mu = 0{,}05$; média lenta 0,01; perfil 0,1; pisos 10^{-3} e 10^{-4}; ciclo(s) declarado(s); retenção nas lacunas
Combinação e saída	$\lambda = 0{,}99$, $\eta = 0{,}5$, a cada 8 passos; envelope com taxa 10^{-3} e margem $0{,}5\times$
Intervalo	$\alpha = 0{,}1$, $\gamma = 0{,}1$, a cada 8 passos (também na saída final)
Grupos	correlação causal ≥ 0,95 reportada junto da entrada aceita (não afeta decisões)

Parte	Parâmetro	Valor	Observação
M1	entradas	m = mín(d, 5)	maior correlação absoluta (médias exponenciais 0,01, só passado)
M1	bandas	[0], [1], [2–3], [4–7], [8–15]	médias; + alvo nas defasagens 1 e 2; k = 3 + 5m
M1	RLS	λ = 0,999; δ = 100	a cada 8 alvos aprendidos; E só depois de k atualizações
M1	seleção	após 100; a cada 5.000	recomeça regressão e combinação
M1	recorte	L ± 2·máx($\hat{\sigma}_L$, piso)	piso: 0,1 × escala lenta do alvo
M1	combinação	AdaHedge	erro quadrático; sombra de 100 atualizações
M2	R	zero / sazonal / persistência	declarada com os dados
M2	H	AdaHedge	erro quadrático, só com R definida
M2	W	troca única, risco 1/(n+1)	perdas gaussianas na escala recente (0,01)
M2	Prod	η ≤ ½; w_B = ½	perdas ÷ máx(perdas, 0,99·N)
M2	porta	ε = 0,002; α = 0,01	só auditoria; recriada a cada decisão
M1, dormência	dormir	ω < 10^{-3} por 2.000 alvos	só depois da sombra
M1, dormência	dormindo	E a cada 8; RLS a cada 64	saída L' = L; AdaHedge congelado
M1, dormência	despertar	EMA(0,01) de g > 0,05	após 100 amostras; AdaHedge recomeça com sombra de 100
M1, dormência	teste na reseleção	dorme de novo após 500 alvos	a menos que ω chegue a 10^{-3}
Núcleo, remoção	disparo	contribuição < 0,5 × referência	referência: pico desde a aceitação, volta ao valor atual a cada teste; ≥ 2.000 passos entre testes
Núcleo, remoção	evidência	hipótese nova por episódio; ε = −0,002	nível α·γ_k·(R^rem + 1), α = 0,05, orçamento próprio
Núcleo, remoção	duração	até 10.000; aceita só após 5.000	prioridade sobre o teste periódico da mesma unidade
Núcleo ancorado	referência dos testes	externas: L; internas: s	numa troca, o tipo da unidade que entra; escala do erro de L
Núcleo ancorado	estrutura de inovação	alvo y − m; NLMS μ = 0,05	mesmas unidades e atributos de s; L = L_1 + wl·(m + ŝΔ − L_1), λ = 0,99, η = 0,5, a cada 8
Núcleo ancorado	portão suave	internas triadas por y − L	sem limiar novo
Núcleo ancorado	pesos na aceitação	externa: do desafiante nas duas	interna: zero na inovação (divisão: o da mãe)
Núcleo ancorado	escala dos testes	piso 0,1·√mín(v_nível, v_Δy)	calculado antes de ver y_t
Núcleo, relatório	matriz de equivalentes	amostra a cada 31 passos; peso 1e-3 × 31	aplicada em até ⌈d/30⌉ linhas por passo; a consulta aplica as pendentes

24. Pseudocódigo e condições de reproducibilidade

Pseudocódigo simplificado de um passo, suficiente para reimplementar a configuração avaliada. Onde o texto e o pseudocódigo diferirem, vale o pseudocódigo junto da tabela de parâmetros (§23).

Núcleo estrutural

```
CONSTANTES  # iguais para qualquer série; nada é ajustado por série
  BANDS = [1], [2–3], [4–7], [8–15], [16–31]      POLES = 0.8, 0.95        L = 31
  M_MAX = 4   SLOTS = 2   WARM = 250   PEAK_N = 200   N_MIN = 100   T_MAX = 5000   COOL = 2000   REM_PERIOD = 2000
  DECIDE_EVERY = 10   SCREEN_EVERY = 4   SCREEN_W = 0.02   Q_UNIT = 15.09 (χ²₅, 99%)   Q_SPLIT = 6.63 (χ²₁, 99%)
  ε: add = swap = split = +0.002, remove = −0.002     α = 0.05     μ_S = 0.05     μ_M = 0.05     CLIP_X = 8
  λ_DMA = 0.99   η = 0.5   EVERY = 8   α_int = 0.10   γ_int = 0.10   SCALE_FLOOR = 0.1   OUT_MARGIN = 0.5   OUT_RHO = 1e-3

ESTADO  # tamanho fixo, dado o número de entradas d e o(s) período(s) s, s2
  H[0..L+1][d+1]  histórico das entradas (inclui o próprio passado do alvo, padronizado)
  band_sum[5][d+1], seg_sum{(i,lo,hi)}   somas correntes das faixas e dos segmentos ativos
  base[d+2]  active{unit → (segments, weights)}  r[2]  estados latentes do resíduo
  M: buffer, w_M, G[s], m_slow        hyps{key → e-process}        slots[≤ 2]

PASSO(x_t, y_t ou lacuna, quarantine):
  # 1. ler
  x̃ ← [x_t, std_causal(y_last)]                                  # média/variância EMA 1e-4, início (0, 1)
  se any |x̃| > CLIP_X: quar_until ← t + L;   x̃ ← clip(x̃, ±CLIP_X);   shift H, band_sum, seg_sum
  # 2. prever
  ŷ_M ← M.predict()                                             # último valor + w_M·ϕ (reversão, diferença, sazonal, perfil)
  ŷ_S ← base·[1, x̃] + Σ_u w_u · block(u)                        # block: médias dos segmentos ativos
  ŷ ← ŷ_M + w_S (ŷ_S − ŷ_M)
  se n_obs ≥ 50: ŷ ← clip(ŷ, env_lo − 0.5·W, env_hi + 0.5·W), W = env_hi − env_lo;  se ŷ não finito: ŷ ← y_last
  para cada experimento e: g_e ← ŷ_S + θ_e·z_e − (contribuição removida)
  retorna ŷ, [ŷ − q̂, ŷ + q̂]
  # 3. observar e aprender (só se y_t observado)
  learn ← y_t observado ∧ ¬quarantine ∧ t > quar_until
  B ← 2·max(σ_r, SCALE_FLOOR·sd_slow(y));  ℓ(u) = min((y_t − u)²/B², 1)
  se learn:
    para cada e: k_e += 1
      se k_e > WARM: e.hyp.observe(ℓ(ŷ_S) − ℓ(g_e) − ε_e)         # evidência
      se k_e ≤ PEAK_N: acumula correlação pré-branqueada por atraso (metade dos atrasos por passo)
      se k_e = PEAK_N: k* ← argmax_k c_xy²/c_xx;  se k* > 1: insere x_i(t−k*) no desafiante
      RLS(θ_e, P_e; z_e, alvo = y_t − ŷ_S + contribuição removida)       # P₀ = 10·I
    NLMS(base, w_u; res = y_t − ŷ_S, μ_S, norma = ‖[1,x̃]‖² + Σ‖block(u)‖²)
    screen_spread(res)                                          # cada parte na sua fase, a cada 4 passos
  D ← λ_DMA·D + ((y_t − ŷ_S)² − (y_t − ŷ_M)²)/σ²;   a cada EVERY: w_S ← 1/(1 + exp(η·D))
  intervalo: miss ← |y_t − ŷ| > q̂;   a cada EVERY: q̂ ← max(0, q̂ + γ_int·σ·Σ(miss − α_int))
  M.update(y_t se observado; senão o último valor observado (retenção), sem aprender)
  env ← envelope dos observados (máx./mín. que relaxam para a média, taxa OUT_RHO)
  r ← POLES·r + (1 − POLES)·(y_t − ŷ)/σ
  se t mod DECIDE_EVERY = 0: DECIDIR()

DECIDIR():
  para cada e: se log E(e.hyp) ≥ log(1/α_hyp): ACEITAR(e)
               senão se n_e ≥ T_MAX ou (n_e ≥ N_MIN e Σ_episode d ≤ 0): encerra (a evidência fica na hipótese)
  encerra experimentos sobre unidades que mudaram;  PREENCHER()

PREENCHER():  enquanto houver vaga livre:
  1. unidade ativa sem teste de remoção há ≥ REM_PERIOD → abre remove
  2. se algum desafiante em aquecimento: pare        # um aquecimento por vez
  3. u* ← argmax stat(u) entre unidades inativas, livres, fora da espera;  s* ← argmax stat(divisões)
  4. escolhe o maior entre stat(u*)/Q_UNIT e stat(s*)/Q_SPLIT (se ≥ 1):
       divisão → split;  |active| < M_MAX → add;  senão → swap (com a unidade de menor contribuição)
  # hipótese nova n recebe nível fixo: α_n = min(α·γ_n·(R+1), 0.5),
  # γ_n = 1/(2P) para n ≤ P = 2·|units|, depois 0.5·C/((n−P)·log²(n−P+1)); R = mudanças já aceitas

e-process(ε):  c = 1 + max(ε, 0);  λ_j = 0.9·2^(−j)/c, j = 0..7;  ψ_j = (−log(1 − cλ_j) − cλ_j)/c²
  observe(d): γ ← clip(média passada de d, −c, 0);  S += d;  V += (d − γ)²
  log E = log( (1/8)·Σ_j exp(λ_j·S − ψ_j·V) )

ACEITAR(e):  add/swap → active[i] ← (BANDS ∪ {[k*]}, θ_e[:-1]);  base[i] += θ_e[-1];  remove → apaga active[u]
             split → troca a faixa [lo,hi] pelas duas metades com os pesos do desafiante;  R += 1
```

M1 e M2 (sobre a previsão L do núcleo)

```
CONSTANTES de M1 e M2   M_MAX = 5   BANDS_E = [0], [1], [2–3], [4–7], [8–15]   λ_RLS = 0.999   δ_RLS = 100
             EVERY = 8   CLIP_K = 2   N_MIN = 100   T_MAX = 5000   LAM = 0.99   SCALE_FLOOR = 0.1   ε_gate = 0.002   α_gate = 0.01

PREVER(x_t):
  L ← núcleo.prever(x_t)                              # pseudocódigo do núcleo acima
  # M1: especialista de precisão
  x ← x_t com ausentes trocados pelo último valor visto
  z ← [1, ỹ_(t−1), ỹ_(t−2), médias das BANDS_E das m = mín(d, M_MAX) entradas escolhidas, padronizadas]
  E ← clip(w·z, L ± CLIP_K·max(σ̂L, piso))      se RLS determinada (n_RLS ≥ k = 3 + 5m)
  L' ← L se E indefinido ou AdaHedge₁.n < N_MIN; senão (1 − ω)·L + ω·E      # sombra
  # M2: ponto de partida na referência trivial
  R ← 0 | y_last | y_(t−s)                            # zero, persistência ou sazonal ingênuo, declarada
  se R indefinida: ŷ ← L'
  senão: H ← w_H·[R, L']; W ← w_W·[R, L']; s ← η·w_A / (η·w_A + w_B/2); ŷ ← s·W + (1 − s)·H
  retorna ŷ, [ŷ − q̂_o, ŷ + q̂_o]

OBSERVAR(y_t, quarantine):
  núcleo.observar(y_t, quarantine)
  se y_t observado:
    AdaHedge₁.update((y_t − L)², (y_t − E)²)          # erro quadrático sem recorte
    learn ← ¬quarantine ∧ entradas dentro do contrato
    se learn: a cada EVERY alvos: triagem (médias exponenciais 1 − LAM) e RLS(z, y_t)
              seleção das m entradas depois de N_MIN alvos e a cada T_MAX; se mudar: RLS e AdaHedge₁ recomeçam
    se ¬quarantine ∧ R definida:
      AdaHedge_H.update((y_t − R)², (y_t − L')²)
      s² ← max(min(σ²_R, σ²_L'), piso²); Switch_W.update((y_t − R)²/2s², (y_t − L')²/2s²)   # reserva em escala log contra 0/0
      N ← max(LAM·N, (y_t − H)², (y_t − W)²); Prod.update((y_t − H)²/N, (y_t − W)²/N)
      gate.observe(...)                               # auditoria: registra eventos, não decide a saída
    intervalo da saída: miss ← |y_t − ŷ| > q̂_o;  a cada EVERY: q̂_o ← max(0, q̂_o + 0.1·σ̂o·Σ(miss − 0.1))
```

Mecanismos da v0.54

```
M1 DORMENTE # substitui a M1 acima quando dorme
  se ativa ∧ após a sombra ∧ ω < 10⁻³ por D alvos seguidos: dormir          # D = 2.000; D = 500 em teste
  se dormindo: L' ← L
    a cada 8 alvos: E calculado; g ← ((y − L)² − (y − E)²)/(y − L)²;  ḡ ← ḡ + 0.01·(g − ḡ)
    a cada 64 alvos: RLS(z, y)
    se ḡ > 0.05 ∧ amostras ≥ 100: despertar; AdaHedge₁ recomeça com sombra
    se a seleção de entradas mudou: despertar em teste

REMOÇÃO DISPARADA # a cada decisão do núcleo, antes do calendário periódico
  para cada unidade ativa u: ref_u ← max(ref_u, contrib_u)
  se contrib_u < 0.5·ref_u ∧ ≥ 2.000 passos desde o último teste disparado de u ∧ u livre ou só em teste periódico de remoção:
    encerrar o teste periódico de u (a hipótese persistente fica)
    abrir episódio com hipótese nova; nível α·γ_k·(R^rem + 1);  ref_u ← contrib_u
    aceitar se log E ≥ log(1/α_k) ∧ passos de evidência ≥ 5.000;  encerrar em 10.000 ou pela varredura

RELATÓRIO DE EQUIVALENTES
  a cada 31 passos: aplicar as linhas pendentes; m ← m + 0.031·(x − m);  xc ← x − m
  a cada passo: aplicar xc a até ⌊d/30⌋ linhas i: C[i, j≥i] ← C[i, j≥i] + 0.031·(xc_i·xc_j − C[i, j≥i]); espelhar
  consulta: aplicar as linhas pendentes; grupo de u = entradas com |correlação| ≥ 0,95
```

Núcleo ancorado (v0.55)

```
NÚCLEO ANCORADO (v0.55) # substitui as linhas correspondentes do núcleo
  PREVER:  m ← memória;  s ← estrutura de nível;  ŝΔ ← base_Δ·[1, x_t] + Σ_u w_Δ,u·bloco_u
           L₁ ← m + wS·(s − m);   L ← L₁ + wI·((m + ŝΔ) − L₁)          # depois, o envelope de saída
           para cada experimento: R ← s se a unidade é interna senão L
             c_u ← (1 − wI)·wS·w_u·b_u + wI·w_Δ,u·b_u   # contribuição de uma unidade externa em L
             g ← R + a − c_u                            # adição: a; remoção: c_u
  OBSERVAR:  piso ← 0.1·√min(v_nível, v_Δy)   # calculado antes de ver y_t;  B ← 2·max(σ̂L, piso)
           d ← min((y − R)²/B², 1) − min((y − g)²/B², 1) − ε;   desafiante aprende (y − R) + c_u
           NLMS(s; y − s);  NLMS(ŝΔ; y − (m + ŝΔ))                # mesmos atributos e denominador, μ = 0,05
           D_I ← 0.99·D_I + ((y − m − ŝΔ)² − (y − L₁)²)/σ²;  a cada 8: wI ← 1/(1 + e^(0.5·D_I))
           triagem: externas e internas com o resíduo y − L   # portão suave
  ACEITAR: a unidade entra em s com os pesos do desafiante; em ŝΔ com os mesmos pesos se for externa, com zero se for interna
```

Condições de reproducibilidade

- **Entradas:** padronizar cada entrada de forma causal antes do núcleo: $z = (x - m)/\sqrt{(v + 10^{-6})}$, com m e v exponenciais de taxa 10^{-4} a partir de (0, 1), atualizadas *depois* de padronizar o valor atual; valores ausentes viram 0 após a padronização (na M1, o último valor visto).
- **Alvo:** passado em unidades originais; ausências são passadas como lacuna (sem aprendizado); uma marca externa de quarentena suspende o aprendizado.
- **Metadados:** período sazonal s (24 para dados horários; nenhum se não houver ciclo), opcionalmente um segundo ciclo s_2 (168 nos prédios), e a referência trivial (zero, persistência ou sazonal; sem declaração: sazonal se houver ciclo, senão persistência).
- **Determinismo:** o algoritmo não usa números aleatórios; dada a mesma sequência de entradas, a saída é determinística.
- **Disponibilidade:** o código promovido (Python), o porte em C do núcleo, os pré-registros, os scripts de análise, as previsões por série e os manifestos SHA-256 de cada versão congelada estão no repositório público github.com/Iquitim/lebre-research (código da LEBRE v0.55 no commit b0522a0, variante B10; a v0.54, com a errata 01, no commit f9906c4); o desenvolvimento e as validações estão no banco de testes público github.com/Iquitim/lebre-lab (este documento leu os seus resultados no commit 7688f84).
- **Ambiente usado:** Python 3.11, numpy 2.2.5, pandas 2.2.3 (versões posteriores mudaram o comportamento de arrays somente leitura), statsmodels 0.15.0; Chronos-2 com o pacote chronos 2.3.2 (na comparação da v0.55, em GPU com torch 2.11.0+cu128); C99 com GCC para Arm 15.2 (−O2, FPU de precisão simples, sem contração FMA); Renode 1.17.

25. Referências

1. Adamskiy, D., Koolen, W. M., Chernov, A., Vovk, V. (2016). A closer look at adaptive regret. *Journal of Machine Learning Research* 17(23), 1–21.
2. Alquier, P. (2021). Non-exponentially weighted aggregation: regret bounds for unbounded loss functions. *ICML*.
3. Amoukou, S. I., Mishra, S., Veloso, M. (2026). Correcting split selection in online decision trees via anytime-valid inference. *arXiv:2605.31239*.
4. Ansari, A. F. et al. (2025). Chronos-2: from univariate to universal forecasting. *arXiv preprint*.
5. Box, G. E. P., Jenkins, G. M. (1970). *Time Series Analysis: Forecasting and Control*. Holden-Day.
6. Campbell, J. Y., Yogo, M. (2006). Efficient tests of stock return predictability. *Journal of Financial Economics* 81(1), 27–60.
7. Cesa-Bianchi, N., Gaillard, P., Lugosi, G., Stoltz, G. (2012). Mirror descent meets fixed share (and feels no regret). *NeurIPS 25*.
8. Cesa-Bianchi, N., Mansour, Y., Stoltz, G. (2007). Improved second-order bounds for prediction with expert advice. *Machine Learning* 66, 321–352.
9. Chagas, V. B. P. et al. (2020). CAMELS-BR: hydrometeorological time series and landscape attributes for 897 catchments in Brazil. *Earth System Science Data* 12, 2075–2096.
10. Chen, S. (2017). Beijing Multi-Site Air Quality. *UCI Machine Learning Repository*, doi:10.24432/C5RK5G.
11. Choe, Y. J., Ramdas, A. (2024). Comparing sequential forecasters. *Operations Research* 72(4), 1368–1387.
12. Choi, S. (2026). Anytime-valid evidence for prespecified predictive corrections. *arXiv:2608.08174*.
13. Clark, T. E., West, K. D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics* 138(1), 291–311.
14. de Heide, R. (2026). Dynamic e-closure for online hypotheses with any-time-valid evidence: closure principles and projective mergers. *arXiv:2608.09927*.
15. de Rooij, S., van Erven, T., Grünwald, P. D., Koolen, W. M. (2014). Follow the leader if you can, hedge if you must. *Journal of Machine Learning Research* 15, 1281–1316.
16. Ekambaram, V. et al. (2024). Tiny Time Mixers (TTMs): fast pre-trained models for enhanced zero/few-shot forecasting of multivariate time series. *NeurIPS 37*.
17. Even-Dar, E., Kearns, M., Mansour, Y., Wortman, J. (2008). Regret to the best vs. regret to the average. *Machine Learning* 72, 21–37.
18. Fan, X., Grama, I., Liu, Q. (2015). Exponential inequalities for martingales with applications. *Electronic Journal of Probability* 20, 1–22.
19. Fernández-Barrios, R., Pastor-López, I., Pikatza-Huerga, A., García Bringas, P. (2026). Candidate comparability before promotion: conditional validation in adaptive network intrusion detection. *arXiv:2609.04388*.
20. Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica* 74(6), 1545–1578.
21. Gibbs, I., Candès, E. J. (2021). Adaptive conformal inference under distribution shift. *NeurIPS 34*.
22. Grünwald, P., de Heide, R., Koolen, W. M. (2024). Safe testing. *Journal of the Royal Statistical Society B* 86(5), 1091–1128.
23. Han, W., Qu, L. (2026). When the martingale never stops firing: anytime-valid gating on real forecast streams. *arXiv:2608.30502*.
24. Haykin, S. (2002). *Adaptive Filter Theory*, 4th ed. Prentice Hall.
25. Hazan, E., Kale, S. (2010). Extracting certainty from uncertainty: regret bounded by variation in costs. *Machine Learning* 80, 165–188.
26. Howard, S. R., Ramdas, A., McAuliffe, J., Sekhon, J. (2021). Time-uniform, nonparametric, nonasymptotic confidence sequences. *Annals of Statistics* 49(2), 1055–1080.
27. Hyndman, R. J., Koehler, A. B., Ord, J. K., Snyder, R. D. (2008). *Forecasting with Exponential Smoothing: The State Space Approach*. Springer.
28. Javanmard, A., Montanari, A. (2018). Online rules for control of false discovery rate and false discovery exceedance. *Annals of Statistics* 46(2), 526–554.
29. Jha, A. (2026). Distributional Granger causality: identification, sequential inference, and adaptive testing. *arXiv:2606.22230*.
30. Koolen, W. M. (2013). The Pareto regret frontier. *NeurIPS 26*.
31. Lara Pinal, E. M., Das, A., Schlüter, S. (2026). A low-cost IoT device for environmental monitoring and embedded solar forecasting with on-device incremental learning. *arXiv:2608.14698*.
32. Lin, S. et al. (2024). SparseTSF: modeling long-term time series forecasting with 1k parameters. *ICML*.

33. Ljung, L. (1999). *System Identification: Theory for the User*, 2nd ed. Prentice Hall.
34. Mallat, S. (1989). A theory for multiresolution signal decomposition: the wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 11(7), 674–693.
35. Meinshausen, N. (2008). Hierarchical testing of variable importance. *Biometrika* 95(2), 265–278.
36. Mhammedi, Z., Koolen, W. M., van Erven, T. (2019). Lipschitz adaptivity with multiple learning rates in online learning. *COLT*.
37. Miller, C. et al. (2020). The Building Data Genome Project 2, energy meter data from the ASHRAE Great Energy Predictor III competition. *Scientific Data* 7, 368.
38. Moulin, A., Esposito, E., van der Hoeven, D. (2025). When lower-order terms dominate: adaptive expert algorithms for heavy-tailed losses. *arXiv:2506.01722*.
39. Orabona, F., Pál, D. (2018). Scale-free online learning. *Theoretical Computer Science* 716, 50–69.
40. Raftery, A. E., Kárný, M., Ettler, P. (2010). Online prediction under model uncertainty via dynamic model averaging. *Technometrics* 52(1), 52–66.
41. Ramdas, A., Grünwald, P., Vovk, V., Shafer, G. (2023). Game-theoretic statistics and safe anytime-valid inference. *Statistical Science* 38(4), 576–601.
42. Sani, A., Neu, G., Lazaric, A. (2014). Exploiting easy data in online optimization. *NeurIPS 27*.
43. Stambaugh, R. F. (1999). Predictive regressions. *Journal of Financial Economics* 54(3), 375–421.
44. van Erven, T., Grünwald, P., de Rooij, S. (2012). Catching up faster by switching sooner: a predictive approach to adaptive estimation with an application to the AIC–BIC dilemma. *Journal of the Royal Statistical Society B* 74(3), 361–417.
45. V'yugin, V., Trunov, V. (2019). Online aggregation of unbounded losses using shifting experts with confidence. *Machine Learning*; arXiv:1808.00741.
46. Wang, H., Ramdas, A. (2023). Catoni-style confidence sequences for heavy-tailed mean estimation. *Stochastic Processes and their Applications*.
47. Waudby-Smith, I., Ramdas, A. (2024). Estimating means of bounded random variables by betting. *Journal of the Royal Statistical Society B* 86(1), 1–27.
48. Widrow, B., Stearns, S. D. (1985). *Adaptive Signal Processing*. Prentice Hall.
49. Xu, Z., Ramdas, A. (2024). Online multiple testing with e-values. *AISTATS*.
50. Xu, Z., Zeng, A., Xu, Q. (2024). FITS: modeling time series with 10k parameters. *ICLR*.
51. Yao, Z., Gang, B., Sun, W. (2025). Safe, always-valid alpha-investing rules for doubly sequential online inference. *arXiv:2512.12244*.
52. Yekutieli, D. (2008). Hierarchical false discovery rate-controlling methodology. *Journal of the American Statistical Association* 103(481), 309–316.
53. Zeng, A., Chen, M., Zhang, L., Xu, Q. (2023). Are transformers effective for time series forecasting? (DLinear, NLinear). *AAAI*.

26. Histórico de revisões

- **Revisão 0** (17/10/2026): primeira edição da v0.55, autocontida — descreve a LEBRE inteira (núcleo ancorado com a estrutura de inovação, o portão suave e a escala de uma passada, a remoção disparada e o relatório de equivalentes barato; M1 com dormência; M2) sem supor a leitura de nenhum outro documento; inclui a avaliação final da v0.55 com o controle placebo, a comparação com 12 modelos externos, a nota formal sobre a validade com qualquer aprendiz previsível e a sua errata 01, e as evidências das versões anteriores.